



人工智能的数学思维

Elegant $\text{\LaTeX}$ 经典之作

作者：吴敏，蒲戈光

组织：Elegant $\text{\LaTeX}$ Program

时间：April 9, 2022



不要以为抹消过去，重新来过，即可发生什么改变。——比企谷八幡

目录

0.1	什么是智能	1
0.2	鹦鹉与乌鸦：何种智能?	2
第 1 章	智能简史：生于数学	4
1.1	数字的发明，智能的开端	4
1.1.1	史前数学：日常需求与实用计算	4
1.1.1.1	手指：长在身上的计数器	5
1.1.2	自然的教育，数字文明的缩影	6
1.1.2.1	手指计数：最简单的工具	6
1.1.2.2	刻痕计数：更长久的记录方式	6
1.1.2.3	结绳记数：更高级的记数法	6
1.1.2.4	荒岛上的自然教育：人类数字发明的倒影	6
1.1.3	数字的位值系统	7
1.1.4	位值制与对数增长在现代计算机中的应用	7
1.2	数字：从具象到抽象	8
1.3	数学的真正诞生：从计算到推理	8
1.4	简明数学史	11
1.4.1	数学萌芽时期	11
1.4.2	初等数学时期	11
1.4.3	近代数学时期	12
1.4.4	现代数学时期	13
1.5	小结	14
第 2 章	智能简史：成于计算机	15
第 3 章	人工智能的三种思维	16
第 4 章	人工智能的数学工具	17
4.1	预备知识	18
4.2	浅谈图像处理：从矩阵到深度学习	18
4.3	第 1 章引言	19
4.3.1	1.1 图像识别如何作用于我们的生活?	19
4.3.2	1.2 追根溯源——其中的数学方法	19
4.3.3	1.3 报告主体结构与主要内容	19
4.4	第 2 章从矩阵到深度学习	19
4.4.1	2.1 矩阵	19
4.4.2	矩阵的应用现状	20
4.4.3	2.1.3 矩阵的基本操作	21
4.5	体会启发与结语	32
4.6	次线性算法	33
4.7	迈进后严谨阶段!	34

第 5 章	机器学习：学习如何学习？	36
5.1	深度学习，真的行	36
5.2	1.1. 起源	37
5.3	1.2. 发展	38
5.4	1.3. 成功案例	39
5.5	1.4. 特点	39
5.6	1.5. 小结	40
5.7	1.6. 练习	40
5.8	1. 引言	42
5.9	2. 背景	44
5.9.1	第一阶段	44
5.9.2	第二阶段	44
5.9.3	3. 第三阶段	44
5.9.4	3. 结构	45
5.9.5	4. 如何训练	45
5.9.6	人工神经网络在信息领域中的应用	47
5.9.7	人工神经网络在医学中的应用	47
5.9.8	人工神经网络在交通领域中的应用	48
5.9.9	人工智能：广跨各学科，综合文理工	51
5.9.10	发展历程：AI 的三次热潮和相应的研究学科突破	51
5.9.11	三次热潮的总结	51
5.10	线性神经网络	52
第 6 章	生成式 AI：机器魔法及其数学思维	53
6.1	背景	53
6.2	什么是 Stable Diffusion	53
6.3	1.4. 核心原理	53
6.4	应用场景	53
第 7 章	力量倍增器：站在 AI 的肩膀上	56
7.1	超级计算机：速度和功耗成为终极挑战	56
第 8 章	结语旅程的尾声	61
致谢		63

引言 什么是智能？

内容提要

- Definition of Theorem
- Ask for help
- Optimization Problem
- Property of Cauchy Series
- Angle of Corner

这一章将带领你从哲学、科学和工程的角度出发，追问“什么是智能”。接下来的章节中，我们将深入探讨数学在人工智能中的具体应用，展示数学如何帮助我们创造出越来越强大的智能系统。

0.1 什么是智能

智能，或许是我们人类最自豪的天赋。

尽管智能并非人类独有，许多动物，如海豚、鸟类、猩猩，甚至章鱼，都表现出高度的学习能力、问题解决能力以及某种形式的社交智能，但人类的智能，以其复杂性和多样性独树一帜，在抽象和创造性上尤为突出。人类具有抽象思维，创造了诸多符号系统，并基于此进行高度复杂的推理和想象。从数学公式到哲学思辨，人类通过语言、文字和符号，建立起了庞大的知识体系和文化遗产。我们可以预见未来、反思过去，并通过科学、技术、工具改变现实世界。正是这种智能上的深度和广度，推动了人类文明的发展。

智能是生命进化过程中形成的一种适应性特征。但随着人工智能的发展，我们正在见证一种新型智能的崛起。在 20 世纪中期，计算机的发明标志着一种全新“智能”形式的诞生。计算机，这种基于二进制系统和算法逻辑的机器，能够完成许多过去被认为只有人类才能做到的任务，如图像识别、语言翻译、甚至写作创作。机器可以通过算法模拟复杂的推理过程，甚至在某些领域超越人类的能力——它们能够比人类更快地进行大规模计算、更高效地分析海量数据。

这促使我们重新思考：究竟什么是“智能”？它是基于生物特性的一种特有思维能力，还是某种可以通过数学和逻辑建模来实现的计算逻辑？

对于智能的定义，在不同学科中有着不同的阐释。在心理学中，智能被视为一种个体解决问题、学习和适应环境的能力。在生物学中，智能更多与生物体的行为、神经系统的复杂性相关。而在计算机科学和人工智能领域，智能则被看作是一种能够在复杂环境中执行任务并达成特定目标的能力。从人工智能的角度看，智能可以被定义为“机器执行通常需要人类智能才能完成的任务的能力”。这些任务包括视觉识别、自然语言处理、学习、推理、决策等。然而，计算机和人类智能之间仍然存在着巨大的差异，特别是在理解、情感和创造力等方面。人工智能的核心在于如何用数学工具来模仿、简化甚至扩展这些认知能力。

机器“智能”是否真的与人类的智能一样？人类的智能伴随着进化而来，经过了数百万年的演变和适应，它不仅仅是一种计算能力，更是情感、直觉、创造力和推理能力的综合体。相对来说，人工智能的发展历史尚短，但其进化速度却让人惊叹。

机器智能的本质在于其基于算法和数据的计算逻辑，而人类智能则包含了情感、意识、创造力等更为复杂和难以定义的元素。智能不仅仅是任务的完成能力，更涉及到意识、理解和体验。也许机器可以在规则内完成任务，优化目标，但它们仍然无法像人类那样拥有感知、情感或独立的创造性思维。尽管如此，在这场由人类主导的智能革命中，我们依然是规则的制定者和方向的掌控者。这也是为什么，理解数学思维如何推动人工智能，能够帮助我们更好地把握未来智能发展的关键脉络。

数学在智能中的角色

自古以来，数学不仅是解决问题的工具，更是智能表达与实现的基础语言。数学的力量在于它能够抽象出复杂问题的本质，提供精确的描述和推理方法。

人工智能中的诸多任务，如模式识别、数据分类、预测等，背后都依赖数学模型进行量化和求解。例如，图像识别问题看似复杂，但可以被归纳为一个线性代数问题：图像被分解为像素点，每个像素点通过向量和矩阵的运算来进行处理。同样，神经网络的训练也依赖于微积分中的优化技术，以最小化损失函数，找到最优参数组合。

机器智能的进化：从计算到学习

数学在推动人工智能从简单计算迈向学习与适应中起到了关键作用。最初，计算机的智能主要体现在通过预先编写的规则来执行任务，模拟人类的某些智能行为。随着大数据和深度学习技术的出现，人工智能开始从数据中“学习”，即所谓“机器学习”。这是一场范式的转变：机器智能从依赖人工预定义的规则，转变为通过模型的不断训练和优化进行自我学习。

在这场范式的转变中，数学再次发挥了至关重要的作用。统计学、线性代数、概率论等数学工具，使机器能够从复杂的海量数据中提取有价值的模式和信息，并进行合理决策。

机器学习依赖于统计学、线性代数、概率论等数学理论。通过这些工具，机器能够从海量数据中提取模式并作出决策，具备了学习和自我优化的能力。

这种数学思维下的机器学习能力，使得智能不仅仅是计算结果的简单输出，而是一种能够学习、适应和自我优化的动态过程。这场智能的进化，无疑奠定了人工智能发展的新高度。

数学思维：解码智能的钥匙

人工智能是模拟、延伸和扩展人类智能的理论、方法、技术及其应用系统的综合学科。AI 作为一门跨学科领域，从多个学科中汲取灵感与启发，融合了不同领域的知识与技术。

数学思维不仅仅是对现有工具的应用，更代表着一种解码世界的方式。数学能够帮助我们从表象中剥离出系统的本质，理清复杂事物之间的逻辑关系。在人工智能领域，数学思维是帮助我们更好理解并发展智能的核心钥匙。人工智能的本质是一种通过数学和计算实现的智能，它利用算法、数据处理和计算资源模拟生物智能的行为。为了解智能如何通过数学实现，我们可以将其分解为几个关键组成部分：

- **感知与反应**：任何智能体首先需要能够感知环境，并对环境做出适当的反应。这是智能的基础，也是进化中所有生物生存的关键。数学在感知数据的处理上扮演重要角色，例如通过卷积神经网络处理视觉输入。
- **学习与记忆**：智能体不仅是对环境做出反应，还包括从经验（数据）中学习，并储存经验用于未来决策。
- **推理与决策**：智能体需要能够进行推理，从已有信息中得出新的结论，从而做出合理的决策。这离不开统计推断、优化等数学方法。
- **创造与适应**：更高级的智能不仅仅是反应式的，而是能够创造性地应对未知的挑战，并在复杂的环境中灵活适应。

人工智能（AI）在这些维度上逐步模仿人类的智能，但它的本质是通过数学和计算实现的。AI 的智能是通过算法、数据处理以及计算资源，以我们在生物智能中所见的行为为目标进行的复杂优化。

0.2 鹦鹉与乌鸦：何种智能？

为了更好地理解智能，我们可以借用一个生动的比喻——鹦鹉与乌鸦。

鹦鹉式智能：模仿而不理解

鹦鹉是模仿高手，能够复制人类的语言，甚至在特定情境下做出看似有意识的反应。然而，鹦鹉并不真正理解它模仿的内容，它只是重复我们的话语，而无法将这些词汇与现实世界中的人、物或情景建立联系。这种行为类似于一些现有的人工智能系统，特别是那些专注于模仿和执行特定任务的 AI 模型。这类 AI 可以通过大量数据训练，在特定任务中表现优异，但它们并不真正理解背后的语义或意图。

这种“鹦鹉式智能”可以类比为**弱 AI** 或**窄 AI**。它们擅长于特定任务，但缺乏广泛的推理和创造能力。当前的许多 AI 模型，如语言生成或图像识别，都是在这一框架下运作的——它们通过模式识别和数据驱动的方式执行任务，却没有真正的自主意识或深度理解。都是在这一框架下运作的——它们通过模式识别和数据驱动的方式执行任务，却没有真正的自主意识或深度理解。

乌鸦式智能：推理与创造

乌鸦向来被认为是最聪明的鸟类之一。与鹦鹉不同，乌鸦不仅擅长模仿，还展现出复杂推理能力、问题解决能力以及创造性的智能。乌鸦是少数能够制造工具的鸟类，能够通过创新思维应对物理世界中的挑战。我们从小都听过各种“乌鸦喝水”的故事，而国外科学家也曾做过一系列“乌鸦喝水”的变化实验。在这些实验中，研究人员使用了各种不同形状的瓶子和不同密度的物体，观察乌鸦如何应对。令人惊讶的是，乌鸦总能在几次尝试后，快速识别并选择那些能够最快让水位上升的物体。这些实验不仅证实了乌鸦对物理规律的深刻理解，还展示了它们高度的认知能力和推理能力，以及面对复杂问题时的创造性和灵活性。另一个著名的例子是，乌鸦会将坚果放在马路上，利用来往车辆碾压坚果壳，并观察红绿灯、斑马线等信号来推理交通规则，最终推理出红绿灯与车辆停靠及行人停走之间的复杂因果关系，从而安全地过马路，吃到被碾碎的坚果肉。这是一种远远超出简单反应的行为，展示了乌鸦对物理世界和人类行为之间复杂因果链的深刻理解。

乌鸦的这一行为没有经过大量数据训练或监督学习，它通过少量的尝试与观察，直接推理出解决问题的方法。乌鸦智能正是我们期望的真正的智能——完全自主的智能：观察、感知、认知、学习、推理、执行。这种智能可以比喻为**强 AI** 或**通用 AI**，具备自主学习、推理和适应能力，能够在不同的环境中灵活应对各种任务。

功耗极低：乌鸦头不到人脑的 1

乌鸦的智能不仅令人惊叹，功耗也极低。人类大脑的功耗大约在 10-25 瓦之间，乌鸦的大脑尺寸约为人类的 1%，功耗约为 0.1-0.2 瓦。这意味着乌鸦无需复杂的能源供应系统或冷却设备，就能完成复杂的推理和问题解决任务。相比之下，现代 AI 系统需要高性能计算设备和大量能源，显示了生物智能的高效性。

智能的层次：从鹦鹉到乌鸦

“鹦鹉”与“乌鸦”的比喻在人工智能领域有着深刻的象征意义，揭示了**智能的不同层次**：

- **鹦鹉式智能**：擅长特定任务，通过数据驱动的模式识别和模仿来实现，针对某些垂直应用有效，但缺乏深度理解和推理能力。
- **乌鸦式智能**：具备复杂的推理和创造性，能够自主学习、适应环境，展现出高水平的智能灵活性。

这个比喻通过比较鹦鹉的模仿性智能和乌鸦的推理性智能，说明了 AI 智能的不同层次。

AI 的未来：向“乌鸦式智能”迈进

现有的 AI 系统，即使是最先进的语言模型和图像识别系统，都还处于“鹦鹉式智能”阶段。这些系统依赖于预定义规则、大量数据、大量计算资源来完成特定任务，但缺乏真正的推理和创造能力。虽然这类 AI 能够生成看似“智能”的对话，但它们的智能基于模式识别和数据驱动，与鹦鹉能模仿人类发音但不理解其语义一样。即使是像 ChatGPT 这样的先进语言模型，在模仿人类语言并生成非常连贯对话上表现几可乱真，但它并不具备关于“意义”的主观理解，无法感知、体验或有意识地推理，只是基于统计模式和相关性根据输入生成最有可能符合上下文的回应。因此，大语言模型更多是“聪明的猜测”，而非真正的理解。这与人类的理解方式存在本质差异。

AI 的未来发展目标是朝着“乌鸦式的智能”迈进，不仅能够模仿，还能推理、学习、适应，在跨任务和多变的环境中展现出灵活的创造力。实现与生物智能相媲美的灵活性和创造力，正是“强 AI”或“通用 AI”所追求的方向。

第 1 章 智能简史：生于数学

内容提要

- Definition of Theorem
- Ask for help
- Optimization Problem

- Property of Cauchy Series
- Angle of Corner

“如果人们不相信数学很简单，那是因为他们没有意识到生活有多复杂。”

——约翰·冯·诺伊曼

智能的历史可以追溯到人类最早期的思维活动，而数学是其中最重要的基础工具之一。

对于古代人来说，数字的发明源于对数量的需求。无论是借手指计数，还是用其他物体辅助，人类通过千年的发展，逐渐完善了从简单符号到抽象数字的演变过程。今天，我们的“自然数”概念似乎理所当然，但这一切都建立在人类历史上无数次的试错与进化中。

人类对“智能”的探讨源远流长。远在古希腊时期，哲学家们就已经开始追问：什么是智慧？什么是理性？我们如何通过思维去理解这个世界？从那时起，人们就梦想着创造能自主思考的机器。神话人物皮格马利翁 (Pygmalion)、代达罗斯 (Daedalus) 和赫淮斯托斯 (Hephaestus) 可以被看作传说中的发明家，而加拉蒂亚 (Galatea)、塔洛斯 (Talos) 和潘多拉 (Pandora) 则可以被视为人造生命 (Ovid and Martin, 2004; Sparkes, 1996; Tandy, 1997)。

这些问题不仅关乎哲学，还对现代科学和技术的发展产生了深远影响。随着时间推移，这种对智能的追问从哲学的纯理论思辨，逐渐转向了科学与工程实践领域。

早期的数学家如欧几里得、阿基米德以及笛卡尔等，通过逻辑和结构化的思维方式，奠定了后来发展计算机智能的理论基础。他们的工作不仅推动了科学与工程的发展，也为智能的理论构建提供了明确的框架。

1.1 数字的发明，智能的开端

1.1.1 史前数学：日常需求与实用计算

数学史往往是从公元前 5 世纪的希腊开始讲起的。毕达哥拉斯创立了算术，泰勒斯和阿那克西曼德创立了几何，奠定了古代数学的两大分支。算术和几何的创立，无疑是数学史上的重大突破。然而，这样的讲法却忽略了一个重要的时代，也就是所谓的“史前”数学。人们并没有等到公元前 5 世纪才开始解决数学问题，特别是那些日常面临的具体数学问题。

在公元前 5 世纪之前，数学并非一种独立的学科，而是伴随着人类生活的需要而逐步发展起来的。史前数学的主要任务是应对日常生活中的具体问题，如计数牲畜、测量土地和管理时间。远古人类通过手指计数、刻痕和结绳的方式解决了基本的数量和度量问题，虽然这些方法原始，却为后来的数学奠定了基础。

人类早期的数学成就源于实际需求，古埃及人和巴比伦人便是典型的例子。他们在天文学、土地测量和贸易中依赖数学工具，通过经验性的方法逐渐累积了丰富的数学知识。然而，这些方法主要依赖于实用性，而非系统的理论研究。

“数学”活动最古老的痕迹之一是在美索不达米亚发现的一块泥板，它可以追溯到公元前 2500 年。这块泥板记录了这样一个计算：如果一个谷仓里有 1152000 份粮食，每个人分得 7 份，一共可以分给多少人呢？不出所料，结果是 164571 人，即用 1152000 除以 7 得到的结果。看来，美索不达米亚的会计师在算术“诞生”之前很久就知道怎么做除法了。甚至，书写完全有可能就是为了记账才发明的——虽然这些事情很难说得准，但若真是如此，数字就比字母发明得还要早了。

1.1.1.1 手指：长在身上的计数器

相信你在许多影视剧中都见过这样的一幕：一位算命先生，掐指一算，口中念念有词。这种“掐指一算”看似神秘，实则源自于古老而简便的计数方法。



图 1.1: “掐指一算”

在远古时代，用手指计数是再自然不过的选择，手指是人类最早的“随身计算器”。手指提供了一个天然的计数系统，帮助人们轻松应对日常的计数需求，如记录牲畜数量、物品交换量，推算季节、节气，安排农耕节日等活动。

手指的构造与多种进制系统有着天然的联系。稍加思考，我们就可以发现十进制、二十进制、十二进制等计数法与手指构造的对应关系。

十进制 (Decimal System) 是最常见、最自然的计数方式。双手的十根手指与十进制自然对应，每根手指代表一个数字，从 1 数到 10，完成一轮计数。十进制系统在全球的广泛使用，源于人类天生拥有十根手指的解剖学特征。正如爱德华·卢卡斯所言，这是“自然界的一个偶然事件”。

十二进制 (Duodecimal System) 则适用于更复杂的计数需求。除大拇指外，四根手指各有三段指节。一只手的的大拇指指向四根手指的各段指节，可以计数 1 到 12。这种方式在古代美索不达米亚和古埃及广泛应用，至今仍用于时间和角度的计数系统中，如 12 小时制、一年 12 个月等。

六十进制 (Sexagesimal System) 则更加复杂。它结合双手来计数。一只手用于计 12（与十二进制相同），另一只手的五根手指则记录 12 的倍数，五轮 12 等于 60。六十进制在古巴比伦时期被发明，沿用至今，广泛用于时间和角度的计量，例如 1 小时 = 60 分钟，1 分钟 = 60 秒，以及 360 度的圆周划分。

二十进制 (Vigesimal System) 也是一种古老的计数法。为了更大范围的计算，一些古代民族不仅用手指，还加上脚趾来计数。例如，中美洲的玛雅文明和阿兹特克文明，以及现今的西非和欧洲部分地区，采用了以 20 为

基数的计数法。

二十进制的痕迹在许多语言中依然存在。现代英语中的“score”表示20的用法便保留了这一印记。例如，莎士比亚在《圣经》英译本中使用“three score and ten”（20的3倍加10，表示70岁）来指代古稀之年；林肯在《葛底斯堡演讲》中使用“four score and seven years ago”（20的4倍加7，表示87）来表达87年前的历史。一百年后，马丁·路德·金在其著名的演讲《I have a dream》中说“Five score years ago”（20的5倍，即100年前）。如今，在现代英语中，“score”的这种用法已不再常见。

英国曾有一个结合十二进制和二十进制的货币系统：1英镑=20先令，1先令=12便士。1971年，英国引入了十进制货币系统，1英镑=100便士，先令在1990年后彻底退出流通。

在法语、丹麦语和巴斯克语中也能找到二十进制的痕迹。例如，法语中的数词从 quatre-vingts(80)、 quatre-vingts-dix(90)，到 quatre-vingts-dix-neuf(99)，表明凯尔特族过去采用二十进制计数法。同时，这些语言中还混杂了六十进制的痕迹，如数词 soixante(60) 到 soixante-dix-neuf(79)。

手指不仅是我们的身体的一部分，还是人类最早的天然计算工具。它帮助我们理解和组织世界，并为现代数学中的位值制和进制系统提供了最初的灵感。直到今天，手指仍是许多人在进行简单计算时的本能工具。可以说，手指是人类最早的“计算器”，引领我们从最原始的计数方法走向了复杂的数学世界。

1.1.2 自然的教育，数字文明的缩影

设想你在一次航海探险中遭遇风暴，不幸漂流到了一个无人孤岛。没有手表、手机，也没有任何现代工具。你很快面临一个问题——如何计算时间？如何记录每天收集的食物？在这种完全回归自然的环境中，你必须依靠最原始的方式来解决这些问题。

1.1.2.1 手指计数：最简单的工具

你的第一反应可能是用手指来计数。十根手指天生就是人类最便捷的“计算器”，帮助你快速记录简单的数量——比如你捕到的鱼或采摘的果实。手指计数是直观而方便，几乎无需思考就能完成。但很快，你意识到这种方法有明显的局限性：当数字变大，或需要记录更复杂的信息时，手指显然不够用了。更重要的是，手指计数无法保存这些数据，一旦忘记，你的记录便随之消失。

1.1.2.2 刻痕计数：更长久的记录方式

为了更长久地保存记录，你开始在岛上的树木或石头上刻下痕迹。每道刻痕代表一天的过去，或你每天捕获的鱼或采摘的果实数量……。刻痕计数法让你能够更长久地保存这些信息。每天的刻痕不断累积，形成一个记录时间和活动的系统。这种方法虽然简单，却比手指计数更加持久、可靠，也能应对稍微复杂的需求，比如记录日期或特定的事件。然而，随着时间的推移，刻痕的数量增加，管理这些信息变得越来越困难。你开始需要一种更便捷、更灵活的方式来记录和传递这些信息。

1.1.2.3 结绳记数：更高级的记数法

幸运的是，你发现了一根绳子，这给了你一个新的选择——结绳记数法。通过在绳子上打不同的结，你可以标记不同的天数、事件或物品的数量。不同形状和位置的结可以表示不同的信息。相比于刻痕，结绳计数法更便捷灵活，更易于携带和传递，成为你在荒岛生活中的高级计数工具。

1.1.2.4 荒岛上的自然教育：人类数字发明的倒影

在这场荒岛冒险中，随着你逐步探索各种计数方法，你无意接受了一种独特的自然教育。这个经历，其实正是早期人类如何发明和发展数字的缩影。在远古时代，人类也像你一样，从最初的手指计数，逐渐发展到刻痕和结绳，寻找更有效的计数方式，逐渐探索出了越来越复杂、抽象的记数方式。

你在荒岛上的探索，正是人类数字文明进化的缩影。无论是刻痕还是结绳，这些方法都体现了人类从最初的物理标记到复杂符号系统的演化路径。通过这些自然的计数方法，你逐步掌握了记录、比较和计算的基本概念。这不仅是你个人的“自然教育”，也是数字发明的最初动力——让生活更加便捷和高效。

1.1.3 数字的位值系统

在人类早期文明中，简单的手指计数和结绳、刻痕等计数方法已广泛用于记录数字，帮助人们应对日常的数值计算。然而，随着社会的发展，人们逐渐认识到，仅靠刻痕和结绳等物理标记在处理更复杂和更大范围的数字时，显得低效而繁琐。于是，更加抽象的符号系统应运而生。从而催生了**位值制**这一革命性的数字表示方式，使得复杂的数值能够通过简单的符号位置来表示和计算。

早期的计数系统大多采用**加法规则**。例如，在古代巴比伦的黏土板上，数字是通过符号的重复来表示的：数字“1”用一个符号表示，数字“2”用两个相同符号表示，数字“3”则用三个相同符号。这种计数方式很眼熟，中文数字、罗马数字、古印度的婆罗门数字和笈多王朝使用的数字，以及大洋彼岸的玛雅数字，都采取了同样的方法。大多数的古代文明在表示前三个数字时，都采取了同样的方式：重复表示“1”的符号一次，两次，三次。古代的中文“一、二、三”、钟表盘上的罗马数字“、 、 ”、阿拉伯数字也体现了同样的重复方式。可是，从数字4开始，所有的文明就都放弃了这种重复。为什么呢？

研究发现，人类的数感对少于3的数字有天然的反应，但超出这个范围后，单纯的重复符号便变得困难。对一些出生几个月的婴孩进行试验，结果证实人类与生俱来的数感的容量不超过三。

试想一下，数字13若用重复排列“1”的符号13次来表示，无论是对书写还是阅读，都会很低效——怎么能一眼就看出它是13，而不是12或者14呢？

类似的问题在罗马数字系统中也很常见。罗马数字系统中，V表示5，X表示10，L表示50，C表示100。此外，向右添加符号为加，如，VI表示数字6，XI表示数字11；相反地，向左添加一个更小数值的符号为减，如IV表示4，IX表示9。尽管使用了加减法规则的计数系统十分直观，但在表示大数时显得十分低效。例如1888年写成罗马数字就是MDCCCLXXXVIII，甚至无法有效表示类似100万那样的数字——除非把1000个M排成一排！

随着人类文明的发展，许多地区开始引入更为先进的计数法，其中最具革命性的是**位值制计数法**。古巴比伦、中国，尤其是印度和阿拉伯，率先采用了这种创新的位值制计数法。这种计数法的关键在于符号的位置决定了其数值。例如，数字“12”和“21”虽然使用相同的符号，但因为符号位置不同，代表的数值也不同。

位值计数法具有出众的简洁性。通过有限的符号，可以表达任意大的数值。例如， 10^{100} 这个超出了物理限制的天文数字，在位值制下仅需101个符号即可表示——一个“1”后面跟着100个“0”。位值计数法用极短的符号链表示极其巨大的数值。

位值制不仅提高了数字的表示效率，还反映了数字的**对数增长**特性，即随着数字的增大，所需的符号长度呈对数增长，符号数量远远少于数字本身的大小。例如，表达 10^{100} 所需的符号长度约为 $\log_2 10^{100} = 100$ （实际为101个）。一般地，表达任意整数 x 所需的符号数量接近 $\log_{10} x$ 。因此，从某种意义上，位值计数系统是最简洁、甚至最优的。

位值制的引入是人类计数方法的一次重大飞跃。从简单的重复符号到高度抽象的符号系统，位值制极大简化了计算过程，推动了计算和数学的发展，奠定了现代数字系统的基础。

1.1.4 位值制与对数增长在现代计算机中的应用

在计算机科学中，在已经排好序的数组中查找某个元素的时间也是数组长度的对数。即使数组规模如同宇宙般庞大，经过几百次迭代后，便能够找到所需的元素——唯一的限制就是光速有限性所带来的信息传播和处理速度的物理极限。

互联网的URL是位值制与对数增长在数据处理和网络寻址中的一个典型应用。一个简短的URL(Uniform Resource Locator, URL, 统一资源定位符)迅速定位到海量信息。想象一下，你希望在网上搜索某项信息。尽管

互联网上的数据量可能以 EB(10^{18} 字节) 甚至 ZB(10^{21} 字节) 计量，只要拥有对应信息的 URL，你几乎瞬间就能找到目标信息。这正是对数增长的强大之处：即使面对巨大规模的数据集，只需少量步骤就能完成检索。

此外，URL 的简短程度令人惊叹，其长度是整个网络大小的对数！这意味着我们可以轻松将 URL 存储在内存中，而 URL 指向的信息量却远远超出了其自身长度。这种简洁有效的特性，展示了对数增长在计算与信息处理中的关键作用。

IPv4 和 IPv6 的设计正是对数增长在实际应用中的另一个实例。IPv4 地址使用 **32 位** 二进制数来表示，每个 IP 地址可以被写成 4 个以点分隔的十进制数（如 192.168.1.1），每部分对应一个 8 位的二进制数。32 位的二进制能够生成 2^{32} ，即约 **43 亿** 个唯一 IP 地址。这在 IPv4 设计之初被认为是足够庞大的数目。然而，随着互联网的迅速扩展，特别是物联网（IoT）设备和移动设备的广泛普及后，IPv4 的 43 亿个地址空间将很快耗尽。

为了解决这一问题，**IPv6** 应运而生。IPv6 使用 **128 位** 二进制数表示，由八组以冒号分隔的 16 进制数构成（如 2001:0db8:85a3:0000:0000:8a2e:0370:7334）。这种 128 位的二进制表示能生成 2^{128} ，即约 3.4×10^{38} 个唯一 IP 地址，相当于为地球上的每粒沙子分配多个 IP 地址。这一数量级足以应对未来几十年甚至几百年内所有联网设备的需求。

IPv4 和 IPv6 的位数与它们能够支持的地址数量之间的巨大落差，展示了对数增长的强大力量。IPv4 仅用 32 位符号就能表示 43 亿个地址，而 IPv6 仅用 128 位符号就能支持 3.4×10^{38} 个地址。随着位数的增加，IP 地址系统实现了指数级的扩展，同时保持了地址表示的简洁性。

1.2 数字：从具象到抽象

几千年来，人类都在探索如何建立数与物的对应关系，现代数字系统的定义正是基于这种探索的延续。一旦人类掌握了计数，数字系统的应用就变得“自然而然”了。或许正因如此，我们才称自然数为“自然”数 (natural number)。然而，实际上，数字的概念一点也不“自然”。

无论是在早期人类在骨头及木棍上有序地刻下划痕，还是结绳或是在容器中放置物品无论是结绳，这些早期方法已代表了相当抽象的符号系统，其中抽象的数学对象与自然中的实际物体之间的分离，同一个数字既可以表示动物的数量，也可以记录借贷量或一个月的天数。自此之后，数学研究的对象不再是必须与实际物体相关的几何图形和数字。研究对象性质的变化，最终引发了解决数学问题的方法的革命。

1.3 数学的真正诞生：从计算到推理

数学作为一种学科，经历了漫长的演化过程。起初，数学的诞生是为了解决生活中的实际问题——如何计数、测量、交易、管理时间等。

公元前 5 世纪的希腊是数学发展的转折点。在此之前，数学主要集中于如何进行计算。

在埃及和美索不达米亚等古老文明中，数学的发展更多地依赖于经验和实际操作。埃及的数学侧重于土地测量、建筑工程和会计管理，而巴比伦人则在天文学、时间计算和度量衡方面取得了显著的成就。他们的数学面向解决日常问题，更多依赖于表格、算法和简单的数值操作。

“数学”活动最古老的痕迹之一是在美索不达米亚发现的一块泥板，它可以追溯到公元前 2500 年。这块泥板记录了这样一个问题：一个谷仓里有 1152000 份粮食。如果每个人分得 7 份，一共可以分给多少人？答案是 164571 人，即用 1152000 除以 7 得到的结果。看来，美索不达米亚的会计师在算术“诞生”之前很久就知道怎么做除法了。美索不达米亚和埃及的会计师不仅会做乘除法，而且掌握了许多其它的运算，比如解二次方程等。土地测量师则会计算矩形、三角形、圆形的面积。

这种实用性的数学（包括算术和几何）在数学史上称为“史前”数学，因为它并不涉及抽象推理，而是围绕日常需求展开。

因此，教科书中的数学史往往是从公元前 5 世纪的希腊开始讲起的，因为希腊数学家让数学从“如何计算”进化到了“为什么如此”。

在公元前 5 世纪的希腊，毕达哥拉斯学派提出了这样一个问题：找出一个等腰直角三角形，使其三边的长度都是自然数。假设等腰直角三角形的直角边长度为 x ，斜边长度为 y 。根据毕达哥拉斯定理（勾股定理）， y^2 就等于 $x^2 + x^2$ 。因此，这个问题最终归结为：找出两个自然数 x 和 y ，使得

$$2x^2 = y^2 \quad (1.1)$$

让我们来试试 4 以内所有 x 和 y 的可能性吧（见表 1.1）。在上述所有情况里， $2x^2$ 都不等于 y^2 。我们当然还可以

x	y	$2x^2$	y^2
1	1	2	1
1	2	2	4
1	3	2	9
1	4	2	16
2	1	8	1
2	2	8	4
2	3	8	9
2	4	8	16
3	1	18	1
3	2	18	4
3	3	18	9
3	4	18	16
4	1	32	1
4	2	32	4
4	3	32	9
4	4	32	16

表 1.1: 4 以内 x 与 y 的所有可能性

在更大的数字范围里继续寻找。事实上，毕达哥拉斯学派很可能寻找了很久，却没能找到解。后来，他们终于相信这个解不存在。他们是怎么说服自己这个解不存在的呢？显然不是穷尽所有的数对，因为这样的数对有无穷不可数个。你就算试到 1000 甚至 100 万，证实没有数对能满足条件，可你还是没法保证在更大的数字里面不可能有解……

既然不能用穷举法，那就试试逻辑推理。不妨假设 x, y 两个数互素。为什么呢？因为若 x, y 至少有一个是奇数时，两者自然互素；反之，若 x, y 都是偶数，则总是可以通过消去公因子来保证 x, y 至少有一个是奇数。据此，我们把数对 x, y 分成以下 3 种情况：

1. x, y 都是奇数；
2. x 是偶数， y 是奇数；
3. x 是奇数， y 是偶数；

我们先从第一种情况开始： x 和 y 都是奇数。此时 (1.1) 的解不存在。因为 y 是奇数，则 y^2 也是奇数。它不可能等于 $2x^2$ ，因为后者必然是偶数。这一论证也同样适用于第二种情况，即 x 是偶数而 y 是奇数。第三种情况即 x 是奇数而 y 是偶数。但在这种情况下，若 $2x^2 = y^2$ 成立，则这个数的一半 x^2 是奇数，同时 y^2 的一半却是偶数——这两个数不可能相等。综上所述，找不到两个自然数 x, y 满足 (1.1)。

为了证明这个问题没有解，毕达哥拉斯学派采用了逻辑推理而不是计算来实现。他们通过分类讨论和推理，证明了无论 x 和 y 是奇数还是偶数，方程 $2x^2 = y^2$ 都不可能有整数解。

这一问题的解决在数学史的发展上具有划时代的意义。它的革命性不仅在于其对未来数学的巨大影响，还在于其抽象性及解决的方法。相比于美索不达米亚泥板上铭刻的诸如“将 1152000 份粮食除以 7 份”的具体问题，毕达哥拉斯学派的问题更为抽象：美索不达米亚的会计师关注粮食的数量，而毕达哥拉斯学派的问题仅涉及数字本身。同样，他们处理的是抽象的几何形式，而非具体的三角形田地。从从粮食的份数到数字，从实际的土地测量转向几何学的抽象思考，迈向抽象这一步的意义不可小觑。田地的面积无非几平方千米，而抽象的几何对象则可以轻松超越这一尺度，进入无限的范围。

古希腊数学家不再满足于计算结果，而是开始重视推导过程。他们通过严谨的逻辑推理，逐步构建了数学

证明和公理系统。这一从计算到推理的转变，被视为数学的真正诞生，使得数学从日常的计算工具演变为以推理和抽象为核心、具有高度抽象和严谨逻辑的独立学科的学科。

一个平方数不可能是另外一个平方数的两倍——这个由毕达哥拉斯学派在 2500 多年前得到的结果，迄今在数学上仍占有重要地位。它证明了，一个短边为 1 米的等腰直角三角形中，斜边的长度为 $\sqrt{2}$ ，约 1.414，但这个数无法通过两个自然数 y 和 x 的比值得到。这揭示了，某些几何关系无法通过自然数的四则运算（加、减、乘、除）运算得到，暗示了更广泛的数系——实数的存在。这一发现让数学进入了一个全新的领域——从实际问题中抽象出纯粹的数学对象并通过推理得出结论。虽然这一发现具有革命性，但毕达哥拉斯学派并没有进一步发展出实数的概念。对他们而言，这一结论动摇了他们对自然数“万物皆数”的信仰，甚至引发了哲学上的困惑与争议。然而，几百年后，这一发现启发了数学家们发展出实数理论，为数论和分析学的诞生奠定了基础。

在古希腊，算术与几何逐渐成为两大数学分支。毕达哥拉斯创立了算术，泰勒斯和阿那克西曼德奠定了几何的基础。这两个分支的诞生，标志着数学从实用计算工具演变为一门以逻辑推理和证明为核心的科学。古希腊数学家的工作不仅为现代数学的发展铺平了道路，也为整个科学体系奠定了坚实的理论基础，开启了数学从经验工具到推理科学的伟大飞跃。

1.4 简明数学史

课本中字斟句酌的叙述，未能表现出创造过程中的斗争、挫折，以及在建立一个可观的结构之前，数学家所经历的艰苦漫长的道路。学生一旦认识到这一点，他将不仅获得真知灼见，还将获得顽强地追求他所攻问题的勇气，并且不会因为自己的工作并非完美无缺而感到颓丧，实在说，叙述数学家如何跌跤，如何在迷雾中摸索前进，并且如何零零碎碎地得到他们的成果，应使搞研究工作的任一新手鼓起勇气。

克莱因，《古今数学思想》序言

数学的发展历程如同一条不断延展的长河，从最初的数字发明，到公元前 5 世纪的希腊数学奠基，再到随后的数千年中，数学逐渐演变为一门多维度、多分支的科学。通过计算与推理的结合，数学不仅成为解决现实问题的工具，也升华为探索抽象概念与逻辑关系的强大思维体系。

数学的发展史可以大致划分为四个不同的时期：数学萌芽时期、初等数学时期、近代数学时期和现代数学时期。需要说明的是，精确地划分这些阶段是不可能的，因为每个时期的特征都是在前一时期的基础上逐渐形成的。然而，这些阶段反映了数学在每个历史阶段中的不同侧重与进步，揭示了数学从最早的经验积累到复杂的理论构建，乃至今天在科技与智能领域的广泛应用的深刻演化。每个时期都在数学发展中扮演了不可或缺的角色。

让我们依次回顾这些数学发展的重要阶段，探索其背后的历史背景与核心成就。

1.4.1 数学萌芽时期

数学的萌芽时期从远古时代延续至公元前 5 世纪，是人类最早利用数学工具应对日常生活需求的阶段。

这一阶段的数学起源于最基本的数数活动。通过手指计数、刻痕和结绳等原始计数手段，人类逐渐形成了自然数的概念。自然数的确立是数学发展的第一步，也是人类对数量的最早认识。从简单的数数开始，逐渐发展出加减乘除等基本运算，为解决日常生活中的问题提供了有效的工具。

古埃及人发展了一些基础的几何公式，在建造金字塔时已经能够运用高度和角度的几何关系；美索不达米亚的会计师不仅掌握了加法和乘法，还能够解简单的二次方程，用于管理粮食和资源。古代美索不达米亚和埃及的泥板和石刻记录了这些早期的数学活动，展现了数学与生活实践的紧密联系。

巴比伦人对天体运动的观察和历法推算也推动了数学的发展。为了精确预测日食、月相以及制定历法，巴比伦的天文学家需要处理大量的时间和角度计算。这些天文观测不仅促进了数学在测量和计算方面的进步，也推动了几何和代数的进一步发展。

这一时期并没有明确的个人数学家记载，更多的是群体性活动。古埃及的建筑师和美索不达米亚的会计师是这一阶段数学发展的重要推动者。埃及人在几何测量中的应用和美索不达米亚人对天文学和代数的研究，构成了数学早期发展的代表性成就。

这一阶段的数学活动是解决问题的经验性工具，尚未形成系统的理论。但它为后续的数学体系发展奠定了数与形的概念基础。

1.4.2 初等数学时期

公元前 5 世纪开始，数学进入了初等数学时期。这个时期的数学探索更加系统和深入，尤其是在欧几里得几何和代数方程的研究中，数与形的关系得到了更加严谨的探讨，算术、几何、代数和三角等数学分支逐渐成形。

毕达哥拉斯：数与宇宙的关系

数学的哲学化起点源自古希腊的毕达哥拉斯学派。毕达哥拉斯 (Pythagoras) 及其追随者提出了“万物皆数”的思想，认为宇宙的本质可以通过数来理解。这一理念激励了希腊数学家们将数学视作解读自然现象的工具。毕达哥拉斯定理（即勾股定理）是这一学派最著名的成就之一，标志着数学开始从经验性计算向理性推理的迈进，开启了数与形结合几何学研究。

欧几里得：公理化体系的奠基人

如果说毕达哥拉斯奠定了数学的哲学基础，那么欧几里得（Euclid）则为数学建立了逻辑结构。他的《几何原本》（《Elements》）是古代数学史上最具影响力的著作之一，也是现代数学公理化体系的奠基之作。

欧几里得通过公理和定理的形式，系统地将几何学结构化，强调了证明的重要性。欧几里得展示了如何从少数的基础假设（公理）出发，通过严密的逻辑推导，推导出一系列复杂的几何命题。这种公理化方法对后世的数学家产生了深远影响，甚至成为了现代数学研究的重要框架。欧几里得的几何不仅仅是关于形状和空间的学问，更标志着数学作为一种基于推理的演绎学科的正式诞生。

阿基米德：数学与物理的桥梁

阿基米德（Archimedes）是古希腊另一位杰出的数学家，他不仅在数学领域取得了重大的突破，还在物理学、机械学等领域做出了重要贡献。阿基米德将几何与物理现象紧密结合，开创了利用数学模型解决物理问题的先例。

他在几何领域的突破，如圆周率的近似计算、浮力定律及流体静力学基本定理的证明，展示了数学在物理学应用中的强大力量。阿基米德的工作不仅扩展了数学的应用范围，还展现了数学在解释自然现象中的力量。

亚里士多德：逻辑与推理

亚里士多德（Aristotle）是古希腊著名的哲学家。亚里士多德认为，数学不应只停留在经验性的层面，而应该通过演绎推理去发现隐藏在事物背后的逻辑关系。他提出的三段论和归纳法，帮助数学家们更好地理解 and 构建逻辑推理过程。这种逻辑推理体系推动了古希腊数学的进一步发展，数学家们开始通过推理和证明而非直观的经验得出结论。

算术与几何这两大分支的创立，标志着数学开始作为一门理论化学科的诞生，逻辑推理和证明逐渐成为数学的核心方法。与此同时，代数学在这一时期取得了重要进展，自然数、有理数和无理数的运算逐渐成为代数的核心主题。除此之外，这一阶段的代数学还开始引入虚数，推动了数的概念向更广的领域扩展。

古希腊数学的遗产

通过抽象思维和逻辑推理，建立了数学作为一种独立学科的基础。古希腊数学家们的贡献不仅仅是发现了一些几何定理和代数法则，更重要的是他们发展了数学思维的方式——通过演绎、证明、公理化等方法，将数学从经验性工具转变为一种严谨的科学。这一传统不仅奠定了现代数学的基础，还推动了之后数千年数学和科学的进步。

中世纪的阿拉伯数学家翻译了希腊经典，并引入了印度的十进制数和“零”的概念。阿尔·花刺子密（al-Khwarizmi）等数学家对代数学的发展做出了巨大贡献，他的著作奠定了代数理论奠定了坚实的基础。

中国的《九章算术》和印度的基础代数成就，也为初等数学的发展增添了重要内容。中国古代数学强调实用性，广泛应用于农业、建筑和税务管理；而印度数学则对数论和代数的早期发展做出了杰出贡献。这些不同文化的数学成果，最终共同塑造了初等数学的广阔基础。

这一时期涵盖了公元前 5 世纪到 17 世纪前的数学发展。数学不再仅限于解决实际问题，而是向抽象领域迈进。古希腊数学通过几何学和数论的研究，构建了数学推理和证明的数学体系。这一阶段的数学成就不仅构成了今天中学数学的主要内容，还对现代数学的基本理论结构产生了深远的影响。

1.4.3 近代数学时期

从 17 世纪开始，随着资本主义的崛起和工业革命的推动，数学进入了一个全新的阶段—变量数学时期。这一时期的数学从研究静态图形和数量问题逐步转向关注变化与运动问题，变量和函数的引入是更好描述运动和变化的关键。

牛顿和莱布尼茨分别独立发明了微积分，标志着数学史上一个重要的转折点。微积分提供了一套精确描述连续变化与瞬时变化的数学工具，成为解决诸如速度、加速度、曲线下面积等问题的强大工具。牛顿通过微积分为物理学中的万有引力定律奠定了理论基础，而莱布尼茨则将微积分符号化并推广到欧洲，极大地推动了数学的发展。微积分不仅让数学得以分析瞬时变化，还为后续的数学分析开创了新的方向。

解析几何的诞生是这一时期的另一个重大突破。笛卡尔通过引入坐标系，将几何与代数结合起来，使得复杂的几何图形、物理的运动及其空间关系可以通过代数方程来精确描述。借助于笛卡尔坐标系，数学家们能够用代数表达曲线、直线的关系，从而简化了几何中的很多问题。解析几何不仅为物理学中的动力学提供了有力工具，还为现代数学的发展铺平了道路。

近代数学时期的另一个重要分支是概率论。概率论起初由费马和帕斯卡为了研究赌博中的随机事件而诞生，但很快超越了这一领域，成为研究不确定性和随机现象的重要工具。费马还对数论做出了重要贡献，提出了许多关于素数与数之间关系的问题，激发了后世数学家对数论的广泛研究。欧拉、拉格朗日等人进一步推动了数论的发展，探讨了代数结构和数论的基本问题。

与此同时，分析学作为微积分的延续，成为这一时期的核心数学分支。通过函数和极限概念的引入，数学家们能够处理无穷小量和变化中的量，开创了分析学的时代。数学分析不仅成为这一时期的核心理论，不仅解决了古希腊时期悬而未决的几何问题，还广泛渗透进了物理学、天文学和工程学，极大地推动了科学的进步。

从 17 世纪开始，数学逐步系统化，并成为理解自然世界的核心工具。科学革命带动了数学的飞速发展，数学不仅在传统的代数和几何领域取得了突破，还在物理学、天文学、工程学等领域中发挥了重要作用。变量数学的引入让人们能够更好地理解宇宙中的变化与运动，推动了自然科学的进步。

总的来说，近代数学时期不仅为数学的进一步抽象化奠定了基础，还通过微积分、解析几何和概率论的兴起，彻底改变了人类对世界的理解方式。数学在这一时期的变革性进展，成为了现代数学发展的根基，也为科学技术的进一步进步提供了强有力的工具。

1.4.4 现代数学时期

从 19 世纪中叶起，数学进入了一个高度抽象化和系统化的阶段，被称为现代数学时期。这个时期的数学阶段不仅延续了之前的分析学发展，还引入了全新的几何和代数理论。代数、几何和分析学等传统学科在此期间发生了质的飞跃，数学的研究对象和方法也逐渐向高度抽象化发展，推动了数学成为一门更加系统和广泛应用的科学。

现代数学的一个显著特征是对数学基础的重新审视与抽象概念的扩展。罗巴切夫斯基和黎曼的非欧几何，颠覆了传统欧几里得平面几何观，提出了球面和鞍面等不同几何结构，揭示了更为广泛的空间和结构关系。并为爱因斯坦的广义相对论提供了数学基础。拓扑学作为新的分支，也在 19 世纪逐渐兴起，打破了传统几何的局限，成为数学研究连续性、边界与形态的重要工具。

同时，现代数学的发展离不开对无穷概念和数学基础的深入研究。康托尔的集合论，为处理无穷大的数学研究提供了严格的工具，将无穷大和无穷小的概念精确化，成为现代数学和数理逻辑的基础理论之一。集合论的发展不仅使数学在抽象层面上得以统一，还激发了对数学自身基础的研究。集合论和数理逻辑的兴起为数学理论提供了全新的理论框架，希尔伯特、哥德尔等数学家在此领域的工作，使得数学的公理化体系进一步得到发展与完善。

20 世纪，统计学、拓扑学、泛函分析等新分支陆续创立，使数学更多元化、更富实用性。数学在众多领域的应用范围得到了前所未有的扩展，数学在物理学、工程学、经济学以及其他自然科学和社会科学等各个学科中的作用变得愈加重要。

现代数学时期的另一个重要推动力是计算机的发明和信息技术的迅猛发展。20 世纪中期，图灵、冯·诺依曼等科学家为计算机科学奠定了理论基础，计算理论逐渐成为数学的重要分支。计算机的强大计算能力使得复杂的数学问题得以快速求解，同时也极大地推动了数理逻辑和算法理论的发展，数学的潜能和边界更进一步发掘。

随着数学的抽象化与理论化趋势日益加深，数学在深入自然科学领域的同时，还广泛渗透到信息科学、工

程学、经济学、社会科学等多个领域，推动了现代社会各个层面的进步。现代数学逐渐成为理解自然世界、构建理论模型和推动技术创新的核心力量。

总之，现代数学时期是数学高度抽象化、系统化的阶段。数学基础理论的深入研究与应用范围的广泛扩展，使得数学不仅在理论层面得到了重大发展，也成为了推动科学和技术进步的关键推动力。通过集合论、非欧几何、拓扑学和计算理论的引入与发展，数学在 20 世纪的进步为现代社会的各个领域带来了不可忽视的影响。

1.5 小结

纵观以上四个时期，数学的发展脉络清晰呈现。数学从最初解决日常问题的工具，逐步演化为一门以逻辑推理和抽象思维为核心的科学。数学史既是一部理论创新史，也是一部与社会发展和科学进步紧密相连的演进史。

从萌芽阶段的经验性计算到古希腊数学家奠定的逻辑推理基础，再到近代变量数学的飞跃和现代数学的高度抽象化，数学经历了从实用工具到抽象学科的跨越。随着社会与科学的持续发展，数学也成为了理解世界、解决问题和推动技术进步的核心力量。

第 2 章 智能简史：成于计算机

内容提要

- ❑ Definition of Theorem
- ❑ Ask for help
- ❑ Optimization Problem
- ❑ Property of Cauchy Series
- ❑ Angle of Corner

“课本中字斟句酌的叙述，未能表现出创造过程中的斗争、挫折，以及在建立一个可观的结构之前，数学家所经历的艰苦漫长的道路。学生一旦认识到这一点，他将不仅获得真知灼见，还将获得顽强地追究他所攻问题的勇气，并且不会因为自己的工作并非完美无缺而感到颓丧，实在说，叙述数学家如何跌跤，如何在迷雾中摸索前进，并且如何零零碎碎地得到他们的成果，应使搞研究工作的任一新手鼓起勇气。”

傅鹰

——约翰·冯·诺伊曼

第3章 人工智能的三种思维

本章提要

❑ 数学思维

❑ 工程思维

❑ 计算思维

发展数学理论是一回事, 实现它又是另一回事。

来自应用, 回归应用: 从数学思维到算法思维到工程思维

数学思维:

-理想情形 -存在性 -可构造性

算法思维

-算法复杂度 -算法优化 -稳定性

工程思维

-允许误差 -大规模问题 -鲁棒性 -经济效应

举一些数值算法稳定性的反例

例: 近似计算 $S_n = \int_0^1 \frac{x^n}{x+5} dx$, 其中 $n = 1, 2, \dots, 8$

解: $S_n + 5S_{(n-1)} = \int_0^1 \frac{x^n + 5x^{(n-1)}}{x+5} dx = \int_0^1 x^{(n-1)} dx = 1/n$

第 4 章 人工智能的数学工具

内容提要

- Definition of Theorem
 - Ask for help
 - Optimization Problem
- Property of Cauchy Series
 - Angle of Corner

微积分

- 导数和偏导数：用于计算函数的变化率，广泛应用于梯度下降算法和神经网络的训练。- 链式法则：用于反向传播算法，以计算神经网络中的梯度。- 梯度和 Hessian 矩阵：用于优化问题，特别是在高维空间中。- 积分和多重积分：用于概率计算和期望值计算，如在贝叶斯推断中。

概率与统计

- 随机变量和概率分布：用于建模和分析随机现象，如正态分布、泊松分布。- 贝叶斯定理：用于更新概率分布，广泛应用于贝叶斯网络和贝叶斯推断。- 最大似然估计 (MLE) 和最大后验估计 (MAP)：用于参数估计和模型选择。- 马尔可夫链和马尔可夫决策过程 (MDP)：用于建模和解决决策过程，特别是在强化学习中。- 蒙特卡罗方法：用于数值积分和概率分布的近似计算。

优化理论

- 凸优化：研究凸函数和凸集合的优化问题，如 LASSO 和支持向量机 (SVM)。- 非凸优化：处理复杂的优化问题，如深度学习中的神经网络训练。- 梯度下降和随机梯度下降：用于迭代优化问题。- 线性规划和整数规划：用于资源分配和组合优化问题。- 拉格朗日乘数法：用于含约束条件的优化问题。

图论

- 图的表示：用于建模关系和网络，如邻接矩阵和邻接表。- 最短路径算法：如 Dijkstra 算法，用于路径规划和网络分析。- 图匹配和图划分：用于社交网络分析、图像分割和聚类。- 网络流和最大流问题：用于优化运输和流量问题。

信息论

- 熵和互信息：用于衡量信息量和依赖关系，在特征选择和通信中应用。- 编码理论：研究数据压缩和错误检测/纠正码，如香农编码和汉明码。- 卡尔曼滤波：用于动态系统的状态估计和信号处理。

计算理论

- 图灵机和计算复杂性：研究计算问题的复杂性和可计算性，如 P 与 NP 问题。- NP 完全性：研究问题的求解难度和算法的效率，判定问题是否具有多项式时间复杂度解。- 自动机理论：研究有限状态机和形式语言，应用于编译器和正则表达式。

离散数学

- 组合数学：用于分析和解决离散结构的问题，如组合优化、排列和组合。- 布尔代数：用于逻辑推理和数理逻辑，特别是在逻辑编程和电路设计中。- 图论和网络流：用于优化和分析网络结构。

动态系统与微分方程

- 常微分方程 (ODEs)：用于建模连续时间的动态系统，如物理模拟和控制理论。- 偏微分方程 (PDEs)：用于建模空间和时间的连续变化，如图像处理和物理场模拟。- 分岔理论和混沌理论：研究动态系统的稳定性和非线性行为。

几何与拓扑

- 微分几何：用于分析曲面和形状，如在计算机视觉和图像处理中的应用。- 拓扑数据分析 (TDA)：用于数据的形状分析和降维，应用于高维数据的可视化。- 计算几何：研究几何对象的算法和数据结构，用于计算机图形学和机器人学。

变分法与计算几何

- 变分法：用于优化问题的解，如在图像处理、路径规划和物理模拟中的应用。- 计算几何：研究几何对象的算法和数据结构，用于图形学、计算机视觉和 CAD 系统。

数值分析

- 数值微分和积分：用于逼近和求解微分方程和积分方程。- 线性代数的数值方法：如 QR 分解、LU 分解，用于求解线性方程组。- 优化的数值方法：如牛顿法、共轭梯度法，用于高效求解优化问题。

笛卡尔几何与代数几何

- 笛卡尔几何：用于解析几何问题，如直线和曲线的表示与计算。- 代数几何：研究多项式方程的解集结构，用于计算机代数系统和图形学。

逻辑与集合论

- 一阶逻辑和高阶逻辑：用于形式化推理和验证。- 集合论：研究集合的性质和操作，是数学的基础理论之一。

4.1 预备知识

要学习深度学习，首先需要先掌握一些基本技能。所有机器学习方法都涉及从数据中提取信息。因此，我们先学习一些关于数据的实用技能，包括存储、操作和预处理数据。

机器学习通常需要处理大型数据集。我们可以将某些数据集视为一个表，其中表的行对应样本，列对应属性。线性代数为人们提供了一些用来处理表格数据的方法。我们不会太深究细节，而是将重点放在矩阵运算的基本原理及其实现上。

深度学习是关于优化的学习。对于一个带有参数的模型，我们想要找到其中能拟合数据的最好模型。在算法的每个步骤中，决定以何种方式调整参数需要一点微积分知识。本章将简要介绍这些知识。幸运的是，‘autograd’包会自动计算微分，本章也将介绍它。

机器学习还涉及如何做出预测：给定观察到的信息，某些未知属性可能的值是多少？要在不确定的情况下进行严格的推断，我们需要借用概率语言。

最后，官方文档提供了本书之外的大量描述和示例。在本章的结尾，我们将展示如何在官方文档中查找所需信息。

本书对读者数学基础无过分要求，只要可以正确理解深度学习所需的数学知识即可。但这并不意味着本书中不涉及数学方面的内容，本章会快速介绍一些基本且常用的数学知识，以便读者能够理解书中的大部分数学内容。如果读者想要深入理解全部数学内容，可以进一步学习本书数学附录中给出的数学基础知识。

-2.1. 数据操作

4.2 浅谈图像处理：从矩阵到深度学习

目录摘要 ABSTRACT 第 1 章引言 1 1.1 图像识别如何作用于我们的生活？ 1 1.2 追根溯源——其中的数学方法 1 1.3 报告主体结构 with 主要内容 1 第 2 章从矩阵到深度学习 2 2.1 矩阵 2 2.1.1 矩阵的起源 2 2.1.2 矩阵的发展 2 2.1.3 矩阵的基本操作 2 2.2 传统图像处理 5 2.2.1 基础知识——图像矩阵化 5 2.2.2 传统图像处理的起源 10 2.2.3 传统图像处理的发展 12 2.2.4 传统图像处理的应用 19 2.3 深度学习与图像处理——三种模型 20 2.3.1 起源 20 2.3.2 单层感知器模型 21 2.3.3 多层感知器模型 21 2.3.4 卷积神经网络模型 22 2.4 深度学习在图像处理上的发展——以目标检测为例 26 2.4.1 起源 26 2.4.2 R-CNN 27 2.4.3 SPP-Net 30 2.4.4 Fast R-CNN 31 2.4.5 Faster R-CNN 32 2.4.6 FPN 34 2.4.7 单阶段算法与两阶段算法 35 2.4.8 总结 35 2.4.9 深度学习图像处理举例 35 第 3 章体会启发与结语 38 3.1 体会与启发 38 3.2 结语 39 参考文献 40 致谢 41

摘要本论文从代数学矩阵开始，讲述了将图像矩阵（数字）化的重要意义，以及如何使用矩阵分析与变换的方法来分析并修改图像，并介绍了传统图像处理技术的建立与发展过程，若干重要算法以及一些弊端，最后将图像处理技术指向了深度学习与神经网络模型，引入人工智能协助以达到更先进的技术水平，并展示了一个具体实例。

4.3 第 1 章引言

4.3.1 1.1 图像识别如何作用于我们的生活？

图像识别是计算机视觉和人工智能领域的重要组成部分，其终极目标是使计算机具有分析和理解图像内容的能力。图像识别是一个综合性的问题，涵盖图像匹配、图像分类、图像检索、人脸检测、行人检测等技术，并在互联网搜索引擎、自动驾驶、医学分析、遥感分析等领域具有广泛的应用价值。具体例子：最近，由于疫情封锁，室内运动成了当下人们主要的运动方式，一款用于督促人们运动的 app 应运而生，那就是天天跳绳，而它就是通过识别人的肢体动作图像来对人的运动做出判断。这样的例子数不胜数。

4.3.2 1.2 追根溯源——其中的数学方法

将图像进行数字（矩阵）化后，我们就可以使用对于矩阵的分析方法来分析图像了，由矩阵的一些基本运算即可达到修改图像的目的，例如可以使用仿射变换来对图像做平移、放大、旋转、剪切等操作。更可以引入更加深入的算法和数学知识来进行一些更为先进的图像处理方式，例如使用高等数学中的卷积概念进行图像分析，使用 Canny 算法实现边缘检测，以及借许多数学知识与编程思维使用深度学习技术训练，达到使用人工智能协助图像分析的目的。

4.3.3 1.3 报告主体结构与主要内容

本报告从矩阵知识引入，介绍了其起源（2.1.1）、发展（2.1.2）、基础知识（2.1.3），这一部分由王晨阳同学负责。然后，我们探究了其在传统图像处理中的应用——图像矩阵化（2.2），层层深入，揭示了现代图像处理中矩阵的作用，这一部分由谭诚同学负责。在传统图像处理（2.2）中我们探究了其方法（2.2.1），起源（2.2.2），发展（2.2.3）及应用（2.2.4），这一部分由汪坤灿同学负责。在深度学习与图像处理中，我们介绍了若干种深度学习的神经网络模型，以及若干个深度学习的算法，这一部分由史晓磊同学负责。最后，我们使用 Python-OpenCV 库以及调用了 Github 上一个已经训练好的模型，完成了一次对图片中人脸的识别检测，这一部分由谭诚同学负责。小组中，我们各自安排撰写各自的文档、ppt，以及录制视频中的各个部分。最后由谭诚同学整合、排版，以及剪辑。

4.4 第 2 章从矩阵到深度学习

去年的某一天，一张利用 AI 修复的林徽因的照片冲上了热搜。可以看出，右边由 AI 修复的照片清晰度有了巨大的提升，尽管仍有些模糊，但是对于照片的关键部分—人脸已经有了巨大的提升。可以看出后者非常像网红脸。

那么人工智能是如何修复照片的呢？那就是对大量人脸数据的特征进行提取。但是对这么大量的数据如何分析呢？

如上图，在电路中，该图是最简单的一个电路模型。其输出端 Y 的值即为输入端 Y 的值，其值有两种，0 和 1。因此，我们可以通俗的认为，0 代表否，1 代表是。因此，对于一个特征的有无，0 代表无，1 代表有。这样就可以用数字记录一个事物的特征。同样的，利用一串数组，可以记录一系列的特征。那么利用矩阵，就可以记录大量的特征。本报告将涉及数学概念中的“矩阵（Matrix）”。

4.4.1 2.1 矩阵

在数学中，矩阵（Matrix）是一个按照长方阵列排列的复数或实数集合 [1]，最早来自于方程组的系数及常数所构成的方阵。这一概念由 19 世纪英国数学家凯利首先提出。作为解决线性方程的工具，矩阵也有不短的历史。成书最早在东汉前期的《九章算术》中，用分离系数法表示线性方程组，得到了其增广矩阵。在消元过程中，

使用的把某行乘以某一非零实数、从某行中减去另一行等运算技巧，相当于矩阵的初等变换。但那时并没有现今理解的矩阵概念，虽然它与现有的矩阵形式上相同，但在当时只是作为线性方程组的标准表示与处理方式。

2.1.1 矩阵的起源

作为解决线性方程的工具，矩阵也有不短的历史。成书最迟在东汉前期的《九章算术》中，用分离系数法表示线性方程组，得到了其增广矩阵。在消元过程中，使用的把某行乘以某一非零实数、从某行中减去另一行等运算技巧，相当于矩阵的初等变换。但那时并没有现今理解的矩阵概念，虽然它与现有的矩阵形式上相同，但在当时只是作为线性方程组的标准表示与处理方式。矩阵正式作为数学中的研究对象出现，则是在行列式的研究发展起来后。逻辑上，矩阵的概念先于行列式，但在实际的历史上则恰好相反。日本数学家关孝和（1683年）与微积分的发现者之一戈特弗里德·威廉·莱布尼茨（1693年）近乎同时地独立建立了行列式论。其后行列式作为解线性方程组的工具逐步发展。1750年，加布里尔·克拉默发现了克莱姆法则。

矩阵最早出现在我国的九章算术中，在九章算术方程篇中，刘徽就给出过“方程”的定义，不过他所定义的方程，指的是由线性方程得到的数码矩阵，其本质就是线性方程组的增广矩阵，不仅如此，他还提出过解线性方程组的两种方法，即利用该方阵进行“直除”和“互乘”运算，“直除”就是将某行的同一倍数加到另一行上，“互乘”则是以一个不为零的数乘该方阵的某一行上，这里已经涉及到了矩阵初等变换的知识。

2.1.2 矩阵的发展 1801年，德国数学家高斯首次将线性方程的全部系数放在一起，并提出了高斯消元法（这种方法在今天的计算机解线性方程组的问题中仍在使用），给出了矩阵的雏形；1844年，德国数学家爱森斯坦首次讨论了变换（也就是今天的“矩阵”）的乘积，为此后的数学家打开了一条新路。1850年，英国数学家西尔维斯特首先使用矩阵一词；1858年，英国数学家凯莱发表《关于矩阵理论的研究报告》。他首先将矩阵作为一个独立的数学对象加以研究，并在这个主题上首先发表了一系列文章，因而被认为是矩阵论的创立者，他给出了现在通用的一系列定义，如两矩阵相等、零矩阵、单位矩阵、两矩阵的和、一个数与一个矩阵的数量积、两个矩阵的积、矩阵的逆、转置矩阵等，并且凯莱还注意到矩阵的乘法是可结合的，但一般不可交换，且 $m \times n$ 矩阵只能用 $n \times k$ 矩阵去右乘。1854年，法国数学家埃米尔特使用了“正交矩阵”这一术语，但他的正式定义直到1878年才由德国数学家费罗贝尼乌斯发表。1879年，费罗贝尼乌斯引入秩的概念。至此，矩阵的体系基本上完全建立起来了。

矩阵的现代概念在19世纪逐渐形成。1800年代，高斯和威廉·若尔当建立了高斯—若尔当消去法。1844年，德国数学家费迪南·艾森斯坦 (F.Eisenstein) 讨论了“变换”（矩阵）及其乘积。1850年，英国数学家詹姆斯·约瑟夫·西尔维斯特 (James Joseph Sylvester) 首先使用矩阵一词。英国数学家凯利被公认为矩阵论的奠基人。他开始将矩阵作为独立的数学对象研究时，许多与矩阵有关的性质已经在行列式的研究中被发现了，这也使得凯利认为矩阵的引进是十分自然的。他说：“我决然不是通过四元数而获得矩阵概念的；它或是直接从行列式的概念而来，或是作为一个表达线性方程组的方便方法而来的。”他从1858年开始，发表了《矩阵论的研究报告》等一系列关于矩阵的专门论文，研究了矩阵的运算律、矩阵的逆以及转置和特征多项式方程。凯利还提出了凯莱-哈密尔顿定理，并验证了 3×3 矩阵的情况，又说进一步的证明是不必要的。哈密尔顿证明了 4×4 矩阵的情况，而一般情况下的证明是德国数学家费罗贝尼乌斯 (F.G.Frohenius) 于1898年给出的。1854年时法国数学家埃米尔特 (C.Hermite) 使用了“正交矩阵”这一术语，但他的正式定义直到1878年才由费罗贝尼乌斯发表。1879年，费罗贝尼乌斯引入矩阵秩的概念。至此，矩阵的体系基本上建立起来了。无限维矩阵的研究始于1884年。庞加莱在两篇不严谨地使用了无限维矩阵和行列式理论的文章后开始了对这一方面的专门研究。1906年，希尔伯特引入无限二次型（相当于无限维矩阵）对积分方程进行研究，极大地促进了无限维矩阵的研究。在此基础上，施密茨、赫林格和特普利茨发展出算子理论，而无限维矩阵成为了研究函数空间算子的有力工具。

4.4.2 矩阵的应用现状

矩阵在机器学习和深度学习上面的应用，有以下几个。1. 在将数据集应用于机器学习模型之前，需要对数据集做预处理，比如给数据去噪、降维，这样子可以减少计算资源和提高模型预测准确度。常用的去噪降维的方法是主成分分析 (PCA)，里面就用到了矩阵，具体步骤为（1）求解数据集的协方差矩阵的特征值和特征向量，（2）根据特征值从大到小排序（3）选取前面几个特征值对应的特征向量作为新的坐标基向量。（4）将所有

的数据集映射到这个新的坐标系中，从而得到降噪降维之后的数据集了。在第（3）步中只选取前面最大的几个特征值所对应的特征向量，是因为小特征值所蕴含的信息量比较小，它们很可能是一些噪声数据。2. 另一个在机器学习中的应用是奇异值分解，奇异值分解的公式为 $M=U\Sigma V$ ，在 Netflix Prize 电影推荐系统中，根据用户对电影的评分来建模的推荐系统使用到了奇异值分解的思想。3. 在深度学习模型的框架中，数据是以矩阵的形式组织的，比如一次输入 64 张彩色图片，输入数据是 $64 \times 3 \times 32 \times 32$ 维度的。这样子一方面可以简化表示，另一方面可以提高计算速度，特别是 GPU 能够针对这个进行优化，如果不以矩阵的形式表示数据，那么 GPU 的优势就没发挥出来。

矩阵是人工智能基础范畴中不可或缺的一部分。必备的数学知识是理解人工智能不可或缺的要素，所有的人工智能技术归根到底都建立在数学模型之上，而这些数学模型又都离不开线性代数的理论框架。线性代数不仅仅是人工智能的基础，更是现代数学和以现代数学作为主要分析方法的众多学科的基础。从量子力学到图像处理都离不开向量和矩阵的使用。而在向量和矩阵背后，线性代数的核心意义在于提供了一种看待世界的抽象视角：万事万物都可以被抽象成某些特征的组合，并在由预置规则定义的框架之下以静态和动态的方式加以观察。线性代数是 AI 专家必须掌握的知识。线性代数是一套非常通用的思想和工具，可以应用于各个领域。如果你只想把人工智能和机器学习的工具当作一个黑匣子，那么你只需要足够的数学计算就可以确定你的问题是否符合模型使用。如果你想提出新想法，线性代数则是你必须要学习的东西。并不是说你需要学习有关数学的所有知识，这样会耽搁于此，失去研究其他更重要的东西（如微积分/统计）的动力。线性代数是应用数学领域，这是人工智能专家离不开的。如果你不精通这个领域，你永远不会成为一个好的 AI 专家。正如斯凯勒·斯皮克曼所说：“线性代数是 21 世纪的数学。”线性代数有助于产生新的想法，这就是为什么它是人工智能科学家和研究人员必须学习的东西。他们可以用标量、向量、张量、矩阵、集合和序列、拓扑、博弈论、图论、函数、线性变换、特征值和特征向量的概念来建立模型。向量矩阵理论在科幻电影中，你通常会看到，通过执行一些类似于神经系统的计算结构，产生了一个神经网络，它生成神经元之间的连接，以匹配人类大脑的推理方式。将矩阵的概念引入到神经网络的研究中神经网络可以通过形成三层人工神经元来实现非线性假设：1. 输入层 2. 隐藏层 3. 输出层特征向量搜索引擎排名的科学是建立在数学科学的基础上的。页面排名，这正是谷歌作为一家基于数学视角的公司的基础。页面排名是一种算法，最初由拉里·佩奇和谢尔盖·布林在他们的研究论文《大型超文本 Web 搜索引擎的剖析》中提出。在这一巨大突破的背后，使用了数百年来众所周知的特征值和特征向量的基本概念。机器人爬虫程序首先检索网页，然后通过分配页面排名值对其进行索引和编目。每个页面的可信度取决于该页面的链接数。

4.4.3 2.1.3 矩阵的基本操作

2.1.3.1 加减法

对应位置相加减。例如：需要注意的是，这两个矩阵必须行列数均相同。

2.1.3.2 矩阵数乘

矩阵的所有元素都乘上这个数即可。

2.1.3.3 矩阵乘法

两个矩阵的乘法仅当第一个矩阵 A 的列数和另一个矩阵 B 的行数相等时才能定义。如果矩阵 A 是 $m \times n$ 矩阵（ m 行 n 列），矩阵 B 是 $n \times k$ 矩阵（ n 行 k 列），则它们的乘积 C 是一个 $m \times k$ 矩阵。对于矩阵 C 的每个元素，它如下计算：容易看出，单位矩阵乘任何矩阵，不论左乘还是右乘，都不会改变矩阵。这在传统的线性代数教材中已经被证明很多次了，这里不再赘述。

2.1.3.4 矩阵转置

将每个元素的行数和列数互换即可。

2.1.3.5 共轭矩阵

共轭是复数域的概念，只是把矩阵中每个元素取其共轭的复数即可。

2.1.3.6 矩阵的特征值及特征向量

设 A 是 n 阶方阵，如果数 λ 和 n 维非零列向量 x 使关系式 $Ax=\lambda x$ 成立，那么这样的数 λ 称为矩阵 A 特征

值，非零向量 x 称为 A 的对应于特征值 λ 的特征向量。对于矩阵的特征值及特征向量，在传统线性代数教材中已经有了足够充分的解释，并对其性质和计算方法也有了足够多的介绍，这里不再赘述了。

矩阵的特征值和特征向量可以揭示线性变换的深层特性，我们稍后会展开介绍其具体应用，并简述其实现原理。

2.1.3.7 线性变换

在数学上，如果满足下式，那么映射 $F(a)$ 就是线性的：

$$F(a + b) = F(a) + F(b) \text{ 以及 } F(ka) = kF(a)$$

如果映射 F 保持了基本运算：加法和数量乘，那么就可以称该映射为线性的。在这种情况下，将两个向量相加然后再进行变换得到的结果和先分别进行变换再将变换后的向量相加得到的结果相同。同样，将一个向量数量乘再进行变换和先进行变换再数量乘的结果也是一样的。

这个线性变换的定义有两条重要的引理：

(1) 映射 $F(a) = aM$ ，当 M 为任意方阵时，此映射是一个线性变换，这是因为： $F(a + b) = (a + b)M = aM + bM = F(a) + F(b)$ $F(ka) = (ka)M = k(aM) = kF(a)$

(2) 零向量的任意线性变换的结果仍然是零向量。（如果 $F(0) = a$ ， $a \neq 0$ 。那么 F 不可能是线性变换。因为 $F(k0) = a$ ，但 $F(k0) \neq kF(0)$ ，因此线性变换不会导致平移（原点位置上不会变化）。

2.1.3.8 矩阵的仿射变换

仿射变换是指线性变换后接着平移。因此仿射变换的集合是线性变换的超集，任何线性变换都是仿射变换，但不是所有仿射变换都是线性变换。

任何具有形式 $v' = vM + b$ 的变换都是仿射变换。

2.1.3.9 矩阵的可逆变换如果存在一个逆变换可以“撤销”原变换，那么该变换是可逆的。换句话说，如果存在逆变换 G ，使得 $G(F(a)) = a$ ，对于任意 a ，映射 $F(a)$ 是可逆的。

存在非仿射变换的可逆变换，但暂不考虑它们。现在，我们集中精力于检测一个仿射变换是否可逆。一个仿射变换就是一个线性变换加上平移，显然，可以用相反的量“撤销”“平移部分”，所以问题变为一个线性变换是否可逆。

显然，除了投影以外，其他变换都能“撤销”。当物体被投影时，某一维有用的信息被抛弃了，而这些信息时不可能恢复的。因此，所有基本变换除了投影都是可逆的。因为任意线性变换都能表达为矩阵，所以求逆变换等价于求矩阵的逆。如果矩阵是奇异的，则变换不可逆；可逆矩阵的行列式不为 0。

2.1.3.10 矩阵的等角变换

如果变换前后两向量夹角的大小和方向都不改变，该变换是等角的。只有平移，旋转和均匀缩放是等角变换。等角变换将会保持比例不变，镜像并不是等角变换，因为尽管两向量夹角的大小不变，但夹角的方向改变了。所有等角变换都是仿射和可逆的。

2.1.3.11 矩阵的正交变换

术语“正交”用来描述具有某种性质的矩阵。正交变换的基本思想是轴保持互相垂直，而且不进行缩放变换。平移、旋转和镜像仅是仅有的正交变换。长度、角度、面积和体积都保持不变。（尽管如此，但因为镜像变换被认为是正交变换，所以一定要密切注意角度、面积和体积的准确定义）。正交矩阵的行列式为 1 或者负 1，所有正交矩阵都是仿射和可逆的。

2.2 传统图像处理

2.2.1 基础知识——图像矩阵化

2.2.1.1 灰度 [9][10][11] 在电子计算机领域中，灰度（Gray scale）数字图像是每个像素只有一个采样颜色的图像。这类图像通常显示为从最暗黑色到最亮的白色的灰度，尽管理论上这个采样可以是任何颜色的不同深浅，甚至可以是不同亮度上的不同颜色。灰度图像与黑白图像不同，在计算机图像领域中黑白图像只有黑白两种颜色，灰度图像在黑色与白色之间还有许多级的颜色深度。但是，在数字图像领域之外，“黑白图像”也表示“灰度图像”，例如灰度的照片通常叫做“黑白照片”。在一些关于数字图像的文章中单色图像等同于灰度图像，在另外一些文章中又等同于黑白图像。[12]

图 2.2.1.1.1 原始彩色图片与灰度图

灰度图像经常是在单个电磁波频谱如可见光内测量每个像素的亮度得到的。用于显示的灰度图像通常用每个采样像素 8 bits 的非线性尺度来保存，这样可以有 256 种灰度 (8bits 就是 2 的 8 次方 =256)。这种精度刚刚能够避免可见的条带有损，并且非常易于编程。在医学图像与遥感图像这些技术应用中经常采用更多的级数以充分利用每个采样 10 或 12 bits 的传感器精度，并且避免计算时的近似误差。在这样的应用领域流行使用 16 bits 即 65536 个组合 (或 65536 种颜色)。[12][13]

2.2.1.2 RGB 颜色系统 [7] 三原色光模式 (RGB color model)，又称 RGB 颜色模型或红绿蓝颜色模型，是一种加色模型，将红 (Red)、绿 (Green)、蓝 (Blue) 三原色的色光以不同的比例相加，以合成产生各种色彩光。RGB 颜色模型的主要目的是在电子系统中检测，表示和显示图像，比如电视和电脑，利用大脑强制视觉生理模糊化 (失焦)，将红绿蓝三原色子像素合成为一色彩像素，产生感知色彩 (其实此真彩色并非加色法所产生的合成色彩，原因为该三原色光从来没有重叠在一起，只是人类为了“想”看到色彩，大脑强制眼睛失焦而形成。红绿蓝三色模型在传统摄影中也有应用。在电子时代之前，基于人类对颜色的感知，RGB 颜色模型已经有了坚实的理论支撑。RGB 是一种依赖于设备的颜色空间：不同设备对特定 RGB 值的检测和重现都不一样，因为颜色物质 (荧光剂或者染料) 和它们对红、绿和蓝的单独响应水平随着制造商的不同而不同，甚至是同样的设备不同的时间也不同。[7]

图 2.2.1.1.1 RGB 颜色空间示意图

一个颜色显示的描述是由三个数值控制的，他分别为 R、G、B。当三个数值为最大 (255) 时，显示为白色，当三个数值最小 (0) 时，显示为黑色。数值表示可以使用以下几种不同的方式：从 0 到 1 之间可用的浮点数来表示、从 0 % 到 100 % 用百分比表示，或者使用 0 到 255 之间的整数以八位数字表示，通常表示为十进制和十六进制的数值。[7]

2.2.1.3 Gamma 校正 [8][11]

伽马校正 (Gamma correction) 又叫伽马非线性化 (gamma nonlinearity)、伽马编码 (gamma encoding) 或是就只单纯叫伽马 (gamma)。是用来针对影片或是影像系统里对于光线的辉度 (luminance) 或是三色刺激值 (tristimulus values) 所进行非线性的运算或反运算。最简单的例子中，伽马校正是由下幂定律公式所定义的： $V_{out} = AV_i^n$

其中 A 是一个常量，输入和输出的值都为非负实数值。一般地来说在 A=1 的通常情况下，输入输出的值的范围都是在 0 到 1 之间。伽马值 $\gamma < 1$ 的情况有时被称作编码伽马值 (encoding gamma)，而执行这个编码运算所使用上述幂定律的过程也叫做伽马压缩 (gamma compression)；相对地，伽马值 $\gamma > 1$ 的情况有时也被称作解码伽马值 (decoding gamma)，而执行这个解码运算所使用上述幂定律的过程也叫做“伽马展开 (gamma expansion)”。[8][11]

RGB 值与功率并非简单的线性关系，而是幂函数关系，这个函数的指数称为 Gamma 值，一般为 2.2，而这个换算过程，称为 Gamma 校正。为什么显示器要 Gamma 校正呢？因为人眼对亮度的感知和物理功率不是成正比的，而是幂函数的关系，这个函数的指数通常为 2.2，称为 Gamma 值。所以 RGB 中的灰度值，为了考虑到较小的存储范围 (0 255) 和较平衡的亮暗部比例，所以需要进行 Gamma 校正，而不是直接对应功率值，因此 RGB 值 RGB 颜色值不能简单直接相加，而是必须用 2.2 次方换算成物理光功率后才能进行下一步计算。

由于 Gamma 校正，在计算机显示设备上的颜色输出的强度通常不是直接正比于在图像文件中 R、G 和 B 值。就是说，即使值 0.5 非常接近于 0 到 1.0 (完全强度) 的一半，计算机显示器在显示 (0.5, 0.5, 0.5) 时候的光强度通常 (在标准 2.2-gamma CRT/LCD 上) 是在显示 (1.0, 1.0, 1.0) 时候的大约 22 %，而不是 50 %。

图 2.2.1.3.1 Gamma 校正

为图像进行伽马编码的目的是用来对人类视觉的特性进行补偿，从而根据人类对光线或者黑白的感知，最大化地利用表示黑白的数据位或带宽。在通常的照明 (既不是漆黑一片，也不是令人目眩的明亮) 的情况下，人类的视觉大体有伽马或者是幂函数的性质。如果不将图像进行伽马编码，那么数据位或者带宽的利用就会分布不均匀——会有过多的数据位或者带宽用来表示人类根本无法察觉到的差异，而用于表示人类非常敏感的视觉感知范围的数据位或者带宽又会不足。图像的伽马编码并不是必须的 (甚至有的时候会适得其反)，浮点数字格式的颜色值已经提供了一部分对数曲线的线性估计。[8][11]

2.2.1.4 图像的数字 (矩阵) 化

位图 [14][15] (英语: Bitmap, 台湾称为点阵图)，又称栅格图 (Raster graphics)，是使用像素阵列 (Pixel-

array/Dot-matrix 点阵) 来表示的图像。我们这篇课题所涉及的图像, 都是在指位图, 而不是矢量图。我们先来考虑灰度图在 OpenCV 中如何存储。OpenCV 是一个跨平台计算机视觉和机器学习软件库, 我们稍后会介绍它。这里我们会用简单的代码来读取一个图片并观察它的输出结果, 来推断出图像是如何数字化的。

C++ 代码以及我们需要读取的 “1.jpg” 图片:

“1.jpg” 图片 (一个方格示意为一个像素) 输出结果是:

事实上, 这也就是矩阵:

结合我们上面介绍过的 RGB 与灰度的知识, 不难发现出: 由于灰度仅由一个大小为 0 255 的八位无符号整数表示, 所以每个像素点只需要用一个数来表示就可以了 (黑色的灰度是 0, 白色的灰度是 255)。

接下来, 我们再来考虑 RGB 色彩系统下的彩色图像的数字 (矩阵) 化。

C++ 代码以及我们需要读取的 “1.jpg” 图片:

“1.jpg” 图片 (一个方格示意为一个像素) 输出结果是:

事实上, 这也就是矩阵:

我们在 “1.jpg” 中预设的三种颜色都是三原色, 也就是: 以 (R,G,B) 三元组表示一个颜色的话, 红色为 (255,0,0), 绿色为 (0,255,0), 蓝色为 (0,0,255)。

而观察我们的矩阵, 这是一个 3x3 像素的图像, 而这个矩阵却是一个 3x9 矩阵, 结合我们上面介绍的 RGB 颜色系统, 可以得知一个颜色被三个矩阵元素表示, 且这三个元素分别就是 RGB 三个值中的某个值。

然而, 我们图像中第一行的颜色顺序为 “红-蓝-红”, 按照 (R,G,B) 三元组表示, 它们应该为 “(255,0,0) - (0,0,255) - (255,0,0)”, 然而矩阵中却是 “(0,0,255) - (255,0,0) - (0,0,255)”, 这说明实际在 OpenCV 中存储时的顺序为 (B,G,R)。

到这里为止, 所有的位图都可以如上数字化了。在 RGB 颜色系统中, 我们还可以分析一个图像中各原色通道的占比, 并用灰度图输出表示:

例如, 上图橙子果肉的颜色用 (R,G,B) 三元组表示大概为 (168,102,0), 在 red 通道图中它最明亮, 在 green 通道图中其次, 在 blue 通道图中最暗。在灰度中, 255 为白色, 0 为黑色, 这表示出了图像中各个位置的原色比例。

2.2.2 传统图像处理的起源 [1]

数字图像处理, 是现代信息处理形式的代表, 具有画面处理程序一体化、图像处理清晰度高等特性。较之传统的图像处理, 如胶片剪辑、胶片冲洗等, 数字图像处理利用计算机对图像进行加工与处理, 满足了图片数字化、可数码操作的需要。1921 年 [1], 人们通过海底电缆将图像由伦敦传输至纽约, 标志着数字图像处理系统的诞生。首个数字图像处理系统名为 “巴特兰” (Bartlane), 该系统使用 5 个不同的灰度级来编码图像。而到了 1929 年, “巴特兰” 编码图像的这一能力已经扩展到了 15 级。

图 2.2.1 1921 年经 “巴特兰” 系统处理的数字图片

图 2.2.2 1929 年经 “巴特兰” 系统处理的数字图片

20 世纪 50 年代, 人们开始对数字图像处理技术进行系统的研究。1964 年, 美国加州的喷气推进实验室使用数字计算机处理了 “徘徊者 7 号” 月球探测器发回的宇宙照片。

图 2.2.3 “徘徊者 7 号” 月球探测器该事件为数字图像处理的一个重要里程碑, 标志着第三代计算机问世后数字图像处理概念开始得到运用。此后数字图像处理技术发展迅速并于不久之后形成一门独立的学科, 初步建立了起来。

图 2.2.4 “徘徊者 7 号” 月球探测器传回的照片

2.2.3 传统图像处理的发展

在数字图像处理成为一门独立的学科之后的三四十年, 随着各领域对图像处理的要求越来越高, 数字图像处理技术得到了更加深入、广泛和迅速的发展。国内外学者在图像处理的各个方面取得了令人瞩目的成果……

伴随着数字图像处理的不断发展 [2], 各种处理技术层出不穷如图像数字化、图像变换、图像增强、图像恢复、图像数据压缩、图像边缘检测、图像分割、图像特征分析、图像配准、图像融合、图像分类、图像识别、基于内容的图像检索、图像数字水印等……

下面将为大家以传统数字图像处理技术中的图像的增强、图像的滤波、图像的边缘检测的典型算法为例，为大家展示下数字图像处理技术的魅力。

2.2.3.1 图像增强算法 [2]

图像增强算法用于增强对所需信息的辨别能力但同时也可能损失一些其他信息。因此在实际的应用中要对图像进行多种变换，然后再从中选取效果较好的一个。下面我们将以图像增强算法中的灰度变换为例来解释说明图像增强的一种实现。

图 2.2.5 利用图像增强算法突出水中鱼类

灰度变换：灰度变换是指根据某种目标条件来确立变换关系逐然后逐点改变图像中每一个像素的灰度值。[3] 让我们假设原图像像素的灰度值 $D=f(x,y)$ ，处理后图像像素的灰度值记为 $I'(x,y)$ ，则灰度增强可表示为： $D' = T(D)$ 其中 D 和 D' 都在图像的灰度范围之内。函数 $T(D)$ 称为灰度变换函数，它描述了输入灰度值和输出灰度值之间的转换关系。当我们确定了灰度变换函数后，一个具体的灰度增强方法便确立了。根据 $T(D)$ 表达式的不同将灰度变换分为线性变换和非线性变换。其中的线性变换如下所示：若 $g(x,y) = T[f(x,y)]$ 是一个线性或分段线性的单值函数例如：对某个定义域内的灰度 $g(x,y)=T[f(x,y)] = a*f(x,y)+b$ ，则由它确定的灰度变换称为灰度线性变换简称线性变换。式中参数 a 为线性函数的斜率 b 为线性函数的在 y 轴的截距。

线性灰度变换具有算法较易实现，使用方便等特性。但是其可扩展性较差。

一般地，我们更多会使用非线性灰度变换。

图 2.2.6 对钙化点的医学影像使用线性灰度变换处理前后对比图

相对线性变换，当映射关系为非线性函数时，该变换显然为非线性变换。常用的非线性变换有对数变换和指数变换。其中的对数变换如右所示： $g(x,y) = c*\ln[f(x,y)+1]$ 公式中的 c 是为了调整曲线的位置和形状而引入的参数。由于对数函数的自身特性，当我们想要对图像的低灰度区进行较大的扩展而对高灰度区进行压缩时可采取此变换。此处的灰度对数变换能使图像灰度分布与人的视觉特性相匹配。其中的指数变换如右所示： $g(x,y) = b*c*[f(x,y)-a]^1$ 公式中 a 、 b 、 c 是为了调整曲线的位置和形状。由于指数函数的特性，故该变换能对图像的高灰度区域给予较大的扩展。

综上，我们可以得出，当我们关注的灰度区不同时，我们可以选用不同的灰度变换来达到理想的效果。

图 2.2.7 对钙化点的医学影像使用非线性灰度变换处理前后对比图

2.2.3.2 图像滤波算法

众所周知，由于外部或内部的各种原因，数字图像不可避免地会有一些噪声 [4]，如拍摄图片时光照不足会产生噪点，扫描图片时我们也无法得到百分之百不含杂质的图像。这便对后续的图像处理造成了影响。因此，图像去噪是数字图像处理工作中一个必不可少的部分，对于后续的各项其他处理都有重要意义。应用图像滤波算法去噪已被应用于各项研究，涉及到了医疗勘探、雷达、文字等方面。发展至今，优化滤波算法，改进滤波算法的设计仍具有重要的意义。下面我们将以滤波算法中的中值滤波为例来说明图像滤波算法的一种实现。

图 2.2.8 利用一种图像滤波算法来去除桥梁探伤图片的噪声常规中值滤波：不同于均值滤波中对像素矩阵中 (x,y) 邻域进行平均化的处理，中值滤波是一种非线性的处理方法。[5] 常规中值滤波首先用 3×3 大小的滑动窗口在彩色图像上自左向右、自上向下移动，设 S_{xy} 代表以点 (x,y) 为中心、大小是 3×3 的矩形图像邻域像素值（窗口）的一组坐标：

再对 S_{xy} 中 9 个点的像素值 (R,G,B) 分别进行排序，一般使用冒泡排序法，得到三个序列 R_{ij}, G_{ij}, B_{ij} ，以 R_{ij} 为例：

其中， $f_1 \leq f_2 \leq f_3 \leq \dots \leq f_9$ 。之后，使用序列 R_{ij} 的中间值替代原窗口中心点 (x,y) 的 R 值 $f(x,y)$ 。G 值、B 值操作过程相同，分别对 (R,G,B) 值完成滤波处理后，点 (x,y) 处的中值滤波处理完成，窗口移动到下一个像素点。

图 2.2.9 常规中值滤波算法流程图

图 2.2.10 利用常规中值滤波算法对加入脉冲噪声后的 Lena 图像处理前后对比图通过对比图可以看到，常规中值滤波算法处理后虽然去除了大部分噪声但是同时也损失了不少图像细节，如 Lena 图中其脸颊和肩膀部分都损失了较多细节，通俗来说，图像某些部分变得较为模糊，仍有很大的改进空间。自适应中值滤波：自适应中值滤波算法是常规中值滤波算法的改进算法，在进行中值滤波处理之前，它会先判断采样点是否是噪声点，如果是噪声点，则进行滤波处理，如果不是噪声，则跳过当前采样点，移动到下一个采样点。和常规中值滤波算法的

前半部分相同。(右图为自适应中值滤波算法流程图)首先用 3×3 大小的滑动窗口在彩色图像上自左向右、自上向下移动, 设 S_{xy} 代表以点 (x,y) 为中心、大小是 3×3 的矩形图像邻域像素值(窗口)的一组坐标:

再对 S_{xy} 中 9 个点的像素值 (R,G,B) 分别进行排序, 一般使用冒泡排序法, 得到三个序列 R_{ij}, G_{ij}, B_{ij} , 以 R_{ij} 为例:

其中, $f_1 \leq f_2 \leq f_3 \leq \dots \leq f_9$ 。当排序后, 中心点 (x,y) 的 R 值 $f(x,y)$ 位于向量 R_{ij} (已排序) 的两端时, 中心点 (x,y) 可能是一个噪声点。如果它同时满足 $f(x,y) \leq T_{min}$ 或 $f(x,y) \geq T_{max}$, 则中心点 (x,y) 判定为噪声点。参数 T_{min} 和 T_{max} 根据情况设定, 一般 T_{min} 取 40, T_{max} 取 190 比较合适。判定为噪声后, 使用序列 R_{ij} 的中间值 f_5 替代原窗口中心点 (x,y) 的值 $f(x,y)$, 完成点 (x,y) 处的中值滤波处理, 然后, 窗口移动到下一个像素点, 如此循环操作。可以看到自适应中值滤波算法在去除噪声的同时, 图像细节损失较少。在大多数情况下, 自适应中值滤波算法的处理效果是要优于常规中值滤波的。

图 2.2.11 利用自适应中值滤波算法对加入脉冲噪声后的 Lena 图像处理前后对比图

图 2.2.12 自适应中值滤波算法流程图

2.2.3.3 图像边缘检测算法图像边缘是图像的基本特征之一, 它包含对人类视觉和机器视觉有价值的物体图像信息。例如在利用计算机锐化图像时便有效利用了图像的边缘信息。图像边缘检测算法是图像处理领域中一种重要的预处理技术, 其广泛地应用于轮廓、特征的抽取和纹理分析等领域。(而其中较晚出现的)Canny 边缘检测算法是针对局部区域或整幅图像确定一个门限 [6], 对图像进行分割, 从而提取出边缘, 下面我们将以 Canny 算法为例来说明图像边缘检测算法的一种实现。

图 2.2.12 应用一种边缘检测算法检测 Lena 图像 Canny 边缘检测算法: Canny 边缘检测算法总共有四个步骤, 分别是: I. 采用高斯滤波的方法对原始图像作平滑处理 II. 梯度幅值与方向的计算 III. 对梯度幅值的非极大值抑制 IV. 双阈值检测和连接边缘。I. 采用高斯滤波的方法对原始图像作平滑处理:

高斯函数如上所示其中, 其中 σ 为高斯滤波的参数, σ 的选择会直接影响滤波效果。图像平滑化的处理步骤如下: (1) 设置一个模板, 在该模板内, 求出所有像素灰度的加权平均值; (2) 将该值赋给该模版中心像素点的灰度值; (3) 按照同样的方法, 扫描图像中的每个像素点, 再进行加权平均计算。II. 梯度幅值与方向的计算: 首先, 对每个像素点求偏导数

再利用下面两个公式得到像素的梯度幅值 $M(i,j)$ 和方向 $\theta(i,j)$ 。

III. 对梯度幅值的非极大值抑制: 由于梯度幅值的极大值附近会产生屋脊带, 故非极大值抑制的原理是通过细化幅值图中的屋脊带, 更好地确定边缘的位置非极大值抑制过程为, 将梯度幅值矩阵 $M(i,j)$ 内的每一个点都作为中心像素点, 与其周围 8 个方向邻域中沿该中心点梯度方向上的两个邻域的梯度幅值进行比较。若中心像素点的幅值小于这两个方向上邻域的梯度幅值, 则该中心像素点边缘标志位的值为 0。经过非极大值抑制, 不仅用一个像素的宽度替代了梯度幅值矩阵的屋脊带宽度, 还保留了屋脊的梯度幅值。经过上述三个步骤的处理后, 我们已经得到了一个边缘检测的粗粒度结果, 其包含有较多的伪边缘。故仍需要进一步处理。IV. 双阈值检测和连接边缘: (1) 设定两个阈值, 即一个高阈值、一个低阈值, 将梯度幅值小于低阈值的像素点所对应的灰度值视为 0; (2) 将低阈值提取出的图像设为 A, 将梯度幅值大于高阈值的图像设为 B, 由于 A 为通过低阈值提取得到的图像, 故边缘的连续性较好, 但会含有较多的伪边缘, B 为梯度幅值大于高阈值的图像, 故其不包含伪边缘, 但是其边缘的连续性不佳; (3) 以图像 B 为基础, 图像 A 为补充, 通过递归追踪法获得边缘信息。至此, Canny 算法的处理步骤便完成了。

图 2.2.13 利用 Canny 算法对两幅图片进行边缘检测的结果

2.2.3.4 传统图像处理算法存在的缺陷

在上述的种种算法中无论是灰度变换中性或是非线性变换中公式参数的选择还是自适应中值滤波算法中 T_{max} 和 T_{min} 的选择抑或是 Canny 边缘检测算法中双阈值的选择都具有一定的主观性。相应地, 根据主观选择的不同, 所导出的结果并不相同。倘若数值选择不当, 则有可能会有一个糟糕的实现表现。那么, 怎样去选择这些数值, 怎样根据不同的实际情况去调换数值便是一个值得考虑的问题, 如果一味地按照固定的参数去应用, 结果可能并不尽如人意。’

2.2.4 传统图像处理的应用

随着数字图像处理技术的不断发展, 目前, 数字图像处理的应用越来越广泛, 它已经与诸多领域如遥感、公

共安全、工业检测、医疗诊断、军事等深度融合，下面我们将举例说明传统图像处理的应用。遥感：如探索者月球图像、勇气号火星图像、再如农作物产量计算、农作物病情防治、山林防火防灾等

图 2.2.4.1 火星外表面图像传回公共安全如：银行防盗、“天网工程”，极大保障了公民的财产和人生安全。工业检测如：上文在滤波算法提到的桥梁探伤、或是道路网裂、龟裂等公路路面破损图像识别。医疗诊断如：上文在 Canny 边缘识别算法中提到的细胞显微成像边缘识别、又如 CT 技术、癌细胞识别、钙化点识别等总结：传统图像处理自六十年代诞生以来，经过五十余年的不断发展，业已形成一门庞大的知识体系。其中包含了诸多算法如图像数字化、图像变换、图像增强、图像恢复、图像数据压缩、图像边缘检测、图像分割、图像特征分析、图像配准、图像融合、图像分类、图像识别、基于内容的图像检索、图形数字水印……，其广泛地应用于各种场景如地理信息科学、摄影摄像技术、航空航天、医学领域等，推动了现今社会的进步和发展。但同时，我们也应该注意到虽然传统数字图像处理可以解决诸多问题，然算法中参数的选择仍然依赖工程师的主观判断，可移植性仍有较大的进步空间。而人工智能思维的出现或许能够填补这一漏洞，使数字图像处理技术得到进一步发展。

2.3 深度学习基础——三种模型

2.3.1 起源

随着第一台电子计算机的问世，人工智能技术的发展拉开序幕。人工智能研究者基于对“智能”的不同理解，逐渐形成了符号主义、联结主义以及行为主义三大流派 [17]。其中，人工神经网络 [18] 是连接主义的代表模型，它通过模拟生物神经网络及其机制，形成了由大量神经元通过互相连接作用形成的网络系统。从上世纪 40 年代的 M-P 神经元和 Hebb 学习准则，到 50 年代的感知器模型，再到 60 年代的自组织映射网络，许多神经计算模型都发展成信号处理、机器视觉、自然语言处理等领域的经典方法 [19]。然而，由于当时该方法的不完备性，对深层神经网络的研究曾一度消弭 [21][22]。2006 年，Hinton 指出具有隐藏层的网络具有优异的特征学习能力，提出了一种面向复杂通用学习任务的深层神经网络。自此，崭新的神经网络研究时代开启，深度学习的概念开始被提出。

2.3.2 单层感知器模型

自从 Cajal 开创了神经元学说以来，许多神经元传递信号的方式在被逐渐发现。下图为一个简化的神经元模型：

图 2.3.1 简化的神经元模型

神经元在无信号输入时保持抑制状态。而当树突和胞体接受的兴奋电位总和超过某个阈值时，它会进入兴奋状态，并经由轴突发出脉冲，刺激其他神经元。而神经元的 M-P 模型 [6] 正是经由这个原理而提出，如下图所示：

图 2.3.2 M-P 模型

图中的 $x_1, x_2, \dots, x_n$ 表示其他相连的神经元传递的输入信号， w_{ij} 代表每个输入信号的权值， f 称为激励函数， y_j 表示当前神经元的输出，那么可以得到表达式：其中 b_j 代表使该神经元激活所需要的阈值。这种通过逻辑角度来描述神经元的方法，为神经网络的理论研究开辟了道路。

2.3.3 多层感知器模型

单层感知机虽然在某些问题上有效，但是并不能解决诸如线性不可分问题等多种问题 [23]。因此，多层感知机的概念产生：它的结构由输入层、隐藏层及输出层构成。下图是一个多层感知器的结构图：

图 2.3.3 多层感知机结构图

注意到，这里每两层之间的任意神经元都与另一层的所有神经元相连接。与单层感知器模型相同，每个输入信号都有一个对应的连接权值，而每一个神经元的输入为前一层所有神经元的输出的加权和。假设 x_m^l 代表着第 l 层第 m 个神经元的输入值， y_m^l 和 b_m^l 分别为该神经元的输出值和偏置值， $w_{im}^{(l-1)}$ 代表该神经元与第 $l-1$ 层第 i 个神经元的连接权值，那么有： $y_m^l = f(x_m^l)$

虽然多层感知器模型解决了单层感知器的缺陷，但是却带来了新的问题，如下图所示，如果需要处理一个 1000×1000 像素的 3 通道 RGB 图片，即使在隐藏层只设置了 1000 个结点，那么待处理的参数也是多达 $1e9$ 的量级。这仅仅只是一层，如果需要得到拟合度高的网络，那么待处理的节点个数将是一个天文数字。同时，这么多参数也可能会带来过拟合的问题。因此，亟需一个新的模型来克服这一缺陷。

2.3.4 卷积神经网络模型

2.3.4.1 感受野

1962年，科学家发现在视觉皮层中存在一系列构造复杂的细胞，它们只能识别到视觉输入空间的局部区域，因此被称为“感受野”[25]。下图为一个感受野模式图：

图 2.3.4 感受野模式图图中最上方的小圆圈就代表着众多感受野，光感受器将得到的信息整合并传递到神经元中，最后再经过进一步处理传到大脑。在识别图片时，这些细胞首先捕捉图片的边缘和轮廓，然后将其整合成一些完整的校组件，最后再将这些小部分最终整合成待识别的对象。下图为人脸识别上的一个例子：

图 2.3.5 感受野

2.3.4.2 边缘提取 [26]

上文在提及感受野时，描述了这些细胞会首先捕捉图片的边缘。那么基于这种边缘提取的思想，也同样被运用到了神经网络中。以提取水平和垂直的信息为例，如下图所示：

图 2.3.6 边缘提取

由于图像可以用多个矩阵来表示，因此期望能用一种矩阵运算实现上图的提取效果，这便引入了“卷积”这一概念。首先，卷积操作定义为对图像矩阵和滤波矩阵做多次内积，如下图所示：

图 2.3.7 卷积图 2.3.8 滤波矩阵

内积指的是两矩阵对应元素相乘，并将其求和放在结果矩阵的相应位置上。在提取运算过程中，图中的卷积核（即 filter）从左到右，从上到下移动过整个图像矩阵，每移动一步分别计算原图中被卷积核覆盖的部分与卷积核的内积。右图中的这个 6×6 的图像矩阵有一个明显的垂直边缘，那么经过与图中所示的卷积核作卷积运算，在最终结果 4×4 的矩阵中，确实提取到了这个垂直边缘，读者可自行模拟这个运算过程。

2.3.4.3 卷积层 [26]

以上介绍了感受野和边缘检测的概念，通过运用这些思想，卷积神经网络 (Conventional Neural Network, CNN) 就模仿了大脑识别图像的这一过程。

首先，卷积神经网络的第一层被称为卷积层，与上述介绍的操作相对应。它的目的是为了提取输入的不同特征，前文中提到的垂直边缘只是众多需要被提取的特征之一。当然，正如大脑中视觉细胞的提取结构，某些卷积层只提取一些诸如边缘和线条等较低级的特征，更高层的网络能从低级特征中进一步提取更复杂的特征。在如此多层的提取中，提取到的特征矩阵会越来越小，这会带来边缘信息丢失等问题，举例来说：

图 2.3.9 边缘信息丢失

如图为一个 5×5 的单通道图片，通常使用一个 3×3 大小的卷积核运算得到一个 3×3 大小的运算结果。如果重复这样的操作多次，那么图像的大小最后可能变成了 1×1 ，而 1×1 的图像毫无特征可言，这并不是我们期望得到的结果。于是接下来引入了零填充的概念：零填充操作非常简单，在每次卷积结束后，在图像最外层加上若干层 0 值。注意到，由于 0 在内积运算中对结果不会造成影响，因此不会对图片增加额外的干扰信息。零填充操作如下图所示：

图 2.3.10 零填充除此以外，卷积层中还有步长、多卷积核以及参数计算公式等内容，虽然其概念和计算并不复杂，但都过于细节，不在此作详细阐述。2.3.4.4 池化层

其次，经过卷积层提取后的特征图数量可能仍然很大，此时需要下采样，即池化操作。目的有二，其一如上文所述是为了减少特征图数，其二还可以提高特征图的鲁棒性，防止过拟合。通常在卷积层后增加一个池化层，一般通过取区域最值、平均值的方法进行采样。最常见的池化层是规模为 2×2 ，步幅为 2，对输入的每个深度切片进行下采样。每个操作对四个数进行，下图所示为一个最大值池化：

图 2.3.11 池化

值得注意的是，池化操作不需要进行学习，也不像卷积需要通过梯度下降进行更新。

2.3.4.5 全连接层

卷积层 + 池化层可以统一看成 CNN 的特征提取层，那么在提取完以后，最终将学习到的特征应用于模型需要的任务。这一层的操作主要有两步：第一步将所有的特征图进行扁平化（变为 $1 \times N$ 的向量），第二步再接一个或多个全连接层，进行模型的学习。下图中的 Fully connection 部分即为全连接层：

图 2.3.12 全连接层

2.3.4.6 CNN 小结

下图为卷积神经网络训练的基本结构。与传统机器学习方法相比，CNN 的权值共享思想使得网络中需要训练的参数变少，降低复杂度的同时，减少了过拟合，更易于训练。到此，对神经网络基础的介绍结束，下一节将结合图像处理中的一个具体方向——目标检测，进一步介绍神经网络在图像处理方向上的发展史。

图 2.3.13 卷积神经网络训练的基本结构

上图为卷积神经网络训练的基本结构。与传统机器学习方法相比，CNN 的权值共享思想使得网络中需要训练的参数变少，降低复杂度的同时，减少了过拟合，更易于训练。到此，对神经网络基础的介绍结束，下一节将结合图像处理中的一个具体方向——目标检测，进一步介绍神经网络在图像处理方向上的发展史。

2.3.2 深度学习图像处理的发展——以目标检测为例 [26][27][28][29]

2.4.1 起源

ImageNet Large Scale Visual Recognition Challenge (ILSVRC) 是 2010 年到 2017 年间举办的机器视觉领域最受追捧且最具权威的学术竞赛之一。在图像分类这个竞赛分支中，2010 年与 2011 年的获胜团队使用了传统的图像分类算法，最低取得了 28.2 % 的错误率。而 2012 年的获胜团队首次将深度学习用于大规模图像分类，使得其错误率比亚军低了 10 %。从这一年开始，深度学习方法在图像领域开始被广泛采用，新的模型的涌现不断降低错误率，而大规模数据集的出现更使其得到了充分的训练。接下来本文会从目标检测方面更详细的介绍其发展。

2.4.2 R-CNN

物体检测相比于图像分类要来的更加复杂，因为我们需要对一张图像中可能含有的多个不同种类的物体进行定位和识别。2012 年深度学习所取得的成功也同样影响到了物体检测的领域，Girshick 等开始目标检测中运用卷积神经网络，提出了 R-CNN 模型。在介绍 R-CNN 之前，我们先简单介绍一下目标检测的滑动窗口方法。它的核心思想就是从左到右，从上到下地滑动窗口，利用分类识别目标。如下图所示：

图 2.4.1 滑动窗口

但是这样的思想存在一个问题：如左图所示，识别人的窗口需要一个竖长方形窗口。但是如果把这个窗口平移到右边，试图用它来识别车辆，但是由于车辆的宽度大于长度，能符合这个窗口的概率不大。同样，如果用右图中识别车辆的横长方形识别人，也同样不成功。因此需要提前设计好多个可能会用到的窗口大小，每种窗口都滑动提取数张图片。提取成功后，将其输入 CNN 分类器中完成后续操作。可以发现，这是一种暴力式的操作，不仅会消耗大量的计算力量，由于人为设定的窗口大小大概率不准，因此其识别率也不高。这种思想的意义在于提供了一种解决目标检测问题的思路。

R-CNN 模型框架如下图所示，它与上述方法不同，不使用暴力方法，而是用候选区域方法，改变了目标检测的模型思路。R-CNN 模型在当时以优异的性能令世人瞩目。后续的 SPPNet、Fast R-CNN、Faster R-CNN 都是在此基础上加以改进的。

图 2.4.2 R-CNN 示意图

具体来说，第一步是生成候选框。这里用到了一种叫做选择性搜索 (Selective Search) 的方法。首先将每个像素作为单独的一组，然后计算每一组的纹理，将两个最接近的组结合起来，重复这样的操作直到所有区域不能再结合为止。下图展示了如何使区域增长：

图 2.4.3 选择搜索算法

这一步中，我们在一张图片上提取了大约 2000 个候选区域。需要注意的是这些候选区域的大小不固定，而 CNN 需要固定大小的输入，所以需要再对候选区域做一些尺寸上的修改。在处理完毕后，第二步 CNN 将在这些候选区域的基础上，提取出更高级、更抽象的特征，作为下一步分类器的输入，提取的这些特征通常会储存在磁盘中。

图 2.4.4 特征提取步骤

第三步，R-CNN 使用支持向量机 (SVM) 进行二分类，这是整个流程中最重要的一部分。假如共需检测 n 个类别，那么需要 n 个不同类别的 SVM 分类器，并且每个分类器会对所有 2000 个候选区域的特征向量进行打分，判断其是否为当前这个 SVM 需要判断的物体类别。具体来说：

图 2.4.5 SVM 分类

如图所示，如果需要识别的类别为猫与狗，那么首先对这 2000 个候选区域是否为猫进行打分。注意到这里的分数只能为是或否，这就是所谓二分类器的意义。同理，狗类别的 SVM 对每张图片是否为狗进行打分。经过

所有 SVM 判断结束后，我们可以大体了解这些候选区域中哪些是无关背景，哪些是需要的目标，以及其具体类别。

第四步，我们发现第一步中得出的建议框有重叠的情况，因此需要利用上一步的打分结果剔除重复的建议框。这其中又引出了一种新方法：非极大值抑制（NMS）。其首要目的就是一个物体只保留一个最优的框，去除那些冗余的候选框。首先，它根据上一步中的打分结果进行概率筛选，将 2000 个区域筛选至一个很小的数值。而这些剩下的框几乎都包含了一部分的图像内容，用上述方法得到的打分结果类似，难以再次筛选。因此下一步需要分别计算每一个候选框与实际目标区域的交并比（IOU），即两图像边框交集的面积与两图像边框并集的面积之比，以及各候选框两两之间的交并比。以下图为例：

图 2.4.6 非极大值抑制

我们发现经过概率筛选后还剩下五个候选框，其中 A、C 框对应黑车，B、D、E 对应白车。那么接下来就要从这两组中分别保留一个与对应车辆重合度最大的候选框。图中已经标识了它们各自相对于车辆的 IoU，那么对于黑车而言，最高的是 A 框。再对 A 框与 C 框计算 IoU，如果其 $\text{IoU} > 0.5$ ，那么意味着两者重合率较高，可以删除掉其中与目标物体重合率不高的，也就是 C。对 B、D、E 而言这个步骤同理，最终只保留了 B。最终在这五个候选框中检测出了 A 与 B 这两个目标。当然，在这个过程后依然还会有位置不准确的情况出现，因此需要用回归训练的方式修正这些候选区域。由于涉及到较多回归知识，在此不再过多赘述。通过以上四个步骤，R-CNN 最终输出了图片中需要被检测的目标位置。

图 2.4.7 VOC2010 数据集运行结果这种方法在 RASCAL VOC 2010 数据集中取得了出色的效果，mAP（对所有目标类别检测的效果取平均值）达到了 53.7 %。但是它仍存在一些尚未解决的问题：首先，由于在提取特征阶段，依然采用传统的选择搜索方法，导致候选区域的数量过多。而对于每个特征，所有的这些候选区域都将被输入到 CNN 中提取一次，不仅占用了大量磁盘空间，还非常耗时。在上述数据集中，检测一张图像的平均时间高达 47s。其次，图像在统一尺寸的过程中易失真，导致不期望看到的几何形变。如下图所示，对这些问题的思考最终导致了 SPP-Net 的产生。

图 2.4.8 SPP-Net 引入 2.4.3 SPP-Net[32]

为了解决上述 R-CNN 的部分缺陷，He 等在 2014 年提出了 SPP-Net，主要创新点在于将一个空间金字塔池化层（spatial pyramid pooling, SPP）添加在卷积层和全连接层之间，从而能适应任何尺寸的图像输入。同时，它还对特征提取步骤进行了修改，使得不需要每个候选区域都经过 CNN，只需要将整张图片输入，使运行速度得到了极大的提高，该层结构如下图所示：

图 2.3.9 SPP-Net

上一行的流程为标准 R-CNN 的流程，而下一行为将其改进后的 SPP-Net 流程。可以发现 R-CNN 先对图像进行选择与变换，再加入卷积层进行提取特征，而 SPP-Net 则直接将整张图片加入卷积层中，得到全图的特征图。随后，通过映射的方式将选择性搜索在原图中的位置对应到特征图中的相应位置。而这些映射过来的特征向量，经过空间金字塔池化层（spatial pyramid pooling, SPP），输出固定大小的特征向量，后续部分与 R-CNN 相同。那么下面将介绍每一步的细节。对于映射操作，我们已经通过 CNN 提取到了整张图片的特征图，并通过选择性搜索算法得到了原图的候选框，接下来需要建立起两张图中对于同一物体的坐标对应关系。如下图所示：

图 2.4.10 映射

这种映射已有明确的数学公式描述，在此不做深入探讨。

下一步，由于在上一步中映射到的特征图大小不一，但是对于一个固定的 CNN，全连接层的输入是一个提前设定好的固定的数值，那么我们需要将特征图转换成固定大小特征向量。而这正是 SPP 的核心作用。假设需要被处理的某个候选区域的特征图的大小为 $12 \times 10 \times 256$ ，那么如下图所示，SPP 会通过池化的方式，把每一个候选区域都变成 1×1 、 2×2 和 4×4 的三张子图，连接到一起变为 $(16+4+1) \times 256 = 5376$ 的大小，并将其交给下一步处理。可以发现，对每一个候选区域的特征图都可以转换为这种形式，这样就实现了大小的统一。

图 2.4.11 空间金字塔池化层 SPP-Net 通过上述方式降低了卷积运算的数据量，减少了运算时间。然而，SPP-Net 算法依然使用了 R-CNN 的框架，由于 SVM 的存在，特征需要存入磁盘，空间占用较大。

2.3.2.4 Fast R-CNN[33] 经由 R-CNN 和 SPP-Net 的经验，在 2015 年，R-CNN 的提出者之一 Girshick 又再次提出了 Fast R-CNN 模型。他发现，上述的两种方法都需要多次训练模型，如训练卷积神经网络和训练 SVM。因

此，他提出的 RoI pooling 整合了整个模型，将 CNN、RoI pooling、分类器甚至前文中省略的回归模块一起训练。下面给出了 Fast R-CNN 的整体流程图：

图 2.4.12 Fast R-CNN 首先，Fast R-CNN 的前几个操作与 SPP-Net 相同。它首先将整个图片输入到一个基础卷积网络中，得到整张图的特征图，然后再将原图中选择性搜索算法的得到的候选框映射到特征图中。接下来，类似于 SPP-Net 中的 SPP 层，Fast R-CNN 给出了一个 RoI pooling 层。可以发现它其实是一个简化版本的 SPP 层。如下图所示：

图 2.4.13 ROI pooling 层在 SPP 层中，我们的得到了大小为 1×1 、 2×2 和 4×4 的三张子图，但是在 RoI pooling 层中我们仅仅通过池化的方式得到了一张 4×4 的子图。虽然前者相对而言较准确一些，但是后者的速度快很多。此外，Faster R-CNN 的整个框架都直接用一个神经网络相连，这是因为 R-CNN 中 CNN 的训练与 SVM 的训练互相独立，两者的参数都无法互相影响，将 SVM 分类通过其他方法代替以后，使得所有过程都在整体的框架中进行，前后部分互相进行反馈与调整。并且，由于不再存在两个的独立的过程，中间也无需再用硬盘空间暂时保存信息，一切都在内存中存储，解决了磁盘占用大的问题。在上述反馈过程中，需要进行损失的计算，这一部分同样涉及到了复杂的数学公式，同样不再赘述。在同样的 RASCAL VOC 2007 数据集，Fast R-CNN 的 mAP 达到了 68.4%。但是，无论是 R-CNN，SPP-Net 还是 Fast R-CNN，其都是建立在传统的选择搜索的基础上，而这成为了上述方法的瓶颈。

2.3.2.5 Faster R-CNN[34] 为了彻底解决这个短板，同年，Ren 等针对选择性搜索算法提取特征较慢的问题，提出了 Faster R-CNN。在该论文中，区域建议网络（RPN）的概念首次被提出，它被设计用来替代传统的选择性搜索算法。简单来说，Faster R-CNN 中也加入了一个提取边缘的神经网络，即寻找候选框的工作也交给神经网络了，如下图所示：

图 2.4.14 R-CNN 算法进化那么需要关注的重点就在于其代替选择性搜索方法的区域建议网络，其主要作用也是为了得出比较准确的候选区域。它的思路是用 $n \times n$ （默认 3×3 ）大小的窗口去扫描特征图，并且在每个被扫描的位置中都考虑 9 种可能的参考窗口（anchors），如下图所示：

图 2.4.15 区域建议网络注意到，上述的 9 种参考网络非常考究。它使用了 128、256、512 三种尺度的窗口大小，对于每种尺度分别又有 1: 1、1: 2、2: 1 三种长宽比，共计 $3 \times 3 = 9$ 种参考窗口。如下图所示：

图 2.4.16 参考窗口形状与大小在得到上述候选区域后，我们将它进行分类判别为前景或背景，并用回归方法修正位置，再加入 RoI 层中，后续的流程与 Fast R-CNN 类似。这种方法提出 RPN 网络取代了传统的选择搜索算法。自此，目标检测的四个步骤，即寻找候选区域、提取特征、目标分类、调整位置被统一到了一个深度神经网络框架中。

图 2.4.17 Faster R-CNN 结构 2.3.2.6 FPN[35] 然而，卷积神经网络在提取特征时，高层特征容易保留语义信息，低层特征容易保留位置信息。具体到目标检测领域，高层特征虽然能保留语义信息，但是由于此时特征图的尺寸较小，含有的位置信息并不多，不利于物体检测；低层网络虽然包含比较多的位置信息，但是图像的语义信息并不多，不利于图像的分类，这个问题在小尺寸物体检测上更为显著，这也就是为什么物体检测算法普遍对小物体检测效果不好的最重要原因之一。基于这种问题，研究者们想到可以使用合并后的高层和低层特征来同时满足分类和检测的需求。传统的金字塔模型通过直接输入多尺度图像的方式构建多尺度的特征，如下图 2.4.18 所示，但是这样的计算成本太高。而 R-CNN、Fast R-CNN 和 Faster R-CNN 选择了只对卷积最顶层，即语义最丰富的一层进行特征提取，如下图 2.4.19 所示，但是如上文所言，这样对于目标的检测能力太差。其他方法如利用卷积网络的层次结构，在提取特征的过程中通过网络的不同层得到了多尺度的特征图。该方法虽然能提高精度，且基本上没有增加耗时，但是依然没有使用更加低层的特征图，对小物体的检测能力较弱。

图 2.4.18 单层特征图 2.4.19 多层特征图于是，综合以上几点考虑，Lin 等提出了特征金字塔网络（FPN）方法。如下图 2.4.20 所示，FPN 不仅使用了层次较深的特征图，并且浅层的特征图也被应用到 FPN 中。并通过自底向上，自顶向下以及横向连接将这些特征图高效的整合起来，在提升精度的同时并没有大幅增加检测时间。上述三个具体操作在此不作深入讨论，实验证明，该特征金字塔结构的特征提取效果优于单尺度的特征提取效果。

图 2.4.20 FPN 模型到此，对双阶段目标检测算法的总结告一段落，列出下表再次将其进行对比：表 2.4.1 二阶段目标检测算法性能对比算法数据集 mAP(%) R-CNN PASCAL VOC 2007 58.5 SPP-Net PASCAL VOC 2007 59.2 Fast R-CNN PASCAL VOC 2007 68.0 Faster R-CNN PASCAL VOC 2007 78.0 FPN MS-COCO 34.4

表 2.4.2 二阶段目标检测算法综合对比算法创新点优势缺陷 R-CNN 将 CNN 应用于目标检测，利用选择分类算法和支持向量机开创深度学习在目标检测领域的先河耗时、占用空间大、易失真 SPP-Net 引入空间金字塔池化层，修改特征提取方式解决失真问题，加快运行效率占用空间依然很大 Fast R-CNN 引入 softmax 替代支持向量机，引入奇异值分解减少了储存空间的占用整体耗时受到选择搜索算法的限制 Faster R-CNN 引入区域建议网络，设计了多参考窗口机制实现端到端的目标检测模型，降低用时对小目标检测能力较差 FPN 引入多层特征与特征融合大幅度提高对小目标的检测能力

2.4.7 单阶段算法与两阶段算法 [36] 上文中出现了两阶段这个字眼，两阶段指的是实现检测的方式主要有两个过程：第一步，提取候选区域；第二步，再对区域进行 CNN 分类识别。因此，它又被称为基于候选区域的检测。而单阶段目标检测算法没有候选区域提取阶段，它采用一个网络一步到位，训练过程也相对简单，可以在一个阶段直接确定目标类别并得到位置检测框。其代表算法有 YOLO 系列与 SSD 系列。由于篇幅问题与作者水平限制，本文中对单阶段目标检测算法不再作深入讨论。2.4.8 总结

图 2.4.21 目标检测路线图上图给出了目标检测近 20 年来的里程碑算法，目标检测技术从传统的选择搜索算法到如今的深度学习算法，在提升精度的同时减少了对耗时和空间的需求。过去的几年中，不断有成熟的目标检测算法应用在工业界落地，不仅便利了人们的生活，也给学术界提供了丰富的灵感来源。下一小节，我们将实现一个简单的人脸识别技术用以演示。

2.4.9 深度学习图像处理举例我们在 github 上下载了几个已经训练好的模型，并以人脸检测为例：

“11.png”和“12.png”使用如下的 Python 代码实现：检测的结果为：

4.5 体会启发与结语

我负责的部分是图像的数字矩阵化。在接触此次课题之前，我对矩阵的认知是相当局限的，仅仅由线性代数的基本课程了解到它对于线性方程组与一些坐标系变换的意义，并没有体会到它如何应用于我们实际的生活，更何况是电子计算机领域呢。通过本次课题的学习，虽然过程稍有艰辛，但我学会了不少知识，体会到了数学思维是如何作用于人类发展历史上的。在本次课题的撰写与学习过程中，我使用了 C++ 和 Python 语言搭载 OpenCV 库来实操了一番，还是非常有趣的经历，也期待自己未来能够掌握更多的技术栈。当然，我需要更多不断地学习，需要学习更多软件工程方面的知识，才可以领会到更多的思想。——谭诚

我个人写的是传统数字图像处理的起源、发展和应用。经过这次的小组作业学习。我对数字图像处理及其发展的脉络和多样的应用场景有了大致的了解。同时也引发了个人对于数字图像处理和计算机视觉的兴趣。在和小组成员的交流沟通中，我也得到了很多锻炼和启发。虽然前后查阅资料、组织语言、制作演示文稿和其他内容的部分是不易的，但当看到小组成员汇报的结果，还是觉得颇为值得。在简要了解完传统数字图像处理之后，发觉其仍存在一定程度上的缺陷，也尝试着去利用老师上课所教授的内容去思考，是否可以用人工智能的思维去改善现有的算法，不仅拓宽了知识面，也锻炼了自己的思维，感受到大有裨益。数字图像处理是丰富多彩、颇具魅力的，其应用领域的宽广也让我切实感到技术落地的魅力，大大增强了自我不断学习相关知识、努力探索学科领域的驱动力。提升了个人对于软件工程学科的认识水平，对自我是一次全方位的发展。——汪坤灿

写完神经网络与目标检测的发展史以后，最大的收获是了解了一个自己从未涉足过的领域是如何发展的。从上世纪的摸索，到最近十年间的快速发展，无数新理论、新模型、新思想在不断诞生。对于非人工智能研究者而言，人工智能的发展看起来似乎是一蹴而就的事情。但是，仅仅在目标检测这一小小的领域，就经历了一个模型从诞生到不断完善每一个部分的过程，甚至直到现在还在不断发展。因此人工智能不该被当作一个概念而热炒，似乎只要高举支持人工智能旗帜就能顺应人工智能的浪潮，而更应该了解其发展历史与具体内涵。在写神经网络与目标检测两段内容之前，我可能都不知道机器学习和深度学习有什么区别和联系，这个写作过程也相当于给自己扫了个盲。我想这份经历也可以沿用到人工智能的其他分支，乃至其他领域的学科上。除此以外，在目标检测模型的发展方面，我的内容是按照问题——解决方案——新问题的思路来撰写的，通过这种方式来理解每个看似不同的模型之间的内在联系，是一种线性连贯的解决问题方式，我想这可能也是一种比较大的启发。——史晓磊

致谢自确定开题以来，小组中的每个成员都花费了大把时间来学习新知识。面对晦涩难懂的学术论文，以

及眼花缭乱的公式与知识，每个成员的努力与付出都值得被铭记，每个成员的心血与成功都值得被尊重与感谢。同时，我们也很感谢华东师范大学软件工程学院的吴敏老师，她为我们带来了半个学期的精彩淋漓的《人工智能的数学思维》课程。很感谢她为我们介绍了近代以来的数学知识发展以及对应电子计算机领域所诞生的新计算机科学，让我们了解到了数学思维与计算机科学的重要性。最后，我们也非常感谢华东师范大学软件工程学院 (East China Normal University, Software Engineering Institute, ECNU-SEI) 开设此门课程。

互不相容的模型组成的森林比其中每一棵树都要睿智。

4.6 次线性算法

到这里为止，我非常感兴趣的还是那些有可能获得置信度的算法的性质。我同样确定，要寻找最优预测算法，囤积海量数据是必不可少的。然而，并不是所有数据都有价值。就像在沙漠深处安装的监视摄像头传来的视频流那样，实际上绝大部分收集来的数据毫无意义。问题在于，在这个大数据的时代，单单读取这些数据来验证它们，真的没有意义，所需的时间就已经不切实际了——我就是这样说服自己不去查阅收到的全部邮件，这种做法没问题的！为了解决这个问题，理论计算机学家将注意力投向了所谓的次线性算法。这些算法的特点就是在不花时间读取所有数据的情况下，仍然能够提取数据集里最核心的内容。也就是说，这些算法能够在读取输入数据时“一目十行”。这种算法在历史上最典型的例子就是谷歌的算法。在谷歌上搜索几乎瞬间就能得到结果，然而，谷歌的数据库包含了互联网的数百万亿网页中相当大的一部分。对于谷歌来说，在向用户返回结果之前探索整个数据库根本不在考虑范围之内，因为这样做要花上几天时间！因此，谷歌的搜索算法必须是次线性的。谷歌用到的技巧跟图书馆和词典一样，就是预先对数据库排序和整理，迅速完成对数据库的查阅。比如说，词典将单词按照字母顺序整理，就能让使用者很快知道希望查找的单词应该会在什么地方。更厉害的是，利用字母顺序，给定词典中的一页以及要查找的单词，使用者就能知道这个单词应该在词典中这一页的前面还是后面。一般来说，在（按照全序关系）排序过的数据库中查找数据非常迅速。所谓的二分算法（大概就是你用词典查单词的时候用的方法）的计算时间是数据库大小的对数。然而谷歌、图书馆管理员和词典使用的算法都需要预先进行大量的计算。要将所有网页整理并排序，除非对其全部访问，否则不可能做到。即使如此，我们能否在既不检索整个数据集，也不预先对其进行处理的前提下，将有用的信息提取出来呢？令人惊讶的是，对于某些有用的信息以及某些数据来说，答案是肯定的。傅里叶变换就属于这种情况。在 19 世纪初，约瑟夫·傅里叶等人就曾研究过傅里叶变换，它是一种对声音、图像、视频以及股票走势等信号的描述方式进行变换的方法 [8]。我们在这里就只讨论声音信号。声音可以通过鼓膜附近气压的变化来描述。但还有另一种等价的描述方式，它对于音乐的谱写来说特别简单，那就是利用组成声音的频率来描述这个声音。傅里叶变换就像一个双语词典，能够将声音的振动变化描述转换为频率描述。这样的翻译有着很多用途，一个原因是要改善声音的话，调整频率通常比调整振动更有效，另一个原因就是声音通常只由为数不多的几个频率组成。实际上，傅里叶变换已经占据了我们的日常生活，据理查德·巴拉纽克教授所言，就连我们的计算机和电话每天都会进行数十亿次傅里叶变换。在每次听音乐、查看数字化图像，或者观看视频的时候，我们都在让机器进行傅里叶变换。因此，计算傅里叶变换的算法如果有任何加速的可能性，都会在程序计算或者计算所需硬件的方面带来数十亿欧元的收益，更不用说用户节省下来的等待时间了。在 1964 年，詹姆斯·库利和约翰·图基就完成了一项壮举，大幅缩短了（离散）傅里叶变换的计算时间。尽管最简单的算法需要的时间与数据量的平方成正比，但库利和图基的算法，又叫快速傅里叶变换，可以在接近线性的时间内完成 9。也就是说，要对一百万字节 (1MB) 的数据进行计算的话，快速傅里叶变换只需要数百万次运算（对于现代计算机来说，这相当于几毫秒的计算），而不是朴素算法所需的 100 万乘以 100 万次运算（差不多 1 分钟的计算）。9 也就是说离散傅里叶变换所需的时间复杂度从 $O(n^2)$ 变成了 $O(n \log n)$ 。然而在大数据的时代，快速傅里叶变换还是太慢了，尤其在处理上十亿字节 (GB) 甚至上万亿字节 (TB) 的数据时更是如此。我们能不能让傅里叶变换变得比现在更快？在 2012 年，哈桑尼耶、因迪克、卡塔比和普赖斯 [9] 发现，答案是肯定的。也可以说他们提出了一个巧妙的算法，可以对信号最主要的个频率进行近似计算，而需要的时间大概在乘以数据量的对数这个数量级 10。重点在于，这个叫作稀疏傅里叶变换的精妙算法的运行时间是次线性的，也就是说它几乎忽略了整个待处理的信号，却能得知这个信号大概是什么。10 它的复杂度实际上是 $O(k \log^2 n)$ 。

思考的多种模式虽然次线性算法在计算机科学中仍不是主流，但我们的大脑似乎喜欢使用这种算法。谁又未曾一目十行读完书面材料，漫不经心地听别人讨论，或者吃饭时根本没有在意食物的味道呢？奇怪的是，有时候文章中的某些词语、讨论中的某些话题或者食物中的某些味道会吸引我们的注意力。当这种情况出现的时候，我们似乎突然就切换到了思考状态。我们会开始使用更缓慢、更精确的算法来仔细分析文章的含义、讨论的深意与本地特色菜的独特味道。我在这里描述的，正是诺贝尔经济学奖得主丹尼尔·卡内曼的杰作《思考，快与慢》的核心。卡内曼区分了两套思考系统：系统一和系统二。系统一就像稀疏傅里叶变换，非常迅速、有效、勤奋，但有可能出现严重错误；系统二就像精确傅里叶变换，很慢且需要大量能量，懒惰但更正确。据卡内曼所说，我们通常会将自己等同于系统二，而且几乎不会意识到系统一的存在。然而，在绝大部分时间内主导的都是系统一，而这会让我们经常犯错。试试这个：球拍和球的价格一共是 1.1 欧元，球拍的价格比球高 1 欧元，那么球的价格是多少？很可能你立刻就看到了答案，但这个答案是错的。根据卡内曼所说，如果这种情况出现，那是因为系统一匆匆忙忙给出了第一个想到的答案；只有在之后，也许是当你看到这里的时候，你的系统二才会开始质疑系统一。我们可能会认为卡内曼希望说服我们放弃系统一，尽可能经常让系统二运作。并非完全如此。毕竟即使系统二得出的结果更正确，但对于大脑来说，使用系统二更疲劳。思考有其代价。然而，正如所有演员、钢琴家和冲浪者都知道的那样，我们不可能一一思考自己的所有行为与动作。我们最终必须能够自然且自发地做出这些动作，无须大量有意识的思考。要做到无须长久思考就能做出合格的动作，演员、钢琴家和冲浪者用的是同样一套方法：他们的系统二会迫使系统一学习所需的动作。对于那些希望学习或者授课的人来说，这可能是最重要的意见。与其说学习是将信息塞进脑中，不如说是让系统二来教导系统一，使得系统一发现一条捷径，能够迅速解决那些系统二已经知道怎么解决，但要花上许多时间和能量的问题。也就是说，学习的根本就是发现又快又（足够）好的捷径。

4.7 迈进后严谨阶段!

数学的学习似乎也是如此进行的。在今天，如果有人问我一个关于加法、指数或者图灵机的问题，那么对我来说，不通过系统二就能回答这些问题也并非毫无可能。这是因为，长年以来我的系统二已经成功教会系统一如何在不花费脑力劳动的前提下回答这些问题！我的大脑中储存着大量捷径，能用于解决大量数学问题，即使是那些对于年轻学生来说略感困难的问题。某些人把这种能力称为数学能力，还有些人把它称为数学直觉。我更愿意把它称为系统二通过努力发现的高效捷径。但这不是系统一的数学训练中最重要方面。数学家、菲尔兹奖获得者陶哲轩在他的博客中 [10] 将数学学习分为三个阶段，分别叫作前严谨阶段、严谨阶段和后严谨阶段。简单来说，学生首先会开始摆弄数字和数学概念，而不会忧心于自己执行的那些代数操作的有效性。然后，随着时间流逝以及接受的数学教育越来越多，严谨性的时刻就会到来，而且很快会转变为纯粹主义：一切都应该用形式化的语言做出解释。最后，后严谨阶段属于研究者，他们花上大部分时间构建不同的启发式论证，用来得出定理证明的大体轮廓，其间会暂时舍弃之前学到的形式体系。关键在于，第二个阶段似乎是到达第三个阶段的必经之路。陶哲轩的说法可以用系统一和系统二的语言来理解。前严谨阶段对应的是系统一和系统二都没有学会严谨性的情况。当系统二发现严谨性及其重要性时，严谨阶段就开始了。在这个阶段中，系统二会教导系统一，让它意识到自身直觉的局限性。但更重要的是，系统一会由此学会测量自身的置信度，这样就能够更好地做出决定，判断自己能解决问题，还是需要向系统二求助。只有经过这种困难的学习过程，系统一才能成为系统二的完美协助者，而不会在重要的时候拖后腿。因此，成为一名优秀的数学家，基本上相当于让系统一足以在这方面胜任——但要达到这一状态，严谨阶段必不可少。话虽如此，即使到了后严谨阶段，系统二仍会不断教导系统一，让它能够进步。这就是在莱姆基·奥利弗和孙达拉拉詹发表了关于素数最后一位数字的研究结果之后，所有数论学家的大脑中发生的事情。这个发现惊动了数论学家的系统一，它关于素数的直觉基于素数定理，而这一捷径预言相邻素数的最后一位数字大多是独立的。在这个情况下，这个捷径出错了。自此之后，数论学家可能进行了某种近似贝叶斯推断，以减少素数定理这一捷径在相邻素数的情况中应用的置信度。丹尼尔·卡内曼的双系统思考模型对于实用贝叶斯主义者来说的确很有趣。当然，这个模型是错的。但毕竟“所有模型都是错的”。然而卡内曼的模型似乎很有用——即使第 17 章暗示还存在负责创造性思考过程的第三个系统。在实践中，尤其是在面对大数据的时候，大部分用到的算法大概是迅速的启发式算法，甚至是次线性的。然而拥

有更缓慢但更正确的算法仍然是必要的。此外，如果我们拥有数个更缓慢、但我们知道足够正确的算法，那么我们就可以用这些算法来训练那些快速的启发式算法。假如我能打个赌，(作为合格的贝叶斯主义者，我喜欢打赌!) 我会说这就是未来人工智能的模样。线性代数

- 矩阵和向量运算：在数据表示和转换中使用，如矩阵乘法、转置和逆矩阵。- 特征值和特征向量：用于数据降维和特征选择，如主成分分析 (PCA)。- 奇异值分解 (SVD)：用于数据压缩、降噪和推荐系统。- 矩阵分解技术：如非负矩阵分解 (NMF) 用于主题建模。

第5章 机器学习：学习如何学习？

内容提要

- Definition of Theorem
- Ask for help
- Optimization Problem

- Property of Cauchy Series
- Angle of Corner

5.1 深度学习，真的行

人工智能发展的两个大阶段

- 自上而下
- 人工建立规则
- 逻辑推理
- 知识库
- 自下而上
- 自主从经验/反馈中学习
- 机器学习、深度学习
- 机器人

推理期知识期

学习期

动手学深度学习《深度学习简介》

你可能已经接触过编程，并开发过一两款程序。同时你可能读过关于深度学习或者机器学习的铺天盖地的报道，尽管很多时候它们被赋予了更广义的名字：人工智能。实际上，或者说幸运的是，大部分程序并不需要深度学习或者是更广义上的人工智能技术。例如，如果我们要为一台微波炉编写一个用户界面，只需要一点儿工夫我们便能设计出十几个按钮以及一系列能精确描述微波炉在各种情况下的表现的规则。再比如，假设我们要编写一个电子邮件客户端。这样的程序比微波炉要复杂一些，但我们还是可以沉下心来一步一步思考：客户端的用户界面将需要几个输入框来接受收件人、主题、邮件正文等，程序将监听键盘输入并写入一个缓冲区，然后将它们显示在相应的输入框中。当用户点击“发送”按钮时，我们需要检查收件人邮箱地址的格式是否正确，并检查邮件主题是否为空，或在主题为空时警告用户，而后用相应的协议传送邮件。

值得注意的是，在以上两个例子中，我们都不需要收集真实世界中的数据，也不需要系统地提取这些数据的特征。只要有充足的时间，我们的常识与编程技巧已经足够让我们完成任务。

与此同时，我们很容易就能找到一些连世界上最好的程序员也无法仅用编程技巧解决的简单问题。例如，假设我们想要编写一个判定一张图像中有没有猫的程序。这件事听起来好像很简单，对不对？程序只需要对每张输入图像输出“真”（表示有猫）或者“假”（表示无猫）即可。但令人惊讶的是，即使是世界上最优秀的计算机科学家和程序员也不懂如何编写这样的程序。

我们该从哪里入手呢？我们先进一步简化这个问题：若假设所有图像的高和宽都是同样的 400 像素大小，一个像素由红绿蓝三个值构成，那么一张图像就由近 50 万个数值表示。那么哪些数值隐藏着我们需要的信息呢？是所有数值的平均数，还是四个角的数值，抑或是图像中的某一个特别的点？事实上，要想解读图像中的内容，需要寻找仅仅在结合成千上万的数值时才会出现的特征，如边缘、质地、形状、眼睛、鼻子等，最终才能判断图像中是否有猫。

一种解决以上问题的思路是逆向思考。与其设计一个解决问题的程序，不如从最终的需求入手来寻找一个解决方案。事实上，这也是目前的机器学习和深度学习应用共同的核心思想：我们可以称其为“用数据编程”。

与其枯坐在房间里思考怎么设计一个识别猫的程序，不如利用人类肉眼在图像中识别猫的能力。我们可以收集一些已知包含猫与不包含猫的真实图像，然后我们的目标就转化成如何从这些图像入手得到一个可以推断出图像中是否有猫的函数。这个函数的形式通常通过我们的知识来针对特定问题选定。例如，我们使用一个二次函数来判断图像中是否有猫，但是像二次函数系数值这样的函数参数的具体值则是通过数据来确定。

通俗来说，机器学习是一门讨论各式各样的适用于不同问题的函数形式，以及如何使用数据来有效地获取函数参数具体值的学科。深度学习是指机器学习中的一类函数，它们的形式通常为多层神经网络。近年来，仰仗着大数据集和强大的硬件，深度学习已逐渐成为处理图像、文本语料和声音信号等复杂高维度数据的主要方法。

我们现在正处于一个程序设计得到深度学习的帮助越来越多的时代。这可以说是计算机科学历史上的一个分水岭。举个例子，深度学习已经在你的手机里：拼写校正、语音识别、认出社交媒体照片里的好友们等。得益于优秀的算法、快速而廉价的算力、前所未有的大量数据以及强大的软件工具，如今大多数软件工程师都有能力建立复杂的模型来解决十年前连最优秀的科学家都觉得棘手的问题。

5.2 .1. 起源

虽然深度学习似乎是最近几年刚兴起的名词，但它所基于的神经网络模型和用数据编程的核心思想已经被研究了数百年。自古以来，人类就一直渴望能从数据中分析出预知未来的窍门。实际上，数据分析正是大部分自然科学的本质，我们希望从日常的观测中提取规则，并找寻不确定性。

早在 17 世纪，[雅各比·伯努利 (1655–1705)] 提出了描述只有两种结果的随机过程（如抛掷一枚硬币）的伯努利分布。大约一个世纪之后，[卡尔·弗里德里希·高斯 (1777–1855)] 发明了今日仍广泛用在从保险计算到医学诊断等领域的最小二乘法。概率论、统计学和模式识别等工具帮助自然科学的实验学家们从数据回归到自然定律，从而发现了如欧姆定律（描述电阻两端电压和流经电阻电流关系的定律）这类可以用线性模型完美表达的一系列自然法则。

即使是在中世纪，数学家也热衷于利用统计学来做出估计。例如，在 [雅各比·科贝尔 (1460–1533)] 的几何书中记载了使用 16 名男子的平均脚长来估计男子的平均脚长。

现代统计学在 20 世纪的真正起飞要归功于数据的收集和发布。统计学巨匠之一 [罗纳德·费雪 (1890–1962)] 对统计学理论和统计学在基因学中的应用功不可没。他发明的许多算法和公式，例如线性判别分析和费雪信息，仍经常被使用。即使是他在 1936 年发布的 Iris 数据集，仍然偶尔被用于演示机器学习算法。

[克劳德·香农 (1916–2001)] 的信息论以及 [阿兰·图灵 (1912–1954)] 的计算理论也对机器学习有深远影响。图灵在他著名的论文 [《计算机器与智能》] 中提出了“机器可以思考吗？”这样一个问题 [1]。在他描述的“图灵测试”中，如果一个人在使用文本交互时不能区分他的对话对象到底是人类还是机器的话，那么即可认为这台机器是有智能的。时至今日，智能机器的发展可谓日新月异。

另一个对深度学习有重大影响的领域是神经科学与心理学。既然人类显然能够展现出智能，那么对于解释并逆向工程人类智能机理的探究也在情理之中。最早的算法之一是由 [唐纳德·赫布 (1904–1985)] 正式提出的。在他开创性的著作 [《行为的组织》] 中，他提出神经是通过正向强化来学习的，即赫布理论 [2]。赫布理论是感知机学习算法的原型，并成为支撑今日深度学习的随机梯度下降算法的基石：强化合意的行为、惩罚不合意的行为，最终获得优良的神经网络参数。

来源于生物学的灵感是神经网络名字的由来。这类研究者可以追溯到一个多世纪前的 [亚历山大·贝恩 (1818–1903)] 和 [查尔斯·斯科特·谢灵顿 (1857–1952)]。研究者们尝试组建模仿神经元互动的计算电路。随着时间发展，神经网络的生物学解释被稀释，但仍保留了这个名字。时至今日，绝大多数神经网络都包含以下的核心原则。

-交替使用线性处理单元与非线性处理单元，它们经常被称为“层”。-使用链式法则（即反向传播）来更新网络的参数。

在最初的快速发展之后，自约 1995 年起至 2005 年，大部分机器学习研究者的视线从神经网络上移开了。这是由于多种原因。首先，训练神经网络需要极强的计算力。尽管 20 世纪末内存已经足够，计算力却不够充足。其次，当时使用的数据集也相对小得多。费雪在 1936 年发布的 Iris 数据集仅有 150 个样本，并被广泛用于测

试算法的性能。具有 6 万个样本的 MNIST 数据集在当时已经被认为是非常庞大了，尽管它如今已被认为是典型的简单数据集。由于数据和计算力的稀缺，从经验上来说，如核方法、决策树和概率图模型等统计工具更优。它们不像神经网络一样需要长时间的训练，并且在强大的理论保证下提供可以预测的结果。

5.3 1.2. 发展

互联网的崛起、价廉物美的传感器和低价的存储器令我们越来越容易获取大量数据。加之便宜的计算力，尤其是原本为电脑游戏设计的 GPU 的出现，上文描述的情况改变了许多。一瞬间，原本被认为不可能的算法和模型变得触手可及。这样的发展趋势从如下表格中可见一斑。

年代	数据样本个数	内存	每秒浮点计算数
1970	102102 (Iris)	1KB	100K (Intel8080)
1980	103103 (波士顿房价)	100KB	1M (Intel80186)
1990	104104 (手写字符识别)	10MB	10M (Intel80486)
2000	107107 (网页)	100MB	1G (IntelCore)
2010	10101010 (广告)	1GB	1T (NVIDIAC2050)
2020	10121012 (社交网络)	100GB	1P (NVIDIADGX-2)

很显然，存储容量没能跟上数据量增长的步伐。与此同时，计算力的增长又盖过了数据量的增长。这样的趋势使得统计模型可以在优化参数上投入更多的计算力，但同时需要提高存储的利用效率，例如使用非线性处理单元。这也相应导致了机器学习和统计学的最优选择从广义线性模型及核方法变化为深度多层神经网络。这样的变化正是诸如多层感知机、卷积神经网络、长短期记忆循环神经网络和 Q 学习等深度学习的支柱模型在过去 10 年从坐了数十年的冷板凳上站起来被“重新发现”的原因。

近年来在统计模型、应用和算法上的进展常被拿来与寒武纪大爆发（历史上物种数量大爆发的一个时期）做比较。但这些进展不仅仅是因为可用资源变多了而让我们得以用新瓶装旧酒。下面的列表仅仅涵盖了近十年来深度学习长足发展的部分原因。

- 优秀的容量控制方法，如丢弃法，使大型网络的训练不再受制于过拟合（大型神经网络学会记忆大部分训练数据的行为）[3]。这是靠在整个网络中注入噪声而达到的，如训练时随机将权重替换为随机的数字[4]。
- 注意力机制解决了另一个困扰统计学超过一个世纪的问题：如何在不增加参数的情况下扩展一个系统的记忆容量和复杂度。注意力机制使用了一个可学习的指针结构来构建出一个精妙的解决方法[5]。也就是说，与其在像机器翻译这样的任务中记忆整个句子，不如记忆指向翻译的中间状态的指针。由于生成译文前不需要再存储整句原文的信息，这样的结构使准确翻译长句变得可能。
- 记忆网络[6]和神经编码器—解释器[7]这样的多阶段设计使得针对推理过程的迭代建模方法变得可能。这些模型允许重复修改深度网络的内部状态，这样就能模拟出推理链条上的各个步骤，就好像处理器在计算过程中修改内存一样。
- 另一个重大发展是生成对抗网络的发明[8]。传统上，用在概率分布估计和生成模型上的统计方法更多地关注于找寻正确的概率分布，以及正确的采样算法。生成对抗网络的关键创新在于将采样部分替换成了任意的含有可微分参数的算法。这些参数将被训练到使判别器不能再分辨真实的和生成的样本。生成对抗网络可使用任意算法来生成输出的这一特性为许多技巧打开了新的大门。例如生成奔跑的斑马[9]和生成名流的照片[10]都是生成对抗网络发展的见证。
- 许多情况下单块 GPU 已经不能满足在大型数据集上进行训练的需要。过去 10 年内我们构建分布式并行训练算法的能力已经有了极大的提升。设计可扩展算法的最大瓶颈在于深度学习优化算法的核心：随机梯度下降需要相对更小的批量。与此同时，更小的批量也会降低 GPU 的效率。如果使用 1,024 块 GPU，每块 GPU 的批量大小为 32 个样本，那么单步训练的批量大小将是 32,000 个以上。近年来李沐[11]、YangYou 等人[12]以及 XianyanJia 等人[13]的工作将批量大小增至多达 64,000 个样例，并把在 ImageNet 数据集上训练 ResNet-50 模型的时间降到了 7 分钟。与之相比，最初的训练时间需要以天来计算。
- 并行计算的能力也为至少在可以采用模拟情况下的强化学习的发展贡献了力量。并行计算帮助计算机在围棋、雅达利游戏、星际争霸和物理模拟上达到了超过人类的水准。
- 深度学习框架也在传播深度学习思想的过程中扮演了重要角色。[Caffe](<https://github.com/BVLC/caffe>)、[Torch](<https://github.com/torch>)和[Theano](<https://github.com/Theano/Theano>)这样的第一代框架使建模变得更简单。许多开创性的论文都用到了这些框架。如今它们已经被[TensorFlow](<https://github.com/tensorflow/tensorflow>)（经常是以高层 API[Keras](<https://github.com/keras-team/keras>)的形式被使用）、[CNTK](<https://github.com/Microsoft/CNTK>)、[Caffe2](<https://github.com/caffe2/caffe2>)和[ApacheMXNet](<https://github.com/apache/mxnet>)

[//github.com/apache/incubator-mxnet](https://github.com/apache/incubator-mxnet)) 所取代。第三代,即命令式深度学习框架,是由用类似 NumPy 的语法来定义模型的 [Chainer](<https://github.com/chainer/chainer>) 所开创的。这样的思想后来被 [PyTorch](<https://github.com/pytorch/pytorch>) 和 MXNet 的 [GluonAPI](<https://github.com/apache/incubator-mxnet>) 采用,后者也正是本书用来教学深度学习的工具。

系统研究者负责构建更好的工具,统计学家建立更好的模型。这样的分工使工作大大简化。举例来说,在 2014 年时,训练一个逻辑回归模型曾是卡内基梅隆大学布置给机器学习方向的新入学博士生的作业问题。时至今日,这个问题只需要少于 10 行的代码便可以完成,普通的程序员都可以做到。

5.4 1.3. 成功案例

长期以来机器学习总能完成其他方法难以完成的目标。例如,自 20 世纪 90 年代起,邮件的分拣就开始使用光学字符识别。实际上这正是知名的 MNIST 和 USPS 手写数字数据集的来源。机器学习也是电子支付系统的支柱,可以用于读取银行支票、进行授信评分以及防止金融欺诈。机器学习算法在网络上被用来提供搜索结果、个性化推荐和网页排序。虽然长期处于公众视野之外,但是机器学习已经渗透到了我们工作和生活的方方面面。直到近年来,在此前认为无法被解决的问题以及直接关系到消费者的问题上取得突破性进展后,机器学习才逐渐变成公众的焦点。这些进展基本归功于深度学习。

-苹果公司的 Siri、亚马逊的 Alexa 和谷歌助手一类的智能助手能以可观的准确率回答口头提出的问题,甚至包括从简单的开关灯具(对残疾群体帮助很大)到提供语音对话帮助。智能助手的出现或许可以作为人工智能开始影响我们生活的标志。-智能助手的关键是需要能够精确识别语音,而这类系统在某些应用上的精确度已经渐渐增长到可以与人类比肩 [14]。-物体识别也经历了漫长的发展过程。在 2010 年从图像中识别出物体的类别仍是一个相当有挑战性的任务。当年日本电气、伊利诺伊大学香槟分校和罗格斯大学团队在 ImageNet 基准测试上取得了 28-博弈曾被认为是人类智能最后的堡垒。自使用时间差分强化学习玩双陆棋的 TD-Gammon 开始,算法和算力的发展催生了一系列在博弈上使用的新算法。与双陆棋不同,国际象棋有更复杂的状态空间和更多的可选动作。“深蓝”用大量的并行、专用硬件和博弈树的高效搜索打败了加里·卡斯帕罗夫 [17]。围棋因其庞大的状态空间被认为是更难的游戏,AlphaGo 在 2016 年用结合深度学习与蒙特卡罗树采样的方法达到了人类水准 [18]。对德州扑克游戏而言,除了巨大的状态空间之外,更大的挑战是博弈的信息并不完全可见,例如看不到对手的牌。而“冷扑大师”用高效的策略体系超越了人类玩家的表现 [19]。以上的例子都体现出了先进的算法是人工智能在博弈上的表现提升的重要原因。-机器学习进步的另一个标志是自动驾驶汽车的发展。尽管距离完全的自动驾驶还有很长的路要走,但诸如 [Tesla](<http://www.tesla.com/>)、[NVIDIA](<http://www.nvidia.com/>)、[MobilEye](<http://www.mobileye.com/>) 和 [Waymo](<http://www.waymo.com/>) 这样的公司发布的具有部分自动驾驶功能的产品展示出了这个领域巨大的进步。完全自动驾驶的难点在于它需要将感知、思考和规则整合在同一个系统中。目前,深度学习主要被应用在计算机视觉的部分,剩余的部分还是需要工程师们的大量调试。

以上列出的仅仅是近年来深度学习所取得的成果的冰山一角。机器人学、物流管理、计算生物学、粒子物理学和天文学近年来的发展也有一部分要归功于深度学习。可以看到,深度学习已经逐渐演变成一个工程师和科学家皆可使用的普适工具。

5.5 1.4. 特点

在描述深度学习的特点之前,我们先回顾并概括一下机器学习和深度学习的关系。机器学习研究如何使计算机系统利用经验改善性能。它是人工智能领域的分支,也是实现人工智能的一种手段。在机器学习的众多研究方向中,表征学习关注如何自动找出表示数据的合适方式,以便更好地将输入变换为正确的输出,而本书要重点探讨的深度学习是具有多级表示的表征学习方法。在每一级(从原始数据开始),深度学习通过简单的函数将该级的表示变换为更高级的表示。因此,深度学习模型也可以看作是由许多简单函数复合而成的函数。当这些复合的函数足够多时,深度学习模型就可以表达非常复杂的变换。

深度学习可以逐级表示越来越抽象的概念或模式。以图像为例，它的输入是一堆原始像素值。深度学习模型中，图像可以逐级表示为特定位置和角度的边缘、由边缘组合得出的花纹、由多种花纹进一步汇合得到的特定部位的模式等。最终，模型能够较容易根据更高级的表示完成给定的任务，如识别图像中的物体。值得一提的是，作为表征学习的一种，深度学习将自动找出每一级表示数据的合适方式。

因此，深度学习的一个外在特点是端到端的训练。也就是说，并不是将单独调试的部分拼凑起来组成一个系统，而是将整个系统组建好之后一起训练。比如说，计算机视觉科学家之前曾一度将特征抽取与机器学习模型的构建分开处理，像是 Canny 边缘探测 [20] 和 SIFT 特征提取 [21] 曾占据统治性地位达 10 年以上，但这也就是人类能找到的最好方法了。当深度学习进入这个领域后，这些特征提取方法就被性能更强的自动优化的逐级过滤器替代了。

相似地，在自然语言处理领域，词袋模型多年来都被认为是不二之选 [22]。词袋模型是将一个句子映射到一个词频向量的模型，但这样的做法完全忽视了单词的排列顺序或者句中的标点符号。不幸的是，我们也没有能力来手工抽取更好的特征。但是自动化的算法反而可以从所有可能的特征中搜寻最好的那个，这也带来了极大的进步。例如，语义相关的词嵌入能够在向量空间中完成如下推理：“柏林-德国 + 中国 = 北京”。可以看出，这些都是端到端训练整个系统带来的效果。

除端到端的训练以外，我们也正在经历从含参数统计模型转向完全无参数的模型。当数据非常稀缺时，我们需要通过简化对现实的假设来得到实用的模型。当数据充足时，我们就可以用能更好地拟合现实的无参数模型来替代这些含参数模型。这也使我们可以得到更精确的模型，尽管需要牺牲一些可解释性。

相对其它经典的机器学习方法而言，深度学习的不同在于：对非最优解的包容、对非凸非线性优化的使用，以及勇于尝试没有被证明过的方法。这种在处理统计问题上的新经验主义吸引了大量人才的涌入，使得大量实际问题有了更好的解决方案。尽管大部分情况下需要为深度学习修改甚至重新发明已经存在数十年的工具，但是这绝对是一件非常有意义并令人兴奋的事。

最后，深度学习社区长期以来以在学术界和企业之间分享工具而自豪，并开源了许多优秀的软件库、统计模型和预训练网络。正是本着开放开源的精神，本书的内容和基于它的教学视频可以自由下载和随意分享。我们致力于为所有人降低学习深度学习的门槛，并希望大家从中获益。

5.6 1.5. 小结

-机器学习研究如何使计算机系统利用经验改善性能。它是人工智能领域的分支，也是实现人工智能的一种手段。
-作为机器学习的一类，表征学习关注如何自动找出表示数据的合适方式。
-深度学习是具有多级表示的表征学习方法。它可以逐级表示越来越抽象的概念或模式。
-深度学习所基于的神经网络模型和用数据编程的核心思想实际上已经被研究了数百年。
-深度学习已经逐渐演变成一个工程师和科学家皆可使用的普适工具。

5.7 1.6. 练习

-你现在正在编写的代码有没有可以被“学习”的部分，也就是说，是否有可以被机器学习改进的部分？
-你在生活中有没有这样的场景：虽有许多展示如何解决问题的样例，但缺少自动解决问题的算法？它们也许是深度学习的最好猎物。
-如果把人工智能的发展看作是第一次工业革命，那么深度学习和数据的关系是否像是蒸汽机与煤炭的关系呢？为什么？
-端到端的训练方法还可以用在哪里？物理学，工程学还是经济学？
-为什么应该让深度网络模仿人脑结构？为什么不该让深度网络模仿人脑结构？

2016 年 3 月 10 日，AlphaGo 登上了各大头条。谷歌研发的人工智能出乎大众意料，打败了围棋界公认的最优秀棋手之一李世石。围棋与国际象棋一样，也是一种两人游戏。然而一直以来，围棋之于国际象棋，就像国际象棋之于井字棋。围棋更复杂，组合更多，也更难以预计。最优秀的围棋棋手有时候甚至会依靠某种直觉，但他们也无法解释这些直觉的来源——有些人甚至断言，这是一种超越机器能力的人类智能。长期以来，最优秀的算法也只能勉强追上中等水平的围棋棋手。

但在数年之间，某种机器学习的模型接连取得了不同凡响的成绩。物体识别、人脸识别、光学字符识别、自然语言处理、自动化翻译以及推荐系统从前都是机器无法解决的问题，但突然之间，它们全部都被深度学习解决了。硅谷的所有投资者挂在嘴边的就只剩下这几个词语，所有网络巨头都开始吹嘘自己现在能够提供些什么新服务。深度学习那引发轰动的成功与经典软件工程的众多方法形成了鲜明的对比。人们习惯先构筑一个理论，用来保证某项技术能正确运作；然后，人们就会沮丧地发现技术超出了理论。这就引发了下面这个永恒的问题：理论和实践之间的差距从何而来？有一句俏皮话是这样说的：“理论上它们是一样的，但是在实践中嘛……”但深度学习的情况似乎与此正好相反。似乎没有任何理论能够预言我们手头上的这项技术会取得成功。理论研究者被打了个措手不及。深度学习的性能简直好得离谱，但似乎没有人知道为什么。深度学习在实践中效果很好，但它在理论上是否可行？这次，实干家对这个问题感兴趣，是因为他们也感觉到，深度学习在理论理解上取得的任何进步，都有可能显著地甚至戏剧性地推动人工智能的发展。

特征学习在深度学习大获成功之前，专业的数据科学家必须干预机器学习的算法，为的是对原始数据进行“清理”，预先简化数据的分析。深度学习研究的主要动机之一就是希望将数据预处理自动化，绕过对数据科学家技能的需求。这种做法让深度学习成为一把瑞士军刀，能够适应各种媒介，无论是图像、音频、视频、文字还是其他实时传感器的探测结果。

人工神经网络的灵感其实来自我们的大脑皮层。这是因为神经科学发现，我们的大脑会通过逐步抽象的方式来分析眼睛所看到的事物。眼睛中的传感器又被称为视锥细胞和视杆细胞，它们会探测那些令其进入激发状态的光线，得到光线的亮度和颜色。计算机科学家会说，这相当于图像中每一个像素的亮度和颜色。我们赋予深度神经网络的可观测变量的，正是这种原始数据。然后，负责计算的第二层神经元一般会衡量相邻像素之间的相关度。人类的第二层神经元都会连接着眼睛的几个视锥细胞和视杆细胞。

人工智能的前沿就是所谓的卷积神经网络 (convolutionneuralnetwork，简称 CNN，因为它们与数学中的卷积运算有关)。这些网络的灵感就是来自视皮层的大体结构。图像分析的性能似乎依靠的正是这种抽象层次的堆积，而只有深度足够大的网络才能做到这一点。

单词的向量表示人们在自然语言处理的经验中也发现了类似的现象。自然语言处理的难点之一就是含有大量的自然语言词汇。与其让单一的神经元专门负责每一个词语的理解，不如通过每个词语与其他词语之间的关系来理解它们。奇怪的是，用数学的语言来说，要做到这一点，我们可以将词语组成的空间嵌入高维线性空间中，这个维度一般来说在 50 和 100 之间。用不那么晦涩的语言来说，每一个词语都会对应着多个神经元的某个激活组合。2013 年，一个由托马斯·米科洛夫领导的谷歌研究团队成功让神经网络学会了之前说的这种英语单词的神经元表达，这是一项引人注目的成就。他们将这种表达称为 word2vec。这种表达能以前述的方式将所有英语单词转换为高维空间中的向量。人们借此对所有单词组成的集合在表示方式上进行精简与结构化，因为从信息的角度来看，单词的向量表示更紧凑，仅需更少的比特数就能描述。但好处不止于此！单词的向量表示还能解释单词之间的众多联系。的确，米科洛夫研究团队的重大发现之一，就是单词之间的向量加法符合我们的直觉。比如，他们发现如果进行皇帝-男人 + 女人的向量运算的话，得到的结果大概就是皇后这个词语的向量表达 [2]！更令人着迷的是，我们在 GAN 中也能观察到这种现象。收集一些戴太阳镜的人的图像和没戴太阳镜的人的图像，你可以利用 GAN 计算出戴太阳镜的人对应的向量平均值以及没戴太阳镜的人对应的向量平均值。然后将这两个向量相减，得到的差就是某个向量，从直觉上来说，它对应着“戴太阳镜”。现在考虑一张没戴太阳镜的人的图像，计算它的向量表示，然后加上“戴太阳镜”的向量表示，就得到了一个新向量。现在利用 GAN 生成这个向量的对应图像。令人惊叹的是，得到的图像就是原来的图像中的人戴上了眼镜 [3]！真是难以置信！神经网络对不同抽象概念的向量求和结果的诠释竟然如此契合大脑对这些概念的直觉组合。

据此，能够阅读实体书的神经网络应该是一个深度神经网络，其中前几层是卷积神经网络，能够识别图像中的字符。然后，在负责视觉的这几层神经元之下，我们会发现一层能将字符合并为词语的神经元，以及另一层将词语转化为向量的神经元，就像 word2vec 所做的那样。最后，还有几层神经元负责解释那些表示词语的向量，将它们与其他概念联系起来。这些概念可以来自对图像或者其他信号的额外分析。因此，高效的深度神经网络在看到猫的照片或者读到“猫”这个词语的时候，应该能够激活同一组神经元。为此，对原始数据的预处理似乎至关重要。一般来讲，对于原始数据的概括来说，无论是为了压缩体量宏大的原始数据，让计算能够在合理的时间内完成，还是为了揭示原始数据中相关性的切实解释，网络深度似乎都必不可少。

指数式的表达能力 * 2016 年 6 月 16 日, 美国斯坦福大学、美国康奈尔大学以及谷歌大脑 (GoogleBrain) 的合作研究人员在 arXiv 上传了两篇非同凡响的论文。我被它们对抽象方法所获成功的别样解释深深迷住了。在本书中, 我只能描述其中于我而言最有吸引力的那一篇。这篇论文题为《深度神经网络中经由暂态混沌出现的指数性表达能力》(“Exponential Expressivity in Deep Neural Networks through Transient Chaos”)。它结合了大量复杂、高深却鲜有联系的数学概念, 比如混沌理论、平均场论和几何曲率。我们慢慢解释。这篇论文一开头就认为, 神经网络不过是一个复杂的数学函数。这个函数以一组测量数据作为输入, 然后将其转化为深度概念的组合。测量数据的集合在数学上组成了一个所谓的向量, 我们可以将它看成极高维度的空间中的一个点。而深度概念的组合也是如此, 它本身就是极高维度的空间中的一个点。这样的话, 神经网络就可以被看成从第一个空间到第二个空间的几何变换。这篇论文提出的问题如下: “典型”的神经网络是如何将空间变形的? 一个“随机选取”的神经网络平均而言是不是会将这些点到处移动? 还是说, 它会在变换中保留曲线的某些几何特性? 这篇论文的回答引人深思: 几何结构的复杂度会随着神经网络深度的增加呈指数增长。更准确地说, 论文研究了几何图形的全局曲率³。从直觉上来说, 圆就是弯曲程度最小的闭合图形, 因为它的弯曲是为了回到自己的出发点。此外, 无论圆的大小如何, 它的全局曲率总是等于 $\tau \sim 6.28$ 。反之, 一条在空间中的所有维度上都反复摆动的精细曲线会拥有非常大的全局曲率。(MW: 傅里叶变换和曲率的关系: 全局曲率越大, 所需要的傅里叶级数越多, 图形越复杂)³ 全局曲率就是曲线方向上单位向量导数的范数的积分。这篇论文证明了, 对于足够“激动”的随机神经网络, 几何图形的曲率会随着网络宽度的增长而呈多项式函数上升, 并随着深度的增长呈指数上升。换句话说, 比起宽度, 网络的深度能让神经网络以更快的速度使对应的几何变换变得更复杂。所以, 这说明深度是识别与分析分形结构的关键, 分形结构代表的就是那些并不总是光滑且正则的行为。然而, 在我们周围的这个世界之中, 分形结构似乎无处不在 [4], 无论是在生物学、宇宙学还是金融之中! 同样, 即使这种说法看似抽象甚至荒谬, 但在所有图像组成的浩瀚集合之中, 所有包含猫的图像组成的集合很可能同样有着分形结构。因此, 网络的深度可能就是识别图像中有没有猫的关键, 对于众多更复杂的任务来说也是如此。

5.8 1. 引言

自古以来, 人类对于自身大脑的探索从未停止。大脑, 这个复杂而精密的器官, 不仅赋予了我们思考、感知和学习的能力, 更让我们在漫长的进化过程中脱颖而出, 成为地球上最智慧的生物。然而, 尽管科学家们已经取得了许多关于大脑结构和功能的重大发现, 但大脑的工作机制仍然充满了未知和神秘。

在大脑的探索之旅中, 一个尤为引人注目的领域是神经网络。神经网络, 特别是人脑中的神经网络, 是一个由数以亿计的神经元通过突触相互连接而成的庞大网络。这些神经元和突触不仅负责传递和处理信息, 还通过复杂的交互作用, 实现了我们的各种感知、思考和行为。

受到人脑神经网络的启发, 科学家们开始尝试构建人工神经网络 (Artificial Neural Networks, ANNs), 以模拟大脑的信息处理过程。

人工神经网络 4 大理论支柱为“阈值逻辑”、“Hebb 学习率”、“梯度下降”、“反向传播”, 前 2 个理论解决了单个神经元层面的建模问题, 后 2 个理论则解决了多层神经网络训练问题。

2006 年 Hinton 首次实现了 5 层神经网络的训练, 之后行业迎来爆发式发展, 不断验证了该技术。

深度学习具备坚实的数学理论基础支撑。人脑绝大多数活动本质上都是广义计算问题, 因此人脑其实是一个复杂的函数, 深度学习就是去找到这个函数, 万能近似定理则从数学上证明了一定条件下深度神经网络模型能够模拟任意的函数。用于深度学习的算力以 6 年 30 万倍的速度增加, 算力是核心瓶颈也是未来提升的关键。从进化角度看, 人的智能是一个随着神经元数量提升, 从量变到质变的过程, 这个量变过程对应人工智能中模型所用算力的提升过程。目前能够实现的 AI 模型中不论从神经元个数还是连接数量看, 与真实人类还有较大的差距, 未来随着现有芯片技术的不断推进, 和突破冯诺依曼架构的类脑芯片等新技术的发展, 算力的持续突破将会不断释放人工智能技术的潜力。

面对大数据的人类大脑

这些算法似乎都离日常生活非常遥远。你可能会说你能够一一记住自己接收的所有数据, 但这就错得离谱了。

人们可能从未察觉，每时每刻充斥我们大脑皮层的数据量大得可怕，有如 CERN 需要处理的数据量。我们的视觉、听觉、嗅觉、触觉、温度感觉，以及其他数不清的感觉，每秒都会向我们传输大约十亿字节 (1GB) 的数据 [4]。如果我们把数十年间收集到的数据累计起来的话，我们会发现感官接收到的数据总量需要用百亿亿字节 (EB) 作为计量单位！这可以说是大得可怕。

与现代信息技术面对的情况类似，我们的大脑也无法储存自身接收到的所有数据。它也不想这样做，因为其中绝大部分数据没有意义，它不得不忘记绝大部分数据。

在视觉数据的处理中，这种状况尤其突出。据神经科学家马库斯·赖希勒所言 [5]，我们的视皮层拥有惊人的能力，可以将十亿字节的视觉数据转换为几千字节的有用数据，这种处理在每一秒都在进行，而且只需要消耗极少的能量 [footnote 视觉]。[footnote 视觉]：赖希勒估计，我们的视网膜每秒会收集到大约 10^{10} 比特的数据，但到达初级视皮层的第四层的数据只有大约 10^4 比特。

在更普遍的意义上，大脑会优先保留数据的“大体概念”，而不是具体细节。一般来说，我敢打赌你不能背出这本书前 15 章中的任意一句话。但在我的期望中，你应该记住了这些章节讨论的是贝叶斯公式、它的逻辑基础、它在归纳推理问题上的应用、它的历史、所罗门诺夫及其在博弈论中的应用，甚至还有它与演化理论之间的联系。即使你可能没有记住读到的任何一个句子，但我仍然希望你记住了读到的文字中各种基础概念的抽象表达。

对于接收到的信息只保留压缩过后的表示，这种能力并非弱点，而正是大脑的强大之处。我们一般都能够回忆起那些重要的事物，而且完全忘却那些对我们来说无足轻重的东西。

用贝叶斯帮助记忆我们之前看到，人类大脑令人叹服的地方之一，就是它将极大量原始数据压缩为寥寥几个想法的能力。受此启发，人工智能研究者发明了自编码器这一架构。自编码器的任务，就是对大量信息进行精简，这些信息可以是高分辨率的图像或者整部电影，等等，最终只留下内容的精髓。换句话说，这些神经网络尝试做到的，正是我们在语文课上被要求做的一种练习：撰写摘要。为了测试摘要的质量，人们也要求自编码器对自己生成的摘要进行解压缩，设想与这一摘要相关的高分辨率图像或其他原始数据是什么样子的。要做到这一点，关键之一就是利用贝叶斯方法。对数据重组，其实就是确定什么数据会得出眼前这个摘要。这正是贝叶斯公式的典型应用！我们需要确定这个摘要的可能原因，因此

<!-- [截屏 2024-09-0418.50.53](/Users/Min369/Downloads/同步空间/Obsidian/书/截屏 2024-09-0418.50.53.png)

-->

另外，我们在下一章也会看到人工智能研究者如何利用这一公式，引入不常见的摘要，向机器赋予了创造性。

短期记忆与长期记忆

金特和朱莉娅·肖研究的是长期记忆。其中，信息被储存在大脑皮层这一神经网络的拓扑结构之中。问题在于访问这些数据可能很困难，需要测试信号在网络中传播的各种可能方式。回忆一首有名的歌曲的歌词一般来说就是这样的情况。在刚开始回忆时，我们通常想起几个词之后就就想不起来了，就好像大脑中电信号的流动停滞了，或者流向了错误的方向一样。然而在重复这种流动之后，我们最终仍能找到正确的道路，回忆起整首歌曲的歌词。

人们在大型数据库中搜寻信息的时候也会碰到同样的问题。给谷歌和其他公司带来巨大财富的事物之一，就是为了加速信息搜索而整合互联网数据的方法。但这并不只是信息整合的问题，人们也经常要在储存容量和存储速度之间对储存信息的媒介进行取舍。

递归神经网络

无论如何，人工神经网络的研究选择了第三条道路：神经信号的环路传播。包含这种环路的神经网络架构又叫递归神经网络。在处理当前数据时，这种网络能够利用前一时刻的部分信息。对于处理本质上有时序特性的数据，比如书中的文本或者讲话中的声音，递归神经网络已经成为最尖端的技术。

递归神经网络用到的技巧也包含在一类更广泛的拥有内部状态的算法之中。值得一提的是，这一类算法包括之前谈到的卡尔曼滤波器和隐马尔可夫模型。内部状态的任务就是以精练的方式提取出前一时刻的信息，用以更好地理解前一个被分析的数据。然而另一个问题就是，与数据读取相比，内部状态会以什么样的速度变化。我有幸在自己学习数学和指导学生学习的过程中都观察到了一点东西。第一次读一份文献时（比如说你正在看的

这本书)，最好不要停留在细节上，以免偏离阅读的主线。因为如果读得太慢，换种说法，就是对于短期记忆这一内部状态修改得太多的话，会使思绪偏离文献想让我们思考的东西。因此，有时候先迅速浏览一遍，再多花点时间细细阅读，最后再速读一遍，这样可能效果更好。每一次阅读都会带来新的东西，因为每一次阅读都联系着短期记忆这一内部状态的不同变化动态。到这里为止，我们讨论的还是对数据的线性阅读，但我们阅读或者聆听的方式并非完全线性的。的确，当某个句子非常晦涩的时候，我们一般会重读几次，然后才继续线性阅读。同样，有时候如果别人一句话还没说完，我们就无法理解。在梵语、印地语和日语中，动词位于句末，所以这种情况尤其显著。同样道理，在数学论文中，计算过程之后通常会有对计算的解释。还有些笑话、广告和电影，正是结尾决定了它们的意义。

为了同时利用过去和未来的数据理解现在，人们提出了另一种神经网络架构，那就是所谓的双向递归神经网络。为了将未来纳入其中，这些网络必须延长得出回应的时间。我们可以打赌，人类大脑中也有类似的结构。这也能解释我们在经过一段延迟之后才理解笑话的能力，甚至有时候这种延迟本身就引人发笑。

最后，人工智能领域的一项最新进展就是引入了迫使遗忘的神经元件。那就是所谓的 LSTM 架构，意思是“长短期记忆” (long-short-term memory)。除了递归神经网络中常见的那些神经元环路之外，LSTM 还拥有另一个额外的环路，它激活的时候会强制让所有神经元环路中的信号消失。这也许就解释了为什么我们在讨论中被打断之后，有时候很难回想起之前讨论的话题。

目前，在处理本质上有时序特性的数据方面，比如语音识别、自然语言分析，等等，LSTM 及其变体似乎就是最尖端的人工智能方法。但我承认自己不理解它为何如此成功，我也承认自己没有足够的专业水平来预测这些领域未来的前沿进展。

5.9 2. 背景

5.9.1 第一阶段

1943 年，美国神经生理学家沃伦·麦卡洛克和数学家沃尔特·皮茨对生物神经元进行建模，首次提出了一种形式神经元模型。这个神经元模型通过电阻等元件构建的物理网络得以实现，被称为 M-P 模型。1958 年，罗森布拉特又提出来了感知器，这意味着经过训练后，计算机能够确定神经元的连接权重。就这样，神经网络的研究迎来了第一次高潮。然而在 1969 年，明斯基等人指出感知器无法解决线性不可分问题，使得神经网络的研究陷入了第一次低谷。

5.9.2 第二阶段

1986 年，Rumelhart(鲁梅尔哈特)等人提出了误差反向传播算法通过设置多层感知器，解决了线性不可分问题。从反向传播算法的发表开始，神经网络迎来第二次高潮。1989 年，Yann Lecun 等研究人员实现了一个 7 层的卷积神经网络 LeNet-5，识别手写数字的精度达到了 98

5.9.3 第三阶段

2006 年，Hinton(辛顿)等人利用限制玻尔兹曼机对神经网络的连续层进行建模，使用逐层预训练的方法抽取模型数据中的高维特征，后来又提出了深度信念网络。这一技巧随后被众多学者推广到了许多不同的神经网络架构上，大大地提高了模型在测试集上的泛化效果。同时，随着硬件计算能力和算法的提升，网络隐层可以不断增加，于是以 Hinton 为代表的研究人员重新将人工神经网络定义为深度学习人工神经网络定义为深度学习，并进行推广。自 2011 年起，神经网络就在语音识别和图像识别基准测试中获得了压倒性优势，由此迎来了它的第三次高潮。

5.9.4 3. 结构

![[R-C](file:///Users/Min369/Library/Group

三个层次：输入层、隐藏层和输出层

输入层是神经网络的基层，它负责接收外界的输入数据。这些数据可以是图像、声音、文本等各种形式，经过预处理后转换成神经网络能够接受的形式。隐藏层是神经网络的核心部分，它由多个神经元组成，负责处理输入数据并传递到下一层。隐藏层的设计和数量需要根据具体的任务来确定，它们的作用是对输入数据进行分类或预测。输出层是神经网络的最高层，它负责将隐藏层处理后的结果转换成实际输出

圆形节点与人工神经元：

在人工神经网络中，每个圆形节点代表一个人工神经元。这些神经元通过特定的连接方式相互交互，模拟生物神经网络的工作原理。

连接与信号传递：

箭头表示从一个神经元的输出到另一个神经元的输入的连接。通过这些连接，信号可以在网络中传递，从一个人工神经元传递到另一个。

权重与激活函数：

每个节点都代表一种特定的输出函数，称为激活函数。每两个节点间的连接都有一个与之相关的权重值，表示前一个神经元对后一个神经元的影响程度。

网络输出：

网络的输出会根据网络的连接方式、权重值以及激励函数的不同而变化。通过调整这些参数，人工神经网络能够学习和适应不同的输入模式，产生预期的输出结果。

5.9.5 4. 如何训练

4.1 简介

反向传播算法（Backpropagation）是目前用来训练人工神经网络（Artificial Neural Network, ANN）的最常用且最有效的算法。其主要思想是：

(1) 将训练集数据输入到 ANN 的输入层，经过隐藏层，最后达到输出层并输出结果，这是 ANN 的前向传播过程；

(2) 由于 ANN 的输出结果与实际结果有误差，则计算估计值与实际值之间的误差，并将该误差从输出层向隐藏层反向传播，直至传播到输入层；

(3) 在反向传播的过程中，根据误差调整各种参数的值；不断迭代上述过程，直至收敛。

4.2 数学推导

1. 变量定义

先定义一些变量：

2. 代价函数

代价函数被用来计算 ANN 输出值与实际值之间的误差。常用的代价函数是二次代价函数(Quadratic cost function)：

其中， x 表示输入的样本， y 表示实际的分类，

3. 公式及其推导

本节将介绍反向传播算法用到的 4 个公式，并进行推导。如果不想了解公式推导过程，请直接看第 4 节的算法步骤。

公式 1（计算最后一层神经网络产生的错误）：

其中，

首先看上面证明的第一行，我们知道损失函数的形式，输出层的每一个输出都能够看作是损失函数的一个变量。

要是不理解的话，假设我们这里的损失函数为之前提到过的二次函数

在神经网络里面可以写为上面的形式，因为一个网络的输出就是最后一层的输出。这下能不能够明显的理解上面的那句话了呢？

那么证明第一行就是通过链式法则得到的。

然后只有和是有依赖关系的，其他的没有依赖关系的求导为 0 不见了，因此，只剩下第二行。第二行出来了，又因为，那么后面的也就都容易推出来了。

公式 2（由后往前，计算每一层神经网络产生的错误）：

推导过程：

通过这个公式，只要我知道 $l+1$ 层的误差，那么我就能够知道 l 层的误差，由此，我就能够倒退直到第 1 层的误差。这个式子就体现了误差的反向传播的特点。然后公式 1 和公式 2 结合起来，我们就能够求出神经网络中任何一层，任何一个神经元上面的误差。

公式 3（计算权重的梯度）：

推导过程：

这个公式告诉我们，某个神经元上面误差对于偏置的偏导要等于在这个神经元上面的误差。而我们之前已经说过了，我们要求梯度的话就需要求出这些偏导，现在通过误差间接得到了偏导。很巧妙。

公式 4（计算偏置的梯度）：

推导过程：

4. 反向传播算法伪代码

输入训练集

对于训练集中的每个样本 x ，设置输入层（Inputlayer）对应的激活值：

前向传播：

计算输出层产生的错误：

反向传播错误：

使用梯度下降（gradientdescent），训练参数：

4.3 激活函数

激活函数（ActivationFunction），就是在[人工神经网络](https://baike.baidu.com/item/人工神经网络/382460)的神经元上运行的[函数](https://baike.baidu.com/item/函数/301912)，负责将神经元的输入映射到输出端，旨在帮助网络学习数据中的复杂模式。

常见类型：ReLU、Sigmoid、Tanh

Sigmoid 激活函数的数学表达式为：

导数表达式为：

函数图像如下：

tanh 激活函数的数学表达式为：

函数图像如下：

实际上，Tanh 函数是 sigmoid 的变形：

与 sigmoid 不同的是，tanh 是“零为中心”的。因此在实际应用中，tanh 会比 sigmoid 更好一些。但是在饱和和神经元的情况下，tanh 还是没有解决梯度消失问题。

什么情况下适合使用 Tanh？

tanh 的输出间隔为 1，并且整个函数以 0 为中心，比 sigmoid 函数更好；

在 tanh 图中，负输入将被强映射为负，而零输入被映射为接近零。

Tanh 有哪些缺点？

仍然存在梯度饱和的问题

依然进行的是指数运算

ReLU 激活函数的数学表达式为：

函数图像如下：

什么情况下适合使用 ReLU？

ReLU 解决了梯度消失的问题，当输入值为正时，神经元不会饱和

由于 ReLU 线性、非饱和的性质，在 SGD 中能够快速收敛

计算复杂度低，不需要进行指数运算

ReLU 有哪些缺点？

与 Sigmoid 一样，其输出不是以 0 为中心的

DeadReLU 问题。当输入为负时，梯度为 0。这个神经元及之后的神经元梯度永远为 0，不再对任何数据有所响应，导致相应参数永远不会被更新

训练神经网络的时候，一旦学习率没有设置好，第一次更新权重的时候，输入是负值，那么这个含有 ReLU 的神经节点就会死亡，再也不会被激活。所以，要设置一个合适的较小的学习率，来降低这种情况的发生

4.1 人工神经网络在各个领域中的应用

5.9.6 人工神经网络在信息领域中的应用

在处理许多问题中，信息来源既不完整，又包含假象，决策规则有时相互矛盾，有时无章可循，这给传统的信息处理方式带来了很大的困难，而神经网络却能很好的处理这些问题，并给出合理的识别与判断。

1. 信息处理

现代信息处理要解决的问题是很复杂的，人工神经网络具有模仿或代替与人的思维有关的功能，可以实现自动诊断、问题求解，解决传统方法所不能或难以解决的问题。人工神经网络系统具有很高的容错性、鲁棒性及自组织性，即使连接线遭到很高程度的破坏，它仍能处在优化工作状态，这点在军事系统电子设备中得到广泛的应用。现有的智能信息系统有智能仪器、自动跟踪监测仪器系统、自动控制制导系统、自动故障诊断和报警系统等。

2. 模式识别

模式识别是对表征事物或现象的各种形式的信息进行处理和分析，来对事物或现象进行描述、辨认、分类和解释的过程。该技术以贝叶斯概率论和申农的信息论为理论基础，对信息的处理过程更接近人类大脑的逻辑思维过程。现在有两种基本的模式识别方法，即统计模式识别方法和结构模式识别方法。人工神经网络是模式识别中的常用方法，近年来发展起来的人工神经网络模式的识别方法逐渐取代传统的模式识别方法。经过多年的研究和发展，模式识别已成为当前比较先进的技术，被广泛应用到文字识别、语音识别、指纹识别、遥感图像识别、人脸识别、手写体字符的识别、工业故障检测、精确制导等方面。

5.9.7 人工神经网络在医学中的应用

由于人体和疾病的复杂性、不可预测性，在生物信号与信息表现形式上、变化规律（自身变化与医学干预后变化）上，对其进行检测与信号表达，获取的数据及信息的分析、决策等诸多方面都存在非常复杂的非线性联系，适合人工神经网络的应用。目前的研究几乎涉及从基础医学到临床医学的各个方面，主要应用在生物信号的检测与自动分析，医学专家系统等。

1. 医学专家系统

传统的专家系统，是把专家的经验 and 知识以规则的形式存储在计算机中，建立知识库，用逻辑推理的方式进行医疗诊断。但是在实际应用中，随着数据库规模的增大，将导致知识“爆炸”，在知识获取途径中也存在“瓶颈”问题，致使工作效率很低。以非线性并行处理为基础的神经网络为专家系统的研究指明了新的发展方向，解决了专家系统的以上问题，并提高了知识的推理、自组织、自学习能力，从而神经网络在医学专家系统中得到广泛的应用和发展。在麻醉与危重医学等相关领域的研究中，涉及到多生理变量的分析与预测，在临床数据中存在着一些尚未发现或无确切证据的关系与现象，信号的处理，干扰信号的自动区分检测，各种临床状况的预测等，都可以应用到人工神经网络技术。

5.9.8 人工神经网络在交通领域的应用

近年来人们对神经网络在交通运输系统中的应用开始了深入的研究。交通运输问题是高度非线性的，可获得的数据通常是大量的、复杂的，用神经网络处理相关问题有它巨大的优越性。应用范围涉及到汽车驾驶员行为的模拟、参数估计、路面维护、车辆检测与分类、交通模式分析、货物运营管理、等领域并已经取得了很好的效果。

4.2 人工神经网络应用和卷积对比

随着科技的快速发展，深度学习已经成为了人工智能领域的重要分支。在深度学习中，卷积神经网络 (CNN) 和人工神经网络 (ANN) 是两种最为常见的网络类型。它们在结构和应用上存在一些显著的区别。本节将对比分析 CNN 和 ANN 的区别，并通过实例阐述两者的应用。

CNN 和 ANN 的区别主要体现在两个方面：结构和应用。首先，从结构上看，CNN 侧重于处理图像数据，它的卷积层和池化层能够有效降低参数的数量，提高网络的性能；而 ANN 则没有这种结构上的限制，可以自由地设计神经网络结构来解决不同的问题。其次，从应用上看，CNN 在处理图像任务时表现出色，如图像分类、目标检测等；而 ANN 则更加通用，可以应用于各种类型的数据和任务。在应用案例方面，CNN 和 ANN 各有优势。例如，在 [图像识别](https://cloud.baidu.com/product/imagerecognition) 任务中，CNN 可以通过学习自动提取图像的特征，从而实现高效的图像分类。相比之下，ANN 需要手动设计特征，因此在这方面的表现可能不如 CNN。然而，在某些复杂的任务中，如 [自然语言处理](https://cloud.baidu.com/product/wenxinworkshop) (NLP)，ANN 则可能更有优势。ANN 可以通过构建深层神经网络，学习和理解语言的复杂模式和结构，从而实现高效的文本分类和语言翻译等任务。

猫是什么？2012 年，谷歌因一条奇怪而又令人不安的公告登上了各大新闻头条。据这些头条所说，谷歌的人工智能发现了“猫”这个概念 [9]！很多人可能觉得这是个平平无奇的新闻，但对我来说，这是机器学习的一个里程碑式的惊人突破，可能比 AlphaGo 在四年之后大败李世石给人留下的印象更深刻、更出人意料。要理解这一点，首先要说明谷歌的人工智能是一个人工神经网络，带有一些接收器，让它可以“看见”数字化图像。谷歌给这个人工神经网络展示了 1000 万幅图像，其中不包含上下文。然后，谷歌将这个人工神经网络放进某种相当于核磁共振成像的处理系统中，用以测量它暴露在其他图像中的时候神经元的实时激活状态。谷歌意识到其中某些神经元大体上当且仅当向其展示的图像包含一只猫时才会激活！真正给人留下深刻印象的是，这并不是谷歌在设计这个人工智能的时候设定的目标。这个人工智能的目标是以最合理有效的方式分析、处理并解释图像中的内容。人工智能必须为它看到的那些图像建立一个模型。为此，它必须做的事情之一就是解释图像中某些像素颜色之间反复出现的相关性。比如说，当图像中的某些像素构成了眼睛的形状，那么在它的左边或者右边不远处通常会有一份与这些像素相似的复制品。一只眼睛的图像通常伴随着另一只眼睛的图像。怎么解释眼睛很少单独出现这一点呢？最惊人的其实是，这个问题的解释似乎大体符合我们之中大多数人会给出的答案：因为照片拍到的动物通常有两只眼睛。人、狗和猫（几乎）都拥有两只眼睛这个事实对我们来说似乎如此微不足道，人们几乎不会对它花上任何时间进行思考。我们是如此习惯于日常生活中的事物，以至于我们甚至不再寻求解释——但这其实是个迷人的生物学问题，需要对视差的数学理解！但对我来说更迷人的，我们竟然可以（大体上）对于什么是人、什么是猫、什么又是狗达成共识。我们甚至没有意识到这些概念既抽象又模糊！猫是什么？怎么定义猫这个概念？更重要的是，猫存在吗？要理解“猫”这个概念的奇怪之处，我们可以先强调这个定义有多么模糊。人们一般认为猫就是两只猫交配后产生的东西，换句话说，猫的双亲都是猫。到这里为止还没有什么惊人的东西，甚至这可能还是非常显然的东西。但其中大有深意。比如说现在有一只猫，它的双亲都是猫，它的双亲的双亲也是猫，它的双亲的双亲的双亲也是猫，以此类推。但是这种对时间的回溯并没有尽头！根据这种推理，我们必须回溯生命演化树，到达猫还没有出现的年代！的确，如果我们回溯到几亿年甚至几十亿年前，我们会到达一个没有哺乳动物、脊椎动物，甚至连真核生物都不存在的时代！猫的双亲都是猫，或者说猫就是两只猫交配后产生的东西，这些说法在逻辑上就有矛盾 [10]。我预计到有些读者会提出用 DNA 的概念来定义猫这个概念。然而这会导致几个问题。首先，我们还没有对猫的所有基因组进行测序，而我们可能永远无法对所有猫的基因组进行测序，因为未来的猫现在还没有出生！所以怎么定义一组与猫对应的 DNA 代码并不是一个显然的问题。其次，即使我们成功做到了这一点，还要对动物进行基因组测序才能断定它是不是猫，这个解决方案在

现实中完全不可行。再次，人们也许会严肃地考虑，包含猫的全套 DNA 的一个单独的猫细胞，比如猫毛中的细胞，它算不算一只猫？最后也是最重要的一点就是，DNA 这个概念在大约半个世纪之前完全不存在。往好了说，这意味着薛定谔、达尔文和亚里士多德在谈论猫的时候其实不知道自己在说什么。我们必须理解这个显而易见的事实：“猫”这个词并没有一个令人满意的严谨的定义。如果我问你猫是什么，你无法给出一个普遍适用、毫无争议的定义。而这不是什么惊人的事情，毕竟你不是通过这种方式学到怎么认知并使用“猫”这个概念的！如果你大概知道猫是什么，那是因为你已经看过上千张甚至上百万张猫的图像，你也听说过猫，也读过有关猫的材料。你通过观察大量数据学到了猫是什么。但你从来没有看见过关于“猫是什么”的形式定义！实际上，在人类历史中，没有人知道怎么给出“猫是什么”的形式定义。还有更神奇的。必定存在第一个想到“猫”这个概念的人。因为这个人是第一个想到这个概念的，不会有人教他这一点，所以这个人就自己发明了“猫”这个概念。为什么？他又是怎么做到的？人类引入的新概念从何而来？这种能力是人类智慧特有的吗？我觉得谷歌人工智能的发现非常震撼人心，因为它给出了这些问题的答案。不，这并非人类智慧特有的能力，因为谷歌的神经网络同样做到了这一点。而它做到这一点是因为它希望分析、综合并解释数字化图像中不同像素颜色之间的相关性，它希望得到一个模型来描述自己看到的東西，而它找到的模型自然导致了“猫”这个概念的诞生！

正确问题的近似解答的价值远远大于错误问题的精确解答的价值。——约翰·图基 (1915—2000) 真理 (.....) 实在过于复杂，除了近似以外都不可行。——约翰·冯·诺伊曼 (1903—1957)

无穷计算在数学里遍地都是。这些计算中最著名的可能是周角率 (它与历史上“喧宾夺主”的圆周率 [2] 的关系是)。在 14 世纪，伟大的印度智者摩陀婆就发现了一个惊人的等式的交错和的 8 倍！；也就是说，周角率不过就是奇数倒数我们可能会认为这种无穷计算毫无用处。但事实上，无穷计算在应用数学的简单模型中无处不在，流体力学方程 (导数和积分都是无穷步的计算结果) 就是一个例子。这是因为，即使无穷计算只代表了一种不可计算的理想情况，但它一般能指出进行近似计算的巧妙方法。比如摩陀婆的等式就能用于计算的近似值，也就是说，它可以用于计算半径已知的圆的周长。工程师在实践中使用的正是这类近似方法。如果你在常用的计算器或者谷歌上查询的值，它们很有可能会撒一点小谎，只给你提供小数点后十几位数字的近似值。这个问题并非只在上发生。你的计算器对于那些二进制表示并非有限的数都处理得非常糟糕 [3]，这样的数包括无理常数，例如和，还有某些有理数，比如 $1/3$ 和 0.2 。此外，因为计算器只能处理近似值，所以它可能会得出一些违反常理的结果，比如说，或者在比大得多的时候会得到，即使本身大于 0。数学家经常会认为，在计算机上进行的计算只不过是数学理论的近似。所罗门诺夫妖的立场却完全相反。对于所罗门诺夫妖来说，实数之类的对象只不过是让我们可以构建算法并对其更好地进行思考的模型。特别是对于尝试追随所罗门诺夫妖步伐的计算机科学家来说，他们用于尝试衡量置信度的模型并不是由实数作为参数组成的模型，而是那些储存在计算机文件中的模型，其中用到的只是数学模型中实数的截断。正因如此，与数学的理想状态相反，人工神经网络的大小可以用字节来计数 4。

渐近展开如果说对这样的数值进行高精度计算毕竟获益有限，那么对物理学、生物学或者数学中出现的曲线、函数和行为进行近似就会产生大量的应用。通过素数定理对素数计数函数进行近似就是这样的情况。更一般的框架中存在这样一项工具，它对于任意模型都可以计算出比模型本身简单得多的近似版本。这项工具就是渐近展开。一般来说，渐近展开可以让我们用一条直线来逼近圆上的一小段圆弧，或者用平面来逼近 (相当圆润的) 地球的一小块表面。用代数术语来说，这相当于用形如的仿射方程来逼近所谓的非线性方程。对于那些变化足够小的现象来说，这种近似完全是可以接受的。这就解释了为什么我们要在学校里花上这么长的时间来研究这些简单的方程，以及为什么这些方程在科学中无处不在 5。

对物理学家来说不可或缺的渐近展开，最精彩的例子可能就是爱因斯坦的广义相对论方程。它的渐近展开可以导出牛顿力学！换个说法，就是牛顿的力学定律，特别是关于万有引力的定律，只不过是爱因斯坦方程的近似，在有限的场景里完全适用。这种有限的场景就是所谓的“弱引力”情况 6。[4] 6 更准确地说，这应该是时空曲率极小的情况。

实用主义的限制然而在现实中，计算能力是有限的。我们之前也看到了，在地球上执行超过 10^{90} 个计算步骤是种不切实际的愿望。这就大大降低了我们用贝叶斯公式进行计算的能力。

作为比较，人类大脑包含大约 10^{15} 突触，这意味着对大脑的完整描述至少需要比特的信息。研究所有包含这么多字符的理论，至少需要 $2^{10^{15}}$ 次计算！因此，即使能用到古戈尔个宇宙，对这些理论应用贝叶斯公式也完

全是一种幻想。

图灵的机器学习 1950 年，艾伦·图灵将这个关于算法不可避免的复杂度的论证过程漂亮地转移到了人工智能问题上。在一篇发表在期刊《心灵：心理学与哲学季度评论》(Mind, a Quarterly Review of Psychology and Philosophy) 上，题为《计算机机制与智能》(“Computing Machinery and Intelligence”) 的论文中，图灵首先提出了一个与算法执行所需时间没什么关系的问题：“机器能思考吗？”图灵尝试回答的就是这个问题。然而“思考”这个词的模糊性让他尝试将问题精确化。与其考虑这个问题，图灵提出了另一个问题，就是机器是否能像人那样行动。

更准确地说，图灵提出了以下的测试：要求一位人类 A 与另外两个实体 X 和 Y 进行书面通信，而这两个实体 X 和 Y 分别是人类和一台机器。如果人类 A 无法分辨 X 和 Y 之中哪一个实体是人类的话，那么机器就通过了测试。换句话说，如果机器知道怎么模仿人类，而任何人类都无法分辨出这台机器不是人类的话，那么机器就成功通过了测试。这就是图灵所谓的“模仿游戏”，我们今天将它称为图灵测试 [5]。

在论文的第 3 节到第 5 节中，图灵重提了他 1936 年的工作，严格定义了机器到底是什么——这个概念推动了计算机的发明，接着就是数字时代的到来！然后在论文的第 6 节中，图灵否定了尝试证明机器不可能思考的 9 个经典论证。但更重要的是，在论文的第 7 节，图灵预料到了其测试中的难点及解决方法。即使仍然不能说计算机当时已经存在，但图灵不仅已经预料到了它们会在未来出现，而且还预料到了它们以后的性能将足以在模仿游戏中取胜：“(工程上的进步) 似乎不可能不足够 (使其通过测试)。”对于图灵来说，“这个问题主要是编程问题”。特别是，图灵以惊人的远见推测出，能成功通过图灵测试的程序代码至少需要大概 10^9 个字符来描述。也就是说，用我们在第 7 章引入的术语来说，图灵自己猜测，图灵测试的所罗门诺夫复杂度应该以十亿字节来计量。为了得到这个估计值，图灵依靠的是他所知的唯一一台能通过图灵测试的机器。对，我说的就是人类大脑！毕竟还有什么能比人类更善于模仿人类呢？对图灵来说值得庆幸的是，当时的神经科学已经给出了人类大脑复杂度的估计值，提出人类的神经元之间大约有 10^{11} 到 10^{15} 个突触——现代的估计值处于 10^{14} 和 5×10^{14} 之间。图灵提出，只有一小部分突触对于通过图灵测试来说是必不可少的，这就是需要 10^{15} 个字符这个数字的来历。

同样出于他无比的智慧，图灵注意到人类大脑能够通过图灵测试。于是他猜测，通过模仿人类大脑成功完成图灵测试，我们能更好地构建能够通过测试的机器。然而图灵也注意到，儿童教育同样是人类最终发育过程中的重要一环。“儿童的大脑可能类似于我们在文具店买到的笔记本，”图灵这样写道，“没什么机关，但有许多张白纸 8。”图灵从而提出，为了帮助机器填满它自己的白纸，可以让它从数据中学习。学习机器的概念，也就是能够学习的机器，就此诞生。

因此，学习机器这个想法能够让机器自己写出包含数十亿字符的程序——必要时可以写得更长。用更贴近算法的语言来说，这相当于肯定了机器学习最终可以让我们研究并探索那些描述长度超过十亿比特的算法。而更关键的是，引导这种探索的并非程序员的指尖，而是原始数据，就像儿童接收到的那样。需要特别指出，图灵的这段论证反驳了众多知识分子的想法，其中还包含一些专家，他们经常这样说：“机器学习效果不错——但数学家不知道为什么。”这是 2015 年《连线》(Wired) 杂志上一篇文章的标题。然而早在 1950 年，艾伦·图灵就预言了机器学习未来会取得成功，甚至明确指出它会在 20 世纪末出现！更厉害的是，关于机器学习会在众多任务中超越人类编写的程序这一情况，图灵已经强调了它的确切原因：只有机器学习才能探索那些长度超过十亿字节的算法空间 [6]。同样，某些专家经常指责那些庞大的神经网络无法被明确解释。然而，巨大而高效的神经网络无法用寥寥几个字符描述出来，至少无法以准确的方式描述出来，这并不令人意外。这是因为，如果神经网络能被简单描述的话，这个不太长的描述就会是简短的一种算法，它能够生成另一个算法 (神经网络)，并借此解决图灵测试之类的问题。这样的话，这个简短的算法就能解决图灵测试。然而，我们刚才推测，这项测试无法被简短的算法解决。

现在剩下的就是明确指出用什么方法来探索长度巨大的算法组成的空间。然而艾伦·图灵并没有指出要做到这一点可以使用的方法，他只是断言学习能力将会是关键。在 21 世纪初，人们提出了大量的方法。我们之前已经谈到过其中几种。不分先后的话，我们可以举出线性回归、逻辑斯谛回归、决策树、决策森林、支持向量机、神经网络、贝叶斯网络，还有马尔可夫随机场。我们会在本章和后面几章中再详细讨论最后这三个机器学习算法。

实用贝叶斯主义为了解决像图灵测试那样拥有巨大的所罗门诺夫复杂度的问题，实用贝叶斯主义者只能放弃贝叶斯公式。他更应该利用那些所需时间没有超出现实可能性的方法。由此我们需要调整“有用”这个概念。

对于纯粹贝叶斯主义者来说，置信度高的理论就是有用的；但对于实用贝叶斯主义者来说，置信度很高，但所需计算时间超出常理的理论实际上并没有用。因此，实用贝叶斯主义者将注意力转向了所需计算时间较短的理论之中更可信的那一部分。

这就让我们能够解释素数定理给出的近似以及牛顿运动定律在实用中的置信度了。对于纯粹贝叶斯主义者来说，这两种描述都没有任何用处，因为两者分别被素数的精确计算以及爱因斯坦的广义相对论超越。然而实用贝叶斯主义者则乐于拥抱这些近似方法，因为它们对计算的需求明显小得多。计算的近似值需要的时间是对数，而牛顿理论中的向量和微分计算与爱因斯坦理论中的张量计算相比远远更快。只要在我们身处的场景中，这两种近似精确到足以被接受（分别是值很大的情况和弱引力的情况），那么对于实用贝叶斯主义者来说，这两种近似就比精确的版本更有用！这种与计算时间有关的“有用”概念同样可以作为对神经网络惊人的成功的首要解释。这是因为，神经网络，或者至少是所谓的前馈神经网络，与那些更精细的算法相反，需要的计算时间不长，而且必定有所限制（图 14.1）。实际上，如果我们考虑前馈神经网络的一个足够广泛的定义，那么这些网络组成的集合恰好就是快速并行算法的集合。因此，在前馈神经网络上进行机器学习，其实就相当于利用快速算法尽可能好地对数据进行解释（如果可能的话，也要利用合适的贝叶斯先验置信度）。所以，这就是迈向实用贝叶斯主义的第一步。

图 14.1 神经网络就是神经元之间一系列通信以及神经元本身进行的基本计算的总和。如果这种通信是无环的，我们就说这是个前馈神经网络，从直觉上来说，也就是通信只会朝一个方向进行，从来不会形成一个闭环

人工智能 (Artificial Intelligence, AI) 始于一个简单的想法。计算机被发明之后，人们很快认识到它的能力远不限于数值计算，可以通过对信息和指令编程完成很多以往只有人脑才能完成的任务。

强调像人一样强调合理性思考

像人一样地思考

合理地思考

行动像人一样地行动合理地行动

|| 强调像人一样 | 强调合理性 || — : — : — : || 思考 | 像人一样地思考 | 合理地思考 || 行动 | 像人一样地思考 | 合理地行动 |

5.9.9 人工智能：广跨各学科，综合文理工

人工智能：对人的意识、思维过程进行模拟的一门学科。

5.9.10 发展历程：AI 的三次热潮和相应的研究学科突破

人工智能发展如同过山车，忽上忽下，从创立以来不断分化

AI 数理基础切换: 从基于逻辑的表达与推理到基于统计的学习与计算

5.9.11 三次热潮的总结

第一阶段(前 30 年):以数理逻辑的表达与推理为主。杰出代表,如 JohnMcCarthy、MarvinMinsky、Herbert-Simmon:懂很多认知科学的东西,有很强的全局观念,拿过图灵奖和很多大奖。但工具基本都是基于数理逻辑和推理。逻辑的东西发展得干净、漂亮。但符号的知识表达不落地;

第二阶段(近30年):以概率统计的建模、学习和计算为主。视觉、自然语言、认知、机器学习、机器人五大领域在1990年中期都找到了概率统计这个新“机制”:统计建模、机器学习、随机算法……

人工智能的主要学派|符号主义学派 Symbolicism|联结主义学派 Connectionism|行为主义学派 Actionism|:-:-|:-:-|起源于 2300 年前的逻辑主义、心理学派和计算机学派|起源于上世纪 40 年代仿生学派或生理学派|起源于上世纪 40 年代,进化主义、控制论||认知即计算:用符号、规则和逻辑来表征指示和进行逻辑推理|认知即网络:用概率矩阵和加权神经元进行模式识别、分类|认知即行动:基于“感知-行动”生成变化,为特定

目标获取其中最优解 || 基本算法：规则和决策树 | 基本算法：深度学习神经网络 | 基本算法：遗传算法、蚁群算法、强化学习 |

三大学派的方法论

| 符号主义学派 Symbolicism | 联结主义学派 Connectionism | 行为主义学派 Actionism | :—: |:—: |:—: || 知识自上而下地设计 | 知识自下而上地涌现 | 知识自下而上地涌现 || 经由专家自上而下基于逻辑设计、推理来实现 | 通过模拟大脑的结构 (神经网络) 来实现知识 | 从简单生物体与环境互动的模式中寻找知识

参考文献

5.10 线性神经网络

在介绍深度神经网络之前，我们需要了解神经网络训练的基础知识。本章我们将介绍神经网络的整个训练过程，包括：定义简单的神经网络架构、数据处理、指定损失函数和如何训练模型。为了更容易学习，我们将从经典算法——线性神经网络开始，介绍神经网络的基础知识。经典统计学习技术中的线性回归和 softmax 回归可以视为线性神经网络，这些知识将为本书其他部分中更复杂的技术奠定基础。

-3.1. 线性回归

文生文、文生图、文生视频

第 6 章 生成式 AI：机器魔法及其数学思维

内容提要

- Definition of Theorem
- Ask for help
- Optimization Problem
- Property of Cauchy Series
- Angle of Corner

近年来，生成模型在人工智能领域取得了显著的进展，特别是在图像生成方面。从简单的图像生成到复杂的文本到图像转换，生成模型展现了强大的潜力和广泛的应用前景。生成对抗网络 (GANs) 和变分自编码器 (VAEs) 等传统方法虽然取得了成功，但仍面临一些挑战，如训练不稳定性和生成质量的限制。因此，研究人员不断探索新的方法来提升生成模型的性能。本文将介绍一种先进的生成模型——StableDiffusion，该模型在文本到图像生成任务中表现出色，通过扩散过程实现高质量图像的生成。

6.1 背景

生成模型是人工智能中的重要研究方向，旨在生成逼真的图像、文本和其他数据。传统方法如生成对抗网络 (GANs) 和变分自编码器 (VAEs) 在图像生成中取得了显著成果，但它们也存在一些局限性。例如，GANs 的训练过程通常不稳定，容易出现模式崩溃 (ModeCollapse); 而 VAEs 生成的图像质量往往不够高。为了解决这些问题，StableDiffusion 引入了基于扩散过程的新方法，通过模拟数据的随机演化行为，从而实现高效且稳定的图像生成。StableDiffusion 利用扩散过程的优点，在生成质量和稳定性方面取得了显著进展。

6.2 什么是 Stable Diffusion

StableDiffusion 是一种基于 Latent Diffusion Models (LDMs) 的生成模型，专为文本到图像生成任务设计。其核心思想是通过扩散过程，从随机噪声逐步生成符合文本描述的高质量图像。StableDiffusion 利用扩散过程模拟数据的随机演化行为，确保生成过程的稳定性和高效性。模型首先从随机噪声开始，经过一系列的变换和调整，逐步接近目标图像。这一过程可以理解为在潜在空间中的变换，使得生成的图像能够准确反映输入的文本描述。Stable Diffusion 的独特之处在于其双向扩散机制：正向扩散将文本描述转化为潜在表示，反向扩散则从潜在表示生成最终图像。

6.3 1.4. 核心原理

StableDiffusion 的核心原理包括两个主要阶段：扩散过程：模型从随机噪声开始，逐步应用一系列变换，使其逐渐接近目标图像。这一过程模拟了数据的随机演化行为，确保生成过程的稳定性和高效性。在扩散过程中，模型学习到数据的分布特性，并利用这些特性对噪声进行调整。反向扩散过程：与扩散过程相反，反向扩散是将噪声逐步变换为目标图像的过程。在这一过程中，模型根据学习到的数据分布特性，逐步去噪并生成符合文本描述的图像。反向扩散过程利用参数化的马尔可夫链进行建模，通过逐步调整和优化，最终生成高质量的图像。通过这两个阶段的有机结合，StableDiffusion 能够高效地将文本描述转化为高质量的图像，展示出强大的生成能力和应用前景。

6.4 应用场景

StableDiffusion 在多个领域中有广泛应用，包括但不限于：

-艺术创作: 通过将文本描述转化为图像, 艺术家可以利用 StableDiffusion 进行创作, 探索新的艺术形式和风格。
 -广告设计: 广告设计师可以使用 StableDiffusion 根据客户需求生成定制的广告图像, 提高设计效率和创意表现力。
 -虚拟现实: 在虚拟现实应用中, StableDiffusion 可以根据文本描述生成逼真的虚拟场景, 提升用户体验。
 -医疗图像处理: 在医疗领域, StableDiffusion 可以根据医生的描述生成医学图像, 辅助诊断和治疗。-这些应用展示了 StableDiffusion 在图像生成领域的广阔前景和巨大潜力, 为各行各业提供了新的工具和方法。

生成式对抗网络如果你在纸上画了几只猫, 那么哪一只更像“真正”的猫呢? 你要怎么做才能量化你的涂鸦和真正的猫之间的相似性? 怎么定义图像之间相似度的度量? 这些问题的用处并非只局限在“你画我猜”(pictionary) 游戏中。测定文字、声音和图像等复杂对象之间的相似性²已经成为实用贝叶斯主义者发起的最困难的挑战之一。这是因为, 真正有趣的数据实际上都是这种复杂的对象, 比如拉普拉斯的著作、心电图以及显微镜下缓步动物的图像。²或者更进一步, 也可以考虑文字、声音、图像上的概率分布。我们以宇宙学为例。今天, 这个领域的的数据基本上就是天空在各种波长下的照片, 从无线电波开始, 跨越微波、红外线、可见光、紫外线、X 射线, 一直到射线。让天体物理学家深深着迷的问题, 就是在给定天空的照片的情况下, 得出不同宇宙学模型的可信参数。这就是贝叶斯公式的典型应用! 这个计算对于纯粹贝叶斯主义者来说易如反掌, 但对实用贝叶斯主义者来说却难于登天。与通常的情况一样, 分母太长难以计算。但问题不止于此。因为宇宙学模型都非常复杂, 即使是思想实验项需要的计算时间也会超出现实的限制。实际上, 正因为这些模型属于贝叶斯网络³, 所以它们在构建时就考虑到了模拟计算的可行性。也就是说, 在合理的时间内, 我们可以做的就是在宇宙学模型参数为的假设下, 描绘模型中可能出现的图像。这就是所谓的生成模型⁴。³ 我们会在第 17 章再提到这一点。

⁴ 换种说法, 生成模型就是一组图像之类的复杂集合上的概率分布, 但它只能通过模型仿真来研究。再换种说法, 生成模型就是被设计成用于取样的模型。我们会在第 17 章进行更深入的讨论。因此, 实用贝叶斯主义者必须依靠某些方法来绕过对思想实验项的直接计算。人们也将其称为无似然方法 (likelihood-free method)。这种方法有很多变种, 比如近似贝叶斯计算 (Approximate Bayesian Computation, 简称 ABC) 和带参数贝叶斯间接似然度 (parametric Bayesian Indirect Likelihood, 简称 pBIL)。但自从 2014 年伊恩·古德费洛及其合作者发表的工作 [18] 以来, 一种特殊的无似然方法似乎赢得了大量研究者在实用上的置信度, 那就是生成式对抗网络 (简称 GAN)。直观来说, GAN 的想法就是将玩“你画我猜”的人类玩家换成一个算法, 它被称为“对抗者”或“教师”。这位“对抗者”的任务就是衡量模型生成的图像与真正的图像有多相似。为此, 我们先抛一枚硬币, 如果正面向上, 那么我们就在庞大的真实图像库中抽选一张图像, 否则要求模型生成一张图像。然后, 无论图像来自哪里, 我们都要求“对抗者”计算出它是真实图像的贝叶斯置信度。如果模型正确的话, 从直觉上来说“对抗者”应该会混淆两种可能性, 也就是会向任何提交的图像都赋予的概率。重点在于, 为了让“对抗者”乐于给出自身的贝叶斯置信度, 古德费洛等人提出, 在图像为真实图像的情况下, “对抗者”需要付出的代价, 反之则需要付出的代价。也就是说, 我们以符合 KL 散度的方式来计算分数。此外, 生成模型随后也可以尝试调整参数, 使得生成的数据更接近真实数据。而关键在于, 这一点有着明确的意义: 无论输入真实的图像, 还是模型生成的图像, 生成的数据需要使“对抗者”给出的数值尽量靠近。实际上, 用于衡量“对抗者”的贝叶斯置信度偏差的同一个分数也可以用来衡量模型的表现⁵! ⁵ 所以模型和“对抗者”实际进行的是零和博弈!

当我写下这段话的时候, GAN 风头正劲。其惊人效果正不断得到提升, 这主要得益于深度学习。2018 年, GAN 中的模型和“对抗者”实际上都换成了 (卷积) 神经网络⁶。正因它们能够对贝叶斯公式进行无似然近似, 再加上神经网络学习的常用工具, GAN 获得了巨大的能力, 足以生成极其难以与真实照片区分的假照片 [19]。从各个角度来说, 正是概率性预测的新度量方法的出现才造就了这些现代人工智能激动人心的表现。⁶ 一般来说, 模型就是一个深度神经网络, 再加上一个用于生成变量的“简单”概率分布。对模型进行模拟就会输出数据。“对抗者”是另一个深度神经网络。这种结构的好处就在于能够应用反向传播算法。这个算法能确定为什么选择了, 然后将这项信息倒推回去, 用以改进生成模型。在这种意义上, 更像是“教师”, 而不是“对抗者”。此外, 为了给本章做个总结, 我想再一次强调在判断预测质量的方法中考虑不确定性的重要性。不幸的是, 在分析各种现象时, 人们往往低估随机的作用。我们必须习惯在思考中考虑不确定性, 而不是在那些本质上不可预测的情境中也要尝试做出确定性的预测。在这个复杂的宇宙中, 没有任何认识是确定无误的, 无论原因是现实的物理本质、经验数据的欠缺、混沌现象的存在, 还是我们在计算能力上的限制。绝大部分预测问题没有简单一致的回答, 回答这类问题时要谨慎。只有最终承认大量事件发生的原因都是运气不好, 这种谨慎才站得住脚。因此,

对模型与预测的判断必须能量化不确定性。量化不确定性实在非常重要，这件事不能被随意决定。

人工智能的创新艺术人工智能学会作曲和绘画还是不久之前的事情。我们在第 16 章也简略提到过，这种创造性过程的关键还是贝叶斯公式。原因在于，在众多深度学习模型中，我们可以在神经网络中激活某些所谓的深度神经元，由此创造出抽象概念之间的结合体。其中一些神经网络就此能够想象出哪些原始数据能激活那些被人为激活的神经元。也就是说，虽然神经网络通常从数据推断出能够概括这些数据的抽象概念，但我们可以要求这些神经网络在已知抽象概念的情况下猜测可能与之有关的数据。然后，选择那些一般而言没有联系的抽象概念，我们就能让神经网络创造出一些既不常见但又相对可信的数据。这就是机器的艺术生成过程。我们可以打赌，这种过程至少与我们大脑中的创造性过程有几分相似。在 2015 年，谷歌利用这种方法，在研究博客上发表了人工智能“深梦”(DeepDream)生成的一些图像 [1]。这些图像有种迷幻的感觉，人们在其中能看到云朵变成了鱼，树变成了寺庙，而树的叶子则变成了飞鸟。更妙的是，你可以要求另一个被称为“深艺”(DeepArt)的人工智能用著名画家的笔触重新诠释你拍的照片，无论是凡·高、毕加索还是康定斯基都可以。我的 Twitter 头像就是“深艺”花了几秒生成的免费劳动成果。在这些人工智能的创造性过程中，重要步骤之一就是神经网络在给定了数据的抽象概括的情况下，找到可信数据的能力。也就是说，神经网络应该能够根据数据 | 抽象概括这一概率分布，即给定被激活的抽象概念时数据出现的概率，进行抽样。这样的话，根据贝叶斯主义，创造性可以归结为根据带有语境的置信度进行抽样。但重要的是，抽样意味着给出有代表性的例子，而不是根据非常复杂的概率分布进行推理。在阐明推理并将其变得更易理解的过程中，这也许相当有用，毕竟哪怕是在数学中，人类的自然学习方式也似乎更倾向于依赖那些有代表性的例子，而不是形式化的理论。我们大脑中的设备似乎优化的是从例子中推断粗略规则的能力，而不是使神经网络符合形式化理论的能力。这就解释了为什么抽样对于人类来说不可或缺。古怪的是，抽样对于机器来说似乎同样不可或缺。但在讨论这一点之前，我们必须先找到合适的模型来表示数据与抽象概括之间的关系。人们提出了几种机器学习架构，用于描述概率分布以及根据这些分布进行抽样。这些结构可以分为两类(不同的复杂模型可以适当地结合在一起): 贝叶斯网络(Bayesian network)—1 它也被称为前馈模型(forward model) 和马尔可夫随机场(Markov random field)。我们先来看看贝叶斯网络。

隐含狄利克雷分布除了卡尔曼滤波器和隐马尔可夫模型，贝叶斯网络的主要成就之一就是在 2000 年前后提出的隐含狄利克雷分布(latent Dirichlet location, 以下简称 LDA)。LDA 的目标是将文档分为不同的类别。计算机可以利用 LDA 以完全自动化的方式将你的电子邮件分别放到名为“私人”“工作”“度假”和“垃圾邮件”的文件夹中。更进一步的话，LDA 甚至能检测出不同类别的组合，而且能判断某份文档的内容一半与工作有关，另一半与度假有关，甚至判断出 2/3 属于私人内容，1/3 属于工作内容。要做到这一点，LDA 利用了贝叶斯网络中的基础概念，也就是因果性的概念，它的好处在于符合我们的直觉，这也使贝叶斯网络成了相对易于解释的概率模型。正是得益于贝叶斯网络与直觉之间的契合，尼尔和伯杰才提出可以在司法领域使用贝叶斯网络，就像我们在第 2 章中看到的那样。文生文、文生图、文生视频

第7章 力量倍增器：站在 AI 的肩膀上

内容提要

- Definition of Theorem
- Ask for help
- Optimization Problem

- Property of Cauchy Series
- Angle of Corner

人类发展几乎是线性的

计算机发明带来的发展是指数级……然而，人类有关自身文明和生物学的进展是零星的，稀疏插值。

关于技术进展，库兹韦尔走得更远，他指责技术界与学术界没有理解技术的指数增长性质，比如摩尔定律就(粗略地)断言了计算机的计算能力每两年就会翻一倍。同样，经济学家布林约尔松和麦卡菲指出，人们对于过去的各种事件赋予了过高的重要性。如果关注各种经济指标，无论是人口还是农业产量，我们就能明显看到一个重要的现象，它超越了所有零星发生的事件，无论是古罗马帝国的崩溃、印刷技术的发明还是对美洲大陆的征服。这个重要现象就是经济指标势不可当的指数上升。布林约尔松、麦卡菲、库兹韦尔以及其他许多人认为，这种新技术促成的指数增长说明未来会与过去大大不同。人工智能、3D 打印、纳米技术和遗传学上的进步都昭示着这样的未来，其中高质量消耗品的大量生产不再需要人类劳动，世界范围内的饥荒和疾病都能得以根除，我们的生活方式也会有翻天覆地的变化。

视频主播 CGPGrey 在一个题为《招聘：谢绝人类》(HumansNeedNotApply) 的优秀纪录片中指出，即使在并不遥远的未来，人类的工作甚至会被嫌弃。对 CGPGrey 来说，技术可能很快就能演变到这样的地步，以后(几乎)人类能完成的工作都可以由机器以更低廉的价格更好地完成 [14]。布林约尔松和麦卡菲也有着相同的观点，他们预言许多工作将会消失。我自己也被这样的论证说服了，我在 2014 年预测了 2034 年失业率会超过 80 但麦卡菲并不是一位失败主义者，恰恰相反，他在一次 TED 论坛 [15] 中谈到了“我们这个时代最奇妙的新经济”。他还补充道：“那里没有竞争。”物质充裕是有保证的。我们可以重新构思这个社会，其中人们不再需要工作——条件是机器生产的物资得到了合适的分配。这种事情在人类史上还从来没有发生过！

尼克·博斯特罗姆看得更长远，他认为技术进步可能并不是指数式的，而是超越指数式的。要理解这一点，我们得回到指数增长的特点：在每一次迭代时，技术或它的某个量化指标都会乘以一个常数。然而对于博斯特罗姆来说，技术越进步，它继续发展的速度就会更大。换句话说，在每一次迭代之后，技术会乘以一个每次迭代都会增加的数值。

这个现象可以用微分方程来建模。我在这一段要用一点数学术语。如果你不熟悉这些术语的话可以直接跳过。指数增长对应着微分方程，而博斯特罗姆眼中的技术进步则更贴近这种形式。但这种方程的解形如，也就是说，这种增长如此迅速，在有限的时间内，就会达到无穷大。经过这样的短暂思考，我们得出的结论就是技术演变可能存在一个奇点，在那个时刻，所有技术会突然达到物理极限。这个技术奇点通常被解释成超级智能(也就是超越人类的人工智能)开始改进自身智能的时刻。因为这个超级智能比它的设计者要更聪明，所以它能够找到超出我们能力的技术解决方案，它的自我改进从而也会不受控制地加速。在非常短的时间内，它就会完全改变我们生活的世界。而且它的行为从根本上无法预见，因为这些行动都来自一个远远超越我们的智能 [16]。博斯特罗姆并没有贸然猜测这个想象中的奇点降临的准确日期，但他并没有排除奇点会在 50 年内出现的可能性。雷·库兹韦尔则更为大胆，他预测技术奇点会在 2045 年出现。这个预测让许多人大为吃惊。对于大部分人来说，这个预测甚至看上去滑稽到了令人脸红的程度。但对于库兹韦尔来说，这只是因为大部分人无法摆脱线性直觉而已。

7.1 超级计算机：速度和功耗成为终极挑战

不止比算力，还要比节能，平衡能耗比。

Facebook 为什么把数据中心放在北极圈（平均温度 1.3 度）？为了节省空调的电费。

即使如此，功耗达到核电站的发电量

数学的深度尽管深度学习大有成为机器学习中抽象方法之巅峰的势头，但跟数学这片山峦相比，它只能算是个小山丘。在人类建立的所有宏大体系之中，数学比起其他造物要远远更抽象、更深刻。数以千计的著作堆积起来，朝抽象的方向越走越远，即使是最厉害的数学家也要认真、努力，才能沉浸于其他人创造的抽象概念之中。要解开寥寥几个方程的部分秘密，可能就需要数年甚至数十年的沉思。一些最伟大的数学家甚至把职业生涯的大部分时间花在同一个方程上。维拉尼这样讲过：“玻尔兹曼方程，真是世界上最美丽的方程(……)!我在还小的时候就遇到了它，我的意思是，在我读博士的时候。”狄拉克也说过，以他的名字命名的方程所包含的智慧超出了他本人的智慧，他没有料到这个方程在物理上的推论，尤其是在他年轻的时候 [7]。而我期望能在本书中与你顺利分享于我而言贝叶斯公式及其出人意料又难以置信的推论的迷人之处。从创作本书的两年前开始，它们就令我激动不已，而且它们很有可能会在之后漫长的岁月中继续令我着迷!的确，要用我们有限的大脑皮层一步一步理解的话，数学实在是太深刻了。为了衡量数学对象，我们必须时时寻觅大体的解释：为了思考向量，我们必须想象出一个箭头；为了思考非欧几何，我们必须想象一块被拉扯变形的布；而为了证明有关素数的定理，我们就必须仔细考虑它们的已知性质。而通常来说，当我们面对数学推理中堆积成山的计算步骤时，可能想立刻放弃努力思考，只想机械地依据计算规则做到最后。“闭上嘴，然后去计算。”戴维·默明就是这样概括量子力学的哥本哈根诠释的。人们可能会以为，这在科学上是种错误的做法。我们不是要尝试理解周遭的世界吗？如果这就是目的，那就应该放弃过度的数学抽象。但贝叶斯公式的作用并不是让可靠的理论适应人类大脑的认知能力。它的目的是预测。如果宇宙的逻辑深度很大，那么最好的预测方法很可能需要极为大量的推理步骤，但这些步骤都对应着深入的计算，它们必然超出了我们的直觉。尤其，数学的深度并不是直觉思考所能比拟的。毕竟，我们的直觉似乎只能进行迅速的计算。因此，直觉推理并没有什么逻辑深度。我认为，这就是对数学超出常理的有效性的主要解释。也就是说，这种有效性并非因为宇宙的本质就是数学（我本人在理解这个概念上很有困难），而是来自这个宇宙当前物理状态的逻辑深度，尤其是因为存在一些逻辑深度很大而所罗门诺夫精致度很小的现象。除此之外，还有我们认知能力上的限制。

数学的简洁性数学超出常理的有效性的第二个解释就是其惊人的简洁性。说到底，本书中绝大部分内容可以归结为贝叶斯公式，它可以用寥寥几个字符来描述。换句话说，这本书可以用比自身简洁得多的方式来描述。书中都是冗余的内容，它的所罗门诺夫精致度相对来说很低。此外，我甚至认为无论是谁，只要花上足够长的时间来思考学习的本质，并尝试优化自己的教学方法，都能写出与这本书相当类似的另一本书。我相信对这些人来说，我在这里所写的都是些显而易见的东西，可以轻松被高度压缩。但这些东西对于教学来说非常有用。数学最伟大的成就之一就是数学语言的汇总，这可以归功于花拉子密。但这还不够。除了简洁以外，花拉子密的数学语言读起来一板一眼，不存在好几种可能的解释，而且无须花时间仔细思考这一语言中每个符号的意义 [8]。事实上，要确定某个形式证明是否正确，只需要一股脑儿去读就行（但要非常专心）。用计算机科学的术语来说，阅读这一语言只需要所罗门诺夫复杂度很小的算法，即使算法所需的计算时间可能很长。数学简洁性最惊人的例子之一就是电动力学方程。当物理学家詹姆斯·麦克斯韦在 1861 年首次引入这些方程的时候，它们一点都不简洁。然而，数学不断增长的抽象性将这些冗长的方程缩短为几个符号：，其中。当然，要通过这些方程进行预测，就必须用到整套算法工具，但就纯粹计算而言，描述这些工具也不需要多长的篇幅。这与那些非形式化的理论形成了鲜明对比，后者强烈依赖于对语言和其他人类“常识”的某种解释。然而，语言和常识的算法描述很可能需要数十亿行代码才能接近人类的表现。正如我们在第 14 章中看到的那样，对于图灵来说，这解释了为什么机器学习对于完全掌握语言和常识来说必不可少。因此，非形式化理论的问题其实不是它们不精确，而是它们需要所罗门诺夫复杂度极大的算法（比如我们的大脑）才能拥有预测能力。然而，如果我们相信所罗门诺夫的偏见，那么所罗门诺夫复杂度极大的理论的先验置信度就会呈指数下降。

当然，自然语言以及人类大脑对它的解释并不是任意而为的。自然选择更偏爱那些能够预测环境和原始部落社会关系的语言和认知过程。然而，这种选择偏好并没有覆盖那些能描述粒子物理学、全球化市场经济和新技术影响的语言和认知过程。对于这些问题来说，即使是非常简化的数学处理，在纯粹贝叶斯主义者的偏见中也会获得优势，这没什么奇怪的。因此，数学的优雅似乎必将使数学家仔细探索并理解那些简洁的算法，也就是在所罗门诺夫的模型下拥有相当大的先验置信度的算法。所以，我们观察到，那些基于数学语言的最优秀的预测性理论通常在经验中也更可信，这也不是什么惊人的事情。

数学的模块性我想用数学超出常理的有效性的第三个也是最后一个解释来结束这一章，那就是数学的模块性。优雅的数学定理通常处于大量学科的交叉位置，构建了数学各个方面的桥梁，它们就像一把瑞士军刀，只要使用方法足够巧妙，就能解决大量问题。正因如此，导数、向量空间和图这些概念在几何学、最优化和概率中比比皆是，而且在物理学、计算机科学、生物学、化学和经济学中也无处不在。计算机科学中的比特、列表结构和排序算法也属于这样的概念。定理组成了预测性理论的基石，就像基础算法组成了所有复杂源代码的基石那样。程序员将算法分解成小块，好让这些基础算法一次又一次地应用在全体代码的不同方面。与之类似，加法和乘法也经常物理模型中被重复使用，而导数这个概念也通常被应用在各种不同的物理量中。这样的话，仅仅利用非常抽象且具有普遍性的方式一次性给出导数的定义，要比每次使用它的时候都重新定义的做法更简单、更优雅。因此，数学语言让我们可以研究大量不同的模型——不必每次都重新发明轮子。现在我们来看一个例子，几十年来它已经成为非讲不可的话题。无论是在数学、机器学习、材料科学或经济学中，实践中的大量问题都可以写成在不同约束条件下对某个目标函数的最小化问题。这个框架就是最优化问题，它统一了大量领域。用于仔细分析并解决这个框架之下的问题的方法，比如梯度下降法、局部搜索和遗传算法，都算得上瑞士军刀。通常，如果能用这个框架建立模型，这些方法就能解决大量问题。理论物理学的情况给人的印象更深刻，尤其是量子场论，它远远不是一个死板的单独理论，而是首先建立在拉格朗日量的量子化 [9] 的基础之上。的确，自从理查德·费曼应用了最小作用量原理之后，物理学家已经习惯了将他们的量子力学写成唯一一个公式，也叫拉格朗日量，一般来说，它的形式是。无论拉格朗日量的具体表达如何，物理学家下一步就能用一套系统化的方法将这个拉格朗日量转化为涉及偏微分的运动方程（也叫欧拉-拉格朗日方程）。然后，这些方程可以被量子化，接下来就能从方程中得到量子化导出的预测结果。也就是说，将拉格朗日量转化为一组预测，这个过程只不过是单纯（但冗长）的计算。更厉害的是，规范理论甚至仅仅从拉格朗日量的对称性出发，就能导出它的准确公式。物理对象及其相互作用可以归结为对它们的对称性所组成的群进行抽象研究，这种做法实在令人心醉神迷。诺特定理正是以这种方式从拉格朗日量的时间平移对称性推导出能量守恒，而从空间平移对称性推导出的则是动量守恒 [10]。更进一步的话，只需简单提出拉格朗日量在某个群的作用下不变，比如说这个群，就能由此构筑一个全新的量子场论。这真是干得太漂亮了！理论物理学成功将自身从光子和电子等基本对象中剥离，只需考虑像拉格朗日量的对称群这种抽象得难以置信的概念。事实上，两个现代理论物理学的伟大发现就是通过将自身限制在这个理论框架中得到的，而且它们远远超前于实验观察的结果。1964 年，默里·盖尔曼和乔治·茨威格正是通过这种方法分别独立提出拉格朗日量应该在这个群的作用下不变。他们发现，这个对称性意味着质子和中子可以被切分为更基本的粒子，它们被称为夸克。经过数十年的理论研究、实验发现和争议之后，盖尔曼和茨威格的模型最终被广泛接受，自此成为粒子物理学标准模型的一部分。但在那个时候，盖尔曼已经因为其他工作获得了诺贝尔物理学奖。然而，诺贝尔奖委员会不愿意在不向盖尔曼授予第二个诺贝尔奖的情况下单独向茨威格授奖，而且他们也不愿意向盖尔曼授予第二个诺贝尔奖。所以茨威格从来没有得到过诺贝尔奖。还有比这更惊人的。还是在 1964 年，三组物理学家，分别是弗朗索瓦·昂格勒和罗伯特·布鲁，彼得·希格斯，还有杰拉尔·古拉尔尼克、卡尔·哈根和汤姆·基布尔，他们各自独立发现在相对论框架下的拉格朗日量表达与带质量粒子的存在性并不相容。为了拯救拉格朗日量这个体系，这六位物理学家引入了一个新的量子场，这个量子场今天被称为希格斯场。表示成拉格朗日量的话，它遵循所谓的规范对称性，但物理状态本身会打破这种对称性。引人注目的是，经典粒子与对称性破缺的希格斯场之间的相互作用，与粒子本身拥有质量时的行为完全无法区分！更妙的是，对希格斯场及其激发态的量子化让这些研究者能够预言新粒子的存在，这种新粒子叫作希格斯玻色子 [11]。你可能也已经知道了，CERN 的大型强子对撞机在 2012 年通过实验发现了希格斯玻色子。第二年，希格斯和昂格勒就获得了诺贝尔奖。抽象方法又获得了胜利。这当然有运气的成分，但从所罗门诺夫精致度和本内特逻辑深度的角度来看，这里的运气成分似乎并没有想象中那么大……

莫拉维克悖论（莫拉维克，明斯基上世纪 80 年代）“对计算机而言，实现逻辑推理等人类高级智慧只需要相对很少的计算能力，而实现感知、运动等低等级智慧却需要巨大的计算资源。”

Steven Pinker（天才哲学家，语言学家）：“对于机器而言，人类困难的问题是简单的，人类简单的问题是困难的。”

“有一句话叫后浪推前浪，后半句话不太美妙。我愿意做那个‘前浪’。”在华东师范大学举办的《天命使徒》研讨会上，华东师范大学终身教授王晓玉的话引起一阵笑声。对人工智能而言，人类会不会是“前浪”？王晓玉

的观点是“人工智能和人的创作，不是对立，而是有重合”。

创意变得更重要。“人工智能首先改变的是教育。如果你没有创意、不会使用工具，就可能被取代。”创新与伦理

自动驾驶：AI 并不与你“共命运”

信息爆炸对认知的影响：成瘾

局部最优解与信息孤岛：大行其道的推荐系统带来思考的惰性、认知的狭窄、……

信息工具无罪，但要慎重圈定使用范围。

如果一个 AI 工具，同时拥有存储人类历史上的所有知识，做数学题会编程会艺术创作（诗歌，文章，图片，语音，视频，…）会行动（配合机器人）…人类物种的优势何在？

比尔盖茨提出三个指导对话的原则：为了充分利用这项非凡技术，应该尝试平衡对人工智能缺点的恐惧与它改善人们生活的能力。既要防范风险，又要让尽可能多的人受益。市场力量不会自然而然地生产出帮助最贫困人群的人工智能产品和服务。相反的可能性更大。需要让世界上最好的人工智能专注于最大的问题。世界需要制定道路规则，让人工智能的任何缺点都远远超过它的好处，让每个人都能享受这些好处，无论他们住在哪里，无论他们有多少钱。

站在人工智能这个巨人的肩膀上，创造更好的人工智能产品和服务，为人类带来生而平等的平和感、富足感。

不管问题多么复杂，如果满足以下五个条件，计算机绝对能够战胜人类。只要有任何一个或者多个条件不满足，计算机做起来就困难了。

1. 必须拥有充足的数据或知识；充足不仅指数量大，多样性，不能残缺等。2. 确定性信息；围棋 自动驾驶 3. 完全信息；无论多么复杂，本质上只需要计算速度快。围棋 自动驾驶 4. 静态；按确定性的规律演化，即可预测性。围棋 自动驾驶 5. 特定领域；单任务。围棋 自动驾驶（行人、其他车辆）

围棋和扑克，哪个容易被 AI 攻克？博弈游戏

** 不确定信息 **

** 可观测状态信息 **

要严密地理解伦理，必须先理解数学。—苏格拉底（公元前 469—公元前 399）解决这个问题（在人工智能中编入道德）是一个值得投入下一代最伟大的数学人才去解决的研究挑战。—尼克·博斯特罗姆（1973—）

伊萨克·阿西莫夫在他的科幻小说中提出了一个有关机器人道德的框架，其中列出了多种行动之间的优先顺序。根据这一顺序，机器人应该最优先保护人类不受伤害。只有在满足第一法则的前提下，机器人才应该遵循人类的指令。然而，指望这样一张优先列表能够解决所有与道德决策相关的问题简直是天方夜谭。这是因为应该采取的行动不仅取决于所有可能的行动，还取决于在什么情景下进行决策。但是可以想象的情景数量众多，并且呈指数增长。列出在所有情况下可以采取的所有行动，就相当于写出一个算法，能够在所有情境下判断出应该执行什么行动。但我们基本上可以确定，这样的算法会拥有巨大的所罗门诺夫复杂度。无论是对人类还是对机器而言，这种算法的编写、读取和应用完全不切实际。

知识是合理的目的吗？现在剩下的工作就是确定什么结果才算可取。我们对社会真正的期望是什么？文明的最终目标是什么？我们在客观上有什么作用？这就是结果论者要回答的根本问题。科学工作者经常提倡对知识的渴望。将知识作为社会的目标，这在道德上成立吗？要求大多数人拥有知识，这是否的确合理？应不应该要求所有人都吞下那颗红色药丸？大概不行。实际上，即使只是将知识定为科学的目标，也会导致许多奇怪的结果。问题在于世界既庞大又复杂。这个世界中可以知晓的事物的数量远远超越了我们的认知能力。欧内斯特·卢瑟福甚至主张“所有科学要么是物理，要么就是集邮”。庞加莱也这样说：“事实的堆砌与一门科学的距离并不比一堆石头与一座房屋的距离近。”我个人也没有任何耐心去背诵那些由零碎知识组成的列表。与其只关心数据，人们更希望寻求这些数据中暗含的理论，常用的方法就是应用贝叶斯公式。但这样的话，目标是什么？就是进行预测吗？我们可不可以认为尝试得出正确结论就是合理的目的？答案绝对是否定的。即使是在 KL 散度这种精细的意义上，尝试得出正确结论也有局限性。

应该学什么，应该教什么？与人类的记忆一样，人工神经网络的记忆在可靠性方面也没有保障，无论它的编码是在神经网络的连接之中还是在网络环路传播的数据之中。我们身边的计算机至少在两项计算任务上远远超

越了我们：计算速度以及信息的可靠储存。我敢打赌，明天的人工智能会知道怎么利用这些实实在在超越人类的能力，它们可能将神经网络的某些方面与其他算法结合起来，这些算法更可靠，也对更特殊的任务进行了优化。

新技术可能已经改变了你的大脑皮层。我们沉迷于智能手机、谷歌和维基百科，这似乎影响了我们对记忆的管理。这不一定是坏事。

我认为，知识和技能的过剩损害了对概念和模型的理解，尤其是对理解这个世界来说最有用、最可信的概念和模型。这种教育往往忽略了模型可信的原因及其适用范围。我的意见是，教授的内容应该大量减少，教师应该只教授那些违反直觉并且有教育意义的重要内容。比如说，我认为应该教授认知偏差、演化理论的关键过程、理论计算机科学和道德功利主义，同时可以削减三角学和量子力学等内容。

此外，贝叶斯公式似乎提示我们应该通过例子来学习，而不是直接记住理论——我们会在接下来的章节中看到，我们的大脑似乎偏向贝叶斯主义，从具体事例出发很快就能推广到一般情况。因此，似乎只有在获得了足够的证据，并使这些数据可以“轻松访问”，让我们能够轻易估计贝叶斯公式中的思想实验项之后，理论的重要性才会突然显现。这样的话，似乎在考虑大量例子，使理论的**效用**凸显眼前之后，再去学习这些理论才更合适。比如说，我们应该先以游戏、谜题和逻辑悖论等能吸引学生的形式来引入数学，之后再向他们解释这些内容都是更普遍的理论的应用事例——这正是我在这本书中努力尝试的做法。

但依我愚见，要教授的最重要的内容还是认识论，还有对于认识论的应用来说不可或缺的统计学。当然，作为极端贝叶斯主义者，我尤其认为贝叶斯公式及其大量违反直觉的推论应该成为教育的支柱之一。我认为是时候放弃积累公认正确的教条知识这种做法了，应当转而教授知识是什么、如何获得知识、如何分辨可信的理论和不值得赋予置信度的理论。不幸的是，在我们这个时代，即使是大科学家也非常欠缺对认识论的理解，很多人甚至不知道贝叶斯主义的存在。

第 8 章 结语旅程的尾声

内容提要

- Definition of Theorem
- Ask for help
- Optimization Problem
- Property of Cauchy Series
- Angle of Corner

通过本次学习，我们小组对计算机视觉以及计算机图形学有了更加深入的了解，也对深度学习和神经网络模型有了一个初步的“不打不相识”。我们从文艺复兴时代的代数学起步，从基本的线性代数知识一步步跨越到了今日具有巨大势头的人工智能和深度学习，对期间科技与知识的进步感到赞叹不已。我们对计算机科学的几个方面有了一定的认识，作为软件工程学院的学生们，我们也越来越期待以后可以接触到更多的计算机技术，以用来解决实际的问题。作为国家未来的工程学人才，我们会时刻保持对新鲜技术的渴望，永远坚持让明天的科技将于今日到来，以造福世界上的每一个人类。很感谢您阅读此篇文章。

这场数学之旅迎来了尾声。

“诺贝尔物理学奖获得者狄拉克也说“数学家参与游戏并在游戏中创造规律”；而在物理学家参与的游戏里，“规律由大自然提供”。只是“随着时间的流逝，我们会愈加明显地察觉到，那些在数学家眼里有趣的规律，同样也是大自然的选择”。

海因里希王子在少女的笔记本里瞥见了“奇妙的象形文字”，“巫术柱”上成列的“占卜符号”和“咒语”。大自然的规律似乎隐藏在这些符号与咒语中，那些“巫术”符号也被解读为现代数学语言中的三角形和圆形。而伽利略认为，大自然就是用数学语言写成的。复数就是个例子。一位富于幻想的数学家在 16 世纪的一个宿命时刻创造了复数——一种没有意义的符号，而复数就是现代量子力学中“微粒运行的场所”。

“可那个想象中的“甚至在空气之外的”游戏有着无法否认的纯美。这种美，源自鲍耶、罗巴切夫斯基、高斯和黎曼这些天才在宿命时刻所创造的理论。他们革新了我们对宇宙几何的看法和时空观，直到我们在相对论中找到了表达世界的方式。狄拉克认为，相对论“在描述大自然时，展现了前所未有的数学之美”。正是它“令人惊叹的数学之美”使物理学家们接受了爱因斯坦的理论，同时也为物理学带来了美学上的深刻改变”

“绘画艺术之美源于自由的创造力，数学之美亦是如此。19 世纪德国数学家格奥尔格·康托尔是现代数学无穷理论的创造者，他也曾说过，“数学的本质就在于它的自由”。除此之外，我们通过这本书还想传达什么呢？当远古先祖在骨头上刻痕，数字出现在他们指间，也就是当数字开始阐释世界的时候，我们看见，在数学发明的高光下闪耀的宿命时刻，在人类历史进程中划分先后的那些瞬间，自由在其中涌现。”

视频网站的魔法

我逐渐沉迷于在网上输出大量知识普及内容的先驱者。全靠他们以及其他知识普及者，我才接触到新可乐的故事、阿施从众实验、米尔格兰姆服从性实验、津巴多的斯坦福监狱实验、安慰剂与反安慰剂效应，以及利贝和海恩斯有关自由意志的实验。我自己也开了个博客，写了一篇博文来讲述这些实验 [13]。这也正是科普的美妙之处，科普总是让人想知道得更多。我非常感兴趣，阅读了所有这些伟大的研究者的著作。我发现了一个全新的宇宙，其中探寻了我们为什么会有某种念头，以及怎样才能更好地思考我们心中的想法。我学到了很多，但尤其重要的是，我对自身无知的广度把握得越来越准确 [14]。

显然，任何作者都没有办法做到面面俱到，不可能讨论到所有关键点、介绍到所有重要人物，或涉及所有亟待解决的数学问题。作者每次都必须做出选择，而这些选择又要受到内在一致性、题材的复杂程度、作者的兴趣和专业知识的限制，还要受到完全人为的字母顺序的限制。这类书的选题策划方案决定了它难免挂一漏万，而大量的好素材最终都不得不忍痛割爱了。

这样一来，本书就成为一个人只身面对浩瀚数学宇宙的感悟。跟随本书在数学知识的海洋中遨游，只能经历无数条路径中的一条，而且我也认为我所选择的从 A 到 Z 的顺序并不是最完美的路径。

数学，有趣而美妙。抛开限制不谈，我仍然希望本书至少能够展示数学这门魅力无穷的学科的概貌。正如

19 世纪数学家索菲亚·柯瓦列夫斯卡娅所说：“许多无缘更深入认识数学的人士把数学与算术混为一谈，而且还误认为它是一门枯燥无味的科学。然而实际上，它是一门需要最强大想象力的科学。” [1] 也许这本书能够再现 5 世纪希腊哲学家普罗克洛斯 (Proclus) 的高尚情怀：“单凭数学便能重振生机，唤醒灵魂……赋予其生命，化想象为现实，变黑暗为智慧的光芒。” [2]

旅途仍在继续但这些形形色色的知识缺少整体结构。庞加莱曾这样说过：“事实的堆砌与一门科学的距离并不比一堆石头与一座房屋的距离近。” 我开始寻求一个关于理论的理论，某种能够让我将形形色色的知识结合起来并得到更好的理解的东西。在很长一段时间中，我并没有意识到答案就在一个公式之中，尽管我一直都在研究它；答案就在一个术语“贝叶斯”之中，这个词在我自己的博士论文题目的开头就出现了 [15]。2016 年初，我逐渐意识到这个公式的重要性。在“骑驴找驴”了很长时间之后，我终于走上了贝叶斯主义的道路。

没有良知的知识不过是对灵魂的戕害。—弗朗索瓦·拉伯雷 (1483 或 1494—1553)

我只能请你多花时间思索这个惊人的结论。我斗胆更进一步期望这本书能够打破你此前对逻辑、知识以及各个方面认知的看法。我也期望这本书能够帮助你更好地确定科学方法的局限性。我还期望这本书能够帮助你怀疑自己的自信过度，因为你很可能深受其害。我同样期望这本书能让你隐约看到如何更好地学习与获取知识。人们在处理“现实”世界的问题时，经常认为数学和哲学与之毫不相干。而人们在谈论日常而具体的事物时，也通常觉得这个领域无须数学博士学位就能理解。这就是严重的自信过度。正如约翰·冯·诺伊曼所说：“如果有人不相信数学是简单的，那是因为他没有意识到人生有多复杂。” 我们无法理解乌鸦悖论，无法理解为什么要选择公立医院而不是私人诊所，无法理解指数增长有多疯狂，这种能力的缺失理应迫使我们怀疑在“真实”世界中自认为已经理解的东西。

但这并不是本书的主要目的。正如在第 1 章中所说的那样，我近几年对认识论的长久思考让我放弃了所谓的科学方法和频率主义。

但最重要的是，我希望你能喜欢这段探索贝叶斯主义的基础和推论必经的旅程，并享受到探索众多学科的乐趣。这些学科对贝叶斯主义的理解和诠释来说非常有用，无论是理论计算机还是认知科学，或者演化生物学和统计物理学。我希望你喜欢奥卡姆剃刀的证明、对归纳问题的抽丝剥茧，还有对实在论的质疑。我也希望阅读这本书对你来说是一次不同寻常的旅程，甚至为你打开了新世界的大门，让你留下不可磨灭的回忆。最重要的是，我希望你能沉浸在激情、着迷和疑问之中，这就是本书的首要目的。

致谢

我们无比感谢本书的中英文版稿件贡献者和论坛用户们。他们帮助增添或改进了书中内容并提供了有价值的反馈。特别地，我们要感谢每一位为这本中文版开源书提交内容改动的贡献者们。这些贡献者的 GitHub 用户名或姓名是（排名不分先后）：..... 谢谢你们为每一位读者改进这本开源书。

本书的初稿在中国科学技术大学、上海财经大学的“深度学习”课程以及浙江大学的“物联网与信息处理”课程和上海交通大学的“面向视觉识别的卷积神经网络”课程中被用于教学。我们在此感谢这些课程的师生，特别是连德富教授、王智教授和罗家佳教授，感谢他们对改进本书提供的宝贵意见。

此外，我们感谢 Amazon Web Services，特别是 Swami Sivasubramanian、Raju Gulabani、Charlie Bell 和 Andrew Jassy 在我们撰写本书时给予的慷慨支持。如果没有可用的时间、资源以及来自同事们的讨论和鼓励，就没有这本书的项目。我们还要感谢 Apache MXNet 团队实现了很多本书所使用的特性。另外，经过同事们的校勘，本书的质量得到了极大的提升。在此我们一一列出章节和校勘人，以表示我们由衷的感谢：引言的校勘人为金颢，预备知识的校勘人为吴俊，深度学习基础的校勘人为张航、王晨光、林海滨，深度学习计算的校勘人为查晟，卷积神经网络的校勘人为张帜、何通，循环神经网络的校勘人为查晟，优化算法的校勘人为郑帅，计算性能的校勘人为郑达、吴俊，计算机视觉的校勘人为解浚源、张帜、何通、张航，自然语言处理的校勘人为王晨光，附录的校勘人为金颢。

感谢将门创投，特别是王慧、高欣欣、常铭珊和白玉为本书的两位中国作者在讲授”动手学深度学习“系列课程时所提供的平台。感谢所有参与这一系列课程的数千名同学们。感谢 Amazon Web Services 中国团队的同事们，特别是费良宏和王晨对作者的支持与鼓励。感谢本书论坛的 3 位版主：王鑫、夏鲁豫和杨培文。他们牺牲了自己宝贵的休息时间来回复大家的提问。感谢人民邮电出版社的杨海玲编辑为我们在本书的出版过程中所提供的各种帮助。

感谢中英文草稿的数百位撰稿人。他们帮助改进了内容并提供了宝贵的反馈。感谢 Anirudh Dagar 和唐源将部分较早版本的 MXNet 实现分别改编为 PyTorch 和 TensorFlow 实现。感谢百度团队将较新的 PyTorch 实现改编为 PaddlePaddle 实现。感谢张帅将更新的 LaTeX 样式集成进 PDF 文件的编译。

特别地，我们要感谢这份中文稿的每一位撰稿人，是他们的无私奉献让这本书变得更好。他们的 GitHub ID 或姓名是（没有特定顺序）：

我们感谢 Amazon Web Services，特别是 Swami Sivasubramanian、Peter DeSantis、Adam Selipsky 和 Andrew Jassy 对撰写本书的慷慨支持。如果没有可用的时间、资源、与同事的讨论和不断的鼓励，这本书就不会出版。

最后，我们要感谢我们的家人。谢谢你们一直陪伴着我们。