



人工智能的数学思维

组织：华东师范大学软件工程学院

时间：2024

目录

第一部分 追问智能	1
前言	2
0.1 内容和结构	3
第 1 章 引言什么是智能?	35
1.1 什么是智能与人工智能	35
1.2 鹦鹉与乌鸦：何种智能?	37
第 2 章 智能，生于数学	
简明数学史	40
2.1 萌芽时期：从计数到位值制	41
2.1.1 史前数学：日常需求与实用计算	41
2.1.2 手指：长身上的计数器	41
2.1.3 数字的位值系统	44
2.1.4 位值制与对数增长在现代计算机中的应用	45
2.1.5 数字：从具象到抽象	46
2.2 初等数学时期：从计算到推理	46
2.2.1 数学的真正诞生：从计算到推理	46
2.2.2 毕达哥拉斯：数与宇宙的关系	49
2.2.3 欧几里得：公理化体系的奠基人	49
2.2.4 阿基米德：数学与物理的桥梁	49
2.2.5 亚里士多德：逻辑与推理	50
2.2.6 古希腊数学的遗产	50
2.3 近代数学时期：变量、函数与微积分	50
2.4 现代数学时期：抽象、结构与计算	51
2.5 三次数学危机：从无理数到不完备	52
2.5.1 第一次危机：无理数的发现与算术信仰的破灭	52
2.5.1.1 危机的产生	53
2.5.1.2 危机的解决	53
2.5.1.3 危机的意义	53
2.5.2 第二次数学危机：微积分基础的争议与解析	54
2.5.2.1 危机的产生	54
2.5.2.2 危机的解决	54

2.5.2.3	危机的意义	54
2.5.3	第三次危机：集合论与逻辑的悖论	55
2.5.4	第三次数学危机及其解决：集合论与逻辑基础的动摇	55
2.5.4.1	危机的产生	55
2.5.4.2	危机的解决	56
2.5.4.3	危机的意义	57
2.6	小结	58
第 3 章 智能，成于计算机		
	简明 AI 史	59
3.1	AI 的萌芽期：理论的起源与计算机的诞生	59
3.2	1950-1970 年代：AI 的奠基与早期探索	61
3.2.1	达特茅斯会后早期黄金期：符号主义 AI	62
3.3	1980 年-1987 年：专家系统与知识工程的兴起	65
3.3.1	代表性专家系统	65
3.3.2	知识表示与规则推理	65
3.3.3	知识工程的广泛应用	66
3.3.4	新兴技术：模糊逻辑与贝叶斯网络	66
3.3.5	第二次“AI 寒冬”的反思与转型	66
3.4	人工智能的分化	67
3.5	1990-2010 年代：联结主义和机器学习的兴起	68
3.5.1	2020 年代：大语言模型（LLM）与生成式人工智能（AIGC）的崛起	68
3.6	人工智能主要学派	69
3.6.1	符号主义学派 (Symbolicism)	69
3.6.2	联结学派/连接学派 (Connectionism)：从神经网络到深度学习	71
3.6.3	行为主义学派 (Actionism)	72
3.6.4	三大学派的比较	73
3.6.5	三大学派对比总结	73
3.7	小结：危机与机遇中的 AI 发展之旅	76
	参考文献	78
	致谢	80

第一部分

追问智能

前言

内容提要

□ Definition of Theorem

□ Ask for help

□ Optimization Problem

□ Property of Cauchy Series

□ Angle of Corner

现在看起来的“显而易见”，在当年却是“困难重重”。

恰如其分地拿捏尺度，显然是智能的外在表现之一。“过犹不及”说得就是这个理。

“语言是思想的边界，技术是思想的实现。”

人工智能的历史源远流长。在古代的神话传说中，技艺高超的工匠可以制作人造“人（robot）”，并为其赋予智能或意识。

本质上，人类发展史就是一部智能简史，人类从计数开始，到数学理论的发展，都在不断追求计算越来越高效、越来越自动化，越来越智能...。从人类文明最早出现数，数的标记和运算，从算术到代数、几何、抽象代数、拓扑、群论等越来越复杂和专门的数学分支，数学史的发展主线背后，是对智能的极致追求。

从人脑和手算发展到一定程度，对更高效计算效率的追求必然会导致计算机的发明，导致人工智能

这个思路非常有启发性，您将人类发展史看作是一部智能简史，从最早的数和运算到现代计算机和人工智能的发展，强调了数学和智能追求之间的紧密联系。我们可以将这个思路融入到书的开篇和部分章节中，甚至作为书的核心主题来展开讨论。以下是对目录的调整建议，结合您的思路：

这个思路非常有启发性，您将人类发展史看作是一部智能简史，从最早的数和运算到现代计算机和人工智能的发展，强调了数学和智能追求之间的紧密联系。我们可以将这个思路融入到书的开篇和部分章节中，甚至作为书的核心主题来展开讨论。以下是对目录的调整建议，结合您的思路：

-它们在数百年的黑暗中闪耀，用数学照亮了人类的历程。

在伏尔泰的小说《老实人》中，坚持莱布尼兹式乐观主义的邦葛罗斯安慰幸存者时，说“如果没有这场灾难，事物就无法继续进行了。因为一切都是最好的安排。”

歌德把历史称作“上帝的神秘作坊”。在这个“作坊”里，堆积这对人类来说无关紧要的小事。只在极少时候，它们才会被某些时刻着凉，史蒂芬·茨威格称之为“高光时刻”。

每一个“宿命时刻”，都是一个个事件串联的了解过。一连串的事件被紧密地编织在一起，经过漫长的发展，事件一个接着一个，然后突然成熟。历史这个“神秘作坊”不只生成武器和战争。其中一些“宿命时刻”如繁星办“熠熠生辉、永不熄灭”。

这本书代表了我们的尝试——让深度学习可平易近人，教会人们概念、背景和代码。

一种结合了代码、数学和 HTML 的媒介

任何一种计算技术要想发挥其全部影响力，都必须得到充分的理解、充分的文档记录，并得到成熟的、维护良好的工具的支持。关键思想应该被清楚地提炼出来，尽可能减少需要让新的从业者跟上时代的入门时间。成熟的库应该自动化常见的任务，示例代码应该使从业者可以轻松地修改、应用和扩展常见的应用程序，以满足他们的需求。以动态网页应用为例。尽管许多公司，如亚马逊，在 20 世纪 90 年代开发了成功的数据库驱动网页应用程序。但在过去的 10 年里，这项技术在帮助创造性企业家方面的潜力已经得到了更大程度的发挥，部分原因是开发了功能强大、文档完整的框架。

测试深度学习的潜力带来了独特的挑战，因为任何一个应用都会将不同的学科结合在一起。应用深度学习需要同时了解（1）以特定方式提出问题的动机；（2）给定建模方法的数学；（3）将模型拟合数据的优化算法；（4）能够有效训练模型、克服数值计算缺陷并最大限度地利用现有硬件的工程方法。同时教授表述问题所需的批判性思维技能、解决问题所需的数学知识，以及实现这些解决方案所需的软件工具，这是一个巨大的挑战。

-数学思维与人工智能的关系

-从数学到智能的发展历程

0.1 内容和结构

全书大致可分为三个部分，在 [图 1](https://zh-v2.d2l.ai/chapter_preface/index.html fig-book-org) 中用不同的颜色呈现：

图 1 全书结构

-第一部分包括基础知识和预备知识。[1 节] 提供深度学习的入门课程。然后在 [2 节] 中，我们将快速介绍实践深度学习所需的前提条件，例如如何存储和处理数据，以及如何应用基于线性代数、微积分和概率基本概念的各种数值运算。[3 节] 和 [4 节] 涵盖了深度学习的最基本概念和技术，例如线性回归、多层感知机和正则化。

-接下来的五章集中讨论现代深度学习技术。[5 节] 描述了深度学习计算的各种关键组件，并为我们随后实现更复杂的模型奠定了基础。接下来，在 [6 节] 和 [7 节] 中，我们介绍了卷积神经网络 (convolutionalneuralnetwork, CNN)，这是构成大多数现代计算机视觉系统骨干的强大工具。随后，在 [8 节] 和 [9 节] 中，我们引入了循环神经网络 (recurrentneuralnetwork, RNN)，这是一种利用数据中的时间或序列结构的模型，通常用于自然语言处理和时间序列预测。在 [10 节] 中，我们介绍了一类新的模型，它采用了一种称为注意力机制的技术，最近它们已经开始在自然语言处理中取代循环神经网络。这一部分将帮助读者快速了解大多数现代深度学习应用背后的基本工具。

-第三部分讨论可伸缩性、效率和应用程序。首先，在 [11 节] 中，我们讨论了用于训练深度学习模型的几种常用优化算法。下一章 [12 节] 将探讨影响深度学习代码计算性能的几个关键因素。在 [13 节] 中，我们展示了深度学习在计算机视觉中的主要应用。在 [14 节] 和 [15 节] 中，我们展示了如何预训练语言表示模型并将其应用于自然语言处理任务。

小结 -深度学习已经彻底改变了模式识别，引入了一系列技术，包括计算机视觉、自然语

言处理、自动语音识别。

-要成功地应用深度学习，必须知道如何抛出一个问题、建模的数学方法、将模型与数据拟合的算法，以及实现所有这些的工程技术。

-这本书提供了一个全面的资源，包括文本、图表、数学和代码，都集中在一个地方。

-要回答与本书相关的问题，请访问我们的论坛 discuss.d2l.ai.

-所有 Jupyter 记事本都可以在 GitHub 上下载。

-本书目的与目标读者

-数学思维与人工智能的关系

-从数学到智能的发展历程

第一部分：人类智能简史

2. 第 1 章：智能简史

-1.2 数学的发展与智能的进化 -表示虚无的数字 0

“印度数学家的成果跟随阿拉伯人在地中海沿岸传播了好久，才最终来到中世纪欧洲翻译家的手中。穆罕默德·花拉子米是一位数学家，出生于乌兹别克斯坦，生活于 780 年至 850 年间，著有《代数学》(Al-kitābal-mukhtaṣarfīhisābal-ğabrwa'l-muqābala)。代数 (algebra) 一词出自书名中的阿拉伯文“al-jabr”的拉丁转写，演算法 (Algorism) 则出自作者花拉子米 (al-Khwārizmī) 的拉丁文译名。在《代数学》这部论著中，没有公式，没有零，甚至连九个印度数字也没有出现。而在公元 8 世纪以前，阿拉伯人使用的是从希腊人那里学来的记数法，传统的希腊数字是用字母表示的。花拉子米在另一部作品——《印度的计算术》中提到了零，“圆圈即无”。我们如今只能看到这部作品的拉丁文版本，与遗失的阿拉伯文真本相比，它在内容上做了相当多的改动。”

“人们何时发现正方形或长方形的对角线与边长之比无法用整数表示，“无限”随之闯入数学的世界？这个比例为何又出现在了由一个兔子问题而衍生出的一串数字中，经斐波那契之手成了黄金比例？”

-发现无理数

-一桩逻辑上的丑闻

-虚数

-一个关于秘密和背叛的故事

-把方程式变成诗

-计算虚数

-非欧几何的世界

-不止于三维

-“真正”的空间几何

-“想象”几何

-弯曲空间

-抽象数学与智能的拓展

-1.3 从手算到计算机

- 计算工具的进化
- 对高效计算的追求如何促成计算机的发明
- 1.4 人工智能的诞生
- 从自动化到智能化的跨越
- 人工智能的早期发展与数学的支撑
- 第二部分：人工智能中的核心数学思维
- 1. 第 2 章：抽象与建模：从现实到数学
- 2.1 建模思维：如何从现实问题抽象出数学模型
- 2.2 常见的 AI 模型及其数学思维：如线性模型、非线性模型等
- 2.3 模型的简化与优化：模型复杂度与可解释性的平衡
- 2. 第 3 章：数据的表示与处理：几何与代数的视角
- 3.1 数据表示与向量空间：如何通过几何思维理解数据
- 3.2 线性代数在 AI 中的角色：从矩阵运算到特征提取
- 3.3 特征值、特征向量与数据降维：PCA、SVD 等技术背后的数学思维
- 3. 第 4 章：不确定性与决策：概率与统计的框架
- 4.1 概率思维：处理不确定性的数学工具
- 4.2 统计推断：如何从数据中学习
- 4. 第 5 章：优化与决策思维：在复杂环境下做出最佳决策
- 最优化问题的数学框架
- 凸优化与非凸优化的区别
- 启发式算法与实用优化方法
- 5. 第 6 章：学习与推理：从算法到智能
- 5.1 机器学习中的数学思维：监督学习与无监督学习的数学基础
- 5.2 推理与知识表示：逻辑、概率与其他形式的推理方法
- 5.3 从理论到实践：算法的优化与应用
- 6. 第 7 章：算法设计中的计算思维
- 经典 AI 算法的数学分析
- 计算复杂度：NP 问题与算法效率
- 计算思维如何影响算法设计
- 7. 第 8 章：深度学习中的数学直觉
- 神经网络的数学基础：从线性代数到非线性激活
- 深度学习的几何与拓扑视角：卷积、池化与拓扑思维
- 深度学习的优化挑战：反向传播与梯度下降的数学理解
- 第三部分：应用与案例分析
- 1. 第 9 章：AI 中的复杂性与可解释性
- 可解释性问题：从数学角度审视 AI 的可解释性
- 实例分析：如何在实际应用中平衡复杂性与可解释性

2. 第 10 章：数据处理与统计推断

- 数据分析中的数学思维
- 统计推断与机器学习模型
- 从数据到决策的思维路径

第四部分：未来展望与思考

10. 第 11 章：智能的未来与数学思维

- 数学思维如何推动智能的发展
- 智能的前沿挑战：AI 发展中的数学难题
- 从数学思维到未来创新：如何利用数学思维推动 AI 的下一步发展

11. 第 12 章：结语

- 从数学思维到人工智能的未来
- 如何在实践中培养数学思维

在这个框架中，第一部分特别突出了人类智能发展的历史背景，并将其与数学的发展相结合，形成一个贯穿全书的主线。这不仅帮助读者理解人工智能的本质，还能引导他们思考数学在智能追求中的关键作用。您觉得这个调整是否符合您的思路呢？===

中道：

势道术 or 道法术器势：道以明向，法以立本，术以立策，器以成事，势以立人
应用深度学习需要同时了解

- (1) 以特定方式提出问题的动机；
- (2) 给定建模方法的数学；
- (3) 将模型拟合数据的优化算法；
- (4) 能够有效训练模型、克服数值计算缺陷并最大限度地利用现有硬件的工程方法。

要成功地应用深度学习，必须知道如何抛出一个问题、建模的数学方法、将模型与数据拟合的算法，以及实现所有这些的工程技术。

这个过程包含了数学思维、算法思维、工程思维。

或者只有教科书，或者只有代码没有数学原理

我们发现了大量关于如何使用给定的深度学习框架（例如，如何对 TensorFlow 中的矩阵进行基本的数值计算）或实现特定技术的代码示例（例如，LeNet、AlexNet、ResNet 的代码片段），这些代码示例分散在各种博客帖子和 GitHub 库中。

但是，这些示例通常关注如何实现给定的方法，但忽略了为什么做出某些算法决策的讨论。

===

就在几年前，不管在大公司还是创业公司，都鲜有工程师和科学家来将深度学习应用到智能产品与服务中。作为深度学习前身的神经网络，才刚刚摆脱被机器学习学术界认为是过时工具的印象。那个时候，即使是机器学习也非新闻头条的常客。它仅仅被看作是一门具有前瞻性，并拥有一系列小范围实际应用的学科。在包含计算机视觉和自然语言处理在内的实

际应用通常需要大量的相关领域知识：这些实际应用被视为相互独立的领域，而机器学习只占其中一小部分。

然而仅仅在这几年之内，深度学习便令全世界大吃一惊。它非常有力地推动了计算机视觉、自然语言处理、自动语音识别、强化学习和统计建模等多个领域的快速发展。随着这些领域的不断进步，我们现在可以制造自动驾驶的汽车，基于短信、邮件甚至电话的自动回复系统，以及在围棋中击败最优秀人类选手的软件。这些由深度学习带来的新工具也正产生着广泛的影响：它们改变了电影制作和疾病诊断的方式，并在从天体物理学到生物学等各个基础科学中扮演越来越重要的角色。

与此同时，深度学习也给它的使用者们带来了独一无二的挑战：任何单一的应用都汇集了各学科的知识。具体来说，应用深度学习需要同时理解：

1. 问题的动机和特点；
2. 将大量不同类型神经网络层通过特定方式组合在一起的模型背后的数学原理；
3. 在原始数据上拟合极复杂的深层模型的优化算法；
4. 有效训练模型、避免数值计算陷阱以及充分利用硬件性能所需的工程技能；
5. 为解决方案挑选合适的变量（超参数）组合的经验。

同样，我们几位作者也面临前所未有的挑战：我们需要在有限的篇幅里糅合深度学习的多方面知识，从而使读者能够较快理解并应用深度学习技术。本书代表了我们的一种尝试：我们将教给读者概念、背景知识和代码；我们将在同一个地方阐述剖析问题所需的批判性思维、解决问题所需的数学知识，以及实现解决方案所需的工程技能。

包含代码、数学、网页、讨论的统一资源

我们在 2017 年 7 月启动了写作这本书的项目。当时我们需要向用户解释 **ApacheMXNet** 在那时的新接口 **Gluon**。遗憾的是，我们并没有找到任何一个资源可以同时满足以下几点需求：

1. 包含较新的方法和应用，并不断更新；
2. 广泛覆盖现代深度学习技术并具有一定的技术深度；
3. 既是严谨的教科书，又是包含可运行代码的生动的教程。

那时，我们在博客和 **GitHub** 上找到了大量的演示特定深度学习框架（例如用 **TensorFlow** 进行数值计算）或实现特定模型（例如 **AlexNet**、**ResNet** 等）的示例代码。这些示例代码的一大价值在于提供了教科书或论文往往省略的实现细节，比如数据的处理和运算的高效率实现。如果不了解这些，即使能将算法倒背如流，也难以将算法应用到自己的项目中去。此外，这些示例代码还使得用户能通过观察修改代码所导致的结果变化而快速验证想法、积累经验。因此，我们坚信动手实践对于学习深度学习的重要性。然而可惜的是，这些示例代码通常侧重于如何实现给定的方法，却忽略了有关算法设计的探究或者实现细节的解释。虽然在像 **Distill** 这样的网站和某些博客上出现了一些有关算法设计和实现细节的讨论，但它们常常缺少示例代码，并通常仅覆盖深度学习的一小部分。

另外，我们欣喜地看到了一些有关深度学习的教科书不断问世，其中最著名的要数 **Goodfellow**、**Bengio** 和 **Courville** 的《深度学习》。该书梳理了深度学习背后的众多概念与方法，是一本极为优秀的教材。然而，这类资源并没有将概念描述与实际代码相结合，以至于有时会令读者对如何实现它们感到毫无头绪。除了这些以外，商业课程提供者虽然制作了众多的

优质资源，但它们的付费门槛依然令不少用户望而生畏。

正因为这样，深度学习用户，尤其是初学者，往往不得不参考来源不同的多种资料。例如，通过教科书或者论文来掌握算法及其相关数学知识，阅读线上文档学习深度学习框架的使用方法，然后寻找感兴趣的算法在这个框架上的实现并摸索如何将它应用到自己的项目中去。如果你正亲身经历这一过程，你可能会感到痛苦：不同来源的资料有时难以相互一一对应，即便能够对应也可能需要花费大量的精力。例如，我们需要将某篇论文公式中的数学变量与某段网上实现中的程序变量一一对应，并在代码中找到论文可能没交代清楚的实现细节，甚至要为运行不同的代码安装不同的运行环境。

针对以上存在的痛点，我们正在着手创建一个为实现以下目标的统一资源：

1. 所有人均可在网上免费获取；
2. 提供足够的技术深度，从而帮助读者实际成为深度学习应用科学家：既理解数学原理，又能够实现并不断改进方法；
3. 包含可运行的代码，为读者展示如何在实际中解决问题。这样不仅直接将数学公式对应成实际代码，而且可以修改代码、观察结果并及时获取经验；
4. 允许我们和整个社区不断快速迭代内容，从而紧跟仍在高速发展的深度学习领域；
5. 由包含有关技术细节问答的论坛作为补充，使大家可以相互答疑并交换经验。

这些目标往往互有冲突：公式、定理和引用最容易通过 **LaTeX** 进行管理和展示，代码自然应该用简单易懂的 **Python** 描述，而网页本身应该是一堆 **HTML** 及配套的 **CSS** 和 **JavaScript**。此外，我们希望这个资源可以作为可执行代码、实体书以及网站。然而，目前并没有任何工具可以完美地满足以上所有需求。

因此，我们不得不自己来集成这样一个工作流。我们决定在 **GitHub** 上分享源代码并允许提交编辑，通过 **Jupyter** 记事本来整合代码、公式、文本、图片等，使用 **Sphinx** 作为渲染引擎来生成不同格式的输出，并使用 **Discourse** 作为论坛。虽然我们的系统尚未完善，但这些选择在互有冲突的目标之间取得了较好的折中。这很可能是使用这种集成工作流发布的第一本书。

从在线课程到纸质书

本书的两位中国作者曾每周末在线免费讲授“动手学深度学习”系列课程。课程的讲义自然成为了本书内容的蓝本。这个课程持续了 5 个月，其间近 3,000 名同学参与了讨论，并贡献了近 5,000 多个有价值的讨论，特别是其中几个参加比赛的练习很受欢迎。这个课程的受欢迎程度出乎我们的意料。尽管我们将课件和课程视频都公开在了网上，但我们同时觉得出版成纸质书也许能让更多喜爱纸质阅读的读者受益。因此，我们委托人民邮电出版社来出版这本书。

从蓝本到成书花费了更多的时间。我们对所有涉及的所有技术点补充了背景介绍，并使用了更加严谨的写作风格，还对版式和示意图做了大量修改。书中所有的代码执行结果都是自动生成的，任何改动都会触发对书中每一段代码的测试，以保证读者在动手实践时能复现结果。

我们的初衷是让更多人更容易地使用深度学习。为了让大家能够便利地获取这些资源，我们保留了免费的网站内容，并且通过不收取出版稿费的方式来降低纸质书的价格，使更多人

有能力购买。

教学资源、计算资源和反馈

本书的英文版 *Dive into Deep Learning* 是加州大学伯克利分校 2019 年春学期“Introduction to Deep Learning”（深度学习导论）课程的教材。同时，截至 2019 年春学期，本书中英文版的内容已被全球 15 所知名大学用于教学。本书的学习社区、免费教学资源（课件、教学视频、更多习题等），以及用于本书学习或教学的免费计算资源（仅限学生和老师）的申请方法在本书网站 [<https://zh.d2l.ai>](<https://zh.d2l.ai/>) 上发布。诚然，将算法、公式、图片、代码和样例统一进一本适合阅读的书，并以具有交互式体验的 *Jupyter* 记事本文件的形式提供给读者，是对我们的极大挑战。书中难免有很多疏忽的地方，敬请原谅，并希望读者能通过每一节后面的二维码向我们反馈阅读本书过程中发现的问题。

结尾处，附上陆游的一句诗作为勉励：

> “纸上得来终觉浅，绝知此事要躬行。”

===

1. 引言

中道：

势道术 or 道法术器势：道以明向，法以立本，术以立策，器以成事，势以立人

第二版

前言

几年前，在大公司和初创公司中，并没有大量的深度学习科学家开发智能产品和服务。我们年轻人（作者）进入这个领域时，机器学习并没有在报纸上获得头条新闻。我们的父母根本不知道什么是机器学习，更不用说为什么我们可能更喜欢机器学习，而不是从事医学或法律职业。机器学习是一门具有前瞻性的学科，在现实世界的应用范围很窄。而那些应用，例如语音识别和计算机视觉，需要大量的领域知识，以至于它们通常被认为是完全独立的领域，而机器学习对这些领域来说只是一个小组件。因此，神经网络——我们在本书中关注的深度学习模型的前身，被认为是过时的工具。

就在过去的五年里，深度学习给世界带来了惊喜，推动了计算机视觉、自然语言处理、自动语音识别、强化学习和统计建模等领域的快速发展。有了这些进步，我们现在可以制造比以往任何时候都更自主的汽车（不过可能没有一些公司试图让大家相信的那么自主），可以自动起草普通邮件的智能回复系统，帮助人们从令人压抑的大收件箱中解放出来。在围棋等棋类游戏中，软件超越了世界上最优秀的人，这曾被认为是几十年后的事。这些工具已经对工业和社会产生了越来越广泛的影响，改变了电影的制作方式、疾病的诊断方式，并在基础科学中扮演着越来越重要的角色——从天体物理学到生物学。

关于本书

这本书代表了我们的尝试——让深度学习可平易近人，教会人们概念、背景和代码。

一种结合了代码、数学和 **HTML** 的媒介

任何一种计算技术要想发挥其全部影响力，都必须得到充分的理解、充分的文档记录，并得到成熟的、维护良好的工具的支持。关键思想应该被清楚地提炼出来，尽可能减少需要让

新的从业者跟上时代的入门时间。成熟的库应该自动化常见的任务，示例代码应该使从业者可以轻松地修改、应用和扩展常见的应用程序，以满足他们的需求。以动态网页应用为例。尽管许多公司，如亚马逊，在 20 世纪 90 年代开发了成功的数据库驱动网页应用程序。但在过去的 10 年里，这项技术在帮助创造性企业家方面的潜力已经得到了更大程度的发挥，部分原因是开发了功能强大、文档完整的框架。

测试深度学习的潜力带来了独特的挑战，因为任何一个应用都会将不同的学科结合在一起。应用深度学习需要同时了解（1）以特定方式提出问题的动机；（2）给定建模方法的数学；（3）将模型拟合数据的优化算法；（4）能够有效训练模型、克服数值计算缺陷并最大限度地利用现有硬件的工程方法。同时教授表述问题所需的批判性思维技能、解决问题所需的数学知识，以及实现这些解决方案所需的软件工具，这是一个巨大的挑战。

在我们开始写这本书的时候，没有资源能够同时满足一些条件：（1）是最新的；（2）涵盖了现代机器学习的所有领域，技术深度丰富；（3）在一本引人入胜的教科书中，人们可以在实践教程中找到干净的可运行代码，并从中穿插高质量的阐述。我们发现了大量关于如何使用给定的深度学习框架（例如，如何对 TensorFlow 中的矩阵进行基本的数值计算）或实现特定技术的代码示例（例如，LeNet、AlexNet、ResNet 的代码片段），这些代码示例分散在各种博客帖子和 GitHub 库中。但是，这些示例通常关注如何实现给定的方法，但忽略了为什么做出某些算法决策的讨论。虽然一些互动资源已经零星地出现以解决特定主题。例如，在网站 [Distill](<http://distill.pub/>) 上发布的引人入胜的博客帖子或个人博客，但它们仅覆盖深度学习中的选定主题，并且通常缺乏相关代码。另一方面，虽然已经出现了几本教科书，其中最著名的是 ([Goodfellow et al., 2016] (https://zh-v2.d2l.ai/chapter_references/zreferences.html#id47)) (中文名《深度学习》)，它对深度学习背后的概念进行了全面的调查，但这些资源并没有将这些概念的描述与这些概念的代码实现结合起来。有时会让读者对如何实现它们一无所知。此外，太多的资源隐藏在商业课程提供商的付费壁垒后面。

我们着手创建的资源可以：（1）每个人都可以免费获得；（2）提供足够的技术深度，为真正成为应用机器学习科学家提供起步；（3）包括可运行的代码，向读者展示如何解决实践中的问题；（4）允许我们和社区的快速更新；（5）由一个 [论坛] (<http://discuss.d2l.ai/>) 作为补充，用于技术细节的互动讨论和回答问题。

这些目标经常是相互冲突的。公式、定理和引用最好用 LaTeX 来管理和布局。代码最好用 Python 描述。网页原生是 HTML 和 JavaScript 的。此外，我们希望内容既可以作为可执行代码访问、作为纸质书访问，作为可下载的 PDF 访问，也可以作为网站在互联网上访问。目前还没有完全适合这些需求的工具和工作流程，所以我们不得不自行组装。我们在 [16.5 节] 中详细描述了我们的方法。我们选择 GitHub 来共享源代码并允许编辑，选择 Jupyter 记事本来混合代码、公式和文本，选择 Sphinx 作为渲染引擎来生成多个输出，并为论坛提供讨论。虽然我们的体系尚不完善，但这些选择在相互冲突的问题之间提供了一个很好的妥协。我们相信，这可能是第一本使用这种集成工作流程出版的书。

在实践中学习

许多教科书教授一系列的主题，每一个都非常详细。例如，Chris Bishop 的优秀教科书

([Bishop, 2006] (https://zh-v2.d2l.ai/chapter_references/zreferences.html#id10))，对每个主题都教得很透彻，以至于要读到线性回归这一章需要大量的工作。虽然专家们喜欢这本书正是因为它的透彻性，但对初学者来说，这一特性限制了它作为介绍性文本的实用性。

在这本书中，我们将适时教授大部分概念。换句话说，你将在实现某些实际目的所需的非常时刻学习概念。虽然我们在开始时花了一些时间来教授基础的背景知识，如线性代数和概率，但我们希望你在思考更深奥的概率分布之前，先体会一下训练模型的满足感。

除了提供基本数学背景速成课程的几节初步课程外，后续的每一章都介绍了适量的新概念，并提供可独立工作的例子——使用真实的数据集。这带来了组织上的挑战。某些模型可能在逻辑上组合在单节中。而一些想法可能最好是通过连续允许几个模型来传授。另一方面，坚持“一个工作例子一节”的策略有一个很大的好处：这使你可以通过利用我们的代码尽可能轻松地启动你自己的研究项目。只需复制这一节的内容并开始修改即可。

我们将根据需要可运行代码与背景材料交错。通常，在充分解释工具之前，我们常常会在提供工具这一方面犯错误（我们将在稍后解释背景）。例如，在充分解释随机梯度下降为什么有用或为什么有效之前，我们可以使用它。这有助于给从业者提供快速解决问题所需的弹药，同时需要读者相信我们的一些决定。

这本书将从头开始教授深度学习的概念。有时，我们想深入研究模型的细节，这些的细节通常会被深度学习框架的高级抽象隐藏起来。特别是在基础教程中，我们希望读者了解在给定层或优化器中发生的一切。在这些情况下，我们通常会提供两个版本的示例：一个是我们从零开始实现一切，仅依赖张量操作和自动微分；另一个是更实际的示例，我们使用深度学习框架的高级 API 编写简洁的代码。一旦我们教了您一些组件是如何工作的，我们就可以在随后的教程中使用高级 API 了。

内容和结构

全书大致可分为三个部分，在 [图 1] (https://zh-v2.d2l.ai/chapter_preface/index.html#fig-book-org) 中用不同的颜色呈现：

图 1 全书结构

- 第一部分包括基础知识和预备知识。[1 节] 提供深度学习的入门课程。然后在 [2 节] 中，我们将快速介绍实践深度学习所需的前提条件，例如如何存储和处理数据，以及如何应用基于线性代数、微积分和概率基本概念的各种数值运算。[3 节] 和 [4 节] 涵盖了深度学习的最基本概念和技术，例如线性回归、多层感知机和正则化。- 接下来的五章集中讨论现代深度学习技术。[5 节] 描述了深度学习计算的各种关键组件，并为我们随后实现更复杂的模型奠定了基础。接下来，在 [6 节] 和 [7 节] 中，我们介绍了卷积神经网络 (convolutional neural network, CNN)，这是构成大多数现代计算机视觉系统骨干的强大工具。随后，在 [8 节] 和 [9 节] 中，我们引入了循环神经网络 (recurrent neural network, RNN)，这是一种利用数据中的时间或序列结构的模型，通常用于自然语言处理和时间序列预测。在 [10 节] 中，我们介绍了一类新的模型，它采用了一种称为注意力机制的技术，最近它们已经开始在自然语言处理中取代循环神经网络。这一部分将帮助读者快速了解大多数现代深度学习应用背后的基本工具。- 第三部分讨论可伸缩性、效率和应用程序。首先，在 [11 节] 中，我们讨论了用于训练深度学习模型

的几种常用优化算法。下一章 [12 节] 将探讨影响深度学习代码计算性能的几个关键因素。在 [13 节] 中，我们展示了深度学习在计算机视觉中的主要应用。在 [14 节] 和 [15 节] 中，我们展示了如何预训练语言表示模型并将其应用于自然语言处理任务。

代码

本书的大部分章节都以可执行代码为特色，因为我们相信交互式学习体验在深度学习中的重要性。目前，某些直觉只能通过试错、小幅调整代码并观察结果来发展。理想情况下，一个优雅的数学理论可能会精确地告诉我们如何调整代码以达到期望的结果。不幸的是，这种优雅的理论目前还没有出现。尽管我们尽了最大努力，但仍然缺乏对各种技术的正式解释，这既是因为描述这些模型的数学可能非常困难，也是因为对这些主题的认真研究最近才进入高潮。我们希望随着深度学习理论的发展，这本书的未来版本将能够在当前版本无法提供的地方提供见解。

有时，为了避免不必要的重复，我们将本书中经常导入和引用的函数、类等封装在 ‘d2l’ 包中。对于要保存到包中的任何代码块，比如一个函数、一个类或者多个导入，我们都会标记为 ‘@save’。我们在 [16.6 节] (https://zh-v2.d2l.ai/chapter_appendix-tools-for-deep-learning/d2l.html#sec-d2l) 中提供了这些函数和类的详细描述。‘d2l’ 软件包是轻量级的，仅需要以下软件包和模块作为依赖项：

```
““ @save import collections import hashlib import math import os import random import re
import shutil import sys import tarfile import time import zipfile from collections import defaultdict
import pandas as pd import requests from IPython import display
```

““

目标受众

本书面向学生（本科生或研究生）、工程师和研究人员，他们希望扎实掌握深度学习的实用技术。因为我们从头开始解释每个概念，所以不需要过往的深度学习或机器学习背景。全面解释深度学习的方法需要一些数学和编程，但我们只假设读者了解一些基础知识，包括线性代数、微积分、概率和非常基础的 Python 编程。此外，在附录中，我们提供了本书所涵盖的大多数数学知识的复习。大多数时候，我们会优先考虑直觉和想法，而不是数学的严谨性。有许多很棒的书可以引导感兴趣的读者走得更远。Bela Bollobas 的《线性分析》([Bollobás, 1999] (https://zh-v2.d2l.ai/chapter_references/zreferences.html#id13)) 对线性代数和函数分析进行了深入的研究。([Wasserman, 2013] (https://zh-v2.d2l.ai/chapter_references/zreferences.html#id178)) 是一本很好的统计学指南。如果读者以前没有使用过 Python 语言，那么可以仔细阅读这个 [Python 教程]

论坛

与本书相关，我们已经启动了一个论坛，在 [discuss.d2l.ai](<https://discuss.d2l.ai/>)。当对本书的任何一节有疑问时，请在每一节的末尾找到相关的讨论页链接。

小结

- 深度学习已经彻底改变了模式识别，引入了一系列技术，包括计算机视觉、自然语言处理、自动语音识别。
- 要成功地应用深度学习，必须知道如何抛出一个问题、建模的数学方法、

将模型与数据拟合的算法，以及实现所有这些的工程技术。- 这本书提供了一个全面的资源，包括文本、图表、数学和代码，都集中在一个地方。- 要回答与本书相关的问题，请访问我们的论坛。- 所有 **Jupyter** 记事本都可以在 **GitHub** 上下载。

第一版

几年前，在大公司和初创公司中，并没有大量的深度学习科学家开发智能产品和服务。我们中年轻人（作者）进入这个领域时，机器学习并没有在报纸上获得头条新闻。我们的父母根本不知道什么是机器学习，更不用说为什么我们可能更喜欢机器学习，而不是从事医学或法律职业。机器学习是一门具有前瞻性的学科，在现实世界的应用范围很窄。而那些应用，例如语音识别和计算机视觉，需要大量的领域知识，以至于它们通常被认为是完全独立的领域，而机器学习对这些领域来说只是一个小组件。因此，神经网络——我们在本书中关注的深度学习模型的前身，被认为是过时的工具。

就在过去的五年里，深度学习给世界带来了惊喜，推动了计算机视觉、自然语言处理、自动语音识别、强化学习和统计建模等领域的快速发展。有了这些进步，我们现在可以制造比以往任何时候都更自主的汽车（不过可能没有一些公司试图让大家相信的那么自主），可以自动起草普通邮件的智能回复系统，帮助人们从令人压抑的大收件箱中解放出来。在围棋等棋类游戏中，软件超越了世界上最优秀的人，这曾被认为是几十年后的事。这些工具已经对工业和社会产生了越来越广泛的影响，改变了电影的制作方式、疾病的诊断方式，并在基础科学中扮演着越来越重要的角色——从天体物理学到生物学。

时至今日，人们常用的计算机程序几乎都是软件开发人员从零编写的。比如，现在开发人员要编写一个程序来管理网上商城。经过思考，开发人员可能提出如下一个解决方案：首先，用户通过 **Web** 浏览器（或移动应用程序）与应用程序进行交互；紧接着，应用程序与数据库引擎进行交互，以保存交易历史记录并跟踪每个用户的动态；其中，这个应用程序的核心——“业务逻辑”，详细说明了应用程序在各种情况下进行的操作。

为了完善业务逻辑，开发人员必须细致地考虑应用程序所有可能遇到的边界情况，并为这些边界情况设计合适的规则。当买家单击将商品添加到购物车时，应用程序会向购物车数据库表中添加一个条目，将该用户 **ID** 与商品 **ID** 关联起来。虽然一次编写出完美应用程序的可能性微乎其微，但在大多数情况下，开发人员可以从上述的业务逻辑出发，编写出符合业务逻辑的应用程序，并不断测试直到满足用户的需求。根据业务逻辑设计自动化系统，驱动正常运行的产品和系统，是一个人类认知上的非凡壮举。

幸运的是，对日益壮大的机器学习科学家群体来说，实现很多任务的自动化并不再屈从于人类所能考虑到的逻辑。想象一下，假如开发人员要试图解决以下问题之一：

- 编写一个应用程序，接受地理信息、卫星图像和一些历史天气信息，并预测明天的天气；
- 编写一个应用程序，接受自然文本表示的问题，并正确回答该问题；
- 编写一个应用程序，接受一张图像，识别出该图像所包含的人，并在每个人周围绘制轮廓；
- 编写一个应用程序，向用户推荐他们可能喜欢，但在自然浏览过程中不太可能遇到的产品。

在这些情况下，即使是顶级程序员也无法提出完美的解决方案，原因可能各不相同。有时任务可能遵循一种随着时间推移而变化的模式，我们需要程序来自动调整。有时任务内的

关系可能太复杂（比如像素和抽象类别之间的关系），需要数千或数百万次的计算。即使人类的眼睛能毫不费力地完成这些难以提出完美解决方案的任务，这其中的计算也超出了人类意识理解范畴。机器学习（**machine learning**, **ML**）是一类强大的可以从经验中学习的技术。通常采用观测数据或与环境交互的形式，机器学习算法会积累更多的经验，其性能也会逐步提高。相反，对于刚刚所说的电子商务平台，如果它一直执行相同的业务逻辑，无论积累多少经验，都不会自动提高，除非开发人员认识到问题并更新软件。本书将带读者开启机器学习之旅，并特别关注深度学习（**deep learning**, **DL**）的基础知识。深度学习是一套强大的技术，它可以推动计算机视觉、自然语言处理、医疗保健和基因组学等不同领域的创新。

1.1. 日常生活中的机器学习

机器学习应用在日常生活中的方方面面。现在，假设本书的作者们一起驱车去咖啡店。阿斯顿拿起一部 iPhone，对它说道：“Hey Siri!”手机的语音识别系统就被唤醒了。接着，李沐对 Siri 说道：“去星巴克咖啡店。”语音识别系统就自动触发语音转文字功能，并启动地图应用程序，地图应用程序在启动后筛选了若干条路线，每条路线都显示了预计的通行时间……由此可见，机器学习渗透在生活中的方方面面，在短短几秒钟的时间里，人们与智能手机的日常互动就可以涉及几种机器学习模型。

现在，假如需要我们编写程序来响应一个“唤醒词”（比如“Alexa”“小爱同学”和“Hey Siri”）。我们试着用一台计算机和一个代码编辑器编写代码，如 [图 1.1.1] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-wake-word) 中所示。问题看似很难解决：麦克风每秒钟将收集大约 44000 个样本，每个样本都是声波振幅的测量值。而该测量值与唤醒词难以直接关联。那又该如何编写程序，令其输入麦克风采集到的原始音频片段，输出是否是，否（表示该片段是否包含唤醒词）的可靠预测呢？我们对编写这个程序毫无头绪，这就是需要机器学习的原因。

图 1.1.1 识别唤醒词

通常，即使我们不知道怎样明确地告诉计算机如何从输入映射到输出，大脑仍然能够自己执行认知功能。换句话说，即使我们不知道如何编写计算机程序来识别“Alexa”这个词，大脑自己也能够识别它。有了这一能力，我们就可以收集一个包含大量音频样本的数据集（**dataset**），并对包含和不包含唤醒词的样本进行标记。利用机器学习算法，我们不需要设计一个“明确地”识别唤醒词的系統。相反，我们只需要定义一个灵活的程序算法，其输出由许多参数（**parameter**）决定，然后使用数据集来确定当下的“最佳参数集”，这些参数通过某种性能度量方式来达到完成任务的最佳性能。

那么到底什么是参数呢？参数可以被看作旋钮，旋钮的转动可以调整程序的行为。任一调整参数后的程序被称为模型（**model**）。通过操作参数而生成的所有不同程序（输入-输出映射）的集合称为“模型族”。使用数据集来选择参数的元程序被称为学习算法（**learning algorithm**）。

在开始用机器学习算法解决问题之前，我们必须精确地定义问题，确定输入（**input**）和输出（**output**）的性质，并选择合适的模型族。在本例中，模型接收一段音频作为输入，然后在是或否中生成一个选择作为输出。如果一切顺利，经过一番训练，模型对于“片段是否包含唤醒词”的预测通常是正确的。

现在模型每次听到“Alexa”这个词时都会发出“是”的声音。由于这里的唤醒词是任意选择

的自然语言，因此我们可能需要一个足够丰富的模型族，使模型多元化。比如，模型族的另一个模型只在听到“Hey Siri”这个词时发出“是”。理想情况下，同一个模型族应该适合于“Alexa”识别和“Hey Siri”识别，因为从直觉上看，它们似乎是相似的任务。然而，如果我们想处理完全不同的输入或输出，比如：从图像映射到字幕，或从英语映射到中文，可能需要一个完全不同的模型族。

但如果模型所有的按钮（模型参数）都被随机设置，就不太可能识别出“Alexa”或“Hey Siri”或任何其他单词。在机器学习中，学习（learning）是一个训练模型的过程。通过这个过程，我们可以发现正确的参数集，从而使模型强制执行所需的行为。换句话说，我们用数据训练（train）模型。如 [图 1.1.2] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-ml-loop) 所示，训练过程通常包含如下步骤：

1. 从一个随机初始化参数的模型开始，这个模型基本没有“智能”；
2. 获取一些数据样本（例如，音频片段以及对应的是或否标签）；
3. 调整参数，使模型在这些样本中表现得更好；
4. 重复第（2）步和第（3）步，直到模型在任务中的表现令人满意。

图 1.1.2 一个典型的训练过程

总而言之，我们没有编写唤醒词识别器，而是编写了一个“学习”程序。如果我们用一个巨大的带标签的数据集，它很可能可以“学习”识别唤醒词。这种“通过用数据集来确定程序行为”的方法可以被看作用数据编程（programming with data）。比如，我们可以通过向机器学习系统，提供许多猫和狗的图片来设计一个“猫图检测器”。检测器最终可以学会：如果输入是猫的图片就输出一个非常大的正数，如果输入是狗的图片就会输出一个非常小的负数。如果检测器不确定输入的图片中是猫还是狗，它会输出接近于零的数……这个例子仅仅是机器学习常见应用的冰山一角，而深度学习是机器学习的一个主要分支，本节稍后的内容将对其进行更详细的解析。

1.2. 机器学习中的关键组件

首先介绍一些核心组件。无论什么类型的机器学习问题，都会遇到这些组件：

1. 可以用来学习的数据（data）；
2. 如何转换数据的模型（model）；
3. 一个目标函数（objective function），用来量化模型的有效性；
4. 调整模型参数以优化目标函数的算法（algorithm）。

1.2.1. 数据

毋庸置疑，如果没有数据，那么数据科学毫无用武之地。每个数据集由一个个样本（example, sample）组成，大多时候，它们遵循独立同分布（independently and identically distributed, i.i.d.）。样本有时也叫做数据点（data point）或者数据实例（data instance），通常每个样本由一组称为特征（features，或协变量（covariates））的属性组成。机器学习模型会根据这些属性进行预测。在上面的监督学习问题中，要预测的是一个特殊的属性，它被称为标签（label，或目标（target））。

当处理图像数据时，每一张单独的照片即为一个样本，它的特征由每个像素数值的有序列表表示。比如， 200×200 彩色照片由 $200 \times 200 \times 3 = 120000$ 个数值组成，其中的“3”对应于每个空间位置的红、绿、蓝通道的强度。再比如，对于一组医疗数据，给定一组标准的特征（如年龄、生命体征和诊断），此数据可以用来尝试预测患者是否会存活。

当每个样本的特征类别数量都是相同的时候，其特征向量是固定长度的，这个长度被称为数据的维数（**dimensionality**）。固定长度的特征向量是一个方便的属性，它可以用来量化学习大量样本。

然而，并不是所有的数据都可以用“固定长度”的向量表示。以图像数据为例，如果它们全部来自标准显微镜设备，那么“固定长度”是可取的；但是如果图像数据来自互联网，它们很难具有相同的分辨率或形状。这时，将图像裁剪成标准尺寸是一种方法，但这种办法很局限，有丢失信息的风险。此外，文本数据更不符合“固定长度”的要求。比如，对于亚马逊等电子商务网站上的客户评论，有些文本数据很简短（比如“好极了”），有些则长篇大论。与传统机器学习方法相比，深度学习的一个主要优势是可以处理不同长度的数据。

一般来说，拥有越多数据的时候，工作就越容易。更多的数据可以被用来训练出更强大的模型，从而减少对预先设想假设的依赖。数据集的由小变大为现代深度学习的成功奠定基础。在没有大数据集的情况下，许多令人兴奋的深度学习模型黯然失色。就算一些深度学习模型在小数据集上能够工作，但其效能并不比传统方法高。

请注意，仅仅拥有海量的数据是不够的，我们还需要正确的数据。如果数据中充满了错误，或者如果数据的特征不能预测任务目标，那么模型很可能无效。有一句古语很好地反映了这个现象：“输入的是垃圾，输出的也是垃圾。”（“**Garbage in, garbage out.**”）此外，糟糕的预测性能甚至会加倍放大事态的严重性。在一些敏感应用中，如预测性监管、简历筛选和用于贷款的风险模型，我们必须特别警惕垃圾数据带来的后果。一种常见的问题来自不均衡的数据集，比如在一个有关医疗的训练数据集中，某些人群没有样本表示。想象一下，假设我们想要训练一个皮肤癌识别模型，但它（在训练数据集中）从未“见过”黑色皮肤的人群，这个模型就会顿时束手无策。

再比如，如果用“过去的招聘决策数据”来训练一个筛选简历的模型，那么机器学习模型可能会无意中捕捉到历史残留的不公正，并将其自动化。然而，这一切都可能在不知情的情况下发生。因此，当数据不具有充分代表性，甚至包含了一些社会偏见时，模型就很有可能存在偏见。

1.2.2. 模型

大多数机器学习会涉及到数据的转换。比如一个“摄取照片并预测笑脸”的系统。再比如通过摄取到的一组传感器读数预测读数的正常与异常程度。虽然简单的模型能够解决如上简单的问题，但本书中关注的问题超出了经典方法的极限。深度学习与经典方法的区别主要在于：前者关注的功能强大的模型，这些模型由神经网络错综复杂的交织在一起，包含层层数据转换，因此被称为深度学习（**deep learning**）。在讨论深度模型的过程中，本书也将提及一些传统方法。

1.2.3. 目标函数

前面的内容将机器学习介绍为“从经验中学习”。这里所说的“学习”，是指自主提高模型完成某些任务的效能。但是，什么才算真正的提高呢？在机器学习中，我们需要定义模型的优劣程度的度量，这个度量在大多数情况是“可优化”的，这被称之为目标函数（**objective function**）。我们通常定义一个目标函数，并希望优化它到最低点。因为越低越好，所以这些函数有时被

称为损失函数 (loss function, 或 cost function)。但这只是一个惯例, 我们也可以取一个新的函数, 优化到它的最高点。这两个函数本质上是相同的, 只是翻转一下符号。

当任务在试图预测数值时, 最常见的损失函数是平方误差 (squared error), 即预测值与实际值之差的平方。当试图解决分类问题时, 最常见的目标函数是最小化错误率, 即预测与实际情况不符的样本比例。有些目标函数 (如平方误差) 很容易被优化, 有些目标 (如错误率) 由于不可微性或其他复杂性难以直接优化。在这些情况下, 通常会优化替代目标。

通常, 损失函数是根据模型参数定义的, 并取决于数据集。在一个数据集上, 我们可以通过最小化总损失来学习模型参数的最佳值。该数据集由一些为训练而收集的样本组成, 称为训练数据集 (training dataset, 或称为训练集 (training set))。然而, 在训练数据上表现良好的模型, 并不一定在“新数据集”上有同样的性能, 这里的“新数据集”通常称为测试数据集 (test dataset, 或称为测试集 (test set))。

综上所述, 可用数据集通常可以分成两部分: 训练数据集用于拟合模型参数, 测试数据集用于评估拟合的模型。然后我们观察模型在这两部分数据集的性能。“一个模型在训练数据集上的性能”可以被想象成“一个学生在模拟考试中的分数”。这个分数用来为一些真正的期末考试做参考, 即使成绩令人鼓舞, 也不能保证期末考试成功。换言之, 测试性能可能会显著偏离训练性能。当一个模型在训练集上表现良好, 但不能推广到测试集时, 这个模型被称为过拟合 (overfitting) 的。就像在现实生活中, 尽管模拟考试考得很好, 真正的考试不一定百发百中。

1.2.4. 优化算法

当我们获得了一些数据源及其表示、一个模型和一个合适的损失函数, 接下来就需要一种算法, 它能够搜索出最佳参数, 以最小化损失函数。深度学习中, 大多流行的优化算法通常基于一种基本方法—梯度下降 (gradient descent)。简而言之, 在每个步骤中, 梯度下降法都会检查每个参数, 看看如果仅对该参数进行少量变动, 训练集损失会朝哪个方向移动。然后, 它在可以减少损失的方向上优化参数。

1.3. 各种机器学习问题

在机器学习的广泛应用中, 唤醒词问题只是冰山一角。前面唤醒词识别的例子, 只是机器学习可以解决的众多问题中的一个。下面将列出一些常见的机器学习问题, 为之后本书的讨论做铺垫。接下来会经常引用前面提到的概念, 如数据、模型和优化算法。

1.3.1. 监督学习

监督学习 (supervised learning) 擅长在“给定输入特征”的情况下预测标签。每个“特征-标签”对都称为一个样本 (example)。有时, 即使标签是未知的, 样本也可以指代输入特征。我们的目标是生成一个模型, 能够将任何输入特征映射到标签 (即预测)。

举一个具体的例子: 假设我们需要预测患者的心脏病是否会发作, 那么观察结果“心脏病发作”或“心脏病没有发作”将是样本的标签。输入特征可能是生命体征, 如心率、舒张压和收缩压等。

监督学习之所以能发挥作用, 是因为在训练参数时, 我们为模型提供了一个数据集, 其中每个样本都有真实的标签。用概率论术语来说, 我们希望预测“估计给定输入特征的标签”

的条件概率。虽然监督学习只是几大类机器学习问题之一，但是在工业中，大部分机器学习的成功应用都使用了监督学习。这是因为在一定程度上，许多重要的任务可以清晰地描述为，在给定一组特定的可用数据的情况下，估计未知事物的概率。比如：

- 根据计算机断层扫描（**Computed Tomography, CT**）肿瘤图像，预测是否为癌症；
- 给出一个英语句子，预测正确的法语翻译；
- 根据本月的财务报告数据，预测下个月股票的价格；

监督学习的学习过程一般可以分为三大步骤：

1. 从已知大量数据样本中随机选取一个子集，为每个样本获取真实标签。有时，这些样本已有标签（例如，患者是否在下一年内康复？）；有时，这些样本可能需要被人工标记（例如，图像分类）。这些输入和相应的标签一起构成了训练数据集；
2. 选择有监督的学习算法，它将训练数据集作为输入，并输出一个“已完成学习的模型”；
3. 将之前没有见过的样本特征放到这个“已完成学习的模型”中，使用模型的输出作为相应标签的预测。

整个监督学习过程如 [图 1.3.1] ([https:// zh-v2.d2l.ai/ chapter_introduction/ index.html#fig-supervised-learning](https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-supervised-learning)) 所示。

![../_images/supervised-learning.svg](https://zh-v2.d2l.ai/_images/supervised-learning.svg)

图 1.3.1 监督学习

综上所述，即使使用简单的描述给定输入特征的预测标签，监督学习也可以采取多种形式的模型，并且需要大量不同的建模决策，这取决于输入和输出的类型、大小和数量。例如，我们使用不同的模型来处理“任意长度的序列”或“固定长度的序列”。

1.3.1.1. 回归

回归（**regression**）是最简单的监督学习任务之一。假设有一组房屋销售数据表格，其中每行对应一个房子，每列对应一个相关的属性，例如房屋的面积、卧室的数量、浴室的数量以及到镇中心的步行距离，等等。每一行的属性构成了一个房子样本的特征向量。如果一个人住在纽约或旧金山，而且他不是亚马逊、谷歌、微软或 **Facebook** 的首席执行官，那么他家的特征向量（房屋面积，卧室数量，浴室数量，步行距离）可能类似于：[600,1,1,60]。如果一个人住在匹兹堡，这个特征向量可能更接近 [3000,4,3,10]……当人们在市场上寻找新房子时，可能需要估计一栋房子的公平市场价值。为什么这个任务可以归类为回归问题呢？本质上是输出决定的。销售价格（即标签）是一个数值。当标签取任意数值时，我们称之为回归问题，此时的目标是生成一个模型，使它的预测非常接近实际标签值。

生活中的许多问题都可归类为回归问题。比如，预测用户对一部电影的评分可以被归类为一个回归问题。这里有一个小插曲：在 2009 年，如果有人设计了一个很棒的算法来预测电影评分，那可能会赢得 [100 万美元的奈飞奖](https://en.wikipedia.org/wiki/Netflix_Prize)。再比如，预测病人在医院的住院时间也是一个回归问题。总而言之，判断回归问题的一个很好的经验法则是，任何有关“有多少”的问题很可能就是回归问题。比如：

- 这个手术需要多少小时；
- 在未来 6 小时，这个镇会有多少降雨量。

即使你以前从未使用过机器学习，可能在不经意间，已经解决了一些回归问题。例如，你让人修理了排水管，承包商花了 3 小时清除污水管道中的污物，然后他寄给你一张 350 美元的账单。而你的朋友雇了同一个承包商 2 小时，他收到了 250 美元的账单。如果有人请你估

算清理污物的费用，你可以假设承包商收取一些基本费用，然后按小时收费。如果这些假设成立，那么给出这两个数据样本，你就已经可以确定承包商的定价结构：50 美元上门服务费，另外每小时 100 美元。在不经意间，你就已经理解并应用了线性回归算法。

然而，以上假设有时并不可取。例如，一些差异是由于两个特征之外的几个因素造成的。在这些情况下，我们将尝试学习最小化“预测值和实际标签值的差异”的模型。本书大部分章节将关注平方误差损失函数的最小化。

1.3.1.2. 分类

虽然回归模型可以很好地解决“有多少”的问题，但是很多问题并非如此。例如，一家银行希望在其移动应用程序中添加支票扫描功能。具体地说，这款应用程序能够自动理解从图像中看到的文本，并将手写字符映射到对应的已知字符之上。这种“哪一个”的问题叫做分类（classification）问题。分类问题希望模型能够预测样本属于哪个类别（category，正式称为类（class））。例如，手写数字可能有 10 类，标签被设置为数字 0~9。最简单的分类问题是只有两类，这被称之为二项分类（binomial classification）。例如，数据集可能由动物图像组成，标签可能是猫狗猫，狗两类。回归是训练一个回归函数来输出一个数值；分类是训练一个分类器来输出预测的类别。

然而模型怎么判断得出这种“是”或“不是”的硬分类预测呢？我们可以试着用概率语言来理解模型。给定一个样本特征，模型为每个可能的类分配一个概率。比如，之前的猫狗分类例子中，分类器可能会输出图像是猫的概率为 0.9。0.9 这个数字表达什么意思呢？可以这样理解：分类器 90

当有两个以上的类别时，我们把这个问题称为多项分类（multiclass classification）问题。常见的例子包括手写字符识别 0,1,2,...,9,a,b,c,...。与解决回归问题不同，分类问题的常见损失函数被称为交叉熵（cross-entropy），本书 [3.4 节] (https://zh-v2.d2l.ai/chapter_linear-networks/softmax-regression.html#sec-softmax) 将详细阐述。

请注意，最常见的类别不一定是最终用于决策的类别。举个例子，假设后院有一个如 [图 1.3.2] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-death-cap) 所示的蘑菇。

现在，我们想要训练一个毒蘑菇检测分类器，根据照片预测蘑菇是否有毒。假设这个分类器输出 [图 1.3.2] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-death-cap) 包含死帽蕈的概率是 0.2。换句话说，分类器 80% 确定图中的蘑菇不是死帽蕈。尽管如此，我们也不会吃它，因为不值得冒 20% 的死亡风险。换句话说，不确定风险的影响远远大于收益。因此，我们需要将“预期风险”作为损失函数，即需要将结果的概率乘以与之相关的收益（或伤害）。在这种情况下，食用蘑菇造成的损失为 $0.2 \times \infty + 0.8 \times 0 = \infty$ ，而丢弃蘑菇的损失为 $0.2 \times 0 + 0.8 \times 1 = 0.8$ 。事实上，谨慎是有道理的，[图 1.3.2] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-death-cap) 中的蘑菇实际上是一个死帽蕈。

分类可能变得比二项分类、多项分类复杂得多。例如，有一些分类任务的变体可以用于寻找层次结构，层次结构假定在许多类之间存在某种关系。因此，并不是所有的错误都是均等的。人们宁愿错误地分入一个相关的类别，也不愿错误地分入一个遥远的类别，这通常被称为层次分类（hierarchical classification）。早期的一个例子是 [卡尔·林奈] (<https://en.wikipedia.org/>

wiki/Carl_Linnaeus)，他对动物进行了层次分类。

在动物分类的应用中，把一只狮子狗误认为雪纳瑞可能不会太糟糕。但如果模型将狮子狗与恐龙混淆，就滑稽至极了。层次结构相关性可能取决于模型的使用者计划如何使用模型。例如，响尾蛇和乌梢蛇血缘上可能很接近，但如果把响尾蛇误认为是乌梢蛇可能会是致命的。因为响尾蛇是有毒的，而乌梢蛇是无毒的。

1.3.1.3. 标记问题

有些分类问题很适合于二项分类或多项分类。例如，我们可以训练一个普通的二项分类器来区分猫和狗。运用最前沿的计算机视觉的算法，这个模型可以很轻松地被训练。尽管如此，无论模型有多精确，当分类器遇到新的动物时可能会束手无策。比如 [图 1.3.3](https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-stackedanimals) 所示的这张“不来梅的城市音乐家”的图像（这是一个流行的德国童话故事），图中有一只猫、一只公鸡、一只狗、一头驴，背景是一些树。取决于我们最终想用模型做什么，将其视为二项分类问题可能没有多大意义。取而代之，我们可能想让模型描绘输入图像的内容，一只猫、一只公鸡、一只狗，还有一头驴。

[!./_images/stackedanimals.png](https://zh-v2.d2l.ai/_images/stackedanimals.png)(https://zh-v2.d2l.ai/_images/stackedanimals.png)

图 1.3.3 一只猫、一只公鸡、一只狗、一头驴

学习预测不相互排斥的类别的问题称为多标签分类 (multi-label classification)。举个例子，人们在技术博客上贴的标签，比如“机器学习”“技术”“小工具”“编程语言”“Linux”“云计算”“AWS”。一篇典型的文章可能会用 5~10 个标签，因为这些概念是相互关联的。关于“云计算”的帖子可能会提到“AWS”，而关于“机器学习”的帖子也可能涉及“编程语言”。

此外，在处理生物医学文献时，我们也会遇到这类问题。正确地标记文献很重要，有利于研究人员对文献进行详尽的审查。在美国国家医学图书馆 (The United States National Library of Medicine)，一些专业的注释员会检查每一篇在 PubMed 中被索引的文章，以便将其与 Mesh 中的相关术语相关联 (Mesh 是一个大约有 28000 个标签的集合)。这是一个十分耗时的过程，注释器通常在归档和标记之间有一年的延迟。这里，机器学习算法可以提供临时标签，直到每一篇文章都有严格的人工审核。事实上，近几年来，BioASQ 组织已经 [举办比赛](http://bioasq.org/) 来完成这项工作。

1.3.1.4. 搜索

有时，我们不仅仅希望输出一个类别或一个实值。在信息检索领域，我们希望对一组项目进行排序。以网络搜索为例，目标不是简单的“查询 (query) - 网页 (page)”分类，而是在海量搜索结果中找到用户最需要的那部分。搜索结果的排序也十分重要，学习算法需要输出有序的元素子集。换句话说，如果要求我们输出字母表中的前 5 个字母，返回“A、B、C、D、E”和“C、A、B、E、D”是不同的。即使结果集是相同的，集内的顺序有时却很重要。

该问题的一种可能的解决方案：首先为集合中的每个元素分配相应的相关性分数，然后检索评级最高的元素。[PageRank](https://en.wikipedia.org/wiki/PageRank)，谷歌搜索引擎背后最初的秘密武器就是这种评分系统的早期例子，但它的奇特之处在于它不依赖于实际的查询。在这里，他们依靠一个简单的相关性过滤来识别一组相关条目，然后根据 PageRank 对包含查

询条件的结果进行排序。如今，搜索引擎使用机器学习和用户行为模型来获取网页相关性得分，很多学术会议也致力于这一主题。

1.3.1.5. 推荐系统

另一类与搜索和排名相关的问题是推荐系统（**recommender system**），它的目标是向特定用户进行“个性化”推荐。例如，对于电影推荐，科幻迷和喜剧爱好者的推荐结果页面可能会有很大不同。类似的应用也会出现在零售产品、音乐和新闻推荐等等。

在某些应用中，客户会提供明确反馈，表达他们对特定产品的喜爱程度。例如，亚马逊上的产品评级和评论。在其他一些情况下，客户会提供隐性反馈。例如，某用户跳过播放列表中的某些歌曲，这可能说明这些歌曲对此用户不大合适。总的来说，推荐系统会为“给定用户和物品”的匹配性打分，这个“分数”可能是估计的评级或购买的概率。由此，对于任何给定的用户，推荐系统都可以检索得分最高的对象集，然后将其推荐给用户。以上只是简单的算法，而工业生产的推荐系统要先进得多，它会将详细的用户活动和项目特征考虑在内。推荐系统算法经过调整，可以捕捉一个人的偏好。比如，[图 1.3.4] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-deeplearning-amazon) 是亚马逊基于个性化算法推荐的深度学习书籍，成功地捕捉了作者的喜好。

图 1.3.4 亚马逊推荐的深度学习书籍

尽管推荐系统具有巨大的应用价值，但单纯用它作为预测模型仍存在一些缺陷。首先，我们的数据只包含“审查后的反馈”：用户更倾向于给他们感觉强烈的事物打分。例如，在五分制电影评分中，会有许多五星级和一星级评分，但三星级却明显很少。此外，推荐系统有可能形成反馈循环：推荐系统首先会优先推送一个购买量较大（可能被认为更好）的商品，然而目前用户的购买习惯往往是遵循推荐算法，但学习算法并不总是考虑到这一细节，进而更频繁地被推荐。综上所述，关于如何处理审查、激励和反馈循环的许多问题，都是重要的开放性研究问题。

1.3.1.6. 序列学习

以上大多数问题都具有固定大小的输入和产生固定大小的输出。例如，在预测房价的问题中，我们考虑从一组固定的特征：房屋面积、卧室数量、浴室数量、步行到市中心的时间；图像分类问题中，输入为固定尺寸的图像，输出则为固定数量（有关每一个类别）的预测概率；在这些情况下，模型只会将输入作为生成输出的“原料”，而不会“记住”输入的具体内容。

如果输入的样本之间没有任何关系，以上模型可能完美无缺。但是如果输入是连续的，模型可能就需要拥有“记忆”功能。比如，我们该如何处理视频片段呢？在这种情况下，每个视频片段可能由不同数量的帧组成。通过前一帧的图像，我们可能对后一帧中发生的事情更有把握。语言也是如此，机器翻译的输入和输出都为文字序列。

再比如，在医学上序列输入和输出就更为重要。设想一下，假设一个模型被用来监控重症监护病人，如果他们在未来 24 小时内死亡的风险超过某个阈值，这个模型就会发出警报。我们绝不希望抛弃过去每小时有关病人病史的所有信息，而仅根据最近的测量结果做出预测。

这些问题是序列学习的实例，是机器学习最令人兴奋的应用之一。序列学习需要摄取输入序列或预测输出序列，或两者兼而有之。具体来说，输入和输出都是可变长度的序列，例

如机器翻译和从语音中转录文本。虽然不可能考虑所有类型的序列转换，但以下特殊情况值得一提。

标记和解析。这涉及到用属性注释文本序列。换句话说，输入和输出的数量基本上是相同的。例如，我们可能想知道动词和主语在哪里，或者可能想知道哪些单词是命名实体。通常，目标是基于结构和语法假设对文本进行分解和注释，以获得一些注释。这听起来比实际情况要复杂得多。下面是一个非常简单的示例，它使用“标记”来注释一个句子，该标记指示哪些单词引用命名实体。标记为“Ent”，是实体（entity）的简写。

“ Tom has dinner in Washington with Sally Ent - - Ent - Ent ”

自动语音识别。在语音识别中，输入序列是说话人的录音（如 [图 1.3.5] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-speech) 所示），输出序列是说话人所说内容的文本记录。它的挑战在于，与文本相比，音频帧多得多（声音通常以 8kHz 或 16kHz 采样）。也就是说，音频和文本之间没有 1:1 的对应关系，因为数千个样本可能对应于一个单独的单词。这也是“序列到序列”的学习问题，其中输出比输入短得多。

图 1.3.5 ‘-D-e-e-p- L-ea-r-ni-ng-’ 在录音中。

文本到语音。这与自动语音识别相反。换句话说，输入是文本，输出是音频文件。在这种情况下，输出比输入长得多。虽然人类很容易识判断发音别扭的音频文件，但这对计算机来说并不是那么简单。

机器翻译。在语音识别中，输入和输出的出现顺序基本相同。而在机器翻译中，颠倒输入和输出的顺序非常重要。换句话说，虽然我们仍将一个序列转换成另一个序列，但是输入和输出的数量以及相应序列的顺序大都不会相同。比如下面这个例子，“错误的对齐”反应了德国人喜欢把动词放在句尾的特殊倾向。

“ 德语: Haben Sie sich schon dieses grossartige Lehrwerk angeschaut? 英语: Did you already check out this excellent tutorial? 错误的对齐: Did you yourself already this excellent tutorial looked-at? ”

其他学习任务也有序列学习的应用。例如，确定“用户阅读网页的顺序”是二维布局分析问题。再比如，对话问题对序列的学习更为复杂：确定下一轮对话，需要考虑对话历史状态以及现实世界的知识……如上这些都是热门的序列学习研究领域。

1.3.2. 无监督学习

到目前为止，所有的例子都与监督学习有关，即需要向模型提供巨大数据集：每个样本包含特征和相应标签值。打趣一下，“监督学习”模型像一个打工仔，有一份极其专业的工作和一位极其平庸的老板。老板站在身后，准确地告诉模型在每种情况下应该做什么，直到模型学会从情况到行动的映射。取悦这位老板很容易，只需尽快识别出模式并模仿他们的行为即可。

相反，如果工作没有十分具体的目标，就需要“自发”地去学习了。比如，老板可能会给我们一大堆数据，然后要求用它做一些数据科学研究，却没有对结果有要求。这类数据中不含

有“目标”的机器学习问题通常被为无监督学习（unsupervised learning），本书后面的章节将讨论无监督学习技术。那么无监督学习可以回答什么样的问题呢？来看看下面的例子。

- 聚类（clustering）问题：没有标签的情况下，我们是否能给数据分类呢？比如，给定一组照片，我们能把它分成风景照片、狗、婴儿、猫和山峰的照片吗？同样，给定一组用户的网页浏览记录，我们能否将具有相似行为的用户聚类呢？- 主成分分析（principal component analysis）问题：我们能否找到少量的参数来准确地捕捉数据的线性相关属性？比如，一个球的运动轨迹可以用球的速度、直径和质量来描述。再比如，裁缝们已经开发出了一小部分参数，这些参数相当准确地描述了人体的形状，以适应衣服的需要。另一个例子：在欧几里得空间中是否存在一种（任意结构的）对象的表示，使其符号属性能够很好地匹配？这可以用来描述实体及其关系，例如“罗马”-“意大利”+“法国”=“巴黎”。- 因果关系（causality）和概率图模型（probabilistic graphical models）问题：我们能否描述观察到的许多数据的根本原因？例如，如果我们有关于房价、污染、犯罪、地理位置、教育和工资的人口统计数据，我们能否简单地根据经验数据发现它们之间的关系？- 生成对抗性网络（generative adversarial networks）：为我们提供一种合成数据的方法，甚至像图像和音频这样复杂的非结构化数据。潜在的统计机制是检查真实和虚假数据是否相同的测试，它是无监督学习的另一个重要而令人兴奋的领域。

1.3.3. 与环境互动

有人一直心存疑虑：机器学习的输入（数据）来自哪里？机器学习的输出又将去往何方？到目前为止，不管是监督学习还是无监督学习，我们都会预先获取大量数据，然后启动模型，不再与环境交互。这里所有学习都是在算法与环境断开后进行的，被称为离线学习（offline learning）。对于监督学习，从环境中收集数据的过程类似于 [图 1.3.6] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-data-collection)。

图 1.3.6 从环境中为监督学习收集数据。

这种简单的离线学习有它的魅力。好的一面是，我们可以孤立地进行模式识别，而不必分心于其他问题。但缺点是，解决的问题相当有限。这时我们可能会期望人工智能不仅能够做出预测，而且能够与真实环境互动。与预测不同，“与真实环境互动”实际上会影响环境。这里的人工智能是“智能代理”，而不仅是“预测模型”。因此，我们必须考虑到它的行为可能会影响未来观察结果。

考虑“与真实环境互动”将打开一整套新的建模问题。以下只是几个例子。

- 环境还记得我们以前做过什么吗？- 环境是否有助于我们建模？例如，用户将文本读入语音识别器。- 环境是否想要打败模型？例如，一个对抗性的设置，如垃圾邮件过滤或玩游戏？- 环境是否重要？- 环境是否变化？例如，未来的数据是否总是与过去相似，还是随着时间的推移会发生变化？是自然变化还是响应我们的自动化工具而发生变化？

当训练和测试数据不同时，最后一个问题提出了分布偏移（distribution shift）的问题。接下来的内容将简要描述强化学习问题，这是一类明确考虑与环境交互的问题。

1.3.4. 强化学习

如果你对使用机器学习开发与环境交互并采取行动感兴趣，那么最终可能会专注于强化

学习 (reinforcement learning)。这可能包括应用到机器人、对话系统，甚至开发视频游戏的人工智能 (AI)。深度强化学习 (deep reinforcement learning) 将深度学习应用于强化学习的问题，是非常热门的研究领域。突破性的深度 Q 网络 (Q-network) 在雅达利游戏中仅使用视觉输入就击败了人类，以及 AlphaGo 程序在棋盘游戏围棋中击败了世界冠军，是两个突出强化学习的例子。

在强化学习问题中，智能体 (agent) 在一系列的时间步骤上与环境交互。在每个特定时间点，智能体从环境接收一些观察 (observation)，并且必须选择一个动作 (action)，然后通过某种机制 (有时称为执行器) 将其传输回环境，最后智能体从环境中获得奖励 (reward)。此后新一轮循环开始，智能体接收后续观察，并选择后续操作，依此类推。强化学习的过程在 [图 1.3.7] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-rl-environment) 中进行了说明。请注意，强化学习的目标是产生一个好的策略 (policy)。强化学习智能体选择的“动作”受策略控制，即一个从环境观察映射到行动的功能。

图 1.3.7 强化学习和环境之间的相互作用

强化学习框架的通用性十分强大。例如，我们可以将任何监督学习问题转化为强化学习问题。假设我们有一个分类问题，可以创建一个强化学习智能体，每个分类对应一个“动作”。然后，我们可以创建一个环境，该环境给予智能体的奖励。这个奖励与原始监督学习问题的损失函数是一致的。

当然，强化学习还可以解决许多监督学习无法解决的问题。例如，在监督学习中，我们总是希望输入与正确的标签相关联。但在强化学习中，我们并不假设环境告诉智能体每个观测的最优动作。一般来说，智能体只是得到一些奖励。此外，环境甚至可能不会告诉是哪些行为导致了奖励。

以强化学习在国际象棋的应用为例。唯一真正的奖励信号出现在游戏结束时：当智能体获胜时，智能体可以得到奖励 1；当智能体失败时，智能体将得到奖励-1。因此，强化学习者必须处理学分分配 (credit assignment) 问题：决定哪些行为是值得奖励的，哪些行为是需要惩罚的。就像一个员工升职一样，这次升职很可能反映了前一年的大量的行动。要想在未来获得更多的晋升，就需要弄清楚这一过程中哪些行为导致了晋升。

强化学习可能还必须处理部分可观测性问题。也就是说，当前的观察结果可能无法阐述有关当前状态的所有信息。比方说，一个清洁机器人发现自己被困在一个许多相同的壁橱的房子里。推断机器人的精确位置 (从而推断其状态)，需要在进入壁橱之前考虑它之前的观察结果。

最后，在任何时间点上，强化学习智能体可能知道一个好的策略，但可能有许多更好的策略从未尝试过的。强化学习智能体必须不断地做出选择：是应该利用当前最好的策略，还是探索新的策略空间 (放弃一些短期回报来换取知识)。

一般的强化学习问题是一个非常普遍的问题。智能体的动作会影响后续的观察，而奖励只与所选的动作相对应。环境可以是完整观察到的，也可以是部分观察到的，解释所有这些复杂性可能会对研究人员要求太高。此外，并不是每个实际问题都表现出所有这些复杂性。因此，学者们研究了一些特殊情况下的强化学习问题。

当环境可被完全观察到时，强化学习问题被称为马尔可夫决策过程（markov decision process）。当状态不依赖于之前的操作时，我们称该问题为上下文赌博机（contextual bandit problem）。当没有状态，只有一组最初未知回报的可用动作时，这个问题就是经典的多臂赌博机（multi-armed bandit problem）。

1.4. 起源

为了解决各种各样的机器学习问题，深度学习提供了强大的工具。虽然许多深度学习方法都是最近才有重大突破，但使用数据和神经网络编程的核心思想已经研究了几个世纪。事实上，人类长期以来就有分析数据和预测未来结果的愿望，而自然科学大部分都植根于此。例如，伯努利分布是以 [雅各布·伯努利（1654-1705）] (<https://en.wikipedia.org/wiki/JacobuBernoulli>) 命名的。而高斯分布是由 [卡尔·弗里德里希·高斯（1777-1855）] (https://en.wikipedia.org/wiki/Carl_Friedrich_Gauss) 发现的，他发明了最小均方算法，至今仍用于解决从保险计算到医疗诊断的许多问题。这些工具算法催生了自然科学中的一种实验方法——例如，电阻中电流和电压的欧姆定律可以用线性模型完美地描述。

即使在中世纪，数学家对估计（estimation）也有敏锐的直觉。例如，[雅各布·克贝尔（1460 – 1533）] (<https://www.maa.org/press/periodicals/convergence/mathematical-treasures-jacob-kobels-geometry>) 的几何学书籍举例说明，通过平均 16 名成年男性的脚的长度，可以得出一英尺的长度。

[!./_images/kobel.jpg](https://zh-v2.d2l.ai/_images/kobel.jpg)(https://zh-v2.d2l.ai/_images/kobel.jpg)

图 1.4.1 估计一英尺的长度

[图 1.4.1] (https://zh-v2.d2l.ai/chapter_introduction/index.htmlfig-kobel) 说明了这个估计器是如何工作的。16 名成年男子被要求脚连脚排成一行。然后将它们的总长度除以 16，得到现在等于 1 英尺的估计值。

这个算法后来被改进以处理畸形的脚——将拥有最短和最长脚的两个人送走，对其余的人取平均值。这是最早的修剪均值估计的例子之一。

随着数据的收集和可获得性，统计数据真正实现了腾飞。[罗纳德·费舍尔（1890-1962）] 对统计理论和在遗传学中的应用做出了重大贡献。他的许多算法（如线性判别分析）和公式（如费舍尔信息矩阵）至今仍被频繁使用。

甚至，费舍尔在 1936 年发布的鸢尾花卉数据集，有时仍然被用来解读机器学习算法。

他也是优生学的倡导者，这提醒我们：数据科学在道德上存疑的使用，与其在工业和自然科学中的生产性使用一样，有着悠远而持久的历史。

机器学习的第二个影响来自 [克劳德·香农（1916-2001）] 的信息论和 [艾伦·图灵（1912-1954）] 的计算理论。图灵在他著名的论文《计算机器与智能》([Turing, 1950] 中提出了“机器能思考吗？”的问题。在他所描述的图灵测试中，如果人类评估者很难根据文本互动区分机器和人类的回答，那么机器就可以被认为是“智能的”。

另一个影响可以在神经科学和心理学的中找到。其中，最古老的算法之一是 [唐纳德·赫布（1904 – 1985）] (https://en.wikipedia.org/wiki/Donald_O._Hebb) 开创性的著作《行为的组织》

([Hebb and Hebb, 1949] (https://zh-v2.d2l.ai/chapter_references/zreferences.html#id62))。他提出神经元通过积极强化学习，是 Rosenblatt 感知器学习算法的原型，被称为“赫布学习”。这个算法也为当今深度学习的许多随机梯度下降算法奠定了基础：强化期望行为和减少不良行为，从而在神经网络中获得良好的参数设置。

神经网络 (neural networks) 的得名源于生物灵感。一个多世纪以来（追溯到 1873 年亚历山大·贝恩和 1890 年詹姆斯·谢林顿的模型），研究人员一直试图组装类似于相互作用的神经元网络的计算电路。随着时间的推移，对生物学的解释变得不再肤浅，但这个名字仍然存在。其核心是当今大多数网络中都可以找到的几个关键原则：

- 线性和非线性处理单元的交替，通常称为层 (layers)；
- 使用链式规则（也称为反向传播 (backpropagation)）一次性调整网络中的全部参数。

经过最初的快速发展，神经网络的研究从 1995 年左右开始停滞不前，直到 2005 年才稍有起色。这主要是因为两个原因。首先，训练网络（在计算上）非常昂贵。在上个世纪末，随机存取存储器 (RAM) 非常强大，而计算能力却很弱。其次，数据集相对较小。事实上，费舍尔 1932 年的鸢尾花卉数据集是测试算法有效性的流行工具，而 MNIST 数据集的 60000 个手写数字的数据集被认为是巨大的。考虑到数据和计算的稀缺性，核方法 (kernel method)、决策树 (decision tree) 和图模型 (graph models) 等强大的统计工具（在经验上）证明是更为优越的。与神经网络不同的是，这些算法不需要数周的训练，而且有很强的理论依据，可以提供可预测的结果。

1.5. 深度学习的发展

大约 2010 年开始，那些在计算上看起来不可行的神经网络算法变得热门起来，实际上是以下两点导致的：其一，随着互联网的公司的出现，为数亿在线用户提供服务，大规模数据集变得触手可及；另外，廉价又高质量的传感器、廉价的数据存储（克莱德定律）以及廉价计算（摩尔定律）的普及，特别是 GPU 的普及，使大规模算力唾手可得。

这一点在 [表 1.5.1] (https://zh-v2.d2l.ai/chapter_introduction/index.html#tab-intro-decade) 中得到了说明。

年代	数据规模	内存	每秒浮点运算
1970	100 (鸢尾花卉)	1 KB	100 KF (Intel 8080)
1980	1 K (波士顿房价)	100 KB	1 MF (Intel 80186)
1990	10 K (光学字符识别)	10 MB	10 MF (Intel 80486)
2000	10 M (网页)	100 MB	1 GF (Intel Core)
2010	10 G (广告)	1 GB	1 TF (Nvidia C2050)
2020	1 T (社交网络)	100 GB	1 PF (Nvidia DGX-2)

很明显，随机存取存储器没有跟上数据增长的步伐。与此同时，算力的增长速度已经超过了现有数据的增长速度。这意味着统计模型需要提高内存效率（这通常是通过添加非线性来实现的），同时由于计算预算的增加，能够花费更多时间来优化这些参数。因此，机器学习和统计的关注点从（广义的）线性模型和核方法转移到了深度神经网络。这也造就了许多深度学习的中流砥柱，如多层感知机 ([McCulloch and Pitts, 1943] (https://zh-v2.d2l.ai/chapter_references/zreferences.html#id106))、卷积神经网络 ([LeCun et al., 1998] (https://zh-v2.d2l.ai/chapter_references/zreferences.html#id90))、长短期记忆网络 ([Graves and Schmidhuber, 2005] (<https://zh-v2.d2l.ai/>))

chapter_references/zreferences.htmlid51)) 和 Q 学习 ([Watkins and Dayan, 1992](https://zh-v2.d2l.ai/chapter_references/zreferences.htmlid179)), 在相对休眠了相当长一段时间之后, 在过去十年中被“重新发现”。

最近十年, 在统计模型、应用和算法方面的进展就像寒武纪大爆发——历史上物种飞速进化的时期。事实上, 最先进的技术不仅仅是将可用资源应用于几十年前的算法的结果。下面列举了帮助研究人员在过去十年中取得巨大进步的想法 (虽然只触及了皮毛)。

- 新的容量控制方法, 如 dropout ([Srivastava et al., 2014], 有助于减轻过拟合的危险。这是通过在神经网络中应用噪声注入 ([Bishop, 1995](https://zh-v2.d2l.ai/chapter_references/zreferences.htmlid9)) 来实现的, 出于训练目的, 用随机变量来代替权重。
- 注意力机制解决了困扰统计学一个多世纪的问题: 如何在不增加可学习参数的情况下增加系统的记忆和复杂性。研究人员通过使用只能被视为可学习的指针结构 ([Bahdanau et al., 2014](https://zh-v2.d2l.ai/chapter_references/zreferences.htmlid6)) 找到了一个优雅的解决方案。不需要记住整个文本序列 (例如用于固定维度表示中的机器翻译), 所有需要存储的都是指向翻译过程的中间状态的指针。这大大提高了长序列的准确性, 因为模型在开始生成新序列之前不再需要记住整个序列。
- 多阶段设计。例如, 存储器网络 ([Sukhbaatar et al., 2015] 和神经编程器-解释器 ([Reed and De Freitas, 2015])。它们允许统计建模者描述用于推理的迭代方法。这些工具允许重复修改深度神经网络的内部状态, 从而执行推理链中的后续步骤, 类似于处理器如何修改用于计算的存储器。
- 另一个关键的发展是生成对抗网络 ([Goodfellow et al., 2014] 的发明。传统模型中, 密度估计和生成模型的统计方法侧重于找到合适的概率分布 (通常是近似的) 和抽样算法。因此, 这些算法在很大程度上受到统计模型固有灵活性的限制。生成式对抗性网络的关键创新是用具有可微参数的任意算法代替采样器。然后对这些数据进行调整, 使得鉴别器 (实际上是一个双样本测试) 不能区分假数据和真实数据。通过使用任意算法生成数据的能力, 它为各种技术打开了密度估计的大门。驰骋的斑马 ([Zhu et al., 2017] 和假名人脸 ([Karras et al., 2017] 的例子都证明了这一进展。即使是业余的涂鸦者也可以根据描述场景布局的草图生成照片级真实图像 ([Park et al., 2019]- 在许多情况下, 单个 GPU 不足以处理可用于训练的大量数据。在过去的十年中, 构建并行和分布式训练算法的能力有了显著提高。设计可伸缩算法的关键挑战之一是深度学习优化的主力——随机梯度下降, 它依赖于相对较小的小批量数据来处理。同时, 小批量限制了 GPU 的效率。因此, 在 1024 个 GPU 上进行训练, 例如每批 32 个图像的小批量大小相当于总计约 32000 个图像的小批量。最近的工作, 首先是由 ([Li, 2017](https://zh-v2.d2l.ai/chapter_references/zreferences.htmlid91)) 完成的, 随后是 ([You et al., 2017](https://zh-v2.d2l.ai/chapter_references/zreferences.htmlid192)) 和 ([Jia et al., 2018](https://zh-v2.d2l.ai/chapter_references/zreferences.htmlid79)), 将观察大小提高到 64000 个, 将 ResNet-50 模型在 ImageNet 数据集上的训练时间减少到不到 7 分钟。作为比较——最初的训练时间是按天为单位的。
- 并行计算的能力也对强化学习的进步做出了相当关键的贡献。这导致了计算机在围棋、雅达里游戏、星际争霸和物理模拟 (例如, 使用 MuJoCo) 中实现超人性能的重大进步。有关如何在 AlphaGo 中实现这一点的说明, 请参见如 ([Silver et al., 2016] 简而言之, 如果有大量的 (状态、动作、奖励) 三元组可用, 即只要有可能尝试很多东西来了解它们之间的关

系，强化学习就会发挥最好的作用。仿真提供了这样一条途径。- 深度学习框架在传播思想方面发挥了至关重要的作用。允许轻松建模的第一代框架包括 [Caffe]、[Torch] 和 [Theano]。许多开创性的论文都是用这些工具写的。到目前为止，它们已经被 [TensorFlow]（通常通过其高级 API [Keras](<https://github.com/keras-team/keras>) 使用）、[CNTK]、[Caffe 2] 和 [Apache MXNet] 所取代。第三代工具，即用于深度学习的命令式工具，可以说是由 [Chainer] 率先推出的，它使用类似于 Python NumPy 的语法来描述模型。这个想法被 [PyTorch]、MXNet 的 [Gluon API] 和 [Jax] 都采纳了。

“系统研究人员构建更好的工具”和“统计建模人员构建更好的神经网络”之间的分工大大简化了工作。例如，在 2014 年，对卡内基梅隆大学机器学习博士生来说，训练线性回归模型曾经是一个不容易的作业问题。而现在，这项任务只需不到 10 行代码就能完成，这让每个程序员轻易掌握了它。

1.6. 深度学习的成功案例

人工智能在交付结果方面有着悠久的历史，它能带来用其他方法很难实现的结果。例如，使用光学字符识别的邮件分拣系统从 20 世纪 90 年代开始部署，毕竟，这是著名的手写数字 MNIST 数据集的来源。这同样适用于阅读银行存款支票和对申请者的信用进行评分。系统会自动检查金融交易是否存在欺诈。这成为许多电子商务支付系统的支柱，如 PayPal、Stripe、支付宝、微信、苹果、Visa 和万事达卡。国际象棋的计算机程序已经竞争了几十年。机器学习在互联网上提供搜索、推荐、个性化和排名。换句话说，机器学习是无处不在的，尽管它经常隐藏在视线之外。

直到最近，人工智能才成为人们关注的焦点，主要是因为解决了以前被认为难以解决的问题，这些问题与消费者直接相关。许多这样的进步都归功于深度学习。

- 智能助理，如苹果的 Siri、亚马逊的 Alexa 和谷歌助手，都能够相当准确地回答口头问题。这包括一些琐碎的工作，比如打开电灯开关（对残疾人来说是个福音）甚至预约理发师和提供电话支持对话。这可能是人工智能正在影响我们生活的最明显的迹象。- 数字助理的一个关键要素是准确识别语音的能力。逐渐地，在某些应用中，此类系统的准确性已经提高到与人类同等水平的程度 ([Xiong et al., 2018](https://zh-v2.d2l.ai/chapter_references/zreferences.html#id190))。- 物体识别同样也取得了长足的进步。估计图片中的物体在 2010 年是一项相当具有挑战性的任务。在 ImageNet 基准上，来自 NEC 实验室和伊利诺伊大学香槟分校的研究人员获得了 28- 游戏曾经是人类智慧的堡垒。从 TD-Gammon 开始，一个使用时差强化学习的五子棋游戏程序，算法和计算的进步导致了算法被广泛应用。与五子棋不同的是，国际象棋有一个复杂得多的状态空间和一组动作。深蓝公司利用大规模并行性、专用硬件和高效搜索游戏树 ([Campbell et al., 2002](https://zh-v2.d2l.ai/chapter_references/zreferences.html#id19)) 击败了加里·卡斯帕罗夫 (Garry Kasparov)。围棋由于其巨大的状态空间，难度更大。AlphaGo 在 2015 年达到了相当于人类的棋力，使用和蒙特卡洛树抽样 ([Silver et al., 2016](https://zh-v2.d2l.ai/chapter_references/zreferences.html#id152)) 相结合的深度学习。扑克中的挑战是状态空间很大，而且没有完全观察到（我们不知道对手的牌）。在扑克游戏中，库图斯使用有效的结构化策略超过了人类的表现 ([Brown and Sandholm, 2017](https://zh-v2.d2l.ai/chapter_references/zreferences.html#id18))。这说

明了游戏取得了令人瞩目的进步以及先进的算法在其中发挥了关键作用的事实。- 人工智能进步的另一个迹象是自动驾驶汽车和卡车的出现。虽然完全自主还没有完全触手可及，但在这个方向上已经取得了很好的进展，特斯拉（Tesla）、英伟达（NVIDIA）和 Waymo 等公司的产品至少实现了部分自主。让完全自主如此具有挑战性的是，正确的驾驶需要感知、推理和将规则纳入系统的能力。目前，深度学习主要应用于这些问题的计算机视觉方面。其余部分则由工程师进行大量调整。

同样，上面的列表仅仅触及了机器学习对实际应用的影响之处的皮毛。例如，机器人学、物流、计算生物学、粒子物理学和天文学最近取得的一些突破性进展至少部分归功于机器学习。因此，机器学习正在成为工程师和科学家必备的工具。

关于人工智能的非技术性文章中，经常提到人工智能奇点的问题：机器学习系统会变得有知觉，并独立于主人来决定那些直接影响人类生计的事情。在某种程度上，人工智能已经直接影响到人类的生活：信誉度的自动评估，车辆的自动驾驶，保释决定的自动准予等等。甚至，我们可以让 Alexa 打开咖啡机。

幸运的是，我们离一个能够控制人类创造者的有知觉的人工智能系统还很远。首先，人工智能系统是以一种特定的、面向目标的方式设计、训练和部署的。虽然他们的行为可能会给人一种通用智能的错觉，但设计的基础是规则、启发式和统计模型的结合。其次，目前还不存在能够自我改进、自我推理、能够在试图解决一般任务的同时，修改、扩展和改进自己的架构的“人工通用智能”工具。

一个更紧迫的问题是人工智能在日常生活中的应用。卡车司机和店员完成的许多琐碎的工作很可能也将是自动化的。农业机器人可能会降低有机农业的成本，它们也将使收割作业自动化。工业革命的这一阶段可能对社会的大部分地区产生深远的影响，因为卡车司机和店员是许多国家最常见的工作之一。此外，如果不加注意地应用统计模型，可能会导致种族、性别或年龄偏见，如果自动驱动相应的决策，则会引起对程序公平性的合理关注。重要的是要确保小心使用这些算法。就我们今天所知，这比恶意超级智能毁灭人类的风险更令人担忧。

1.7. 特点

到目前为止，本节已经广泛地讨论了机器学习，它既是人工智能的一个分支，也是人工智能的一种方法。虽然深度学习是机器学习的一个子集，但令人眼花缭乱的算法和应用程序集让人很难评估深度学习的具体成分是什么。这就像试图确定披萨所需的配料一样困难，因为几乎每种成分都是可以替代的。

如前所述，机器学习可以使用数据来学习输入和输出之间的转换，例如在语音识别中将音频转换为文本。在这样做时，通常需要以适合算法的方式表示数据，以便将这种表示转换为输出。深度学习是“深度”的，模型学习了许多“层”的转换，每一层提供一个层次的表示。例如，靠近输入的层可以表示数据的低级细节，而接近分类输出的层可以表示用于区分的更抽象的概念。由于表示学习（representation learning）目的是寻找表示本身，因此深度学习可以称为“多级表示学习”。

本节到目前为止讨论的问题，例如从原始音频信号中学习，图像的原始像素值，或者任意长度的句子与外语中的对应句子之间的映射，都是深度学习优于传统机器学习方法的问题。

事实证明，这些多层模型能够以以前的工具所不能的方式处理低级的感知数据。毋庸置疑，深度学习方法中最显著的共同点是使用端到端训练。也就是说，与其基于单独调整的组件组装系统，不如构建系统，然后联合调整它们的性能。例如，在计算机视觉中，科学家们习惯于将特征工程的过程与建立机器学习模型的过程分开。Canny 边缘检测器 ([Canny, 1987](https://zh-v2.d2l.ai/chapter_references/zreferences.html#id20)) 和 SIFT 特征提取器 ([Lowe, 2004](https://zh-v2.d2l.ai/chapter_references/zreferences.html#id102)) 作为将图像映射到特征向量的算法，在过去的十年里占据了至高无上的地位。在过去的日子里，将机器学习应用于这些问题的关键部分是提出人工设计的特征工程方法，将数据转换为某种适合于浅层模型的形式。然而，与一个算法自动执行的数百万个选择相比，人类通过特征工程所能完成的事情很少。当深度学习开始时，这些特征抽取器被自动调整的滤波器所取代，产生了更高的精确度。

因此，深度学习的一个关键优势是它不仅取代了传统学习管道末端的浅层模型，而且还取代了劳动密集型的特征工程过程。此外，通过取代大部分特定领域的预处理，深度学习消除了以前分隔计算机视觉、语音识别、自然语言处理、医学信息学和其他应用领域的许多界限，为解决各种问题提供了一套统一的工具。

除了端到端的训练，人们正在经历从参数统计描述到完全非参数模型的转变。当数据稀缺时，人们需要依靠简化对现实的假设来获得有用的模型。当数据丰富时，可以用更准确地拟合实际情况的非参数模型来代替。在某种程度上，这反映了物理学在上个世纪中叶随着计算机的出现所经历的进步。现在人们可以借助于相关偏微分方程的数值模拟，而不是用手来求解电子行为的参数近似。这导致了更精确的模型，尽管常常以牺牲可解释性为代价。

与以前工作的另一个不同之处是接受次优解，处理非凸非线性优化问题，并且愿意在证明之前尝试。这种在处理统计问题上新发现的经验主义，加上人才的迅速涌入，导致了实用算法的快速进步。尽管在许多情况下，这是以修改和重新发明存在了数十年的工具为代价的。

最后，深度学习社区引以为豪的是，他们跨越学术界和企业界共享工具，发布了许多优秀的算法库、统计模型和经过训练的开源神经网络。正是本着这种精神，本书免费分发和使用。我们努力降低每个人了解深度学习的门槛，希望读者能从中受益。

1.8. 小结

- 机器学习研究计算机系统如何利用经验（通常是数据）来提高特定任务的性能。它结合了统计学、数据挖掘和优化的思想。通常，它是被用作实现人工智能解决方案的一种手段。- 表示学习作为机器学习的一类，其研究的重点是如何自动找到合适的表示方式。深度学习是通过学习多层次的转换来进行的多层次的表示学习。- 深度学习不仅取代了传统机器学习的浅层模型，而且取代了劳动密集型的特征工程。- 最近在深度学习方面取得的许多进展，大都是由廉价传感器和互联网规模应用所产生的大量数据，以及（通过 GPU）算力的突破来触发的。- 整个系统优化是获得高性能的关键环节。有效的深度学习框架的开源使得这一点的设计和实现变得非常容易。

1.9. 练习

1. 你当前正在编写的代码的哪些部分可以“学习”，即通过学习和自动确定代码中所做的设计选择来改进？你的代码是否包含启发式设计选择？2. 你遇到的哪些问题有许多解决它们

的样本，但没有具体的自动化方法？这些可能是使用深度学习的主要候选者。3. 如果把人工智能的发展看作一场新的工业革命，那么算法和数据之间的关系是什么？它类似于蒸汽机和煤吗？根本区别是什么？4. 你还可以在哪里应用端到端的训练方法，比如 [图 1.1.2] (https://zh-v2.d2l.ai/chapter_introduction/index.html#fig-ml-loop)、物理、工程和计量经济学？

`<iframe src="https://discuss.d2l.ai/embed/comments?topic_id=1744" id="discourse-embed-frame" width="100`

这本书写于一个翻天覆地的时代，技术的演变让我们重新审视贝叶斯公式以及它在知识大厦中的位置。

这本书也写在了一个传播方式改变了我们谈论科学方式的年代。

贝叶斯主义就是假设“现实”的所有模型、理论或概念都只不过是某种信念、虚构或诗歌，尤其要指出的是，“所有模型都是错的”；然后，实际数据应该迫使我们调整赋予不同模型的重要性，即置信度；关键在于，调整这些置信度的方式应该尽可能严谨地遵循贝叶斯公式。

“我之前一直觉得这种知识哲学没有意义。它似乎否定了所有关于现实和真理的概念，即使这些概念对研究人员来说如此重要；但它又似乎”

完全符合物理学家、诺贝尔物理学奖获得者理查德·费曼的说法 [4]：“我能带着疑问、不确定和无知活着。我觉得，比起知道一些可能错误的答案，还是不知道答案的生活更有趣。我有些近似的答案，对于各种问题也有些确定程度或高或低的合理信念，但我不会绝对确信任何事情。也有很多我一点都不明白的事情，但我不一定需要一个答案。我不害怕‘我不知道’这个事实。”

你可能会觉得这种观点激动人心，或者希望将这种看待知识的方法拒之门外。然而在选择接受还是拒绝贝叶斯主义之前，我只能鼓励你先花点时间，长考一下贝叶斯公式与它的推论。

遗憾的是，这本书里的主要向导，也就是我，对这个公式的理解还非常浅薄。

工程思维/应用思维：

正是这种限制迫使我们只能考虑一种必定仅作为近似的贝叶斯主义，我称之为实用贝叶斯主义。它跟纯粹贝叶斯主义的不同之处，就是它要求(迅速的)可计算性。

可能你也猜到了，理解纯粹贝叶斯主义者与实用贝叶斯主义者并不容易。为此，我们必须考虑大量的基础概念，它们来自数学、逻辑学、统计学、计算机科学、人工智能，甚至还有物理学、生物学、神经科学、心理学和经济学。我们需要谈到对数、逆否命题、值、所罗门诺夫复杂度和神经网络，还有熵、达尔文式演化、虚假回忆、认知偏差和金融泡沫。另外，我们也会用到科学史中的大量例子来考验我们这两位虚构人物。

对，我知道为了理解贝叶斯公式，要明白的东西可不少.....

但这岂不是正好，因为我喜欢在闲暇时解释现代科学，我甚至为此开通了名为 **Science4All** 的 **YouTube** 频道！所以，与其把这本书当成哲学书来读，我请大家不如把它当成科学和数学的科普书。另外，在解释贝叶斯主义的途中，我也不惜绕几个弯，拐到科学的漫谈上，暗地里就是为了鼓励你在了解科学理论的道路上走得更远！

人类实在太有智慧了，希望能越来越向她靠近..... 即使在开始教授这门课以及撰写这本

书之后，我仍然一遍又一遍地从这个主题中发现了不可胜数的惊人奇景，它已经变成我最喜欢的数学等式了。

要以理性的方式谈论理性，就要先用理性的方式定义理性……这就像一条咬着自己尾巴的蛇。

这个难点当然并非贝叶斯公式所独有，所有知识哲学似乎都必然受制于这种自我指涉。数学家也曾花上数个世纪的努力来发展没有自我指涉的理论，然而并不成功。(哥德尔，谢谢你!)

严谨、简洁与清晰。它定义了如此清晰的推理规则 3，应用这些规则似乎足以相对精确地(即使只是近似地)理解这个世界。这正是计算机科学家的理想，只要按下启动按钮，机器就能执行一系列指令来自动达到目标。这说的当然就是人工智能!30 年以来，贝叶斯公式一直处于这个领域中众多研究的核心，这大概并非偶然。

法国的打分制以 20 分为满分。

即使指明用到了什么方法也不够。利用机器学习在大数据中推断出有用信息的数据科学家很早就发现了，没有人工干扰不一定能保证客观性。无论是人还是机器，我们似乎都必定要在某个模型内部进行推理。所以说，我们的结论似乎必然依赖于模型。纯粹贝叶斯主义者断定，这就说明了所有知识都必然是主观的。

可惜的是，这本书跟一切篇幅有限的书一样，难免挂一漏万。我在这里先为本书不可胜数的不足之处说声抱歉，尤其是因为我没有花时间将贝叶斯主义与其他与之竞争的哲学流派进行深入比较。我的目标没那么远大，只是希望能帮助你理解贝叶斯主义的某些重要方面，至少是我理解的那些方面。的确，跟本书一样，我的大脑也是有限的，所以请你原谅我的无知之处。我会尝试提及和揭示尽可能多的对我来说重要的思想，但也必定会遗漏那些我不知道或误判其重要性的内容。

另外，本书描述的是截至出版时我的认知状态，但在掌握贝叶斯主义的旅程中，我希望之后能取得更多的进展。如果你愿意伴随我踏上这段旅程的话，请在 **Twitter** 上关注我 (@science4all)，并查看我的视频频道 **Science4All**，我从 2018 年末开始在频道中放了一系列关于贝叶斯公式的视频。我同样邀请你前往我和哲学家蒂博·吉罗(网名是 **Monsieur Phi**) 共同主持的播客“公理”(Axiome)，倾听我们的思考。尽管我们的目标是探讨所有与数学、哲学和各种自然科学有关的东西，但鉴于我们都对概率和逻辑无比着迷，我们也反复谈到了贝叶斯主义的方方面面，其中一些内容在本书中没有提及，比如贝特朗悖论的贝叶斯解释 [12]。

读这本书的时候请不要急躁，要多花点时间思考，但也不要轻易放弃。

读这本书的时候请不要急躁，要多花点时间思考，但也不要轻易放弃。这本书并不是越往后面越难，你可以在没有阅读之前章节的情况下享受每一章——虽然按顺序阅读每一章可能更好。这不是一本教材，也没有考试。我不会要求你理解所有内容，甚至强烈建议你跳过那些太复杂的段落继续阅读(如果你之后肯回到这些难度较大的段落的话)。我的目标不是让你成为贝叶斯主义的专家。

我最希望的是，你能享受贝叶斯的推理以及在理解贝叶斯主义的基础和推论时用到的那些科学内容，并从中找到美感。我希望你能把自己当作一位探险家，出发去探索未知的土地，发现各种各样的动物、植物、文化与引人入胜的风景，而不一定要花时间学会本地语言中的

所有细微之处。我希望你能从这段旅程中获益。如果你跟随我的脚步的话，那么我希望你也会沉浸在热忱、魅力和疑问之中，这就是本书的首要目的。

学习是一支舞蹈。

正如一般的数学内容，这个公式的抽象性和复杂程度足以吓退我们之中不够勇敢的那些人。

想要做到这一点，毅力与精进是不可或缺的。

要付出的代价就是大量脑力劳动，但其回报绝对丰厚。对于纯粹贝叶斯主义者来说，最终能够（足够）正确思考的能力就在航程的终点。

贝叶斯公式的优雅，还有它的推论将我引向了不可胜数的快乐思考，从中得出的知识哲学让我一直感受着快乐和幸福。正因如此，我最终得出，贝叶斯公式是数学中最优美的等式。

对于纯粹贝叶斯主义者来说，用理性的方式研究历史是完全可行的。对于某些人来说，历史、物种演化与宇宙学这些学科并非科学，因为它们不能通过可重复的实验来研究。有趣的是，这种思考不过是来自波普尔哲学以及频率主义统计学的单纯假象。

所有人类知识从直觉开始，然后转变为观念，最后化为思想。伊曼努尔·康德 (1724—1804)

根据贝叶斯定理，任何理论都不完美。取而代之的是一项未竟的工作，它永远处于推敲与测试之中。

==== 前言数学踏上新的征程

人们常说，刚刚过去的一个世纪是数学真正的黄金时代。数学在 20 世纪的进步比先前所有的世纪加起来还要大。然而，刚刚开始的这个世纪也可能同样是数学发展的好时候。或许，数学在这个世纪的变迁会和 20 世纪一样巨大，甚至更为惊人。引发这种想法的信号之一是一场渐变：自 20 世纪 70 年代开始，数学方法的基石——证明的概念逐渐发生演变，让一个古老却有些被人忽视的数学概念重新回到了舞台中央，这就是“计算”。

计算能成为引发革命的导火索，这看起来有点不合常理。算法，比如做加法和做乘法的算法，常常被视为数学知识中最基础的一部分，做计算也经常被看成是缺乏创造性的枯燥工作。数学家们自己对计算也颇有成见，勒内·托姆就曾说过：“我的论述中很大一部分属于纯粹的猜想，大家基本上可以把它们看成是梦话。我接受这种定性……如今，世界上到处有这么多月学者在做计算，难道有人做梦不是件好事吗？”用计算来做梦，大概还真有点难度啊……

不幸的是，对计算的偏见恰恰根植于“数学证明”这一概念的定义里。确实，欧几里得以降，“证明”的定义就是利用公理和演绎规则构建的一套推理。然而，要解决一个数学问题，仅仅需要构建一套推理吗？数学的实践难道没有告诉我们，解决问题需要把推理的步骤和计算的步骤巧妙地融合起来吗？公理化方法若局限在推理中，它所展现的数学视野恐怕也会十分狭隘。正是因为人们对约束过多的公理化方法多有批评，才让计算有机会重新出现在数学的舞台上。现在，已有一些研究工作（它们之间未必有关联）渐渐开始质疑推理高于计算的优势地位，并倡导一种更为平衡的观点，让两者互为补充。

这场革命让我们重新考量推理和计算之间的关系，同时也促使我们重新审视数学与物理学、生物学等自然科学之间的对话，特别是数学为何能在这些学科中发挥难以理解的强大作

用这一古老问题，以及自然理论的逻辑形式这一全新问题。此外，这场革命给“分析判断”和“综合判断”等哲学概念带来了新的火花。它还让我们反思数学与计算机科学之间的关系，而且数学似乎是唯一一门不需要借助机器的科学，它为什么如此独特？

最后，最振奋人心的是，这场革命让我们隐约看到了一些解决数学问题的新方式，它摆脱了过去的技术强加给证明长度的枷锁——数学也许正踏上新的征程，去探索从未涉足的全新领域。

诚然，公理化方法的危机并不是凭空出现的。从 20 世纪上半叶起就有许多先兆，特别是两种理论——可计算性理论和构造性理论的出现。这两种理论本身虽然没有质疑公理化方法，却重新确立了计算在数学大厦中的地位。在讨论公理化危机之前，我们会简要回顾这两个概念的历史。不过，还是让我们先上溯远古，探寻计算这一概念的起源，看看古希腊人对数学的“发明”过程吧。

目标读者本书面向学生（本科生或研究生）、工程师和研究人员，他们希望扎实掌握深度学习的实用技术。因为我们从头开始解释每个概念，所以不需要过往的深度学习或机器学习背景。全面解释深度学习的方法需要一些数学和编程，但我们只假设读者了解一些基础知识，包括线性代数、微积分、概率和非常基础的 Python 编程。此外，在附录中，我们提供了本书所涵盖的大多数数学知识的复习。大多数时候，我们会优先考虑直觉和想法，而不是数学的严谨性。有许多很棒的书可以引导感兴趣的读者走得更远。Bela Bollobas 的《线性分析》([Bollobás,1999](https://zh-v2.d2l.ai/chapter_references/zreferences.html#id13)) 对线性代数和函数分析进行了深入的研究。([Wasserman,2013](https://zh-v2.d2l.ai/chapter_references/zreferences.html#id178)) 是一本很好的统计学指南。

-数学思维与人工智能的关系 -从数学到智能的发展历程

第一章 引言什么是智能？

内容提要

- Definition of Theorem
- Ask for help
- Optimization Problem
- Property of Cauchy Series
- Angle of Corner

这一章将带领你从哲学、科学和工程的角度出发，追问“什么是智能”。接下来的章节中，我们将深入探讨数学在人工智能中的具体应用，展示数学如何帮助我们创造出越来越强大的智能系统。

1.1 什么是智能与人工智能

智能 (intelligence)，如今已经成为现代生活中很常见的一个词，比如智能手机、智能家居、智能驾驶等。在不同使用场合中，智能的含义也不太一样。比如“智能手机”中的“智能”一般是指由计算机控制并具有某种智能行为的意思。这里的“计算机控制”+“智能行为”隐含了对人工智能的简单定义。

智能并非人类独有，许多动物，如海豚、鸟类、猩猩，甚至章鱼，都表现出高度的学习能力、问题解决能力以及某种形式的社交智能，但人类的智能，但人类的智能以其复杂性和多样性独树一帜，在抽象和创造性上尤为突出。人类具有抽象思维，创造了诸多符号系统，并基于此进行高度复杂的推理和想象。从数学公式到哲学思辨，人类通过语言、文字和符号，建立起了庞大的知识体系和文化遗产。我们可以预见未来、反思过去，并通过科学、技术、工具改变现实世界。正是这种智能上的深度和广度，推动了人类文明的发展。

智能是生命进化过程中形成的一种适应性特征。但随着人工智能的发展，我们正在见证一种新型智能的崛起。在 20 世纪中期，计算机的发明标志着一种全新“智能”形式的诞生。计算机，这种基于二进制系统和算法逻辑的机器，能够完成许多过去被认为只有人类才能做到的任务，如图像识别、语言翻译、甚至写作创作。机器可以通过算法模拟复杂的推理过程，甚至在某些领域超越人类的能力——它们能够比人类更快地进行大规模计算、更高效地分析海量数据。

这促使我们重新思考：究竟什么是“智能”？它是基于生物特性的一种特有思维能力，还是某种可以通过数学和逻辑建模来实现的计算逻辑？

对于智能的定义，在不同学科中有着不同的阐释。在心理学中，智能被视为一种个体解决问题、学习和适应环境的能力。在生物学中，智能更多与生物体的行为、神经系统的复杂性相关。而在计算机科学和人工智能领域，智能则被看作是一种能够在复杂环境中执行任务并达成特定目标的能力。从人工智能的角度看，智能可以被定义为“机器执行通常需要人类智能才能完成的任务的能力”。这些任务包括视觉识别、自然语言处理、学习、推理、决策等。然

而，计算机和人类智能之间仍然存在着巨大的差异，特别是在理解、情感和创造力等方面。人工智能的核心在于如何用数学工具来模仿、简化甚至扩展这些认知能力。

机器“智能”是否真的与人类的智能一样？人类的智能伴随着进化而来，经过了数百万年的演变和适应，它不仅仅是一种计算能力，更是情感、直觉、创造力和推理能力的综合体。相对来说，人工智能的发展历史尚短，但其进化速度却让人惊叹。

机器智能的本质在于其基于算法和数据的计算逻辑，而人类智能则包含了情感、意识、创造力等更为复杂和难以定义的元素。智能不仅仅是任务的完成能力，更涉及到意识、理解和体验。也许机器可以在规则内完成任务，优化目标，但它们仍然无法像人类那样拥有感知、情感或独立的创造性思维。尽管如此，在这场由人类主导的智能革命中，我们依然是规则的制定者和方向的掌控者。这也是为什么，理解数学思维如何推动人工智能，能够帮助我们更好地把握未来智能发展的关键脉络。

数学在智能中的角色

自古以来，数学不仅是解决问题的工具，更是智能表达与实现的基础语言。数学的力量在于它能够抽象出复杂问题的本质，提供精确的描述和推理方法。

人工智能中的诸多任务，如模式识别、数据分类、预测等，背后都依赖数学模型进行量化和求解。例如，图像识别问题看似复杂，但可以被归纳为一个线性代数问题：图像被分解为像素点，每个像素点通过向量和矩阵的运算来进行处理。同样，神经网络的训练也依赖于微积分中的优化技术，以最小化损失函数，找到最优参数组合。

机器智能的进化：从计算到学习

数学在推动人工智能从简单计算迈向学习与适应中起到了关键作用。最初，计算机的智能主要体现在通过预先编写的规则来执行任务，模拟人类的某些智能行为。随着大数据和深度学习技术的出现，人工智能开始从数据中“学习”，即所谓“机器学习”。这是一场范式的转变：机器智能从依赖人工预定义的规则，转变为通过模型的不训练和优化进行自我学习。

在这场范式的转变中，数学再次发挥了至关重要的作用。统计学、线性代数、概率论等数学工具，使机器能够从复杂的海量数据中提取有价值的模式和信息，并进行合理决策。

机器学习依赖于统计学、线性代数、概率论等数学理论。通过这些工具，机器能够从海量数据中提取模式并作出决策，具备了学习和自我优化的能力。

这种数学思维下的机器学习能力，使得智能不仅仅是计算结果的简单输出，而是一种能够学习、适应和自我优化的动态过程。这场智能的进化，无疑奠定了人工智能发展的新高度。

数学思维：解码智能的钥匙

人工智能是模拟、延伸和扩展人类智能的理论、方法、技术及其应用系统的综合学科。AI 作为一门跨学科领域，从多个学科中汲取灵感与启发，融合了不同领域的知识与技术。

数学思维不仅仅是对现有工具的应用，更代表着一种解码世界的方式。数学能够帮助我们从表象中剥离出系统的本质，理清复杂事物之间的逻辑关系。在人工智能领域，数学思维是帮助我们更好理解并发展智能的核心钥匙。人工智能的本质是一种通过数学和计算实现的智能，它利用算法、数据处理和计算资源模拟生物智能的行为。为了理解智能如何通过数学实现，我们可以将其分解为几个关键组成部分：

- **感知与反应**：任何智能体首先需要能够感知环境，并对环境做出适当的反应。这是智能的基础，也是进化中所有生物生存的关键。数学在感知数据的处理上扮演重要角色，例如通过卷积神经网络处理视觉输入。
- **学习与记忆**：智能体不仅是对环境做出反应，还包括从经验（数据）中学习，，储存经验用于未来决策。
- **推理与决策**：智能体需要能够进行推理，从已有信息中得出新的结论，从而做出合理的决策。这离不开统计推断、优化等数学方法。
- **创造与适应**：更高级的智能不仅仅是反应式的，而是能够创造性地应对未知的挑战，并在复杂的环境中灵活适应。

人工智能（AI）在这些维度上逐步模仿人类的智能，但它的本质是通过数学和计算实现的。AI 的智能是通过算法、数据处理以及计算资源，以我们在生物智能中所见的行为为目标进行的复杂优化。

1.2 鹦鹉与乌鸦：何种智能？

为了更好地理解智能，我们可以借用一个生动的比喻——鹦鹉与乌鸦。

鹦鹉式智能：模仿而不理解

鹦鹉是模仿高手，能够复制人类的语言，甚至在特定情境下做出看似有意识的反应。然而，鹦鹉并不真正理解它模仿的内容，它只是重复我们的话语，而无法将这些词汇与现实世界中的人、物或情景建立联系。这种行为类似于一些现有的人工智能系统，特别是那些专注于模仿和执行特定任务的 AI 模型。这类 AI 可以通过大量数据训练，在特定任务中表现优异，但它们并不真正理解背后的语义或意图。

这种“鹦鹉式智能”可以类比为**弱 AI**或**窄 AI**。它们擅长于特定任务，但缺乏广泛的推理和创造能力。当前的许多 AI 模型，如语言生成或图像识别，都是在这一框架下运作的——它们通过模式识别和数据驱动的方式执行任务，却没有真正的自主意识或深度理解。都是在这一框架下运作的——它们通过模式识别和数据驱动的方式执行任务，却没有真正的自主意识或深度理解。

乌鸦式智能：推理与创造

乌鸦向来被认为是最聪明的鸟类之一。与鹦鹉不同，乌鸦不仅擅长模仿，还展现出复杂推理能力、问题解决能力以及创造性的智能。乌鸦是少数能够制造工具的鸟类，能够通过创新思维应对物理世界中的挑战。我们从小都听过各种“乌鸦喝水”的故事，而国外科学家也曾做过一系列“乌鸦喝水”的变化实验。在这些实验中，研究人员使用了各种不同形状的瓶子和不同密度的物体，观察乌鸦如何应对。令人惊讶的是，乌鸦总能在几次尝试后，快速识别并选择那些能够最快让水位上升的物体。这些实验不仅证实了乌鸦对物理规律的深刻理解，还展示了它们高度的认知能力和推理能力，以及面对复杂问题时的创造性和灵活性。另一个著名的例子是，乌鸦会将坚果放在马路上，利用来往车辆碾压坚果壳，并观察红绿灯、斑马线等信号来推理交通规则，最终推理出红绿灯与车辆停靠及行人停走之间的复杂因果关系，从而安全地过马路，吃到被碾碎的坚果肉。这是一种远远超出简单反应的行为，展示了乌鸦对物理世界和人类行为之间复杂因果链的深刻理解。

乌鸦的这一行为没有经过大量数据训练或监督学习，它通过少量的尝试与观察，直接推理出解决问题的方法。乌鸦智能正是我们期望的真正的智能——完全自主的智能：观察、感知、认知、学习、推理、执行。这种智能可以比喻为**强 AI** 或**通用 AI**，具备自主学习、推理和适应能力，能够在不同的环境中灵活应对各种任务。

功耗极低：乌鸦头不到人脑的 1

乌鸦的智能不仅令人惊叹，功耗也极低。人类大脑的功耗大约在 10-25 瓦之间，乌鸦的大脑尺寸约为人类的 1%，功耗约为 0.1-0.2 瓦。这意味着乌鸦无需复杂的能源供应系统或冷却设备，就能完成复杂的推理和问题解决任务。相比之下，现代 AI 系统需要高性能计算设备和大量能源，显示了生物智能的高效性。

智能的层次：从鹦鹉到乌鸦

“鹦鹉”与“乌鸦”的比喻在人工智能领域有着深刻的象征意义，揭示了**智能的不同层次**：

- **鹦鹉式智能**：擅长特定任务，通过数据驱动的模式识别和模仿来实现，针对某些垂直应用有效，但缺乏深度理解和推理能力。
- **乌鸦式智能**：具备复杂的推理和创造性，能够自主学习、适应环境，展现出高水平的智能灵活性。

这个比喻通过比较鹦鹉的模仿性智能和乌鸦的推理性智能，说明了 AI 智能的不同层次。

AI 的未来：向“乌鸦式智能”迈进

现有的 AI 系统，即使是最先进的语言模型和图像识别系统，都还处于“鹦鹉式智能”阶段。这些系统依赖于预定义规则、大量数据、大量计算资源来完成特定任务，但缺乏真正的推理和创造能力。虽然这类 AI 能够生成看似“智能”的对话，但它们的智能基于模式识别和数据驱动，与鹦鹉能模仿人类发音但不理解其语义一样。即使是像 ChatGPT 这样的先进语言模型，在模

仿人类语言并生成非常连贯对话上表现几可乱真，但它并不具备关于“意义”的主观理解，无法感知、体验或有意识地推理，只是基于统计模式和相关性根据输入生成最有可能符合上下文的回应。因此，大语言模型更多是“聪明的猜测”，而非真正的理解。这与人类的理解方式存在本质差异。

AI的未来发展目标是朝着“乌鸦式的智能”迈进，不仅能够模仿，还能推理、学习、适应，在跨任务和多变的环境中展现出灵活的创造力。实现与生物智能相媲美的灵活性和创造力，正是“强 AI”或“通用 AI”所要追求的方向。

人工智能: 模拟、延伸和扩展人的智能的理论、方法、技术及应用系统

第二章 智能，生于数学

简明数学史

内容提要

- 萌芽：结绳计数与位值制
- 初等：几何、公理化与证明
- 近代：变量/函数、微积分与解析几何
- 现代：集合论、逻辑与可计算性
- 三次数学危机（无理数、微积分基础、集合论悖论）

“如果人们不相信数学很简单，那是因为他们没有意识到生活有多复杂。”

—— 约翰·冯·诺伊曼

智能的历史可以追溯到人类最早期的思维活动，而数学是其中最重要的基础工具之一。本章将按“萌芽—初等—近代—现代”的时间脉络，说明数学观念如何层层抽象，并在每一步为后来的计算与智能埋下线索。

对于古代人来说，数字的发明源于对数量的需求。无论是借手指计数，还是用其他物体辅助，人类通过千年的发展，逐渐完善了从简单符号到抽象数字的演变。今天看似“自然”的自然数概念，其实是无数社会实践与思想试验的沉淀。正是这些最初的表征与规则，使“可计算的表示”成为可能。

人类对“智能”的探讨源远流长。远在古代希腊时期，哲学家们就已经开始追问：什么是智慧？什么是理性？我们如何通过思维去理解这个世界？从那时起，人们就梦想着创造能自主思考的机器：皮格马利翁（Pygmalion）、代达罗斯（Daedalus）、赫淮斯托斯（Hephaestus）等可被视为传说中的发明家，而加拉蒂亚（Galatea）、塔洛斯（Talos）与潘多拉（Pandora）则可被视为人造生命 [OvidMartin2004, Sparkes1996, Tandy1997]。这些想象后来在科学与工程中转化为“问题—表示—算法—数据”的框架，神话中的愿景开始落地为可检验的系统。

这些问题不仅关乎哲学，还对现代科学和技术的发展产生了深远影响。随着时间推移，这种对智能的追问从哲学的纯理论思辨，逐渐转向了科学与工程的实践领域。早期的数学家如欧几里得、阿基米德以及笛卡尔等，通过逻辑和结构化的思维方式，为计算与智能提供了基础：欧氏公理化对应模型的可验证性；笛卡尔坐标促成连续空间的特征化；阿基米德近似展示了可计算思想的雏形。数学逐渐从实用算术走向系统推理，成为连接抽象理念与工程实现的桥梁。

数学的发展史可以粗分为四期：萌芽、初等、近代与现代。这些分期并非泾渭分明，而是层层叠加与概念外延的扩展。为把握演化主线，接下来我们依次回顾四个阶段的关键观念与方法，并在节末用 *examplebox* 收束为“AI 建模要点”。

2.1 萌芽时期：从计数到位值制

数学的萌芽时期从远古时代延续至公元前 5 世纪，是人类最早利用数学工具应对日常生活需求的阶段。通过手指计数、刻痕和结绳，人类逐渐形成自然数的概念与四则运算雏形，为后续的几何与代数提供了素材和直觉。总体上，这一时期以“就事论理”的经验法则为主，但已显露出从数与形中提炼稳定规则的趋势。

2.1.1 史前数学：日常需求与实用计算

在公元前 5 世纪之前，数学并非独立的学科，而是伴随着人类生活的需要而逐步发展的：牲畜计数、土地丈量、历法制定与贸易核算等场景催生了各种方法。古代美索不达米亚与埃及的泥板与石刻清楚记录了这些活动，展现了数学与生活实践的紧密联系。

“数学”活动最古老的痕迹之一是在美索不达米亚发现的一块泥板（约公元前 2500 年）。泥板记录了这样一个计算：如果谷仓里有 1152000 份粮食，每个人分得 7 份，一共可以分给多少人？结果是 164571 人，即用 1152000 除以 7 的结果。这说明在算术“成书”之前，美索不达米亚的会计师们已经能熟练地进行除法运算了。甚至，书写完全有可能就是为了记账才发明的——若真如此，数字就比字母发明得还要早了。

古埃及人发展了一些基础的几何公式，在建造金字塔时已经能够运用高度和角度的几何关系；古代美索不达米亚的会计师不仅掌握了加法和乘法，还能够解简单的二次方程，用于管理粮食和资源。巴比伦人对天体运动的观察和历法推算也推动了数学的发展。为了精确预测日食、月相以及制定历法，巴比伦的天文学家需要处理大量的时间和角度计算。这些天文观测不仅进一步提升了测量和计算的要求，也反过来推动了几何和代数的进一步发展。

总体而言，这一阶段的数学活动是解决问题的经验性工具，尚未形成系统的理论。但它为后续的数学体系发展奠定了“数”与“形”的概念基础。这些先于理论的操作共同催化出对“可复用规则”的渴望，从而引向更稳健的记数手段。由此，问题逐渐从一次性的分配与测度，逐渐转向对“如何表示与传递数量”的一般方法。

下节转向最朴素也最普及的载体——手指计数。

2.1.2 手指：长身上的计数器

相信你在许多影视剧中都见过这样的一幕：一位算命先生，掐指一算，口中念念有词。这种“掐指一算”看似神秘，实则源自于古老而简便的计数方法。

在远古时代，用手指计数是再自然不过的选择，手指是人类最早的“随身计算器”。手指提供了一个天然的计数系统，帮助人们轻松应对日常的计数需求，如记录牲畜数量、物品交换量，推算季节、节气，安排农耕节日等活动。

手指的构造与多种进制系统有着天然的联系。稍加思考，我们就可以发现十进制、二十进制、十二进制等计数法与手指构造的对应关系。



图 2.1: “掐指一算”

十进制 (Decimal System) 是最常见、最自然的计数方式。双手的十根手指与十进制自然对应，每根手指代表一个数字，从 1 数到 10，完成一轮计数。十进制系统在全球的广泛使用，源于人类天生拥有十根手指的解剖学特征。正如爱德华·卢卡斯所言，这是“自然界的一个偶然事件”。

十二进制 (Duodecimal System) 则适用于更复杂的计数需求。除大拇指外，四根手指各有三段指节。一只手的拇指指向四根手指的各段指节，可以计数 1 到 12。这种方式在古代美索不达米亚和古埃及广泛应用，至今仍用于时间和角度的计数系统中，如 12 小时制、一年 12 个月等。

六十进制 (Sexagesimal System) 则更加复杂。它结合双手来计数。一只手用于计 12（与十二进制相同），另一只手的五根手指则记录 12 的倍数，五轮 12 等于 60。六十进制在古巴比伦时期被发明，沿用至今，广泛用于时间和角度的计量，例如 1 小时 = 60 分钟，1 分钟 = 60 秒，以及 360 度的圆周划分。

二十进制 (Vigesimal System) 也是一种古老的计数法。为了更大范围的计算，一些古代民族不仅用手指，还加上脚趾来计数。例如，中美洲的玛雅文明和阿兹特克文明，以及现今的西非和欧洲部分地区，采用了以 20 为基数的计数法。

二十进制的痕迹在许多语言中依然存在。现代英语中的“score”表示 20 的用法便保留了这一印记。例如，莎士比亚在《圣经》英译本中使用“three score and ten”（20 的 3 倍加 10，表示 70 岁）来指代古稀之年；林肯在《葛底斯堡演讲》中使用“four score and seven years ago”（20 的 4 倍加 7，表示 87）来表达 87 年前的历史。一百年后，马丁·路德·金在其著名的演讲《I have a dream》中说“Five score years ago”（20 的 5 倍，即 100 年前）。如今，在现代英语中，“score”的这种用法已不再常见。

英国曾有一个结合十二进制和二十进制的货币系统：1 英镑 = 20 先令，1 先令 = 12 便士。1971 年，英国引入了十进制货币系统，1 英镑 = 100 便士，先令在 1990 年后彻底退出流通。

在法语、丹麦语和巴斯克语中也能找到二十进制的痕迹。例如，法语中的数词从 quatre-

vingts(80)、quatre-vingts-dix(90)，到 quatre-vingts-dix-neuf(99)，表明凯尔特族过去采用二十进制计数法。同时，这些语言中还混杂了六十进制的痕迹，如数词 soixante(60) 到 soixante-dix-neuf(79)。

手指不仅是我们身体的一部分，还是人类最早的天然计算工具。它帮助我们理解和组织世界，并为现代数学中的位值制和进制系统提供了最初的灵感。直到今天，手指仍是许多人在进行简单计算时的本能工具。可以说，手指是人类最早的“计算器”，引领我们从最原始的计数方法走向了复杂的数学世界。（一句话抽象：自然器官 $\Rightarrow$ 位权/进位的“硬件先验”。）

自然的教育，数字文明的缩影

设想你在一次航海探险中遭遇风暴，不幸漂流到了一个无人孤岛。没有手表、手机，也没有任何现代工具。你很快面临一个问题——如何计算时间？如何记录每天收集的食物？在这种完全回归自然的环境中，你必须依靠最原始的方式来解决这些问题。

手指计数：最简单的工具

你的第一反应可能是用手指来计数。十根手指天生就是人类最便捷的“计算器”，帮助你快速记录简单的数量——比如你捕到的鱼或采摘的果实。手指计数是直观而方便，几乎无需思考就能完成。但很快，你意识到这种方法有明显的局限性：当数字变大，或需要记录更复杂的信息时，手指显然不够用了。更重要的是，手指计数无法保存这些数据，一旦忘记，你的记录便随之消失。（抽象：易得的“工作记忆”vs. 可复查的“外部记忆”。）

刻痕计数：更长久的记录方式

为了更长久地保存记录，你开始在岛上的树木或石头上刻下痕迹。每道刻痕代表一天的过去，或你每天捕获的鱼或采摘的果实数量……。刻痕计数法让你能够更长久地保存这些信息。每天的刻痕不断累积，形成一个记录时间和活动的系统。这种方法虽然简单，却比手指计数更加持久、可靠，也能应对稍微复杂的需求，比如记录日期或特定的事件。然而，随着时间的推移，刻痕的数量增加，管理这些信息变得越来越困难。你开始需要一种更便捷、更灵活的方式来记录和传递这些信息。（AI 启发：从短上下文到外部存储/检索——RAG 的原型。）

结绳记数：更高级的记数法

幸运的是，你发现了一根绳子，这给了你一个新的选择——结绳记数法。通过在绳子上打不同的结，你可以标记不同的天数、事件或物品的数量。不同形状和位置的结可以表示不同的信息。相比于刻痕，结绳计数法更便捷灵活，更易于携带和传递，成为你在荒岛生活中的高级计数工具。（抽象：符号化与压缩编码；启发：离散化/量化。）

荒岛上的自然教育：人类数字发明的倒影

在这场荒岛冒险中，随着你逐步探索各种计数方法，你无意识接受了一种独特的自然教育。这个经历，其实正是早期人类如何发明和发展数字的缩影。在远古时代，人类也像你一样，从最初的手指计数，逐渐发展到刻痕和结绳，寻找更有效的计数方式，逐渐探索出了越来越复杂、抽象的记数方式。

你在荒岛上的探索，正是人类数字文明进化的缩影。无论是刻痕还是结绳，这些方法都体现了人类从最初的物理标记到复杂符号系统的演化路径。通过这些自然的计数方法，你逐步掌握了记录、比较和计算的基本概念。这不仅是你个人的“自然教育”，也是数字发明的最初动力——让生活更加便捷和高效。（一句话抽象：需求—表示—外部化—标准化的演化链。）

从需求出发，人的记数方式沿着“即时—留痕—编码”的路径外化与标准化。下文据此上升到一般而稳定的表示——位值制。

2.1.3 数字的位值系统

在人类早期文明中，简单的手指计数和结绳、刻痕等计数方法已广泛用于记录数字，帮助人们应对日常的数值计算。然而，随着社会的发展，人们逐渐认识到，仅靠刻痕和结绳等物理标记在处理更复杂和更大范围的数字时，显得低效而繁琐。于是，更加抽象的符号系统应运而生。从而催生了**位值制**这一革命性的数字表示方式，使得复杂的数值能够通过简单的符号位置来表示和计算。

早期的计数系统大多采用**加法规则**。例如，在古代巴比伦的黏土板上，数字是通过符号的重复来表示的：数字“1”用一个符号表示，数字“2”用两个相同符号表示，数字“3”则用三个相同符号。

这种计数方式很眼熟，中文数字、罗马数字、古印度的婆罗门数字和笈多王朝使用的数字，以及大洋彼岸的玛雅数字，都采取了同样的方法。大多数的古代文明在表示前三个数字时，都采取了同样的方式：重复表示“1”的符号一次，两次，三次。古代的中文“一、二、三”、钟表盘上的罗马数字“I、II、III”、阿拉伯数字也体现了同样的重复方式。可是，从数字4开始，所有的文明就都放弃了这种重复。为什么呢？

研究发现，人类的数感对少于3的数字有天然的反应，但超出这个范围后，单纯的重复符号便变得困难。对一些出生几个月的婴孩进行试验，结果证实人类与生俱来的数感的容量不超过三。

试想一下，数字13若用重复排列“1”的符号13次来表示，无论是对书写还是阅读，都会很低效——怎么能一眼就看出它是13，而不是12或者14呢？

类似的问题在罗马数字系统中也很常见。罗马数字系统中，V表示5，X表示10，L表示50，C表示100。此外，向右添加符号为加，如VI表示数字6，XI表示数字11；相反地，向左添加一个更小数值的符号为减，如IV表示4，IX表示9。尽管使用了加减法规则的计数系统十分直观，但在表示大数时显得十分低效。例如1888年写成罗马数字就是MDCCCLXXXVIII，甚至无法有效表示类似100万那样的数字——除非把1000个M排成一排！

早期加法型记数（如罗马数字）在表达大数与运算效率上受限。位值制用“位置决定权重”的方式，以极少符号表达极大数量，长度近似 $\log x$ 。这不仅简化书写与计算，也带来压缩与编码的思想（最短码长度 $\approx -\log p$ ）。位值制因此成为现代信息处理与计算架构的共通底座。下节将把这种“对数规模”的优势，连接到计算机检索与寻址的具体应用。

随着人类文明的发展，许多地区开始引入更为先进的计数法，其中最具革命性的是**位值制计数法**。古巴比伦、中国，尤其是印度和阿拉伯，率先采用了这种创新的位值制计数法。这种计数法的关键在于符号的位置决定了其数值。例如，数字“12”和“21”虽然使用相同的符号，但因为符号位置不同，代表的数值也不同。

位值计数法具有出众的简洁性。通过有限的符号，可以表达任意大的数值。例如， 10^{100} 这个超出了物理限制的天文数字，在位值制下仅需 101 个符号即可表示——一个“1”后面跟着 100 个“0”。位值计数法用极短的符号链表示极其巨大的数值。

位值制不仅提高了数字的表示效率，还反映了数字的**对数增长**特性，即随着数字的增大，所需的符号长度呈对数增长，符号数量远远少于数字本身的大小。例如，表达 10^{100} 所需的符号长度约为 $\log_{10}(10^{100}) = 100$ 。一般地，表达任意整数 x 所需的符号数量接近 $\log_{10} x$ 。因此，从某种意义上，位值计数系统是最简洁、甚至最优的。（信息论视角：最短码长度 $\approx -\log p$ 。）

位值制的引入是人类计数方法的一次重大飞跃。从简单的重复符号到高度抽象的符号系统，位值制极大简化了计算过程，推动了计算和数学的发展，奠定了现代数字系统的基础。（一句话抽象：位权 $\Rightarrow$ 表达与计算的指数增益；AI 启发：词表/位宽/量化。）

2.1.4 位值制与对数增长在现代计算机中的应用

在计算机科学中，在已经排好序的数组中查找某个元素的时间也是数组长度的对数。即使数组规模如同宇宙般庞大，经过几百次迭代后，便能够找到所需的元素——唯一的限制就是光速有限性所带来的信息传播和处理速度的物理极限。

互联网的 URL 是位值制与对数增长在数据处理和网络寻址中的一个典型应用。一个简短的 URL (Uniform Resource Locator, URL, 统一资源定位符) 迅速定位到海量信息。想象一下，你希望在网上搜索某项信息。尽管互联网上的数据量可能以 EB (10^{18} 字节) 甚至 ZB (10^{21} 字节) 计量，只要拥有对应信息的 URL，你几乎瞬间就能找到目标信息。这正是对数增长的强大之处：即使面对巨大规模的数据集，只需少量步骤就能完成检索。

此外，URL 的简短程度令人惊叹，其长度是整个网络大小的对数！这意味着我们可以轻松将 URL 存储在内存中，而 URL 指向的信息量却远远超出了其自身长度。这种简洁有效的特性，展示了对数增长在计算与信息处理中的关键作用。

IPv4 和 IPv6 的设计正是对数增长在实际应用中的另一个实例。IPv4 地址使用 **32 位** 二进制数来表示，每个 IP 地址可以被写成 4 个以点分隔的十进制数（如 192.168.1.1），每部分对应一个 8 位的二进制数。32 位的二进制能够生成 2^{32} ，即约 **43 亿** 个唯一 IP 地址。这在 IPv4 设计之初被认为是足够庞大的数目。然而，随着互联网的迅速扩展，特别是物联网（IoT）设备和移动设备的广泛普及后，IPv4 的 43 亿个地址空间将很快耗尽。

为了解决这一问题，**IPv6** 应运而生。**IPv6** 使用 **128 位** 二进制数表示，由八组以冒号分隔的 16 进制数构成（如 2001:0db8:85a3:0000:0000:8a2e:0370:7334）。这种 128 位的二进制表示能生成 2^{128} ，即约 3.4×10^{38} 个唯一 IP 地址，相当于为地球上的每粒沙子分配多个 IP 地址。这一数量级足以应对未来几十年甚至几百年内所有联网设备的需求。

IPv4 和 **IPv6** 的位数与它们能够支持的地址数量之间的巨大落差，展示了对数增长的强大力量。**IPv4** 仅用 32 位符号就能表示 43 亿个地址，而 **IPv6** 仅用 128 位符号就能支持 3.4×10^{38} 个地址。随着位数的增加，IP 地址系统实现了指数级的扩展，同时保持了地址表示的简洁性。（AI 去向：索引结构/向量检索/稀疏路由一见 8.2、8.5。）

已排序数组的二分查找复杂度为 $O(\log n)$ ；互联网的 URL 与索引把海量内容映射为短标识；**IPv4/IPv6** 以位宽指数扩容可寻址空间。这些实例共同说明：位宽/词表/索引决定容量上限，对数级步骤决定检索效率。这为后文的“模型索引与稀疏路由”提供了经验参照。下一节我们从“表示的效率”转向“表示的抽象度”。

2.1.5 数字：从具象到抽象

几千年来，人类都在探索如何建立数与物的对应关系，现代数字系统的定义正是基于这种探索的延续。一旦人类掌握了计数，数字系统的应用就变得“自然而然”了。或许正因如此，我们才称自然数为“自然”数 (natural number)。然而，实际上，数字的概念一点也不“自然”。

无论是在早期人类在骨头及木棍上有序地刻下划痕，还是结绳或是在容器中放置物品无论是结绳，这些早期方法已代表了相当抽象的符号系统，其中抽象的数学对象与自然中的实际物体之间的分离，同一个数字既可以表示动物的数量，也可以记录借贷量或一个月的天数。自此之后，数学研究的对象不再是必须与实际物体相关的几何图形和数字。研究对象性质的变化，最终引发了解决数学问题的方法的革命。（AI 启发：可迁移表征与多任务共享—抽象层提高，泛化/可解释间的取舍加剧。）

抽象提高了可迁移性，也带来语义漂移与解释性的张力。

2.2 初等数学时期：从计算到推理

公元前 5 世纪开始，数学进入了初等数学时期。这个时期的数学探索更加系统和深入，尤其是在欧几里得几何和代数方程的研究中，数与形的关系得到了更加严谨的探讨，算术、几何、代数和三角等数学分支逐渐成形。

公元前 5 世纪起，欧几里得几何与代数方程的研究使数与形的关系走向严密，算术、几何、代数与三角逐渐定型。核心转变在于：从求值走向论证，从技巧走向体系。

2.2.1 数学的真正诞生：从计算到推理

数学作为一种学科，经历了漫长的演化过程。起初，数学的诞生是为了解决生活中的实际问题——如何计数、测量、交易、管理时间等。

公元前 5 世纪的希腊是数学发展的转折点。在此之前，数学主要集中于如何进行计算。

在埃及和美索不达米亚等古老文明中，数学的发展更多地依赖于经验和实际操作。埃及的数学侧重于土地测量、建筑工程和会计管理，而巴比伦人则在天文学、时间计算和度量衡方面取得了显著的成就。他们的数学面向解决日常问题，更多依赖于表格、算法和简单的数值操作。

“数学”活动最古老的痕迹之一是在美索不达米亚发现的一块泥板，它可以追溯到公元前 2500 年。这块泥板记录了这样一个问题：一个谷仓里有 1152000 份粮食。如果每个人分得 7 份，一共可以分给多少人？答案是 164571 人，即用 1152000 除以 7 得到的结果。看来，美索不达米亚的会计师在算术“诞生”之前很久就知道怎么做除法了。美索不达米亚和埃及的会计师不仅会做乘除法，而且掌握了许多其它的运算，比如解二次方程等。土地测量师则会计算矩形、三角形、圆形的面积。

这种实用性的数学（包括算术和几何）在数学史上称为“史前”数学，因为它并不涉及抽象推理，而是围绕日常需求展开。

古代文明的数学多服务于实践；希腊学者把关注点转向命题的可证性。等腰直角三角形三边皆为整数的设想，化为方程 $2x^2 = y^2$ 。穷举无效，转而假设互素并分类奇偶，导出矛盾，因而无解。由此，数学的目标从“得到一个数”变为“给出必然理由”。这一转折打开了更广阔的对象与方法空间。

因此，教科书中的数学史往往是从公元前 5 世纪的希腊开始讲起的，因为希腊数学家让数学从“如何计算”进化到了“为什么如此”。

在公元前 5 世纪的希腊，毕达哥拉斯学派提出了这样一个问题：找出一个等腰直角三角形，使其三边的长度都是自然数。假设等腰直角三角形的直角边长度为 x ，斜边长度为 y 。根据毕达哥拉斯定理（勾股定理）， y^2 就等于 $x^2 + x^2$ 。因此，这个问题最终归结为：找出两个自然数 x 和 y ，使得

$$2x^2 = y^2. \quad (2.1)$$

让我们来试试 4 以内所有 x 和 y 的可能性吧（见表 2.1）。

在上述所有情况里， $2x^2$ 都不等于 y^2 。我们当然还可以在更大的数字范围里继续寻找。事实上，毕达哥拉斯学派很可能寻找了很久，却没能找到解。后来，他们终于相信这个解不存在。他们是怎么说服自己这个解不存在的呢？（删去多余空格）显然不是穷尽所有的数对，因为这样的数对有无穷多个（且为可数集）。（原文“无穷不可数个”不当）你就算试到 1000 甚至 100 万，证实没有数对能满足条件，可你还是没法保证在更大的数字里面不可能有解……

既然不能用穷举法，那就试试逻辑推理。不妨假设 x, y 两个数互素。为什么呢？因为若 x, y 至少有一个是奇数时，两者自然互素；反之，若 x, y 都是偶数，则总是可以通过消去公因子来保证 x, y 至少有一个是奇数。据此，我们把数对 x, y 分成以下 3 种情况：

1. x, y 都是奇数；
2. x 是偶数， y 是奇数；
3. x 是奇数， y 是偶数；

我们先从第一种情况开始： x 和 y 都是奇数。此时 (2.1) 的解不存在。因为 y 是奇数，则

表 2.1: 4 以内 x 与 y 的所有可能性

x	y	$2x^2$	y^2
1	1	2	1
1	2	2	4
1	3	2	9
1	4	2	16
2	1	8	1
2	2	8	4
2	3	8	9
2	4	8	16
3	1	18	1
3	2	18	4
3	3	18	9
3	4	18	16
4	1	32	1
4	2	32	4
4	3	32	9
4	4	32	16

y^2 也是奇数。它不可能等于 $2x^2$ ，因为后者必然是偶数。这一论证也同样适用于第二种情况，即 x 是偶数而 y 是奇数。第三种情况即 x 是奇数而 y 是偶数。但在这种情况下，若 $2x^2 = y^2$ 成立，则这个数的一半 x^2 是奇数，同时 y^2 的一半却是偶数——这两个数不可能相等。综上所述，找不到两个自然数 x, y 满足 (2.1)。

为了证明这个问题没有解，毕达哥拉斯学派采用了逻辑推理而不是计算来实现。他们通过分类讨论和推理，证明了无论 x 和 y 是奇数还是偶数，方程 $2x^2 = y^2$ 都不可能有整数解。

这一问题的解决在数学史的发展上具有划时代的意义。它的革命性不仅在于其对未来数学的巨大影响，还在于其抽象性及解决的方法。相比于美索不达米亚泥板上铭刻的诸如“将 1152000 份粮食除以 7 份”的具体问题，毕达哥拉斯学派的问题更为抽象：美索不达米亚的会计师关注粮食的数量，而毕达哥拉斯学派的问题仅涉及数字本身。同样，他们处理的是抽象的几何形式，而非具体的三角形田地。从粮食的份数到数字，从实际的土地测量转向几何学的抽象思考，迈向抽象这一步的意义不可小觑。田地的面积无非几平方千米，而抽象的几何对象则可以轻松超越这一尺度，进入无限的范围。

古希腊数学家不再满足于计算结果，而是开始重视推导过程。他们通过严谨的逻辑推理，逐步构建了数学证明和公理系统。这一从计算到推理的转变，被视为数学的真正诞生，使得数学从日常的计算工具演变为以推理和抽象为核心、具有高度抽象和严谨逻辑的独立学科的学科。（删去“的学科”重复）

一个平方数不可能是另外一个平方数的两倍——这个由毕达哥拉斯学派在 2500 多年前得到的结果，迄今在数学上仍占有重要地位。它证明了，一个短边为 1 米的等腰直角三角形中，斜边的长度为 $\sqrt{2}$ ，约 1.414，但这个数无法通过两个自然数 y 和 x 的比值得到。这揭示了，某些几何关系无法通过自然数的四则运算（加、减、乘、除）运算得到，暗示了更广泛的数系——实数的存在。这一发现让数学进入了一个全新的领域——从实际问题中抽象出纯粹

的数学对象并通过推理得出结论。虽然这一发现具有革命性，但毕达哥拉斯学派并没有进一步发展出实数的概念。对他们而言，这一结论动摇了他们对自然数“万物皆数”的信仰，甚至引发了哲学上的困惑与争议。然而，几百年后，这一发现启发了数学家们发展出实数理论，为数论和分析学的诞生奠定了基础。（AI 启发：超出“有理”可表达性的现象推动了更大状态空间的建模——如连续表征与实值网络。）

2.2.2 毕达哥拉斯：数与宇宙的关系

数学的哲学化起点源自古希腊的毕达哥拉斯学派。毕达哥拉斯 (Pythagoras) 及其追随者提出了“万物皆数”的思想，认为宇宙的本质可以通过数来理解。（修正“及及其”重复）这一理念激励了希腊数学家们将数学视作解读自然现象的工具。毕达哥拉斯定理（即勾股定理）是这一学派最著名的成就之一，标志着数学开始从经验性计算向理性推理的迈进，开启了数与形结合几何学研究。（AI 去向：几何先验 → 物理世界建模；见 9.2 几何深度学习。）

2.2.3 欧几里得：公理化体系的奠基人

如果说毕达哥拉斯奠定了数学的哲学基础，那么欧几里得 (Euclid) 则为数学建立了逻辑结构。他的《几何原本》(《Elements》) 是古代数学史上最具影响力的著作之一，也是现代数学公理化体系的奠基之作。

欧几里得通过公理和定理的形式，系统地将几何学结构化，强调了证明的重要性。欧几里得展示了如何从少数的基础假设（公理）出发，通过严密的逻辑推导，推导出一系列复杂的几何命题。这种公理化方法对后世的数学家产生了深远影响，甚至成为了现代数学研究的重要框架。欧几里得的几何不仅仅是关于形状和空间的学问，更标志着数学作为一种基于推理的演绎学科的正式诞生。（AI 启发：明确假设集 $\Rightarrow$ 可复现实验与安全边界；见 10.1 可验证与可信 AI。）

2.2.4 阿基米德：数学与物理的桥梁

阿基米德 (Archimedes) 是古希腊另一位杰出的数学家，他不仅在数学领域取得了重大的突破，还在物理学、机械学等领域做出了重要贡献。阿基米德将几何与物理现象紧密结合，开创了利用数学模型解决物理问题的先例。

他在几何领域的突破，如圆周率的近似计算、浮力定律及流体静力学基本定理的证明，展示了数学在物理学应用中的强大力量。阿基米德的工作不仅扩展了数学的应用范围，还展现了数学在解释自然现象中的力量。（AI 去向：连续量的近似—数值稳定/误差控制；见 8.2 优化与数值性。）

2.2.5 亚里士多德：逻辑与推理

亚里士多德（Aristotle）是古希腊著名的哲学家。亚里士多德认为，数学不应只停留在经验性的层面，而应该通过演绎推理去发现隐藏在事物背后的逻辑关系。他提出的三段论和归纳法，帮助数学家们更好地理解和构建逻辑推理过程。这种逻辑推理体系推动了古希腊数学的进一步发展，数学家们开始通过推理和证明而非直观的经验得出结论。（AI 启发：符号推理与统计学习的互补；见 11.3 神经—符号融合。）

算术与几何这两大分支的创立，标志着数学开始作为一门理论化学科的诞生，逻辑推理和证明逐渐成为数学的核心方法。与此同时，代数学在这一时期取得了重要进展，自然数、有理数和无理数的运算逐渐成为代数的核心主题。除此之外，这一阶段的代数学还开始引入虚数，推动了数的概念向更广的领域扩展。

2.2.6 古希腊数学的遗产

通过抽象思维和逻辑推理，建立了数学作为一种独立学科的基础。古希腊数学家们的贡献不仅仅是发现了一些几何定理和代数法则，更重要的是他们发展了数学思维的方式——通过演绎、证明、公理化等方法，将数学从经验性工具转变为一种严谨的科学。这一传统不仅奠定了现代数学的基础，还推动了之后数千年数学和科学的进步。（一句话抽象：证据链 $\Rightarrow$ 可靠知识；AI 去向：可解释与可证明的系统。）

中世纪的阿拉伯数学家翻译了希腊经典，并引入了印度的十进制数和“零”的概念。阿尔·花刺子密（al-Khwarizmi）等数学家对代数学的发展做出了巨大贡献，他的著作奠定了代数理论奠定了坚实的基础。（“algorithm”一词即源于其姓名的拉丁化形式。）

中国的《九章算术》和印度的基础代数成就，也为初等数学的发展增添了重要内容。中国古代数学强调实用性，广泛应用于农业、建筑和税务管理；而印度数学则对数论和代数的早期发展做出了杰出贡献。这些不同文化的数学成果，最终共同塑造了初等数学的广阔基础。

这一时期涵盖了公元前 5 世纪到 17 世纪前的数学发展。数学不再仅限于解决实际问题，而是向抽象领域迈进。古希腊数学通过几何学和数论的研究，构建了数学推理和证明的数学体系。这一阶段的数学成就不仅构成了今天中学数学的主要内容，还对现代数学的基本理论结构产生了深远的影响。

2.3 近代数学时期：变量、函数与微积分

从 17 世纪开始，随着资本主义的崛起和工业革命的推动，数学进入了一个全新的阶段——变量数学时期。这一时期的数学从研究静态图形和数量问题逐步转向关注变化与运动问题，变量和函数的引入是更好描述运动和变化的关键。

牛顿和莱布尼茨分别独立发明了微积分，标志着数学史上一个重要的转折点。微积分提供了一套精确描述连续变化与瞬时变化的数学工具，成为解决诸如速度、加速度、曲线下面积等问题的强大工具。牛顿通过微积分为物理学中的万有引力定律奠定了理论基础，而莱布

尼茨则将微积分符号化并推广到欧洲，极大地推动了数学的发展。微积分不仅让数学得以分析瞬时变化，还为后续的数学分析开创了新的方向。

解析几何的诞生是这一时期的另一个重大突破。笛卡尔通过引入坐标系，将几何与代数结合起来，使得复杂的几何图形、物理的运动及其空间关系可以通过代数方程来精确描述。借助于笛卡尔坐标系，数学家们能够用代数表达曲线、直线的关系，从而简化了几何中的很多问题。解析几何不仅为物理学中的动力学提供了有力工具，还为现代数学的发展铺平了道路。

近代数学时期的另一个重要分支是概率论。概率论起初由费马和帕斯卡为了研究赌博中的随机事件而诞生，但很快超越了这一领域，成为研究不确定性和随机现象的重要工具。费马还对数论做出了重要贡献，提出了许多关于素数与数之间关系的问题，激发了后世数学家对数论的广泛研究。欧拉、拉格朗日等人进一步推动了数论的发展，探讨了代数结构和数论的基本问题。

与此同时，分析学作为微积分的延续，成为这一时期的核心数学分支。通过函数和极限概念的引入，数学家们能够处理无穷小量和变化中的量，开创了分析学的时代。数学分析不仅成为这一时期的核心理论，不仅解决了古希腊时期悬而未决的几何问题，还广泛渗透进了物理学、天文学和工程学，极大地推动了科学的进步。（AI 启发：梯度/最优化—现代深度学习的计算内核。）

从 17 世纪开始，数学逐步系统化，并成为理解自然世界的核心工具。科学革命带动了数学的飞速发展，数学不仅在传统的代数和几何领域取得了突破，还在物理学、天文学、工程学等领域中发挥了重要作用。变量数学的引入让人们能够更好地理解宇宙中的变化与运动，推动了自然科学的进步。

总的来说，近代数学时期不仅为数学的进一步抽象化奠定了基础，还通过微积分、解析几何和概率论的兴起，彻底改变了人类对世界的理解方式。数学在这一时期的变革性进展，成为了现代数学发展的根基，也为科学技术的进一步进步提供了强有力的工具。（一句话抽象：变化、空间与不确定性三件套；AI 去向：优化、几何表示、概率图模型。）

2.4 现代数学时期：抽象、结构与计算

从 19 世纪中叶起，数学进入了一个高度抽象化和系统化的阶段，被称为现代数学时期。这个时期的数学阶段不仅延续了之前的分析学发展，还引入了全新的几何和代数理论。代数、几何和分析学等传统学科在此期间发生了质的飞跃，数学的研究对象和方法也逐渐向高度抽象化发展，推动了数学成为一门更加系统和广泛应用的科学。

现代数学的一个显著特征是对数学基础的重新审视与抽象概念的扩展。罗巴切夫斯基和黎曼的非欧几何（删去重复逗号），颠覆了传统欧几里得平面几何观，提出了球面和鞍面等不同几何结构，揭示了更为广泛的空间和结构关系。并为爱因斯坦的广义相对论提供了数学基础。拓扑学作为新的分支，也在 19 世纪逐渐兴起，打破了传统几何的局限，成为数学研究连续性、边界与形态的重要工具。

同时，现代数学的发展离不开对无穷概念和数学基础的深入研究。康托尔的集合论，为

处理无穷大的数学研究提供了严格的工具，将无穷大和无穷小的概念精确化，成为现代数学和数理逻辑的基础理论之一。集合论的发展不仅使数学在抽象层面上得以统一，还激发了对数学自身基础的研究。集合论和数理逻辑的兴起为数学理论提供了全新的理论框架，希尔伯特、哥德尔等数学家在此领域的工作，使得数学的公理化体系进一步得到发展与完善。

20 世纪，统计学、拓扑学、泛函分析等新分支陆续创立，使数学更多元化、更富实用性。数学在众多领域的应用范围得到了前所未有的扩展，数学在物理学、工程学、经济学以及其他自然科学和社会科学等各个学科中的作用变得愈加重要。（AI 去向：统计学习理论、泛函空间中的核方法与 RKHS。）

现代数学时期的另一个重要推动力是计算机的发明和信息技术的迅猛发展。20 世纪中期，图灵、冯·诺依曼等科学家为计算机科学奠定了理论基础，计算理论逐渐成为数学的重要分支。计算机的强大计算能力使得复杂的数学问题得以快速求解，同时也极大地推动了数理逻辑和算法理论的发展，数学的潜能和边界更进一步发掘。（一句话抽象：可计算/复杂度的边界塑造了“可做之事”。）

随着数学的抽象化与理论化趋势日益加深，数学在深入自然科学领域的同时，还广泛渗透到信息科学、工程学、经济学、社会科学等多个领域，推动了现代社会各个层面的进步。现代数学逐渐成为理解自然世界、构建理论模型和推动技术创新的核心力量。

总之，现代数学时期是数学高度抽象化、系统化的阶段。数学基础理论的深入研究与应用范围的广泛扩展，使得数学不仅在理论层面得到了重大发展，也成为了推动科学和技术进步的关键推动力。通过集合论、非欧几何、拓扑学和计算理论的引入与发展，数学在 20 世纪的进步为现代社会的各个领域带来了不可忽视的影响。（AI 去向：可计算性/复杂度 → 算法选择与系统设计的第一性约束。）

2.5 三次数学危机：从无理数到不完备

数学发展的历程中，曾三次面临深刻的理论挑战，这些危机不仅推动了数学的变革，也影响了其作为一门科学的根本性质。这三次数学危机分别发生在古希腊时期、17 世纪微积分的创立期以及 19 世纪末的集合论时代。每一次危机都促使数学家重新审视数学理论的基本概念，构建更加严密的数学体系，从而推动了数学从工具性学科向更高抽象层次的科学发展。（一句话抽象：边界被突破—再公理化—再出发。）

2.5.1 第一次危机：无理数的发现与算术信仰的破灭

第一次数学危机发生在古希腊，起因是**无理数**的发现。古希腊的毕达哥拉斯学派主张“万物皆数”，但这里的“数”是指整数或整数之比，即有理数。他们认为世界的规律可以通过数与比例来完美解释，这一思想赋予了数学一种神秘的普适性。

2.5.1.1 危机的产生

然而，毕达哥拉斯学派在研究边长为 1 的等腰直角三角形时却遇到了矛盾。根据毕达哥拉斯定理（即勾股定理），斜边长度的平方为 $2 (= 1^2 + 1^2)$ ，但可以证明斜边长度无法用任何两个整数的比值来表示，这意味着它不属于有理数。这一发现彻底动摇了毕达哥拉斯学派对于有理数是万物根源的信念，引发了数学史上的第一次重大危机。

无理数的存在打破了古希腊数学家对数字和比例的简化认识，表明数的体系并不完备，迫使数学家们不得不重新审视数的定义。（AI 去向：连续表征与几何先验一见 9 章。）

2.5.1.2 危机的解决

1. 转向几何方法 为了应对无理数问题，古希腊数学家选择更多依赖**几何方法**而非算术来处理无理数的概念。欧几里得在其著作《几何原本》（Elements*）中，系统化了几何学，通过线段、面积等几何量来间接表示无理数，成功绕过了当时无法表达无理数的难题。

几何化的处理方式希腊数学家解决无理数问题提供了一个有效的工具，维持了数学的逻辑一致性。几何学在这一危机后成为古希腊数学的主导分支。

2. 比与比例的概念 欧几里得在几何学中进一步发展了**比（比例）理论**，通过探讨不同长度线段之间的比例关系，间接处理无理数表达问题。在《几何原本》第十卷中，他讨论了不成比例的线段（即不能用有理数表示其比例的线段），这实际上就是无理数的一种几何表述。一个著名的例子是黄金分割比例。这种方法让数学家能够处理无理数带来的计算问题，并保持几何学的逻辑一致性。

3. 无理数的接受与扩展 虽然古希腊数学家未能明确提出“无理数”这一术语，但他们的几何手段为后来接受与正式提出无理数提供了基础。到 17 世纪，随着代数学的迅速发展，数学家们开始正视并重新定义数的概念。无理数逐渐从几何比率演变为代数中的一类新的数字体系，并在数学的各个分支中逐渐占据了重要地位。

4. 实数体系的建立 19 世纪，数学家通过构建更加严谨的实数理论彻底解决了无理数的表示问题。魏尔斯特拉斯等人通过极限和连续性的概念，为实数定义奠定了基础，构建了完整的实数体系，统一了有理数和无理数的表示方式。至此，无理数得到了明确的数学定义，彻底解决了自古希腊时期以来的无理数危机。（AI 去向：连续优化/可微分编程一见 8 章。）

2.5.1.3 危机的意义

无理数危机的解决是数学史上的一大转折点，经过了数代数家的努力。虽然无理数的发现带来了危机，但最终促使了数学向更高的层次发展。几何学的抽象化、代数学的进步以及实数体系的确立，标志着数学摆脱了毕达哥拉斯学派的局限，迈入了新的发展阶段。这场危机不仅将数的概念从有理数扩展到无理数，还为后来的数学分析和数论奠定了坚实的基础。

2.5.2 第二次数学危机：微积分基础的争议与解析

第二次数学危机出现在 17 世纪，伴随着**微积分**的诞生。微积分由牛顿和莱布尼茨独立提出，是解决变化率和曲线面积等问题的强大工具。

2.5.2.1 危机的产生

虽然在解决实际问题上取得了巨大的成功，但微积分的早期发展在理论上存在许多模糊之处，尤其是关于**无穷小量**（infinitesimals）的使用，引发了深刻的数学危机。微积分的核心思想之一是使用无穷小量来定义变化率和累积变化。比如，导数被定义为“函数的瞬时变化率”，而积分则表示曲线下面积的无限累加。然而，当时的数学家并没有严格定义什么是无穷小量，它既不能被归为零，也不是某个确定的数，以致于在某些推导过程中无穷小量一会等于 0，一会又不等于 0。这种模糊性使得微积分缺乏严密的逻辑基础，许多数学家无法接受微积分作为严格数学工具的合理性。**贝克莱**等学者猛烈批评了微积分理论，指出其在逻辑上存在的缺陷，“微积分似乎依赖于‘幽灵般的消失量’”。

2.5.2.2 危机的解决

解决这一危机的关键在于**极限**（limit）概念的引入。17 世纪末至 18 世纪初，数学家们逐渐认识到，无穷小量可以通过极限概念加以精确描述。极限理论通过定义函数在某一点附近的行为，能够描述无穷小量趋于零的过程，避免对模糊无穷小量概念的依赖。

19 世纪，柯西和魏尔斯特拉斯等数学家通过引入**极限理论**，对极限、连续性、导数和积分的定义进行了重新审视，对微积分进行了严密的逻辑重构。

柯西首次明确使用极限概念来定义导数和积分，奠定了现代分析学的基础。而魏尔斯特拉斯则通过对极限的精确定义，彻底摆脱了无穷小量的概念，构建了严谨的微积分体系。极限概念取代了无穷小量，导数被定义为函数在某一点的瞬时变化率，积分则作为求和的极限。这一重新定义消除了无穷小量的模糊性，将微积分从模糊的直觉推导转变为明确的、严格的数学定义，确保了微积分中的推导和计算具有严格的逻辑基础。通过这种方式，微积分危机得到了全面解决，数学家们能够自信地使用微积分来解决变化率和复杂的动态问题。（AI 去向：梯度传播与稳定性分析一见 8.2。）

2.5.2.3 危机的意义

第二次数学危机的解决，标志着数学从经验性工具走向了更加严谨的理论体系。通过引入极限概念和分析学的系统化构建，数学家们不仅解决了微积分中的基础问题，还推动了现代数学分析的诞生。这一危机的解决具有深远的意义，不仅使微积分成为物理学、天文学、工程学等领域的基础工具，还推动了整个数学的发展。微积分危机的解决使得数学家们对数、函数和极限有了更深刻的理解，并奠定了未来分析学和数理逻辑的基石。

2.5.3 第三次危机：集合论与逻辑的悖论

第三次数学危机发生在 19 世纪末至 20 世纪初，伴随着**集合论**的诞生和发展。康托尔在 19 世纪提出了集合论，首次系统地研究了无穷集合的性质，并对无穷数进行了分类和操作。他证明了无穷集合不仅存在，而且可以通过不同的方式进行数学上的操作。然而，随着无穷概念的深入研究，数学家们开始意识到在无穷集合中存在的悖论，这些悖论挑战了数学的逻辑一致性。

最著名的悖论是**罗素悖论**。它揭示了集合论中定义集合的一些方式会导致自相矛盾。例如，考虑“所有不包含自身的集合的集合”这一定义，这样的集合如果包含自身就违反了定义，但如果不包含自身，它又应该包含自己。这种自相矛盾的问题对整个数学的基础提出了挑战，暴露了当时的数学体系存在严重的不完整性。

面对这些悖论，数学家们开始寻求解决方案。**希尔伯特**发起了一个庞大的计划，试图通过公理化数学来消除这些不一致性。**哥德尔的不完备性定理**最终表明，任何公理化体系内部都无法完全解决这些问题，数学总是存在某些无法在体系内部证明或证伪的命题。这一危机迫使数学家们重新思考数学的逻辑结构，并促成了数理逻辑、集合论以及形式化数学的深入发展。（AI 去向：可证明性边界—对齐与安全的理论底线。）

2.5.4 第三次数学危机及其解决：集合论与逻辑基础的动摇

第三次数学危机发生在 19 世纪末至 20 世纪初，源自**集合论**的提出及其暴露出的逻辑悖论问题。康托尔所创立的集合论在数学上提供了一种全新的方法来处理无穷大和无穷小的问题，并在一定程度上统一了数学的基础。然而，随着对集合论的深入研究，数学家们发现其中隐藏着自相矛盾的悖论，最著名的便是**罗素悖论 (Russell's Paradox)**。这一发现暴露了当时集合论的基础漏洞，动摇了整个数学体系的逻辑一致性，标志着数学史上的第三次重大危机。

2.5.4.1 危机的产生

康托尔在 19 世纪末提出了**集合论**，对数学领域产生了深远的影响。这一理论通过对无穷大的精确描述，为数学提供了处理无限集的新工具。此外，引入集合的概念，康托尔重新定义了数的构成方式。然而，随着集合论的推广，数学家们逐渐发现了一些无法避免的矛盾，特别是**自指悖论**，其中最具代表性的就是罗素悖论。

罗素悖论考虑这样一个集合：**所有不包含自身的集合的集合**，问这个集合是否包含自身？如果该集合包含自身，就违反了自身的定义；如果不包含自身，又与定义矛盾。

为了形象地说明**罗素悖论**，我们可以借用著名的**理发师悖论**。“理发师悖论”是罗素悖论的通俗表达版本，帮助我们更直观地理解其逻辑上的自相矛盾。

理发师悖论：

在一个小镇上，有一位理发师，他发布了这样一个规定：**他只为那些不自己剃须的人剃须**。也就是说，理发师为所有不自己剃须的居民剃须，而所有自己剃须的居民则不由理发师

剃须。于是问题来了——**谁给理发师剃须？**

这个问题引发了两种情况：1. 如果理发师不自己剃须，那么根据规则，他应该由自己来剃须，因为他不属于那些自己剃须的人。2. 但是，如果理发师给自己剃须，他属于那些自己剃须的人，就不属于理发师的服务对象，理发师就不应该给自己剃须。

于是，无论理发师是否自己剃须，都会违反规则。这就是理发师悖论，它揭示了在规定中存在的自相矛盾。这个悖论的本质在于自指——理发师同时属于要剃须和不剃须的两种情况，从而导致了逻辑上的矛盾。

罗素悖论：罗素悖论与理发师悖论类似，它讨论的是**集合**的自包含问题。它考虑这样的集合：**所有不包含自身的集合的集合**，问这个集合是否包含自身。

- 如果这个集合包含自身，那么它就不属于那些不包含自身的集合，因此不能包含自身。
- 如果这个集合不包含自身，那么根据定义，它必须包含自身，因为它属于那些不包含自身的集合。

因此，这种情况下也产生了自相矛盾，就像理发师悖论一样，这也是一种**自指性悖论**，在逻辑上无法自洽。

罗素悖论暴露出在集合论的基本定义中存在自相矛盾的逻辑缺陷，打破了数学家对集合论及其逻辑基础的信心。

这一悖论引发了数学家对数学基础的全面反思，特别是对数学逻辑和集合论的可靠性的质疑。如果作为集合论无法避免悖论，数学的逻辑基础和所有建立在这些逻辑基础上的数学理论也将面临同样的不确定性。

2.5.4.2 危机的解决

为了解决这一危机，数学家们开始重新审视数学的逻辑基础，试图通过更加严密的逻辑系统来修补集合论的悖论，并确保数学体系的完整性和一致性。解决这一危机的主要路径有以下几方面：

1. 形式系统的引入

解决罗素悖论的关键之一在于对数学进行形式化处理。以希尔伯特为代表的数学家提出了**形式系统**的思想，即通过定义一组公理和推理规则，将所有数学命题都归结为形式符号的推理。在这种系统中，所有推理必须严格按照形式化规则进行，以确保逻辑的自治性。希尔伯特的形式系统被认为是解决罗素悖论的一种手段，因为通过形式化处理可以避免自指性和逻辑上的悖论。

希尔伯特的“公理化计划”试图通过一组完备的公理和逻辑规则构建数学的基础确保数学推理的一致性和完备性，并证明数学体系的无矛盾性。然而，这一计划在哥德尔的不完备性定理面前遭遇了挑战，但它奠定了数学逻辑的基础，为后来的形式逻辑系统和数学结构提供了工具。（AI 去向：形式规约与可验证合约一见 10 章。）

2. 类型论的提出

为了解决集合论中的悖论，罗素本人提出了**类型论**（Theory of Types），

该理论通过对集合进行分层，将集合划分为不同的类型，禁止集合包含自身或同类类型的集合，从而避免自指性带来的矛盾。这种层次化的集合结构避免了自指的产生，有效消除了罗素悖论带来的自相矛盾。但类型论也受到一些批评，特别是由于它的操作复杂性以及对数学理论应用的限制。然而，类型论在逻辑学和计算机科学中的应用仍然具有重要意义，尤其在编程语言理论中得到了广泛应用。（AI 去向：类型系统 → 静态检查与安全沙箱。）

3. 公理化集合论

集合论的进一步发展得益于**策梅洛-弗兰克尔公理系统**（Zermelo-Fraenkel set theory, ZF）。这一系统通过一套精心设计的公理，对集合的构成和操作进行了规范化处理，避免了自指和无限回归等问题，消除了罗素悖论的根源。策梅洛首先提出了以选择公理为基础的集合论公理系统，后来弗兰克尔对其进行了扩展，形成了 ZF 体系。ZF 公理化系统通过严格的公理定义，为集合论提供了一个无悖论的逻辑基础，确保了数学推理的可靠性。ZF 集合论不仅为集合论奠定了坚实的基础，还成为了现代数学中集合论的标准体系。通过公理化的方式，数学家能够在逻辑上避免悖论，同时也确保了数学体系的逻辑一致性和严格性。举个例子：以“正则性公理”禁止集合自含，从根本上排除了“自我成员”的构型。

4. 哥德尔不完备性定理

尽管公理化的集合论解决了逻辑悖论问题，但库尔特·哥德尔（Kurt Gödel）的**不完备性定理**（Gödel's Incompleteness Theorem）揭示了一个新的局限性：在任何足够复杂的公理系统中，都存在一些命题，既无法在系统内部证明其真伪，也无法推翻。这一结果否定了希尔伯特的完备性计划，证明了即便数学可以通过形式系统避免自相矛盾，也无法保证其逻辑的完备性。数学在本质上是无法完备的。（AI 去向：可证明性边界对“全能对齐”的否定——务实转向评测与约束优化。）

尽管如此，哥德尔不完备性定理并未动摇数学的基础，反而让数学家更加意识到逻辑系统的局限性。数学家因此更加重视逻辑学的精密性，推动了数理逻辑和元数学的进一步发展。

2.5.4.3 危机的意义

第三次数学危机通过公理化、形式系统、类型论和逻辑分析的多重努力得到了有效解决。这一危机不仅推动了数学基础理论的深入研究，也促使数学家对逻辑一致性和严密性的要求更为严格。通过策梅洛-弗兰克尔公理化体系，数学家为现代集合论提供了无悖论的基础。尽管哥德尔的不完备性定理提出了数学体系不完备的本质限制，指出数学系统永远不可能完美无缺，但它同时也为数学逻辑的发展提供了新的方向。（一句话抽象：形式系统保障一致性，不保完备性——工程上以规约与监控兜底。）

这一危机的解决，使得数学从逻辑上更加稳固，并为后续的数学研究奠定了更高标准的严谨性。数学基础的重建不仅加强了数学逻辑的力量，还推动了现代数学向更高层次的抽象

发展，为数理逻辑、模型论和计算理论等新兴学科的诞生铺平了道路。

这些三次数学危机深刻影响了数学的演进，促使数学家们不断重新审视基本概念，并推动了数学向更高的抽象层次发展。每一次危机的解决不仅重塑了数学的结构，还推动了新领域的诞生，使数学始终在挑战中突破，走向新的高度。

2.6 小结

纵观以上四个时期，数学的发展脉络清晰呈现。数学从最初解决日常问题的工具，逐步演化为一门以逻辑推理和抽象思维为核心的科学。数学史既是一部理论创新史，也是一部与社会发展和科学进步紧密相连的演进史。

从萌芽阶段的经验性计算到古希腊数学家奠定的逻辑推理基础，再到近代变量数学的飞跃和现代数学的高度抽象化，数学经历了从实用工具到抽象学科的跨越。随着社会与科学的持续发展，数学也成为了理解世界、解决问题和推动技术进步的核心力量。（复盘：本章每节“examplebox”即为 AI 建模的落地锚点。）

纵观历史，数学的应用几乎渗透到了每一个领域中。人类历史上的每一个重大事件的背后都有数学的身影：

- 达芬奇的绘画（15-16 世纪）
- 哥白尼的日心说（16 世纪）
- 牛顿的万有引力定律（17 世纪）
- 马尔萨斯的人口论（18 世纪）
- 巴赫的 12 平均律（18 世纪）
- 孟德尔的遗传学（19 世纪）
- 晶体结构的确定（19 世纪）
- 人人平等（所有的直角都相等）、三权分立的政治结构（19 世纪）
- 无线电波的发现（19 世纪）
- 巴贝奇的“机械”计算机（19 世纪）
- 达尔文的进化论（19 世纪）
- 爱因斯坦的相对论（20 世纪初）
- DNA 双螺旋凝结的打开（20 世纪）
- 冯·诺依曼的二进制编码和现代计算机（20 世纪）
- 图灵机（20 世纪）
-

（总收束：本章以“现象—抽象—启发—取舍—去向”形成可迁移的学习闭环，后续章节将据此展开各模块的可操作细节与练习。）

第三章 智能，成于计算机

简明 AI 史

内容提要

- Definition of Theorem
- Property of Cauchy Series
- Ask for help
- Angle of Corner
- Optimization Problem

—— 傅鹰

—— 约翰·冯·诺伊曼

人工智能（AI）的发展史和数学史一样，是一部不断突破技术限制、追求理解智能本质的进化历程。从最初的理论奠基，到今天无处不在的智能应用，AI 的发展经历了多个阶段，每一个阶段都为未来奠定了新的基础。

3.1 AI 的萌芽期：理论的起源与计算机的诞生

AI 的概念可以追溯到 20 世纪中叶，然而其理论根基则来自更早的数学与逻辑学研究。事实上，AI 的出现并非偶然，它是人类在探索计算的更高效率和智能模拟道路上的自然延续。

回顾数学史，不难发现，人类的进步始终伴随着对**更高计算效率**和**更强智能模拟**的追求。从最早的数数工具，到代数、几何的兴起，再到微积分和分析学的创立，每一次数学理论的突破，都是为了解决日益复杂的问题，并提升计算的效率和智能化程度。**举个例子**。

随着数学理论的发展，特别是近现代数学时期数理逻辑和计算理论的提出，人工智能的理论基础逐步形成。然而，在 AI 真正出现之前，人类已经通过多个世纪的努力，逐步发明了各种计算机器，以减轻人类在计算方面的负担。人类很早就认识到，计算不必局限于脑力或手工操作，一些重复性和繁复的计算可以通过机械的方法来执行，从而提高效率，减少人为误差。

其中最著名的早期计算工具之一便是中国古老的**算盘**。**算盘**的发明可以追溯到公元前数百年，它是一种基于十进制系统的手动计算工具，广泛应用于商业、税务和日常生活中，用于快速进行加减乘除运算。尽管原理简单，但算盘展示了人类利用工具来加速复杂计算的思想，代表了早期机械化计算工具的雏形。

随着时间的推移，机械计算设备逐渐变得更为复杂和精密。1642 年，法国数学家**布莱兹·帕斯卡**（Blaise Pascal）发明了第一台机械计算器——“帕斯卡计算器”，它可以执行十进制加法运算，标志着机械与数学计算结合的开端。1678 年，德国数学家**莱布尼兹**（Gottfried Wilhelm

Leibniz) 进一步改进了帕斯卡的设计, 发明了能够执行十进制数乘除运算的机械计算机, 揭示了机械计算在复杂运算中的巨大潜力。

不仅是机械计算工具, 自动化的思想也融入了各类生产工具的设计中。19 世纪, **雅卡尔织机**通过打孔卡片来控制织物图案的变化, 展示了早期的编程思想。这种通过机械手段实现将繁复的任务自动化的理念, 预示着计算机自动化编程的雏形, 间接推动了后来智能技术的发展。

19 世纪, 随着工业革命的推进, 人类对计算的需求愈加迫切, 特别是在天文学、工程学和金融领域。大量数字和复杂方程式问题已远超出人类的手工能力, 催生了更多计算机器的发明。1821 年, 英国数学家**查尔斯·巴贝奇** (Charles Babbage) 设计了“差分机”, 这是一种专门用于提高乘法速度和改进对数表精度的机械计算装置。尽管由于设计成本过高, 差分机的后续发展以失败告终, 但巴贝奇在 1834 年设计的“分析机”被认为是通用计算机的雏形, 通过打孔纸带输入程序和数据, 预示了现代计算机的基本理念。尽管“分析机”最终因技术局限也未能实现, 但巴贝奇的思想奠定了现代计算机的概念基础: 通过程序控制的通用计算机。

20 世纪初, 数学家如**大卫·希尔伯特**、**库尔特·哥德尔**和**阿兰·图灵**提出了关于计算与逻辑的基本理论, 为人工智能的萌芽提供了肥沃的土壤。**阿兰·图灵**在 1936 年发表的《论可计算数》一文中, 提出了**图灵机**的概念, 奠定了现代计算理论的基础和框架。图灵机是一种模拟计算过程的抽象数学模型, 这一思想不仅为后来电子计算机的发明打下了坚实的理论基础, 也为人工智能提出了一个关键问题——**机器能否像人类一样思考?** 1950 年, 图灵提出了著名的**图灵测试**, 作为判断机器是否具备智能的标准, 开启了对机器智能的早期探索。图灵的思想对随后的人工智能发展产生了深远的影响, 确定了未来人工智能的发展方向。

20 世纪, 电子技术的突破使计算机摆脱了传统机械部件的限制, 转向实用电子开关、电路板和真空管, 使计算速度提高了无数倍, 实现了前所未有的效率飞跃。

真正具有突破性的发明出现在 1942 年, 美国的**约翰·阿塔纳索夫** (John Vincent Atanasoff) 和**克利福德·贝瑞** (Clifford Berry) 制造了第一台电子计算机——**Atanasoff-Berry 计算机 (ABC)**, 首次使用二进制来表示数据, 并通过电子开关代替了机械部件, 标志着从机械计算向电子计算的重大转变, 尽管它尚无法进行编程。

随后, **ENIAC**, 由**约翰·冯·诺依曼** (John von Neumann) 等人设计, 成为世界上第一台通用电子计算机。**ENIAC** 不仅能进行复杂的计算, 还采用了冯·诺依曼的存储程序架构, 即将程序和数据存储在计算机内存中。这一架构成为现代计算机的基础, 大幅提高了计算机的灵活性和计算效率。

这些电子计算机的发明, 不仅标志着计算能力的巨大飞跃, 也为人工智能的早期发展提供了关键的技术平台。电子计算机使得机器能够在更大规模上执行复杂的计算和推理任务, 推动了智能模拟从理论走向实践, 开启了自动化计算的新纪元。**AI** 作为一种思想和技术, 诞生在数学、逻辑和计算科学的交汇点上, 标志着智能模拟从理论走向实践的新时代。

因此, **AI** 的发展历程, 既是人类追求越来越高效计算的延续, 也是计算思维逐步外化并加速进化的体现。从算盘、机械计算器到电子计算机, 每个阶段的技术进步都使计算变得更加高效和智能化, 推动了从人工计算到机器计算的转变。这一趋势也为 **AI** 的诞生铺平了道路,

使得机器不仅能执行运算，还具备了模拟人类思维、学习和决策的潜力。AI 正是这一智能化趋势的巅峰成果，是人类不断努力提升计算能力和模拟智能行为的必然延伸。

3.2 1950-1970 年代：AI 的奠基与早期探索

1950 到 1970 年代，人工智能开始从理论走向实践。1950 年代被视为人工智能的正式起点。在此期间，数学、逻辑学、计算机科学和神经科学的交汇，为人工智能的早期发展铺设了道路。

阿兰·图灵的贡献无疑是这个时期最为重要的起点。1950 年，他在论文《计算机与智能》中提出了衡量机器是否具备智能的标准——“图灵测试”。图灵通过设想一台机器与人类对话的情境，开启了对机器是否能够模拟人类智能的讨论，奠定了早期人工智能研究的理论基础。

约翰·冯·诺依曼的工作对 AI 的发展也产生了重要影响。1940 年代，冯·诺依曼提出了自复制自动机的理论，并在计算机设计中推广了“存储程序”的概念，这使得计算机能够按照程序指令自动执行复杂任务。冯·诺依曼的计算机架构为人工智能提供了强大的硬件基础，也为智能程序的实现铺平了道路。

增加参考文献《面对面的办公室》

成就一生的会议

约翰·麦卡锡（John McCarthy）是 AI 奠基时期最关键的人物之一。他的思想和研究引领了 AI 这一全新领域的诞生和早期发展。

1948 年，年轻的麦卡锡在普林斯顿大学听了**冯·诺依曼**关于自复制自动机的报告后，激发了他对“用计算机模拟人类智能”的强烈兴趣。1949 年，麦卡锡在普林斯顿数学系攻读博士学位时首次在论文中提出了“用计算机来模拟人类智能”的想法，尽管当时这一概念十分模糊，但已展现出 AI 作为独立研究领域的雏形。在冯·诺依曼的鼓励和支持下，麦卡锡将主要研究方向定为在机器上模拟人的智能，特别是将下棋问题作为重点课题之一。此后，为了减少计算机需要考虑的棋步，麦卡锡发明了 α - β 剪枝算法。这一方法有效地减少了计算量，至今仍是解决人工智能问题中一种常用的高效方法。

麦卡锡和贝尔实验室的**克劳德·香农**（Claude Shannon）——“信息论”的创始人，在人工智能方面的若干深入探讨之后，他们萌生召开一次研讨会的共识。1956 年，在洛克菲勒基金会的一笔微薄的赞助下，他们邀请到当时哈佛大学的**马文·明斯基**（Marvin Minsky）和 IBM 工程师**罗彻斯特**等几位学者，在达特茅斯学院组织了这次夏季研讨会。

在达特茅斯会议上，“人工智能”一词降临，备选名字有“自动机研究”、“复杂信息处理”、“机器智能”与“控制论”，与会者最终选择了“人工智能”（Artificial Intelligence），简洁而富有指向性。

“……学习的每一方面或智力的任何其他功能，原则上都可以准确地描述，并由机器模拟。我们将尝试制造能够使用语言、提炼抽象概念的机器的方法，……如果一批优秀的科学家在一起研究一个夏天，那么这一领域中的一个或多个问题就能得到显著的推进。”这种大胆的设

想不仅为 AI 的核心研究方向指明了道路，也传达出一种对机器智能的乐观信念——即智能行为是可以被精确模拟的。

这次会议成为众多奠基者的灵感之源，确立了人工智能学科的基础框架，使“人工智能”这一领域获得科学界的认可，并为未来几十年的研究奠定了重要的学术基础。

汇集了 10 位科学家，持续 2 个月的达特茅斯会议是计算机史上的一座里程碑。会议的主要参与者后来都在计算机科学和人工智能领域取得了杰出的成就。

- **约翰·麦卡锡 (John McCarthy)**：作为达特茅斯会议的主要发起人，麦卡锡不仅提出了“人工智能”这一术语，还在麻省理工学院 (MIT) 建立了第一个 AI 实验室，开发了 AI 的主要编程语言之一——Lisp，为 AI 的符号处理和逻辑推理奠定了基础。1971 年，麦卡锡因其在 AI 领域的杰出贡献而获得图灵奖。
- **马文·明斯基 (Marvin Minsky)**：人工智能和认知科学的先驱，达特茅斯会议的主要参与者之一。明斯基在 MIT 建立了著名的 AI 实验室，将人工智能的研究扩展到学习和认知的复杂领域。他于 1969 年获得图灵奖，彰显了其在 AI 理论和方法上的重要贡献。
- **克劳德·香农 (Claude Shannon)**：作为信息论的创始人，香农在达特茅斯会议上的参与为 AI 带来了信息处理的理论支持。他通过“信息熵”概念，为通信和数据处理打下了数学基础，推动了 AI 在数据传输和编码方面的进展，为机器学习和模式识别等 AI 技术的日后发展提供了理论依据。
- **艾伦·纽厄尔 (Allen Newell) 和赫伯特·西蒙 (Herbert Simon)**：这两位科学家不仅在达特茅斯会议上推动了 AI 的发展，还共同开发了早期的 AI 程序，如 Logic Theorist 和 General Problem Solver (GPS)，这些系统奠定了符号主义 AI 的基础。两人于 1975 年共同获得图灵奖，以表彰他们在逻辑推理和问题求解的 AI 系统上的创新。西蒙还因在经济学和认知科学的交叉研究中取得的杰出成果，于 1978 年获得诺贝尔经济学奖。
- **纳撒尼尔·罗切斯特 (Nathaniel Rochester)**：作为 IBM 计算机设计团队的一员，罗切斯特在达特茅斯会议上带来了对硬件和计算机体系结构的深刻理解，为 AI 的技术发展提供了重要支持。他为符号主义 AI 的实际应用提供了硬件基础，使得 AI 研究在之后的几十年中得以快速发展。

达特茅斯会议不仅是 AI 发展的里程碑，更是奠基者们各自成就的起点。他们在日后的研究和创新中，将符号处理、逻辑推理、信息论、经济学等跨学科思想融入 AI 之中，为这门新兴学科注入了多元化的基础。这次会议标志着人工智能领域的正式诞生，掀起了未来几十年 AI 研究的浪潮，因此，1956 年也被称为“AI 元年”。

3.2.1 达特茅斯会后早期黄金期：符号主义 AI

在达特茅斯会议之后，人工智能进入了早期探索阶段，其核心概念逐步成型。研究者们围绕“机器能否像人类一样思考”这一问题展开了深入探索，人工智能从学术设想走向实际研究，并取得了一系列早期的重要成果。

1958 年，明斯基和麦卡锡在麻省理工学院建立了世界上第一个人工智能实验室——MIT AI

Lab。同年，麦卡锡发明了 **Lisp** 编程语言。**Lisp** 的灵活性和符号处理能力使其成为 AI 研究的首要编程语言之一，尤其是在自然语言处理和知识表示等领域。

20 世纪五六十年代，大多研究者都聚焦于自上而下的研究方向，**符号主义 AI (Symbolic AI)** 是这一时期的主流，即主张通过符号操作来建立人脑模型从而模拟智能。这一时期的 AI 研究主要聚焦于**符号处理**和**规则推理**，形成了一种“强 AI”乐观主义的思潮。科学家们设想，通过逻辑推理和符号处理，机器能够像人类一样解决问题，甚至达到通用智能的水平。早在 1956 年，西蒙和纽厄尔预言“10 年之内，计算机将成为国际象棋世界冠军”。1966 年，西蒙再次乐观预言“20 年内，机器能完成人能做到的工作”。

研究者们开发了早期的专家系统和逻辑推理系统，如阿伦·纽厄尔和赫伯特·西蒙等人研发的 **Logic Theorist** 和不依赖于具体领域的通用问题求解器 **General Problem Solver**，尝试模拟人类解决问题的逻辑推理过程，展示出机器进行逻辑推理的潜力。**机器定理证明**是这一时期最先取得重大突破的领域之一。1956 年，**Logic Theorist** 由阿伦·纽厄尔和赫伯特·西蒙等人在兰德公司开发，被认为是首个具有“人工智能”特征的计算机程序，**Logic Theorist** 的目标是模拟人类的逻辑推理能力，能够自动证明逻辑定理。**Logic Theorist** 可独立证明罗素和怀特海所著《数学原理》第二章的 38 条定理，1963 年能证明该章的全部 52 条定理，甚至为其中一个定理上找到了比原作者给出的证明更为简洁的证明。这一成就引起轰动，显示出计算机在某些逻辑推理任务中的潜力。

其它成果包括：

- 1958 年，华人数学家王浩在 IBM704 上仅用 5 分钟便证明了《数学原理》有关命题演算的 220 条定理。
- 1963 年，IBM 公司研制出平面几何的定理证明程序。
- 1963 年，Slagle 发表了一个符号积分程序 **SAINT**，可自动计算输入函数的积分表达式。4 年后推出的升级版 **SIN**，达到专家级水准。

这些为机器定理证明的“封闭”逻辑系统系统的成功为后续 AI 系统奠定了基础，但也暴露出符号 AI 系统明显的局限性——只能处理严格定义的逻辑问题，难以应对更复杂的、不确定的现实问题。

以手写字母识别 (如图 3.1) 为例，手写字母在形态上具有高度的变化性和不确定性。不同人书写的“A”可能形态差异很大，甚至同一个人也会因速度、情绪等不同而写出不同的“A”。如果让 **Logic Theorist** 识别手写字母“A”和“B”，它会陷入困境，因为符号主义 AI 依赖预先设定的规则进行逻辑推理，要求字母形态稳定且符合固定定义。而现实中的手写字母形态多样，难以满足这些硬性规则，因此，符号主义 AI 在这种不确定、变化多样的环境下表现不佳。

虽然这些早期 AI 系统在模拟人类逻辑推理能力上取得了成功，能够解决简单的逻辑问题，但在面对复杂多变的现实问题时，它们的表现力和适应性明显不足，难以应对更广泛的智能任务。这一局限性表明，符号主义 AI 在处理现实中的不确定性问题时仍面临巨大挑战。



图 3.1: 手写数字识别

自我学习

与此同时，AI 研究者也开始探索机器学习的可能性，机器学习领域获得不少突破。1959 年，阿瑟·塞缪尔（Arthur Samuel）研制了一款跳棋程序，能够通过自我对弈提升棋艺。1962 年，它击败美国州冠军。这款程序被认为是早期**机器学习**的范例，展示了机器通过经验不断提高性能的潜力，标志着 AI 研究从预设规则向基于学习的方向发展。1956 年，Selfridge 研制出第一个字符识别程序，开辟了模式识别这一新领域。

1974-1980 年代初：第一次“AI 寒冬”

虽然早期的符号 AI 研究取得了显著进展，但随着研究的持续推进，符号 AI 的局限性日益显现。尽管符号 AI 擅长逻辑推理，且在特定任务上表现出色，但在应对现实世界的复杂性和不确定性问题时，特别在处理非结构化数据方面，表现出了明显的不足。

1965 年，机器定理证明领域遇到了瓶颈。例如，计算机推了数十万步也无法证明“两个连续函数之和仍是连续函数”。萨缪尔的跳棋程序停留在了州冠军的水准，难以突破。更糟糕的问题出现在**机器翻译**领域，计算机在自然语言理解与翻译中表现得极其差劲。例如，翻译程序将英语句子“The spirit is willing but the flesh is weak.”（心有余而力不足）翻译成俄语，再回译成英语时，得到的句子竟变成了“The wine is good but the meet is spoiled.”（酒是好的，肉变质了）。这种笑话般的错误凸显出符号 AI 在处理语言模糊性方面的无力。

1970 年代的乐观情绪（如通用智能）推动了大量 AI 项目的启动，然而，随着这些项目未能达最初的预期，尤其是在应对现实世界的复杂性方面暴露出显著局限，加上计算资源需求高，导致了随后 1974 年开始的第一次“AI 寒冬”—投资者和政府机构对 AI 研究的资金支持大幅削减，研究热情和社会关注下降，许多 AI 项目被取消，研究活动在 1974 年至 1980 年间大幅缩减，AI 研究陷入低谷期。

尽管如此，低谷期的 AI 领域并非全无进展，反而通过知识工程和专家系统的兴起找到了新的突破口。

3.3 1980 年-1987 年：专家系统与知识工程的兴起

从 1980 年至 1987 年，AI 研究进入了一个新的阶段，以**专家系统**和**知识工程**的兴起为代表。美国计算机科学爱德华·费根鲍姆指出，传统的人工智能过于强调通用求解方法的作用，忽略了具体的领域知识。因此，他提出了基于知识的专家系统。**知识工程**是利用人工智能技术来构建专家系统的一种方法。**专家系统**是基于符号逻辑的 AI 系统，通过将专家的知识编码为计算规则，帮助机器在特定领域中进行推理和决策，模仿领域专家解决问题的过程。

3.3.1 代表性专家系统

典型的专家系统包括医学诊断系统 **MYCIN** 和化学分析系统 **DENDRAL**，它们分别在医疗和化学领域取得了显著成效。通过嵌入领域专家的知识，专家系统在复杂任务中展现出较高的决策能力，推动了知识工程成为 AI 研究的重要分支。

- **DENDRAL**: 开发始于 1965 年，由斯坦福大学的爱德华·费根鲍姆 (Edward Feigenbaum) 和约书亚·莱德伯格 (Joshua Lederberg) 带领的团队创建。**DENDRAL** 则是一种用于化学分析的系统，能够根据分子结构推断化学物质。它被认为是第一个成功的专家系统，标志着知识工程的开端。
- **MYCIN**: 开发始于 1972 年，由斯坦福大学的布鲁斯·布坎南 (Bruce Buchanan) 和爱德华·肖特利夫 (Edward Shortliffe) 领导的团队创建。**MYCIN** 是一个医学专家系统，专注于诊断血液感染并推荐抗生素。它通过一系列规则模拟专家在诊断细菌感染时的决策过程，其规则系统和推理机制为后续专家系统的发展影响深远。

虽然 **DENDRAL** 和 **MYCIN** 的开发始于 1960 年代末至 1970 年初，但它们在 1970 年代后期到 1980 年代中期得到实际应用和广泛推广，成为知识工程的核心。这些专家系统的成功验证了知识工程的可行性。各种专家系统陆续涌现，尤其在医疗、化学分析、工程设计和商业决策等特定任务中，标志着 AI 技术的一个实用转变。研究者们从这些成功中看到了基于知识的 AI 应用的巨大潜力，开始着重于知识获取、知识表示和推理机制的系统性开发。这一时期成为专家系统和知识工程在实际应用中迅速扩展的高峰期。

3.3.2 知识表示与规则推理

专家系统的成功得益于对**知识表示**和**推理机制**的深入研究。**知识表示**是指如何在计算机中存储和处理专家的领域知识，而**规则推理**则是通过符号操作来进行逻辑推理的过程。在专家系统中，领域专家的知识被转换为计算机可以处理的规则集，从而模拟专家的判断。这种规则系统让计算机能够在特定领域中像人类专家一样做出高效的决策。

3.3.3 知识工程的广泛应用

DENDRAL 和 MYCIN 的成功验证了知识工程的可行性后，推动了更广泛的行业应用。知识工程通过获取和编码人类专家的知识，为 AI 系统提供了专业化的领域知识，并形成了软件产业的一个新分支。知识工程的兴起不仅推动了专家系统的广泛应用，也促成了 AI 技术在全球范围内的合作和竞争。

受知识工程的激励，日本的第五代计算机计划、英国的阿尔维计划、西欧的尤里卡计划、美国的星计划和中国的 863 计划陆续推出，尽管这些计划的目标并不完全针对 AI，但 AI 是其重要组成部分，成为提升国家科技竞争力的一部分。

3.3.4 新兴技术：模糊逻辑与贝叶斯网络

在这一时期，AI 领域还从知识工程中衍生出了新的学科分支，如模糊逻辑和贝叶斯网络。模糊逻辑提供了一种处理灰色区域的推理方式，使 AI 能够在信息不完全的情况下也能做出决策。贝叶斯网络则通过统计方法来处理不确定性，被广泛应用于诊断、预测和决策系统中。这些方法通过处理不确定性和模糊性，有效弥补了传统符号主义 AI 在处理复杂现实问题上的局限。

3.3.5 第二次“AI 寒冬”的反思与转型

20 世纪 80 年代中期，专家系统和知识工程在医疗诊断、工程设计、化学分析等狭窄领域表现出色，但伴着随大量实践的累积，其局限性也逐渐显现。知识获取成为了最大的瓶颈：专家系统高度依赖领域专家的知识输入和精确的规则，知识获取和维护成本高昂，系统缺乏灵活性和自适应性，难以应对多样和动态的现实需求。此外，硬件技术和计算资源的限制也不足以支撑更大规模的 AI 系统发展。

随着专家系统的商业化受阻，AI 进入了第二次寒冬。1987 年至 1993 年之间，投资者和政府逐渐减少了对 AI 的资金支持，许多原本大规模投资的 AI 项目被迫中止。日本的“第五代计算机计划”因未能在智能计算取得预期成果而停滞，其他国家的大型 AI 项目也相继缩减，导全球范围内的 AI 研究热潮急速降温。在这次寒冬期内，AI 研究的资金大幅削减，许多研究人员转向其他领域。

第二次的 AI 寒冬虽然带来了低谷，却促使 AI 领域反思技术路径，重新审视符号主义 AI 的局限性。研究者和行业逐渐认识到，仅凭符号规则和知识编码不足以实现真正的智能。

知识工程和专家系统的应用展现了 AI 技术在特定领域的应用潜力，推动了 AI 从学术研究向实用化的转变。尽管专家系统存在明显局限，但这些实践经验和技术积累为之后的机器学习、神经网络等数据驱动方向的复兴提供了宝贵启示，推动 AI 研究进入了新的发展阶段。

寒冬的沉寂期反而带来了新的视角，促使研究者在方法和技术上寻求突破和创新。这些反思和积累成为推动 AI 转型的重要动力，为现代 AI 的崛起，尤其是后续深度学习的发展，奠定了坚实的基础。

3.4 人工智能的分化

1987 年以后，人工智能分化为六大学科：

- 计算机视觉 (模式识别，图像处理等)
- 自然语言理解与交流 (语音识别、合成、对话等)
- 认知与推理 (各种物理和社会常识等)
- 机器学习 (各种统计建模、分析工具和计算方法)
- 机器人学 (机械、控制、设计、运动规划、任务规划等)
- 博弈与伦理 (多代理人 agents 的交互、对抗与合作、机器人与社会融合等)




图 3.2: “1987 年后人工智能的分化”




图 3.3: “1987 年后人工智能的分化”



图 3.4: “1987 年后人工智能的分化”

可以看出来，人工智能在全面模拟人的智能，不仅是大脑智能，还包括眼睛智能，耳朵智能，手智能，口智能。

3.5 1990-2010 年代：联结主义和机器学习的兴起

20 世纪 80 年代，**机器学习**由原本的边缘分支成为关注的焦点。研究者发现，如果采用完全不同的世界观，即让知识通过自下而上的方式涌现，而不是让专家们自上而下地设计出来，机器学习的问题其实可以得到很好解决。

自下而上的涌现智能的方案很早就提出过，但没有引起注意：一批人：可通过模拟大脑结构（神经网络）来实现（联结学派）另一批人：可从那些简单生物体与环境互动的模式中寻找答案（行为学派）20 世纪 80-90 年代，传统的人工智能符号学派、联结学派、行为学派三足鼎立。

早期的学习算法开始在符号 AI 的基础上发展，成为 AI 从符号主义向数据驱动方法转型的基础。

尽管 1987-1993 年期间的 AI“寒冬”导致研究资金减少，学术界对神经网络等方向的探索仍在继续。特别是在 1990 年代后期，联结主义和机器学习的复兴为 AI 注入了新的活力。研究者们开始着力于数据驱动的学习算法，这些研究逐步成为现代 AI，尤其是深度学习的起点。

进入 90 年代后，AI 研究逐渐从符号主义（基于符号的 AI）转向数据驱动的机器学习（**基于数据的 AI**）。在计算机能力提升和数据量爆发增长的推动下，机器学习逐渐成为 AI 研究的主流。通过统计学习和数据驱动的模式识别，A 系统能够大数据进行训练，显著提升识别和决策的准确性。

在这一阶段，**神经网络**的复兴尤为关键。虽然早期的神经网络（如感知机）在 1960 年代就已提出，但因计算能力受限，没有达到理想效果。1990 年代后，神经网络在计算能力提升的推动下重新焕发生机，显示出巨大潜力。**1997 年，IBM 的“深蓝”战胜国际象棋冠军卡斯帕罗夫**，标志着 AI 在某些特定任务上的重大突破，成为该领域的重要里程碑。

到了 2010 年代，**深度学习**技术的突破推动了 AI 的飞速发展。基于**卷积神经网络（CNN）**和**递归神经网络（RNN）**等深度学习模型的广泛应用，AI 在图像识别、语音识别、自然语言处理等多个领域取得了显著进展。2012 年，**AlexNet** 在 ImageNet 竞赛获胜，奠定了深度学习在图像识别领域的领先地位。2016 年，谷歌的 **AlphaGo** 战胜围棋世界冠军李世石，进一步展示了深度学习和强化学习在复杂问题处理上的强大能力，为 AI 新时代拉开了序幕。

3.5.1 2020 年代：大语言模型（LLM）与生成式人工智能（AIGC）的崛起

进入 2020 年代，人工智能在语言处理和内容生成领域迎来了崭新的突破。**大语言模型（LLM）**和**AI 生成内容（AIGC）**技术的兴起，标志着 AI 在自然语言理解、图像生成等跨模态任务上的重大进展。这一阶段的 AI 系统不仅限于执行特定任务，还展示出强大的语言生成和创意能力，推动了 AI 在内容生成、对话系统、设计创作等多元领域的应用。

大语言模型（LLM）通过海量文本数据的训练和数十亿参数的深度优化，使得 AI 具备了对自然语言的复杂理解和生成能力。**GPT 系列、BERT**等模型的出现，让 AI 能够生成具有上下文连贯性和逻辑性的文本内容，实现更自然、更智能的人机互动。这些模型不仅能处理简

单的文本任务，还能在医学、法律、科技等领域为人类提供辅助性建议。LLM 的创新，尤其在教育、客服和专业问答等领域的广泛应用，使得 AI 能够更深入地理解和模拟人类语言的多样性和细腻性，逐步拓宽了人工智能的应用范围。

与此同时，**AI 生成内容 (AIGC)** 技术使 AI 从信息处理者发展为创意生成者。AIGC 让 AI 不仅可以理解和操作文本，还能够在图像、视频、音乐等领域生成内容，为人类的创意需求提供助力。例如，基于扩散模型和生成对抗网络 (GANs) 的图像生成器能够创作出栩栩如生的图像，甚至具备了艺术创作的初步能力。AIGC 技术使 AI 在广告、娱乐、设计和教育等多个领域得到了广泛应用，不仅缩短了内容创作的时间，还为人类的创作过程带来了新鲜的灵感和可能性。

LLM 和 AIGC 的兴起不仅丰富了 AI 的应用场景，更重要的是，它让 AI 在情感识别、语言生成和创意表达方面具备了更强的适应性，使得 AI 从单纯的“工具”逐渐演变为可以合作、创新的“伙伴”。AI 能够生成具有人性化特质的内容，从而在客服、医疗和心理咨询等对人类情感需求更高的领域中提供更加贴近人类需求的服务。

2020 年代的 LLM 和 AIGC 的进展，标志着 AI 从知识服务者走向创意合作者的转变。这一阶段的 AI 不仅展示了生成文本、图像等复杂内容的能力，也在理解人类表达和模拟创意思维上迈出了一大步。LLM 和 AIGC 带来了前所未有的机遇，将继续推动 AI 技术在更多领域的应用与普及，引领人类进入一个充满创新和智慧的新时代。

3.6 人工智能主要学派

人工智能从诞生至今，经历了一次又一次的繁荣与低谷，其发展历程大体上可以分为“推理期”，“知识期”和“学习期”。[0]

在人工智能的研究中，不同学派以各自的方法和理论基础探索智能的本质。这些学派的差异体现在如何定义智能、模拟智能的方法以及应用的领域中。三大主要学派包括**符号主义学派**、**联结主义学派**和**行为主义学派**，它们分别代表了对智能问题的三种主要思维方式。

3.6.1 符号主义学派 (Symbolicism)

符号主义学派：知识驱动的推理与表现

符号主义学派，又称**逻辑主义**或**符号处理学派**，是 AI 发展的早期重要分支之一。符号主义学派的理论基础源于 20 世纪中期的认知科学和数理逻辑。符号主义学派主张，人类的知识和认知可以通过符号加以形式化，且问题解决可以通过符号操作（如逻辑推理）完成。因此，符号主义学派主要专注于建立规则和逻辑系统，尝试通过符号和规则来模拟人类的高级思维过程，包括推理、规划和知识表示。

符号主义学派基于对问题的“高阶”解释，核心思想是智能行为能够通过逻辑规则和知识库来模拟，依赖于启发式搜索和基于规则的推理系统，试图用知识与经验的积累来填补信息

空白。这种“If-then”式的推理方式使符号主义在规则明确的任务中表现出色，被广泛应用于医疗诊断、金融分析等领域的专家系统。

符号主义学派的成果与应用

符号主义学派的代表性成果包括早期的专家系统（如 MYCIN 和 DENDRAL）、逻辑定理证明系统（如 Logic Theorist）、推理系统和象征性规划系统。

- **人机对弈：“深蓝”战胜卡斯帕罗夫** 1997 年 5 月 11 日，IBM 的超级计算机“深蓝”在国际象棋比赛中战胜了国际象棋大师卡斯帕罗夫，标志着符号主义 AI 的一次里程碑事件。深蓝经过四位国际象棋特级大师的训练，储存了 100 年来几乎所有国际特级大师的开局和残局下法，利用启发式搜索可在 1 秒钟内计算两亿步棋。这种超强搜索能力，使得“深蓝”通过规则匹配和快速推理“险胜”人类选手，显示了符号主义在明确规则系统中的强大计算能力。
- **知识问答：Watson 战胜人类选手** 2011 年 2 月 14-16 日，在《危险》问答比赛中，IBM 的超级计算机 Watson 战胜人类选手。Watson 是个自然语言处理高手。它能够快速理解主持人的提问，并调用广泛的知识库回答问题。它的知识涵盖时事、历史、文学、科学、艺术、流行文化、体育、地理、文字游戏等多个领域，甚至理解语言的隐含意思，比如字谜和双关语，甚至还装满诸如莎士比亚戏剧的独白。Watson 充分体现了符号主义 AI 在自然语言理解和知识问答中的突破性进展。
- **医疗应用：Watson Health** IBM Watson 还被应用于医疗领域，基于大量医学数据和患者数据，为药物研发和个性化健康管理提供支持。例如，在癌症免疫治疗方面，Watson 从数百万篇医学论文的 2500 万篇摘要、400 万条病人数据以及 1861 年以来的药物专利中提取信息，为个性化治疗提供方案。此外，在糖尿病管理上，Watson 能够对来自 1 万名匿名患者的电子健康记录、医保数据和其他公共数据进行实时分析和预测，提前 3-4 小时预测血糖波动，预测准确率达 75-86%，帮助患者有效管理健康。

符号主义 AI 的优势与局限

符号主义具有以下优势：

1. **可解释性**：符号主义的推理过程与人类的思维方式基本一致，因而具有很强的可解释性，使人们能够理解和追踪系统的推理过程。
2. **鲁棒性强**：符号规则系统在处理结构化、规则明确的问题时表现出色，具有较高的稳定性，尤其适用于特定领域内的任务。
3. **逻辑推理能力**：符号主义系统能够执行复杂的逻辑推理，适用于处理涉及高级认知的任务，如规划和知识表示等。

20 世纪 80 年代后，符号主义学派的发展逐渐减缓，主要原因在于其依赖的“演绎逻辑和语义描述”以及或“形式化方法”不可能为所有的对象建立模型。符号主义系统需要对问题抽象出一个精确数学意义上的解析式数学模型，通过构建理想的数学模型和逻辑规则来模拟智能

行为。一旦模型建立，计算任务与能力就被唯一地确定。确定的算法无法表示现实世界问题所固有的测不准性和不完备性：世界是动态的、复杂的，无法用一个模型来表达。此外，图灵意义下的可计算问题都是可递归的，但可递归并不是解决问题的唯一途径。虽然符号处理可以应对某些递归性问题，但对于智能的全面理解和表现，符号主义学派的框架显然不够完整。

符号主义学派的主要局限性可归纳如下：

1. **知识依赖性**：符号主义系统依赖于大量准确、结构化的知识和规则，但人类知识难以全面准确地形式化，这种依赖性限制了系统在现实问题中的表现。
2. **缺乏灵活性**：符号主义系统只能应对预先定义的问题，难以适应动态、复杂和不确定的环境。这种限制使其在处理非结构化问题时表现不佳。
3. **条件与分枝问题**：在复杂的动态系统中，符号主义面临两大瓶颈：**条件问题 (Qualification Problem)**，即难以穷尽智能行为的所有先决条件；**分枝问题 (Ramification Problem)**，即无法枚举智能行为的所有隐含结果。符号主义系统因此难以应对复杂环境中的不确定性和隐含影响。
4. **应用领域狭窄**：尽管符号主义模型在逻辑推理和规则明确的任务中表现出色，但在感知、语言理解等模糊和动态性较强的任务中，由于对人工定义的规则和知识库的依赖，其适应性较差。

符号主义学派在 AI 发展的早期取得了显著成就，为人类理解和模拟智能行为提供了框架和方法。然而，随着应用需求的增加和技术环境的变化，符号主义的局限性逐渐显现，学界认识到，为应对复杂的动态环境，还需结合其他学派的思维方式。符号主义的贡献在于奠定了知识驱动的 AI 基础，展示了通过逻辑推理模拟人类智能的可能性，为之后联结主义与行为主义的发展开辟了道路。

3.6.2 联结学派/连接学派 (Connectionism)：从神经网络到深度学习

20 世纪 80 年代之后，随着计算能力的提升和神经科学的深入研究，人工智能的重心逐渐转向**联结主义学派**，也称**人工神经网络学派**。联结主义学派认为智能的产生并非依赖于符号和逻辑规则，而是源于大脑中成千上万个神经元的联结和计算。正如其支持者所言，“高级的智能行为是从大量神经网络的连接中自发出现的”。

联结主义学派主张通过模仿大脑神经网络的工作原理来实现智能。大脑由一万亿个神经元细胞通过错综复杂的相互连接形成了复杂的认知和决策能力。特别关注如何通过数据训练来自动调整网络参数，使系统能够在数据中自发学习和优化。其核心思路是模仿神经元的工作方式，构建多层网络结构，调整神经元之间的连接权重，使得系统逐渐具备特定的识别和判断能力。例如，神经网络的训练过程就是通过不断调整权重，逐步优化输出结果的过程。不同于符号主义学派的知识驱动，联结主义的这一训练机制强调**数据驱动的学习**，即依靠大量的数据输入，使系统在学习自动调整网络参数，以形成稳定的模式识别和分类能力。

联结主义学派的重要进展包括从早期的**感知机模型**到更复杂的**卷积神经网络 (CNN)**、**递归神经网络 (RNN)** 等模型，最终发展到现代**深度学习**模型。这些模型推动了 AI 在图像识别、

自然语言处理、生成式 AI 等领域的广泛应用，成为现代 AI 的重要工具。这一学派的成就在近年来引发了广泛关注和思考。

尽管联结主义学派推动了人工智能的飞跃式进展，但其局限性也不容忽视。首先，联结主义模型对大量数据的依赖较高，若数据不足或质量不佳，模型的表现可能会大幅下降。其次，随着神经网络层次增加，其计算复杂度也随之提高，导致训练和运行成本显著增加。其次，神经网络通常被视为“黑箱”，即难以解释其内部决策依据。这一“黑箱”问题主要源于以下几点：

- **多层非线性结构**：神经网络的层层变换过程使其难以还原具体决策路径，庞大的参数量也导致分析“哪些特征在决策中起了关键作用”变得困难。
- **局部特征依赖性**：模型往往基于局部特征组合来进行决策，而缺乏对整体决策过程的全局视角。例如，在图像分类中，模型可能依赖某些局部图案作出决策，使得预测依据难以解读。
- **数据驱动缺乏推理链**：联结主义模型倾向于基于统计特征进行预测，缺乏类似符号主义系统的逻辑推理链，不便于展示推理过程。

尽管存在可解释性方面的挑战，联结主义的理论和技術构建了现代神经网络的基石，极大地推动了现代 AI 的发展。在下一章中，我们将进一步探讨联结主义的核心思想、模型结构及其应用实践。

3.6.3 行为主义学派 (Actionism)

行为主义学派源于 20 世纪中叶，其理论基础来自行为主义心理学和生物学对动物行为的研究，认为智能体可以通过与环境的交互获得经验，从而逐步学习最优的行为策略。行为主义学派主张智能的形成基于行动与环境反馈的相互作用，智能体在反复试错中调整自身策略，优化行为序列，以实现既定目标。

行为主义学派的早期探索主要集中于模仿昆虫等低等生物的行为模式。简单生物无需复杂的大脑结构，也不会按照传统的方式进行复杂的知识表示和推理来执行智能行为，仅通过直接的环境交互就能实现适应性行为。例如，昆虫能够灵活移动、快速反应、躲避捕食者的攻击；小小的蚂蚁所组成的庞大蚁群展现出高度写作的群体智能。这些生物体的行为为行为主义学派提供了灵感。随着计算能力的提升，行为主义方法逐渐被应用于机器人控制、游戏策略等领域，特别适合在高不确定性和动态环境中构建智能体行为。

行为主义学派的一个典型实现是**强化学习**（Reinforcement Learning, RL）算法，尤其是 Q 学习和深度强化学习（DRL）。这些方法通过奖励机制引导智能体在环境中逐步优化策略。例如，AlphaGo 挑战围棋世界冠军的成功便是强化学习和深度学习结合的成果。AlphaGo 在与环境的持续交互中，逐步学习复杂博弈中的最佳策略，展示了人工智能在自我优化和复杂决策方面的潜力。

MIT 机器人专家 Rodney Brooks 设计的模仿昆虫的机器人正是这一学派的经典案例。通过四肢和关节的协调，这些机器人能够在复杂地形中灵活爬行，巧妙避开障碍物，无需复杂

的大脑控制。类似地，波士顿动力公司（Boston Dynamics）开发的四足机器人在不同地形和环境中表现出高度的适应性和鲁棒性。这些机器人的行为不依赖于复杂的认知模型或高级符号推理，而主要依靠局部传感器数据、反馈控制和运动算法来实现稳定的运动与环境适应，在一定程度上可以被称为“无脑机器人设计”。这种设计理念类似于昆虫等简单生物的直接感知-行动环的反应式行为，展示了行为主义学派在机器人开发和运动控制中的实际价值。

尽管行为主义学派取得了诸多进展，仍面临明显的局限性：

1. **高维度和复杂环境下的学习效率低**：行为主义学派在高维、复杂环境中往往需要大量交互才能收敛到合理策略，试错成本较高。
2. **奖励依赖**：行为主义模型依赖奖励反馈引导学习，当目标明确时效果良好，但在奖励稀疏或模糊的情况下，学习效果可能较差。
3. **难以实现高阶智能的自然涌现**：尽管行为学派在模仿昆虫和群体智能方面取得了一定成果，但对于实现更高层次智能行为的涌现机制，行为学派难以给出明确解释和实现路径，因此在复杂任务的应用中受到限制。

尽管行为学派在模拟高级智能方面仍有不足，其在机器人技术、自动驾驶等实际应用中展示了极强的适应性和应用潜力。

3.6.4 三大学派的比较

3.6.5 三大学派对比总结

人工智能的发展经历了显著的转型：从依赖人工规则的符号主义学派，到借助经验和反馈的联结主义与行为主义学派，AI的核心方法从“推理期”和“知识期”逐渐过渡到“学习期”。这种变化反映了AI在应对复杂问题时，从自上而下的规则构建转向自下而上的经验学习。符号主义学派强调人工设计规则和知识库来解决问题，而联结主义学派和行为主义学派则更关注如何通过数据驱动的方式从经验中学习知识。

人工智能发展过程中，**符号主义学派**、**联结主义学派**和**行为主义学派**分别从不同角度探索智能的本质。每一学派都有其独特的理论基础、代表方法和应用领域，也各有特色。符号学派主要关注智能的逻辑和推理过程，模拟智能软件的工作方式；联结学派则通过模仿大脑神经元结构，试图在“硬件”层面上还原智能；而行为学派则基于简单生物体与环境互动的模式，从动态环境中找寻适应性智能。

1. **符号主义学派 (传统人工智能)**：以逻辑和符号操作为基础，符号主义学派侧重于通过规则和知识库模拟人类的逻辑推理能力。其典型方法包括基于规则的专家系统，主要应用于知识明确、规则清晰的领域，如医疗诊断和金融分析。符号主义的优势在于其强大的可解释性，推理过程清晰可见，便于理解。然而，符号主义在处理复杂、不确定的环境时表现有限，因为它依赖于结构化的知识库和固定规则，难以应对环境的动态变化。符号主义的知识设计是**自上而下**的，主要通过逻辑设计和专家知识进行知识建模，但人类的知识和经验往往难以精确描述，并且复杂的推理过程增加了计算难度。
2. **联结主义学派**：借鉴神经科学，联结主义学派通过构建人工神经网络来模拟大脑的学习

和感知机制。其代表模型包括卷积神经网络（CNN）、递归神经网络（RNN）等，强调通过数据驱动的学习，在大规模数据中自动调整参数，广泛应用于图像识别、语音识别和自然语言处理等领域。联结主义学派的优点在于其强大的数据处理能力，可以自适应复杂数据环境；联结主义的知识形成是**自下而上**的，通过模拟神经网络结构涌现知识。然而，其“黑箱”性质导致可解释性不足，且训练过程依赖大量数据和计算资源。

3. **行为主义学派**：基于行为主义心理学和生物学对动物行为的研究，行为主义学派强调通过智能体与环境的交互来优化行为策略，其典型实现是强化学习。行为主义方法更适合动态和不确定环境中的智能体训练，例如自动驾驶、机器人控制和游戏对抗。行为主义的特点是其试错式学习机制，使得智能体在持续反馈中逐步优化策略。然而，其高维度环境中的学习效率较低，且高度依赖明确的奖励信号，难以实现对高阶智能的自然涌现。

学派间的比较：

- **理论基础**：符号主义学派依赖符号和逻辑推理，经由专家自上而下基于逻辑来构建知识系统；联结主义学派模仿神经网络的结构，自下而上实现知识的涌现；行为主义学派则从智能体的行动和环境反馈中寻找最优策略，构建出适应性的智能。三者代表了不同的智能观：符号主义偏向于逻辑和推理，联结主义倾向于模式识别和学习，行为主义重视试错与适应。
- **适用领域**：符号主义适用于规则明确、知识体系完善的场景；联结主义适合海量数据驱动的模式识别任务；行为主义则在动态、非结构化的环境中表现突出，如自动驾驶和机器人控制。
- **** 优劣势 ****：符号主义具有良好的可解释性，但灵活性有限；联结主义具备强大的感知与模式识别能力，但对数据依赖性高，且可解释性不足；行为主义适应性强，但在高维度和奖励稀疏的环境下学习效率较低，难以实现复杂智能的涌现。

三大学派的各自特长和局限使得现代人工智能研究趋向于融合不同方法。例如，将符号逻辑引入神经网络以提升可解释性，或将强化学习与深度学习结合以应对复杂策略任务。通过综合符号推理、神经网络和交互学习的优势，现代 AI 逐渐朝着多模态、多层次的智能系统发展，在更多领域实现了实际应用。

表 3.1: 三大学派的比较

学派	主要观点	优势	局限性
符号主义	符号和规则模拟人类智能	擅长结构化问题和逻辑推理	难以处理非结构化和动态环境
联结主义	神经网络模拟大脑联结	数据驱动，自动学习	需要大量数据，解释性不足
行为主义	交互和反馈强化行为学习	适用于策略优化和动态决策	需要大量交互，目标不明确时效率低

三大学派的方法论

表 3.2: 人工智能主要学派

符号主义学派	联结主义学派	行为主义学派
认知即计算 - 起源于 2300 年前，更关注哲学、逻辑学和心理学，将学习视为逆向演绎 - 使用符号、规则和逻辑来表征知识和进行逻辑推理 常用算法：规则和决策树	认知即网络 - 起源于上世纪 40 年代，专注物理学和神经科学 - 使用概率矩阵和加权神经元来动态地识别、分类、归纳 常用算法：深度学习神经网络、反向传播	感知-行动 - 起源于上世纪 40 年代 - 在遗传学、进化生物学、控制论的基础上，生成变化，为特定目标获取其中最优解 常用算法：遗传算法、蚁群算法、强化学习




图 3.5: 智能金字塔

3.7 小结：危机与机遇中的 AI 发展之旅

纵观人工智能的成长历程，它既是一场理解智能的探索，也是一场应对挑战的征途。AI 的发展如同蜿蜒的河流，经历过激荡的浪潮，也度过了平静的深潭。在数次寒冬的洗礼后，AI 不断焕发新的生机，展示出危机中的无限机遇。

每一次技术突破和危机，都塑造了 AI 的未来方向。

1. 达特茅斯会议后的开创期（1956 年 - 1970 年代初）：1956 年的达特茅斯会议首次提出“人工智能”概念，开启了 AI 的黄金时代。研究者尝试用逻辑推理和符号操作来模仿智能，开发了 Logic Theorist 和 General Problem Solver 等符号主义 AI 的早期成果，虽为初探，却为智能探索奠定了基础。

2. 第一次 AI 寒冬（1974 年 - 1980 年代初）：由于符号主义 AI 无法解决现实问题的模糊性和不确定性，以及高昂的资源消耗，AI 研究在此期间陷入低谷，资金支持大幅削减。这场寒冬也促使研究者反思符号主义 AI 的局限性，重新思考智能的实现路径，为下一阶段的知识工程发展铺平了道路。

3. 专家系统和知识工程的兴起（1970 年代末 - 1980 年代中期）：第一次 AI 寒冬后，DENDRAL 和 MYCIN 等专家系统展示了 AI 在医疗、化学分析等领域的实际应用潜力，使 AI 逐渐从实验室走向商业应用，知识工程兴起。但由于专家系统过度依赖手动编码的知识和固定规则，逐渐暴露出适应性不足的局限。

4. 第二次 AI 寒冬（1980 年代末 - 1990 年代初）：专家系统的高昂维护成本和对环境的适应性限制使得全球的 AI 项目纷纷缩减以至于停滞，AI 再次进入低谷。但这场寒冬促使 AI 领域认识到，仅靠符号规则难以实现真正智能，推动了方法上的转型。

5. 联结主义和机器学习的崛起（1990 年代 - 2010 年左右）：以神经网络和数据驱动方法为基础，联结主义和机器学习的蓬勃发展，标志着 AI 从符号主义迈向数据驱动的新时代。机器学习逐渐成为主流方法，通过模式识别和大数据训练，使 AI 具备了在各种任务中自我改进的能力。1997 年，IBM 的“深蓝”战胜卡斯帕罗夫，这一里程碑事件展现了机器学习在复杂决策中的潜力，也宣告了数据驱动 AI 的初步胜利。

6. 深度学习的快速发展（2010 年代）：在计算能力提升和数据量增加的支持下，深度学习技术在图像识别、语音识别、自然语言处理等领域取得突破性进展，使 AI 再度迎来黄金期。2016 年，AlphaGo 战胜李世石，标志 AI 在复杂推理问题上的新高度。寒冬中的积累与反思，转化为深度学习这一数据驱动方法的强大推动力，成就了 AI 新时代的辉煌。

7. 大语言模型（LLM）与 AIGC 的崛起（2020 年代）：近年来，基于数十亿参数和海量数据训练的大规模语言模型（如 GPT 系列和 BERT）与 AI 生成内容（AIGC）技术迅速崛起。LLM 具备深度语言理解和生成能力，能进行逻辑连贯的文本生成，开创了更加自然的智能人机互动。AIGC 进一步拓展了 AI 的创作边界，使 AI 从信息回答者进化为创意合作伙伴，广泛应用于创意内容生成、广告、教育和娱乐领域。

在危机与机遇交织的 AI 发展史中，每一次危机都意味着新的机遇。两次寒冬带来低谷，但也促使 AI 领域在反思中寻找新方向，逐渐摆脱了对符号逻辑的单一依赖，向数据驱动和自

适应学习的方向迈进。

知识工程为 AI 的应用打开了大门，而机器学习和深度学习的崛起则奠定了现代 AI 的基础。

今天，AI 的视野已从实验室扩展到生活的方方面面，从模仿人类思维到自主学习，从专注特定领域到应对复杂决策。AI 的历程是一部充满智慧与勇气的进化史，展现了智能的无限潜力。我们期待 AI 继续向前，为人类揭示智能的更多可能性，并引领我们在未知中发现更广阔的世界。

参考文献

- [0] “A Logical Calculus of Ideas Immanent in Nervous Activity”. In: *Bulletin of Mathematical Biophysics* 5 (1943), pp. 127–147.
- [0] Yoshua Bengio. “Practical recommendations for gradient-based training of deep architectures”. In: *Neural networks: Tricks of the trade: Second edition*. Springer, 2012, pp. 437–478.
- [0] George Cybenko. “Approximation by superpositions of a sigmoidal function”. In: *Mathematics of control, signals and systems* 2.4 (1989), pp. 303–314.
- [0] Kunihiro Fukushima and Sei Miyake. “Neocognitron: A new algorithm for pattern recognition tolerant of deformations and shifts in position”. In: *Pattern recognition* 15.6 (1982), pp. 455–469.
- [0] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. “Multilayer feedforward networks are universal approximators”. In: *Neural Networks* 2.5 (1989), pp. 359–366.
- [0] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. “Universal approximation of an unknown mapping and its derivatives using multilayer feedforward networks”. In: *Neural networks* 3.5 (1990), pp. 551–560.
- [0] David H Hubel and Torsten N Wiesel. “Receptive fields and functional architecture of monkey striate cortex”. In: *The Journal of physiology* 195.1 (1968), pp. 215–243.
- [0] Han Jiawei, Kamber Micheline, and Pei Jian. *Data Mining: Concepts and Techniques*. -3rd. Morgan Kaufmann, 2011.
- [0] Fukushima K and Miyake S. “Neocognitron: A self-organizing neural network model for a mechanism of visual pattern recognition”. In: *Competition and cooperation in neural nets*. Springer, Berlin, Heidelberg, 1982, pp. 267–285.
- [0] Diederik P Kingma and Jimmy Ba. “Adam: A method for stochastic optimization”. In: *arXiv preprint arXiv:1412.6980* (2014).
- [0] Yann Le Cun, Boser Brian, and et al. Denker John S. “Handwritten digit recognition with a back-propagation network”. In: *Advances in neural information processing systems*. 1990, pp. 396–404.
- [0] Yann Le Cun et al. “Handwritten digit recognition: Applications of neural net chips and automatic learning”. In: *Neurocomputing: Algorithms, Architectures and Applications*. Springer. 1990, pp. 303–318.
- [0] Yann LeCun et al. “Backpropagation applied to handwritten zip code recognition”. In: *Neural computation* 1.4 (1989), pp. 541–551.

- [0] Yann LeCun et al. “Gradient-based learning applied to document recognition”. In: *Proceedings of the IEEE* 86.11 (1998), pp. 2278–2324.
- [0] Minsky Marvin and A Papert Seymour. “Perceptrons”. In: *Cambridge, MA: MIT Press* 6.318-362 (1969), p. 7.
- [0] Warren S McCulloch and Walter Pitts. “A logical calculus of the ideas immanent in nervous activity”. In: *The bulletin of mathematical biophysics* 5 (1943), pp. 115–133.
- [0] Tom Mitchell. *Machine Learning*. McGraw-Hill Education, 1997.
- [0] Michael Nielsen. *Neural Networks and Deep Learning*. Accessed: 2025-03-03. 2015. URL: <http://neuralnetworksanddeeplearning.com/>.
- [0] Hastie T, Tibshirani R, and Friedman J. 统计学习基础 (*The Elements of Statistical Learning*). 北京: 世界图书出版公司, 2015.
- [0] Alan Turing. *Computing Machinery and Intelligence*. Oxford, 1950.
- [0] Vladimir Naumovich Vapnik. 统计学习理论的本质. 清华大学华夏出版社, 2000.
- [0] Ashish Vaswani et al. “Attention is all you need”. In: *Advances in neural information processing systems* 30 (2017).
- [0] 于剑. 机器学习—从公理到算法. 北京: 清华大学出版社, 2017.
- [0] [意] 翁贝托·博塔兹尼. 余婷婷译. 尖叫的数学—令人惊叹的数学之美. 湖南科学技术出版社, 2021.
- [0] 周志华. 机器学习. 清华大学出版社, 2016.
- [0] Vladimir N. Vapnik. 张学工译. 统计学习理论的本质. 北京: 清华大学出版社, 2000.
- [0] 张玉宏. 深度学习之美—AI 时代的数据处理与最佳实践. 电子工业出版社, 2018.
- [0] 张玉宏. 深度学习之美: AI 时代的数据处理与最佳实践. 电子工业出版社, 2018.
- [0] Tom Mitchell. 曾华军等译. 机器学习. 北京: 机械工业出版社, 2002.
- [0] 王珏, 周志华, 周傲英. 机器学习及其应用. Vol. 4. 清华大学出版社有限公司, 2006.

致谢

写作是一项孤独的事业。形单影只，与键盘为伴，上一秒文思泉涌，下一秒却自我怀疑。但从某些方面来说，作家这一职业实质上具有社会性。每位作者都可以反思哪些人激发了他们的创作灵感，并深深感谢那些深刻影响了他们创作的作家、思想家、研究者，以及各种不同的思想。

无论他们是否知道，下列人士都给予了我特别的启发与帮助，谨致谢忱：

我们无比感谢本书的中英文版稿件贡献者和论坛用户们。他们帮助增添或改进了书中内容并提供了有价值的反馈。特别地，我们要感谢每一位为这本中文版开源书提交内容改动的贡献者们。这些贡献者的 **GitHub** 用户名或姓名是（排名不分先后）：..... 谢谢你们为每一位读者改进这本开源书。

本书的初稿在中国科学技术大学、上海财经大学的“深度学习”课程以及浙江大学的“物联网与信息处理”课程和上海交通大学的“面向视觉识别的卷积神经网络”课程中被用于教学。我们在此感谢这些课程的师生，特别是连德富教授、王智教授和罗家佳教授，感谢他们对改进本书提供的宝贵意见。

此外，我们感谢 **Amazon Web Services**，特别是 **Swami Sivasubramanian**、**Raju Gulabani**、**Charlie Bell** 和 **Andrew Jassy** 在我们撰写本书时给予的慷慨支持。如果没有可用的时间、资源以及来自同事们的讨论和鼓励，就没有这本书的项目。我们还要感谢 **Apache MXNet** 团队实现了很多本书所使用的特性。另外，经过同事们的校勘，本书的质量得到了极大的提升。在此我们一一列出章节和校勘人，以表示我们由衷的感谢：引言的校勘人为金颢，预备知识的校勘人为吴俊，深度学习基础的校勘人为张航、王晨光、林海滨，深度学习计算的校勘人为查晟，卷积神经网络的校勘人为张帜、何通，循环神经网络的校勘人为查晟，优化算法的校勘人为郑帅，计算性能的校勘人为郑达、吴俊，计算机视觉的校勘人为解浚源、张帜、何通、张航，自然语言处理的校勘人为王晨光，附录的校勘人为金颢。

感谢将门创投，特别是王慧、高欣欣、常铭珊和白玉为本书的两位中国作者在讲授“动手学深度学习”系列课程时所提供的平台。感谢所有参与这一系列课程的数千名同学们。感谢 **Amazon Web Services** 中国团队的同事们，特别是费良宏和王晨对作者的支持与鼓励。感谢本书论坛的 3 位版主：王鑫、夏鲁豫和杨培文。他们牺牲了自己宝贵的休息时间来回大家的提问。感谢人民邮电出版社的杨海玲编辑为我们在本书的出版过程中所提供的各种帮助。

感谢中英文草稿的数百位撰稿人。他们帮助改进了内容并提供了宝贵的反馈。感谢 **Anirudh Dagar** 和唐源将部分较早版本的 **MXNet** 实现分别改编为 **PyTorch** 和 **TensorFlow** 实现。感谢百度团队将较新的 **PyTorch** 实现改编为 **PaddlePaddle** 实现。感谢张帅将更新的 **LaTeX** 样式集成进 **PDF** 文件的编译。

特别地，我们要感谢这份中文稿的每一位撰稿人，是他们的无私奉献让这本书变得更好。他们的 **GitHub ID** 或姓名是（没有特定顺序）：

我们感谢 **Amazon Web Services**，特别是 **Swami Sivasubramanian**、**Peter DeSantis**、**Adam**

Selipsky 和 Andrew Jassy 对撰写本书的慷慨支持。如果没有可用的时间、资源、与同事的讨论和不断的鼓励，这本书就不会出版。

最后，我们要感谢我们的家人。谢谢你们一直陪伴着我们。

表 3: 术语对照表

中文	英文	定义 (≤ 20 字)	首次出现
泛化	generalization	在新样本上保持性能	第 7 章
归纳偏好	inductive bias	学习算法内在偏向	第 7 章
对抗样本	adversarial example	微扰使模型误判的输入	第 10 章
表示学习	representation learning	从数据自动提取特征	第 8 章
因果图	causal graph	变量因果关系的有向图	第 12 章

表 4: 通用符号约定

符号	含义	域/形状/单位	默认约定	首次出现
$\mathbf{x}$	输入特征向量	$\mathbb{R}^d$	列向量, 粗体表 向量	第 7 章
y	监督标签	$\{0, 1\}$ 或 $\mathbb{R}$	分 类/回 归 上 下 文 限 定	第 7 章
$\hat{y}$	模型预测	同 y	argmax 或 回 归 输 出	第 7 章
$\mathbf{W}$	权重矩阵	$\mathbb{R}^{n \times d}$	行 对 应 单 元, 列 对 应 特 征	第 7 章
b	偏置	$\mathbb{R}$	标 量	第 7 章
$\mathcal{L}$	损失函数	—	统 一 写 作 “损 失 (loss)”	第 7 章
λ	正则系数	$\mathbb{R}_{\geq 0}$	L2 默 认 为 权 重 衰 减	第 7 章
η	学习率	$\mathbb{R}_{> 0}$	SGD/Adam 上 下 文 说 明	第 7 章
$\sigma(\cdot)$	激活函数	—	章 内 注 明 具 体 形 式	第 7 章
ϵ	扰动幅度	$\mathbb{R}_{\geq 0}$	对 抗 样 本/数 值 稳 定	第 10 章