

人工智能的数学思维

吴敏，蒲戈光

April 9, 2022

目录

0.1	什么是智能与人工智能	1
0.2	鹦鹉与乌鸦：何种智能？	4
1	智能，生于数学	
	简明数学史	9
1.1	数学萌芽时期	10
1.1.1	史前数学：日常需求与实用计算	11
1.1.2	手指：长在身上的计数器	12
1.1.3	数字的位值系统	15
1.1.4	位值制与对数增长在现代计算机中的应用	17
1.1.5	数字：从具象到抽象	18
1.2	初等数学时期	18
1.2.1	数学的真正诞生：从计算到推理	18
1.2.2	毕达哥拉斯：数与宇宙的关系	22
1.2.3	欧几里得：公理化体系的奠基人	22
1.2.4	阿基米德：数学与物理的桥梁	22
1.2.5	亚里士多德：逻辑与推理	23
1.2.6	古希腊数学的遗产	23
1.3	近代数学时期	24
1.4	现代数学时期	25
1.5	小结	26

1.6	数学史上的三次数学危机	27
1.6.1	第一次危机：无理数的发现与算术信仰的破灭	27
	危机的产生	27
	危机的解决	27
	危机的意义	28
1.6.2	第二次数学危机：微积分基础的争议与解析	28
	危机的产生	29
	危机的解决	29
	危机的意义	30
1.6.3	第三次危机：集合论与无穷的悖论	30
1.6.4	第三次数学危机及其解决：集合论与逻辑基础的动摇	31
	危机的产生	31
	危机的解决	32
	危机的意义	34
1.7	小结	34
1.8	简明数学史	36
1.8.1	数学萌芽时期	36
1.8.2	初等数学时期	37
1.8.3	近代数学时期	39
1.8.4	现代数学时期	40
1.9	小结	42
2	人工智能的三种思维：从理论到应用的跨越	43
2.1	数学思维：定义和可能性的框架	44
2.2	算法思维：从理论到可计算的路径	46
2.2.1	算法复杂度	47
2.2.2	算法优化	49
2.2.3	算法稳定性	50
2.3	工程思维：从可计算到可用的实际落地	51

2.4	两个从数学思维到工程思维的例子	55
2.4.1	数字图像处理：从理论到实际应用的三重思维	55
2.4.2	数学思维：图像处理的理论基础	56
2.4.3	算法思维：从理论模型到具体算法	56
2.4.4	工程思维：图像处理的实际落地	57
2.4.5	总结	58
2.4.6	数学思维：推荐系统的理论建模	58
2.4.7	算法思维：理论到实现的路径	59
2.4.8	工程思维：推荐系统的实际部署	60
2.4.9	综合说明	61
2.5	小结：三种思维的交融与驱动	61
3	机器学习：学习如何学习？	63
3.1	机器学习成为必然选择	64
3.1.1	机器学习：从数据中学习规律	66
3.2	机器学习是什么？	66
3.3	机器学习：寻找一个函数	67
3.3.1	数据驱动的函数优化	70
3.3.2	挑战：找到一个精准的函数	70
3.3.3	机器学习的未来：构建更灵活的映射函数	71
3.4	机器学习三要素：模型、学习准则、优化	71
3.4.1	模型：映射关系的表示	71
3.4.2	学习准则：衡量映射的好坏	73
	损失函数	73
3.4.3	风险最小化准则	73
3.4.4	优化：找到最优参数	74
	梯度下降（Gradient Descent）	75
	随机梯度下降（SGD）	75
	提前停止	75

高级优化算法	75
3.4.5 三要素的协同作用	76
3.4.6 监督学习、无监督学习和强化学习	76
3.4.7 监督学习：通过标注数据进行映射学习	76
3.4.8 无监督学习：通过未标注数据发现模式	78
3.4.9 强化学习：通过与环境互动学习策略	78
3.4.10 深度学习，真的行	80
3.5 1.1 起源	80
3.6 1.2 发展	82
3.7 1.3 成功案例	95
3.8 1.4 特点	96
3.9 1.5 小结	98
3.10 1.6 练习	98
3.11 1. 引言	102
3.12 2. 背景	106
3.12.1 第一阶段	106
3.12.2 第二阶段	106
3.12.3 3. 第三阶段	106
3.12.4 3. 结构	106
3.12.5 4. 如何训练	107
3.12.6 人工神经网络在信息领域中的应用	110
3.12.7 人工神经网络在医学中的应用	111
3.12.8 人工神经网络在交通领域的应用	112
3.12.9 人工智能：广跨各学科，综合文理工	119
3.12.10 发展历程：AI 的三次热潮和相应的研究学科突破	119
3.12.11 三次热潮的总结	119
3.13 线性神经网络	120

引言 什么是智能？

这一章将带领你从哲学、科学和工程的角度出发，追问“什么是智能”。接下来的章节中，我们将深入探讨数学在人工智能中的具体应用，展示数学如何帮助我们创造出越来越强大的智能系统。

0.1 什么是智能与人工智能

智能 (*intelligence*)，如今已经成为现代生活中很常见的一个词，比如智能手机、智能家居、智能驾驶等。在不同使用场合中，智能的含义也不太一样。比如“智能手机”中的“智能”一般是指由计算机控制并具有某种智能行为的意思。这里的“计算机控制”+“智能行为”隐含了对人工智能的简单定义。

简单地讲，人工智能 (*Artificial Intelligence, AI*) 就是让机器具有人类的智能，这也是人们长期追求的目标。这里关于什么是“智能”并没有一个很明确的定义，但一般认为智能 (或特指人类智能) 是知识和智力的总和，都和大脑的思维活动有关。人类大脑是经过了上亿年的进化才形成了如此复杂的结构，但至今仍然没有完全了解。虽然随着神经科学、认知心理学等学科的发展，人们对大脑的结构有了一定程度的了解，但对大脑的智能究竟怎么产生的还知道的很少。我们并不理解大脑的运作原理，以及如何产生意识、情感、记忆等功能。因此，通过“复制”一个人脑来实现人工智能在目前阶段是不切实际的。

智能并非人类独有，许多动物，如海豚、鸟类、猩猩，甚至章鱼，都表

现出高度的学习能力、问题解决能力以及某种形式的社交智能，但人类的智能，但人类的智能以其复杂性和多样性独树一帜，在抽象和创造性上尤为突出。人类具有抽象思维，创造了诸多符号系统，并基于此进行高度复杂的推理和想象。从数学公式到哲学思辨，人类通过语言、文字和符号，建立起了庞大的知识体系和文化遗产。我们可以预见未来、反思过去，并通过科学、技术、工具改变现实世界。正是这种智能上的深度和广度，推动了人类文明的发展。

智能是生命进化过程中形成的一种适应性特征。但随着人工智能的发展，我们正在见证一种新型智能的崛起。在 20 世纪中期，计算机的发明标志着一种全新“智能”形式的诞生。计算机，这种基于二进制系统和算法逻辑的机器，能够完成许多过去被认为只有人类才能做到的任务，如图像识别、语言翻译、甚至写作创作。机器可以通过算法模拟复杂的推理过程，甚至在某些领域超越人类的能力——它们能够比人类更快地进行大规模计算、更高效地分析海量数据。

这促使我们重新思考：究竟什么是“智能”？它是基于生物特性的一种特有思维能力，还是某种可以通过数学和逻辑建模来实现的计算逻辑？

对于智能的定义，在不同学科中有着不同的阐释。在心理学中，智能被视为一种个体解决问题、学习和适应环境的能力。在生物学中，智能更多与生物体的行为、神经系统的复杂性相关。而在计算机科学和人工智能领域，智能则被看作是一种能够在复杂环境中执行任务并达成特定目标的能力。从人工智能的角度看，智能可以被定义为“机器执行通常需要人类智能才能完成的任务的能力”。这些任务包括视觉识别、自然语言处理、学习、推理、决策等。然而，计算机和人类智能之间仍然存在着巨大的差异，特别是在理解、情感和创造力等方面。人工智能的核心在于如何用数学工具来模仿、简化甚至扩展这些认知能力。

机器“智能”是否真的与人类的智能一样？人类的智能伴随着进化而来，经过了数百万年的演变和适应，它不仅仅是一种计算能力，更是情感、直觉、创造力和推理能力的综合体。相对来说，人工智能的发展历史尚短，但其进化速度却让人惊叹。

机器智能的本质在于其基于算法和数据的计算逻辑，而人类智能则包含了情感、意识、创造力等更为复杂和难以定义的元素。智能不仅仅是任务的完成能力，更涉及到意识、理解和体验。也许机器可以在规则内完成任务，优化目标，但它们仍然无法像人类那样拥有感知、情感或独立的创造性思维。尽管如此，在这场由人类主导的智能革命中，我们依然是规则的制定者和方向的掌控者。这也是为什么，理解数学思维如何推动人工智能，能够帮助我们更好地把握未来智能发展的关键脉络。

数学在智能中的角色

自古以来，数学不仅是解决问题的工具，更是智能表达与实现的基础语言。数学的力量在于它能够抽象出复杂问题的本质，提供精确的描述和推理方法。

人工智能中的诸多任务，如模式识别、数据分类、预测等，背后都依赖数学模型进行量化和求解。例如，图像识别问题看似复杂，但可以被归纳为一个线性代数问题：图像被分解为像素点，每个像素点通过向量和矩阵的运算来进行处理。同样，神经网络的训练也依赖于微积分中的优化技术，以最小化损失函数，找到最优参数组合。

机器智能的进化：从计算到学习

数学在推动人工智能从简单计算迈向学习与适应中起到了关键作用。最初，计算机的智能主要体现在通过预先编写的规则来执行任务，模拟人类的某些智能行为。随着大数据和深度学习技术的出现，人工智能开始从数据中“学习”，即所谓“机器学习”。这是一场范式的转变：机器智能从依赖人工预定义的规则，转变为通过模型的不断训练和优化进行自我学习。

在这场范式的转变中，数学再次发挥了至关重要的作用。统计学、线性代数、概率论等数学工具，使机器能够从复杂的海量数据中提取有价值的模式和信息，并进行合理决策。

机器学习依赖于统计学、线性代数、概率论等数学理论。通过这些工

具，机器能够从海量数据中提取模式并作出决策，具备了学习和自我优化的能力。

这种数学思维下的机器学习能力，使得智能不仅仅是计算结果的简单输出，而是一种能够学习、适应和自我优化的动态过程。这场智能的进化，无疑奠定了人工智能发展的新高度。

数学思维：解码智能的钥匙

人工智能是模拟、延伸和扩展人类智能的理论、方法、技术及其应用系统的综合学科。AI 作为一门跨学科领域，从多个学科中汲取灵感与启发，融合了不同领域的知识与技术。

数学思维不仅仅是对现有工具的应用，更代表着一种解码世界的方式。数学能够帮助我们从表象中剥离出系统的本质，理清复杂事物之间的逻辑关系。在人工智能领域，数学思维是帮助我们更好理解并发展智能的核心钥匙。人工智能的本质是一种通过数学和计算实现的智能，它利用算法、数据处理和计算资源模拟生物智能的行为。为了理解智能如何通过数学实现，我们可以将其分解为几个关键组成部分：

- **感知与反应：**任何智能体首先需要能够感知环境，并对环境做出适当的反应。这是智能的基础，也是进化中所有生物生存的关键。数学在感知数据的处理上扮演重要角色，例如通过卷积神经网络处理视觉输入。
- **学习与记忆：**智能体不仅是对环境做出反应，还包括从经验（数据）中学习，，储存经验用于未来决策。
- **推理与决策：**智能体需要能够进行推理，从已有信息中得出新的结论，从而做出合理的决策。这离不开统计推断、优化等数学方法。
- **创造与适应：**更高级的智能不仅仅是反应式的，而是能够创造性地应对未知的挑战，并在复杂的环境中灵活适应。

人工智能（AI）在这些维度上逐步模仿人类的智能，但它的本质是通过数学和计算实现的。AI 的智能是通过算法、数据处理以及计算资源，以我们在生物智能中所见的行为为目标进行的复杂优化。

0.2 鹦鹉与乌鸦：何种智能？

为了更好地理解智能，我们可以借用一个生动的比喻——鹦鹉与乌鸦。

鹦鹉式智能：模仿而不理解

鹦鹉是模仿高手，能够复制人类的语言，甚至在特定情境下做出看似有意识的反应。然而，鹦鹉并不真正理解它模仿的内容，它只是重复我们的话语，而无法将这些词汇与现实世界中的人、物或情景建立联系。这种行为类似于一些现有的人工智能系统，特别是那些专注于模仿和执行特定任务的 AI 模型。这类 AI 可以通过大量数据训练，在特定任务中表现优异，但它们并不真正理解背后的语义或意图。

这种“鹦鹉式智能”可以类比为**弱 AI** 或**窄 AI**。它们擅长于特定任务，但缺乏广泛的推理和创造能力。当前的许多 AI 模型，如语言生成或图像识别，都是在这一框架下运作的——它们通过模式识别和数据驱动的方式执行任务，却没有真正的自主意识或深度理解。都是在这一框架下运作的——它们通过模式识别和数据驱动的方式执行任务，却没有真正的自主意识或深度理解。

乌鸦式智能：推理与创造

乌鸦向来被认为是最聪明的鸟类之一。与鹦鹉不同，乌鸦不仅擅长模仿，还展现出复杂推理能力、问题解决能力以及创造性的智能。乌鸦是少数能够制造工具的鸟类，能够通过创新思维应对物理世界中的挑战。我们从小都听过各种“乌鸦喝水”的故事，而国外科学家也曾做过一系列“乌鸦喝水”的变化实验。在这些实验中，研究人员使用了各种不同形状的瓶子和不

同密度的物体，观察乌鸦如何应对。令人惊讶的是，乌鸦总能在几次尝试后，快速识别并选择那些能够最快让水位上升的物体。这些实验不仅证实了乌鸦对物理规律的深刻理解，还展示了它们高度的认知能力和推理能力，以及面对复杂问题时的创造性和灵活性。另一个著名的例子是，乌鸦会将坚果放在马路上，利用来往车辆碾压坚果壳，并观察红绿灯、斑马线等信号来推理交通规则，最终推理出红绿灯与车辆停靠及行人停走之间的复杂因果关系，从而安全地过马路，吃到被碾碎的坚果肉。这是一种远远超出简单反应的行为，展示了乌鸦对物理世界和人类行为之间复杂因果链的深刻理解。

乌鸦的这一行为没有经过大量数据训练或监督学习，它通过少量的尝试与观察，直接推理出解决问题的方法。乌鸦智能正是我们期望的真正的智能——完全自主的智能：观察、感知、认知、学习、推理、执行。这种智能可以比喻为**强 AI** 或**通用 AI**，具备自主学习、推理和适应能力，能够在不同的环境中灵活应对各种任务。

功耗极低：乌鸦头不到人脑的 1

乌鸦的智能不仅令人惊叹，功耗也极低。人类大脑的功耗大约在 10-25 瓦之间，乌鸦的大脑尺寸约为人类的 1%，功耗约为 0.1-0.2 瓦。这意味着乌鸦无需复杂的能源供应系统或冷却设备，就能完成复杂的推理和问题解决任务。相比之下，现代 AI 系统需要高性能计算设备和大量能源，显示了生物智能的高效性。

智能的层次：从鹦鹉到乌鸦

“鹦鹉”与“乌鸦”的比喻在人工智能领域有着深刻的象征意义，揭示了智能的不同层次：

- **鹦鹉式智能**：擅长特定任务，通过数据驱动的模式识别和模仿来实现，针对某些垂直应用有效，但缺乏深度理解和推理能力。
- **乌鸦式智能**：具备复杂的推理和创造性，能够自主学习、适应环境，展现出高水平的智能灵活性。

这个比喻通过比较鹦鹉的模仿性智能和乌鸦的推理性智能，说明了 AI 智能的不同层次。

AI 的未来：向“乌鸦式智能”迈进

现有的 AI 系统，即使是最先进的语言模型和图像识别系统，都还处于“鹦鹉式智能”阶段。这些系统依赖于预定义规则、大量数据、大量计算资源来完成特定任务，但缺乏真正的推理和创造能力。虽然这类 AI 能够生成看似“智能”的对话，但它们的智能基于模式识别和数据驱动，与鹦鹉能模仿人类发音但不理解其语义一样。即使是像 ChatGPT 这样的先进语言模型，在模仿人类语言并生成非常连贯对话上表现几可乱真，但它并不具备关于“意义”的主观理解，无法感知、体验或有意识地推理，只是基于统计模式和相关性根据输入生成最有可能符合上下文的回应。因此，大语言模型更多是“聪明的猜测”，而非真正的理解。这与人类的理解方式存在本质差异。

AI 的未来发展目标是朝着“乌鸦式的智能”迈进，不仅能够模仿，还能推理、学习、适应，在跨任务和多变的环境中展现出灵活的创造力。实现与生物智能相媲美的灵活性和创造力，正是“强 AI”或“通用 AI”所要追求的方向。

人工智能：模拟、延伸和扩展人的智能的理论、方法、技术及应用系统

Chapter 1

智能，生于数学 简明数学史

“如果人们不相信数学很简单，那是因为他们没有意识到生活有多复杂。”

约翰·冯·诺伊曼

“课本中字斟句酌的叙述，未能表现出创造过程中的斗争、挫折，以及在建立一个可观的结构之前，数学家所经历的艰苦漫长的道路。学生一旦认识到这一点，他将不仅获得真知灼见，还将获得顽强地追究他所攻问题的勇气，并且不会因为自己的工作并非完美无缺而感到颓丧，实在说，叙述数学家如何跌跤，如何在迷雾中摸索前进，并且如何零零碎碎地得到他们的成果，应使搞研究工作的任一新手鼓起勇气。”

克莱因，《古今数学思想》序言

智能的历史可以追溯到人类最早期的思维活动，而数学是其中最重要的基础工具之一。

对于古代人来说，数字的发明源于对数量的需求。无论是借手指计数，还是用其他物体辅助，人类通过千年的发展，逐渐完善了从简单符号到

抽象数字的演变过程。今天，我们的“自然数”概念似乎理所当然，但这一切都建立在人类历史上无数次的试错与进化中。

人类对“智能”的探讨源远流长。远在古代希腊时期，哲学家们就已经开始追问：什么是智慧？什么是理性？我们如何通过思维去理解这个世界？从那时起，人们就梦想着创造能自主思考的机器。神话人物皮格马利翁 (Pygmalion)、代达罗斯 (Daedalus) 和赫淮斯托斯 (Hephaestus) 可以被看作传说中的发明家，而加拉蒂亚 (Galatea)、塔洛斯 (Talos) 和潘多拉 (Pandora) 则可以被视为人造生命 (Ovid and Martin, 2004; Sparkes, 1996; Tandy, 1997)。

这些问题不仅关乎哲学，还对现代科学技术的发展产生了深远影响。随着时间推移，这种对智能的追问从哲学的纯理论思辨，逐渐转向了科学与工程实践领域。

早期的数学家如欧几里得、阿基米德以及笛卡尔等，通过逻辑和结构化的思维方式，奠定了后来发展计算机智能的理论基础。他们的工作不仅推动了科学与工程的发展，也为智能的理论构建提供了明确的框架。

数学的发展历程如同一条不断延展的长河，从最初的数字发明，到公元前 5 世纪的希腊数学奠基，再到随后的数千年中，数学逐渐演变为一门多维度、多分支的科学。通过计算与推理的结合，数学不仅成为解决现实问题的工具，也升华为探索抽象概念与逻辑关系的强大思维体系。

数学的发展史可以大致划分为四个不同的时期：数学萌芽时期、初等数学时期、近代数学时期和现代数学时期。需要说明的是，精确地划分这些阶段是不可能的，因为每个时期的特征都是在前一时期的基础上逐渐形成的。然而，这些阶段反映了数学在每个历史阶段中的不同侧重与进步，揭示了数学从最早的经验积累到复杂的理论构建，乃至今天在科技与智能领域的广泛应用的深刻演化。每个时期都在数学发展中扮演了不可或缺的角色。

让我们依次回顾这些数学发展的重要阶段，探索其背后的历史背景与核心成就。

1.1 数学萌芽时期

数学的萌芽时期从远古时代延续至公元前 5 世纪，是人类最早利用数学工具应对日常生活需求的阶段。

这一阶段的数学起源于最基本的数数活动。通过手指计数、刻痕和结绳等原始计数手段，人类逐渐形成了自然数的概念。自然数的确立是数学发展的第一步，也是人类对数量的最早认识。从简单的数数开始，逐渐发展出加减乘除等基本运算，为解决日常生活中的问题提供了有效的工具。

古埃及人发展了一些基础的几何公式，在建造金字塔时已经能够运用高度和角度的几何关系；美索不达米亚的会计师不仅掌握了加法和乘法，还能够解简单的二次方程，用于管理粮食和资源。古代美索不达米亚和埃及的泥板和石刻记录了这些早期的数学活动，展现了数学与生活实践的紧密联系。

巴比伦人对天体运动的观察和历法推算也推动了数学的发展。为了精确预测日食、月相以及制定历法，巴比伦的天文学家需要处理大量的时间和角度计算。这些天文观测不仅促进了数学在测量和计算方面的进步，也推动了几何和代数的进一步发展。

这一时期并没有明确的个人数学家记载，更多的是群体性活动。古埃及的建筑师和美索不达米亚的会计师是这一阶段数学发展的重要推动者。埃及人在几何测量中的应用和美索不达米亚人对天文学和代数的研究，构成了数学早期发展的代表性成就。

这一阶段的数学活动是解决问题的经验性工具，尚未形成系统的理论。但它为后续的数学体系发展奠定了数与形的概念基础。

1.1.1 史前数学：日常需求与实用计算

数学史往往是从公元前 5 世纪的希腊开始讲起的。毕达哥拉斯创立了算术，泰勒斯和阿那克西曼德创立了几何，奠定了古代数学的两大分支。算术和几何的创立，无疑是数学史上的重大突破。然而，这样的讲法却忽略

了一个重要的时代，也就是所谓的“史前”数学。人们并没有等到公元前 5 世纪才开始解决数学问题，特别是那些日常面临的具体数学问题。

在公元前 5 世纪之前，数学并非一种独立的学科，而是伴随着人类生活的需要而逐步发展起来的。史前数学的主要任务是应对日常生活中的具体问题，如计数牲畜、测量土地和管理时间。远古人类通过手指计数、刻痕和结绳的方式解决了基本的数量和度量问题，虽然这些方法原始，却为后来的数学奠定了基础。

人类早期的数学成就源于实际需求，古埃及人和巴比伦人便是典型的例子。他们在天文学、土地测量和贸易中依赖数学工具，通过经验性的方法逐渐累积了丰富的数学知识。然而，这些方法主要依赖于实用性，而非系统的理论研究。

“数学”活动最古老的痕迹之一是在美索不达米亚发现的一块泥板，它可以追溯到公元前 2500 年。这块泥板记录了这样一个计算：如果一个谷仓里有 1152000 份粮食，每个人分得 7 份，一共可以分给多少人呢？不出所料，结果是 164571 人，即用 1152000 除以 7 得到的结果。看来，美索不达米亚的会计师在算术“诞生”之前很久就知道怎么做除法了。甚至，书写完全有可能就是为了记账才发明的——虽然这些事情很难说得准，但若真是如此，数字就比字母发明得还要早了。

1.1.2 手指：长在身上的计数器

相信你在许多影视剧中都见过这样的一幕：一位算命先生，掐指一算，口中念念有词。这种“掐指一算”看似神秘，实则源自于古老而简便的计数方法。

在远古时代，用手指计数是再自然不过的选择，手指是人类最早的“随身计算器”。手指提供了一个天然的计数系统，帮助人们轻松应对日常的计数需求，如记录牲畜数量、物品交换量，推算季节、节气，安排农耕节日等活动。

手指的构造与多种进制系统有着天然的联系。稍加思考，我们就可以



图 1.1: “掐指一算”

发现十进制、二十进制、十二进制等计数法与手指构造的对应关系。

十进制 (Decimal System) 是最常见、最自然的计数方式。双手的十根手指与十进制自然对应，每根手指代表一个数字，从 1 数到 10，完成一轮计数。十进制系统在全球的广泛使用，源于人类天生拥有十根手指的解剖学特征。正如爱德华·卢卡斯所言，这是“自然界的一个偶然事件”。

十二进制 (Duodecimal System) 则适用于更复杂的计数需求。除大拇指外，四根手指各有三段指节。一只手的大拇指指向四根手指的各段指节，可以计数 1 到 12。这种方式在古代美索不达米亚和古埃及广泛应用，至今仍用于时间和角度的计数系统中，如 12 小时制、一年 12 个月等。

六十进制 (Sexagesimal System) 则更加复杂。它结合双手来计数。一只手用于计 12 (与十二进制相同)，另一只手的五根手指则记录 12 的倍数，五轮 12 等于 60。六十进制在古巴比伦时期被发明，沿用至今，广泛用于时间和角度的计量，例如 1 小时 = 60 分钟，1 分钟 = 60 秒，以及 360 度的圆周划分。

二十进制 (Vigesimal System) 也是一种古老的计数法。为了更大范围的计算，一些古代民族不仅用手指，还加上脚趾来计数。例如，中美洲的玛雅文明和阿兹特克文明，以及现今的西非和欧洲部分地区，采用了以 20 为

基数的计数法。

二十进制的痕迹在许多语言中依然存在。现代英语中的“score”表示 20 的用法便保留了这一印记。例如，莎士比亚在《圣经》英译本中使用“three score and ten”（20 的 3 倍加 10，表示 70 岁）来指代古稀之年；林肯在《葛底斯堡演讲》中使用“four score and seven years ago”（20 的 4 倍加 7，表示 87）来表达 87 年前的历史。一百年后，马丁·路德·金在其著名的演讲《I have a dream》中说“Five score years ago”（20 的 5 倍，即 100 年前）。如今，在现代英语中，“score”的这种用法已不再常见。

英国曾有一个结合十二进制和二十进制的货币系统：1 英镑 = 20 先令，1 先令 = 12 便士。1971 年，英国引入了十进制货币系统，1 英镑 = 100 便士，先令在 1990 年后彻底退出流通。

在法语、丹麦语和巴斯克语中也能找到二十进制的痕迹。例如，法语中的数词从 quatre-vingts(80)、quatre-vingts-dix(90)，到 quatre-vingts-dix-neuf(99)，表明凯尔特族过去采用二十进制计数法。同时，这些语言中还混杂了六十进制的痕迹，如数词 soixante(60) 到 soixante-dix-neuf(79)。

手指不仅是我们身体的一部分，还是人类最早的天然计算工具。它帮助我们理解和组织世界，并为现代数学中的位值制和进制系统提供了最初的灵感。直到今天，手指仍是许多人在进行简单计算时的本能工具。可以说，手指是人类最早的“计算器”，引领我们从最原始的计数方法走向了复杂的数学世界。

自然的教育，数字文明的缩影

设想你在一次航海探险中遭遇风暴，不幸漂流到了一个无人孤岛。没有手表、手机，也没有任何现代工具。你很快面临一个问题——如何计算时间？如何记录每天收集的食物？在这种完全回归自然的环境中，你必须依靠最原始的方式来解决这些问题。

手指计数：最简单的工具

你的第一反应可能是用手指来计数。十根手指天生就是人类最便捷的“计算器”，帮助你快速记录简单的数量——比如你捕到的鱼或采摘的果实。手指计数是直观而方便，几乎无需思考就能完成。但很快，你意识到这种方法有明显的局限性：当数字变大，或需要记录更复杂的信息时，手指显然不够用了。更重要的是，手指计数无法保存这些数据，一旦忘记，你的记录便随之消失。

刻痕计数：更长久的记录方式

为了更长久地保存记录，你开始在岛上的树木或石头上刻下痕迹。每道刻痕代表一天的过去，或你每天捕获的鱼或采摘的果实数量……。刻痕计数法让你能够更长久地保存这些信息。每天的刻痕不断累积，形成一个记录时间和活动的系统。这种方法虽然简单，却比手指计数更加持久、可靠，也能应对稍微复杂的需求，比如记录日期或特定的事件。然而，随着时间的推移，刻痕的数量增加，管理这些信息变得越来越困难。你开始需要一种更便捷、更灵活的方式来记录和传递这些信息。

结绳记数：更高级的记数法

幸运的是，你发现了一根绳子，这给了你一个新的选择——结绳记数法。通过在绳子上打不同的结，你可以标记不同的天数、事件或物品的数量。不同形状和位置的结可以表示不同的信息。相比于刻痕，结绳计数法更便捷灵活，更易于携带和传递，成为你在荒岛生活中的高级计数工具。

荒岛上的自然教育：人类数字发明的倒影

在这场荒岛冒险中，随着你逐步探索各种计数方法，你无意间接受了一种独特的自然教育。这个经历，其实正是早期人类如何发明和发展数字的缩影。在远古时代，人类也像你一样，从最初的手指计数，逐渐发展到刻

痕和结绳，寻找更有效的计数方式，逐渐探索出了越来越复杂、抽象的记数方式。

你在荒岛上的探索，正是人类数字文明进化的缩影。无论是刻痕还是结绳，这些方法都体现了人类从最初的物理标记到复杂符号系统的演化路径。通过这些自然的计数方法，你逐步掌握了记录、比较和计算的基本概念。这不仅是你个人的“自然教育”，也是数字发明的最初动力——让生活更加便捷和高效。

1.1.3 数字的位值系统

在人类早期文明中，简单的手指计数和结绳、刻痕等计数方法已广泛用于记录数字，帮助人们应对日常的数值计算。然而，随着社会的发展，人们逐渐认识到，仅靠刻痕和结绳等物理标记在处理更复杂和更大范围的数字时，显得低效而繁琐。于是，更加抽象的符号系统应运而生。从而催生了**位值制**这一革命性的数字表示方式，使得复杂的数值能够通过简单的符号位置来表示和计算。

早期的计数系统大多采用**加法规则**。例如，在古代巴比伦的黏土板上，数字是通过符号的重复来表示的：数字“1”用一个符号表示，数字“2”用两个相同符号表示，数字“3”则用三个相同符号。这种计数方式很眼熟，中文数字、罗马数字、古印度的婆罗门数字和笈多王朝使用的数字，以及大洋彼岸的玛雅数字，都采取了同样的方法。大多数的古代文明在表示前三个数字时，都采取了同样的方式：重复表示“1”的符号一次，两次，三次。古代的中文“一、二、三”、钟表盘上的罗马数字“Ⅰ、Ⅱ、Ⅲ”、阿拉伯数字也体现了同样的重复方式。可是，从数字 4 开始，所有的文明就都放弃了这种重复。为什么呢？

研究发现，人类的数感对少于 3 的数字有天然的反应，但超出这个范围后，单纯的重复符号便变得困难。对一些出生几个月的婴儿进行试验，结果证实人类与生俱来的数感的容量不超过三。

试想一下，数字 13 若用重复排列“1”的符号 13 次来表示，无论是对

书写还是阅读，都会很低效——怎么能一眼就看出它是 13，而不是 12 或者 14 呢？

类似的问题在罗马数字系统中也很常见。罗马数字系统中，V 表示 5，X 表示 10，L 表示 50，C 表示 100。此外，向右添加符号为加，如，VI 表示数字 6，XI 表示数字 11；相反地，向左添加一个更小数值的符号为减，如 IV 表示 4，IX 表示 9。尽管使用了加减法规则的计数系统十分直观，但在表示大数时显得十分低效。例如 1888 年写成罗马数字就是 MDCCCLXXXVIII，甚至无法有效表示类似 100 万那样的数字——除非把 1000 个 M 排成一排！

随着人类文明的发展，许多地区开始引入更为先进的计数法，其中最具革命性的是**位值制计数法**。古巴比伦、中国，尤其是印度和阿拉伯，率先采用了这种创新的位值制计数法。这种计数法的关键在于符号的位置决定了其数值。例如，数字“12”和“21”虽然使用相同的符号，但因为符号位置不同，代表的数值也不同。

位值计数法具有出众的简洁性。通过有限的符号，可以表达任意大的数值。例如， 10^{100} 这个超出了物理限制的天文数字，在位值制下仅需 101 个符号即可表示——一个“1”后面跟着 100 个“0”。位值计数法用极短的符号链表示极其巨大的数值。

位值制不仅提高了数字的表示效率，还反映了数字的**对数增长**特性，即随着数字的增大，所需的符号长度呈对数增长，符号数量远远少于数字本身的大小。例如，表达 10^{100} 所需的符号长度约为 $\log_2 10^{100} = 100$ (实际为 101 个)。一般地，表达任意整数 x 所需的符号数量接近 $\log_2 x$ 。因此，从某种意义上，位值计数系统是最简洁、甚至最优的。

位值制的引入是人类计数方法的一次重大飞跃。从简单的重复符号到高度抽象的符号系统，位值制极大简化了计算过程，推动了计算和数学的发展，奠定了现代数字系统的基础。

1.1.4 位值制与对数增长在现代计算机中的应用

在计算机科学中，在已经排好序的数组中查找某个元素的时间也是数组长度的对数。即使数组规模如同宇宙般庞大，经过几百次迭代后，便能够找到所需的元素——唯一的限制就是光速有限性所带来的信息传播和处理速度的物理极限。

互联网的 URL 是位值制与对数增长在数据处理和网络寻址中的一个典型应用。一个简短的 URL (Uniform Resource Locator, URL, 统一资源定位符) 迅速定位到海量信息。想象一下，你希望在网上搜索某项信息。尽管互联网上的数据量可能以 EB(10^{18} 字节) 甚至 ZB(10^{21} 字节) 计量，只要拥有对应信息的 URL，你几乎瞬间就能找到目标信息。这正是对数增长的强大之处：即使面对巨大规模的数据集，只需少量步骤就能完成检索。

此外，URL 的简短程度令人惊叹，其长度是整个网络大小的对数！这意味着我们可以轻松将 URL 存储在内存中，而 URL 指向的信息量却远远超出了其自身长度。这种简洁有效的特性，展示了对数增长在计算与信息处理中的关键作用。

IPv4 和 IPv6 的设计正是对数增长在实际应用中的另一个实例。IPv4 地址使用 **32 位** 二进制数来表示，每个 IP 地址可以被写成 4 个以点分隔的十进制数（如 192.168.1.1），每部分对应一个 8 位的二进制数。32 位的二进制能够生成 2^{32} ，即约 **43 亿** 个唯一 IP 地址。这在 IPv4 设计之初被认为是足够庞大的数目。然而，随着互联网的迅速扩展，特别是物联网（IoT）设备和移动设备的广泛普及后，IPv4 的 43 亿个地址空间将很快耗尽。

为了解决这一问题，**IPv6** 应运而生。IPv6 使用 **128 位** 二进制数表示，由八组以冒号分隔的 16 进制数构成（如 2001:0db8:85a3:0000:0000:8a2e:0370:7334）。这种 128 位的二进制表示能生成 2^{128} ，即约 3.4×10^{38} 个唯一 IP 地址，相当于为地球上的每粒沙子分配多个 IP 地址。这一数量级足以应对未来几十年甚至几百年内所有联网设备的需求。

IPv4 和 IPv6 的位数与它们能够支持的地址数量之间的巨大落差，展示了对数增长的强大力量。IPv4 仅用 32 位符号就能表示 43 亿个地址，而

IPv6 仅用 128 位符号就能支持 3.4×10^{38} 个地址。随着位数的增加，IP 地址系统实现了指数级的扩展，同时保持了地址表示的简洁性。

1.1.5 数字：从具象到抽象

几千年来，人类都在探索如何建立数与物的对应关系，现代数字系统的定义正是基于这种探索的延续。一旦人类掌握了计数，数字系统的应用就变得“自然而然”了。或许正因如此，我们才称自然数为“自然”数 (natural number)。然而，实际上，数字的概念一点也不“自然”。

无论是在早期人类在骨头及木棍上有序地刻下划痕，还是结绳或是在容器中放置物品无论是结绳，这些早期方法已代表了相当抽象的符号系统，其中抽象的数学对象与自然中的实际物体之间的分离，同一个数字既可以表示动物的数量，也可以记录借贷量或一个月的天数。自此之后，数学研究的对象不再是必须与实际物体相关的几何图形和数字。研究对象性质的变化，最终引发了解决数学问题的方法的革命。

1.2 初等数学时期

公元前 5 世纪开始，数学进入了初等数学时期。这个时期的数学探索更加系统和深入，尤其是在欧几里得几何和代数方程的研究中，数与形的关系得到了更加严谨的探讨，算术、几何、代数和三角等数学分支逐渐成形。

1.2.1 数学的真正诞生：从计算到推理

数学作为一种学科，经历了漫长的演化过程。起初，数学的诞生是为了解决生活中的实际问题——如何计数、测量、交易、管理时间等。

公元前 5 世纪的希腊是数学发展的转折点。在此之前，数学主要集中于如何进行计算。

在埃及和美索不达米亚等古老文明中，数学的发展更多地依赖于经验和实际操作。埃及的数学侧重于土地测量、建筑工程和会计管理，而巴比伦人则在天文学、时间计算和度量衡方面取得了显著的成就。他们的数学面向解决日常问题，更多依赖于表格、算法和简单的数值操作。

“数学”活动最古老的痕迹之一是在美索不达米亚发现的一块泥板，它可以追溯到公元前 2500 年。这块泥板记录了这样一个问题：一个谷仓里有 1152000 份粮食。如果每个人分得 7 份，一共可以分给多少人？答案是 164571 人，即用 1152000 除以 7 得到的结果。看来，美索不达米亚的会计师在算术“诞生”之前很久就知道怎么做除法了。美索不达米亚和埃及的会计师不仅会做乘除法，而且掌握了许多其它的运算，比如解二次方程等。土地测量师则会计算矩形、三角形、圆形的面积。

这种实用性的数学（包括算术和几何）在数学史上称为“史前”数学，因为它并不涉及抽象推理，而是围绕日常需求展开。

因此，教科书中的数学史往往是从公元前 5 世纪的希腊开始讲起的，因为希腊数学家让数学从“如何计算”进化到了“为什么如此”。

在公元前 5 世纪的希腊，毕达哥拉斯学派提出了这样一个问题：找出一个等腰直角三角形，使其三边的长度都是自然数。假设等腰直角三角形的直角边长度为 x ，斜边长度为 y 。根据毕达哥拉斯定理（勾股定理）， y^2 就等于 $x^2 + x^2$ 。因此，这个问题最终归结为：找出两个自然数 x 和 y ，使得

$$2x^2 = y^2 \quad (1.1)$$

让我们来试试 4 以内所有 x 和 y 的可能性吧（见表 1.1）。在上述所有情况里， $2x^2$ 都不等于 y^2 。我们当然还可以在更大的数字范围里继续寻找。事实上，毕达哥拉斯学派很可能寻找了很久，却没能找到解。后来，他们终于相信这个解不存在。他们是怎么说服自己这个解不存在的呢？显然不是穷尽所有的数对，因为这样的数对有无穷不可数个。你就算试到 1000 甚至 100 万，证实没有数对能满足条件，可你还是没法保证在更大的数字里面不可能有解……

既然不能用穷举法，那就试试逻辑推理。不妨假设 x, y 两个数互素。为

x	y	$2x^2$	y^2
1	1	2	1
1	2	2	4
1	3	2	9
1	4	2	16
2	1	8	1
2	2	8	4
2	3	8	9
2	4	8	16
3	1	18	1
3	2	18	4
3	3	18	9
3	4	18	16
4	1	32	1
4	2	32	4
4	3	32	9
4	4	32	16

表 1.1: 4 以内 x 与 y 的所有可能性

什么呢？因为若 x, y 至少有一个是奇数时，两者自然互素；反之，若 x, y 都是偶数，则总是可以通过消去公因子来保证 x, y 至少有一个是奇数。据此，我们把数对 x, y 分成以下 3 种情况：

1. x, y 都是奇数；
2. x 是偶数， y 是奇数；
3. x 是奇数， y 是偶数；

我们先从第一种情况开始： x 和 y 都是奇数。此时 (1.1) 的解不存在。因为 y 是奇数，则 y^2 也是奇数。它不可能等于 $2x^2$ ，因为后者必然是偶数。这一论证也同样适用于第二种情况，即 x 是偶数而 y 是奇数。第三种情况即 x 是奇数而 y 是偶数。但在这种情况下，若 $2x^2 = y^2$ 成立，则这个数的一半 x^2 是奇数，同时 y^2 的一半却是偶数——这两个数不可能相等。综上所述，找不到两个自然数 x, y 满足 (1.1)。

为了证明这个问题没有解，毕达哥拉斯学派采用了逻辑推理而不是计算来实现。他们通过分类讨论和推理，证明了无论 x 和 y 是奇数还是偶数，方程 $2x^2 = y^2$ 都不可能具有整数解。

这一问题的解决在数学史的发展上具有划时代的意义。它的革命性不仅在于其对未来数学的巨大影响，还在于其抽象性及解决的方法。相比于美索不达米亚泥板上铭刻的诸如“将 1152000 份粮食除以 7 份”的具体问题，毕达哥拉斯学派的问题更为抽象：美索不达米亚的会计师关注粮食的数量，而毕达哥拉斯学派的问题仅涉及数字本身。同样，他们处理的是抽象的几何形式，而非具体的三角形田地。从从粮食的份数到数字，从实际的土地测量转向几何学的抽象思考，迈向抽象这一步的意义不可小觑。田地的面积无非几平方千米，而抽象的几何对象则可以轻松超越这一尺度，进入无限的范围。

古希腊数学家不再满足于计算结果，而是开始重视推导过程。他们通过严谨的逻辑推理，逐步构建了数学证明和公理系统。这一从计算到推理的转变，被视为数学的真正诞生，使得数学从日常的计算工具演变为以推理和抽象为核心、具有高度抽象和严谨逻辑的独立学科的学科。

一个平方数不可能是另外一个平方数的两倍——这个由毕达哥拉斯学派在 2500 多年前得到的结果，迄今在数学上仍占有重要地位。它证明了，一个短边为 1 米的等腰直角三角形中，斜边的长度为 $\sqrt{2}$ ，约 1.414，但这个数无法通过两个自然数 y 和 x 的比值得到。这揭示了，某些几何关系无法通过自然数的四则运算（加、减、乘、除）运算得到，暗示了更广泛的数系——实数的存在。这一发现让数学进入了一个全新的领域——从实际问题中抽象出纯粹的数学对象并通过推理得出结论。虽然这一发现具有革命性，但毕达哥拉斯学派并没有进一步发展出实数的概念。对他们而言，这一结论动摇了他们对自然数“万物皆数”的信仰，甚至引发了哲学上的困惑与争议。然而，几百年后，这一发现启发了数学家们发展出实数理论，为数论和分析学的诞生奠定了基础。

1.2.2 毕达哥拉斯：数与宇宙的关系

数学的哲学化起点源自古希腊的毕达哥拉斯学派。毕达哥拉斯 (Pythagoras) 及其追随者提出了“万物皆数”的思想，认为宇宙的本质可以通过数来理解。这一理念激励了希腊数学家们将数学视作解读自然现象的工具。毕达哥拉斯定理（即勾股定理）是这一学派最著名的成就之一，标志着数学开始从经验性计算向理性推理的迈进，开启了数与形结合几何学研究。

1.2.3 欧几里得：公理化体系的奠基人

如果说毕达哥拉斯奠定了数学的哲学基础，那么欧几里得 (Euclid) 则为数学建立了逻辑结构。他的《几何原本》(《Elements》) 是古代数学史上最具有影响力的著作之一，也是现代数学公理化体系的奠基之作。

欧几里得通过公理和定理的形式，系统地将几何学结构化，强调了证明的重要性。欧几里得展示了如何从少数的基础假设（公理）出发，通过严密的逻辑推导，推导出一系列复杂的几何命题。这种公理化方法对后世的数学家产生了深远影响，甚至成为了现代数学研究的重要框架。欧几里得的几何不仅仅是关于形状和空间的学问，更标志着数学作为一种基于推理

的演绎学科的正式诞生。

1.2.4 阿基米德：数学与物理的桥梁

阿基米德 (Archimedes) 是古希腊另一位杰出的数学家，他不仅在数学领域取得了重大的突破，还在物理学、机械学等领域做出了重要贡献。阿基米德将几何与物理现象紧密结合，开创了利用数学模型解决物理问题的先例。

他在几何领域的突破，如圆周率的近似计算、浮力定律及流体静力学基本定理的证明，展示了数学在物理学应用中的强大力量。阿基米德的工作不仅扩展了数学的应用范围，还展现了数学在解释自然现象中的力量。

1.2.5 亚里士多德：逻辑与推理

亚里士多德 (Aristotle) 是古希腊著名的哲学家。亚里士多德认为，数学不应只停留在经验性的层面，而应该通过演绎推理去发现隐藏在事物背后的逻辑关系。他提出的三段论和归纳法，帮助数学家们更好地理解 and 构建逻辑推理过程。这种逻辑推理体系推动了古希腊数学的进一步发展，数学家们开始通过推理和证明而非直观的经验得出结论。

算术与几何这两大分支的创立，标志着数学开始作为一门理论化学科的诞生，逻辑推理和证明逐渐成为数学的核心方法。与此同时，代数学在这一时期取得了重要进展，自然数、有理数和无理数的运算逐渐成为代数的核心主题。除此之外，这一阶段的代数学还开始引入虚数，推动了数的概念向更广的领域扩展。

1.2.6 古希腊数学的遗产

通过抽象思维和逻辑推理，建立了数学作为一种独立学科的基础。古希腊数学家们的贡献不仅仅是发现了一些几何定理和代数法则，更重要的是他们发展了数学思维的方式——通过演绎、证明、公理化等方法，将数学

从经验性工具转变为一种严谨的科学。这一传统不仅奠定了现代数学的基础，还推动了之后数千年数学和科学的进步。

中世纪的阿拉伯数学家翻译了希腊经典，并引入了印度的十进制数和“零”的概念。阿尔·花刺子密 (al-Khwarizmi) 等数学家对代数学的发展做出了巨大贡献，他的著作奠定了代数理论奠定了坚实的基础。

中国的《九章算术》和印度的基础代数成就，也为初等数学的发展增添了重要内容。中国古代数学强调实用性，广泛应用于农业、建筑和税务管理；而印度数学则对数论和代数的早期发展做出了杰出贡献。这些不同文化的数学成果，最终共同塑造了初等数学的广阔基础。

这一时期涵盖了公元前 5 世纪到 17 世纪前的数学发展。数学不再仅限于解决实际问题，而是向抽象领域迈进。古希腊数学通过几何学和数论的研究，构建了数学推理和证明的数学体系。这一阶段的数学成就不仅构成了今天中学数学的主要内容，还对现代数学的基本理论结构产生了深远的影响。

1.3 近代数学时期

从 17 世纪开始，随着资本主义的崛起和工业革命的推动，数学进入了一个全新的阶段——变量数学时期。这一时期的数学从研究静态图形和数量问题逐步转向关注变化与运动问题，变量和函数的引入是更好描述运动和变化的关键。

牛顿和莱布尼茨分别独立发明了微积分，标志着数学史上一个重要的转折点。微积分提供了一套精确描述连续变化与瞬时变化的数学工具，成为解决诸如速度、加速度、曲线下面积等问题的强大工具。牛顿通过微积分为物理学中的万有引力定律奠定了理论基础，而莱布尼茨则将微积分符号化并推广到欧洲，极大地推动了数学的发展。微积分不仅让数学得以分析瞬时变化，还为后续的数学分析开创了新的方向。

解析几何的诞生是这一时期的另一个重大突破。笛卡尔通过引入坐标系，将几何与代数结合起来，使得复杂的几何图形、物理的运动及其空间关

系可以通过代数方程来精确描述。借助于笛卡尔坐标系，数学家们能够用代数表达曲线、直线的关系，从而简化了几何中的很多问题。解析几何不仅为物理学中的动力学提供了有力工具，还为现代数学的发展铺平了道路。

近代数学时期的另一个重要分支是概率论。概率论起初由费马和帕斯卡为了研究赌博中的随机事件而诞生，但很快超越了这一领域，成为研究不确定性和随机现象的重要工具。费马还对数论做出了重要贡献，提出了许多关于素数与数之间关系的问题，激发了后世数学家对数论的广泛研究。欧拉、拉格朗日等人进一步推动了数论的发展，探讨了代数结构和数论的基本问题。

与此同时，分析学作为微积分的延续，成为这一时期的核心数学分支。通过函数和极限概念的引入，数学家们能够处理无穷小量和变化中的量，开创了分析学的时代。数学分析不仅成为这一时期的核心理论，不仅解决了古希腊时期悬而未决的几何问题，还广泛渗透进了物理学、天文学和工程学，极大地推动了科学的进步。

从 17 世纪开始，数学逐步系统化，并成为理解自然世界的核心工具。科学革命带动了数学的飞速发展，数学不仅在传统的代数和几何领域取得了突破，还在物理学、天文学、工程学等领域中发挥了重要作用。变量数学的引入让人们能够更好地理解宇宙中的变化与运动，推动了自然科学的进步。

总的来说，近代数学时期不仅为数学的进一步抽象化奠定了基础，还通过微积分、解析几何和概率论的兴起，彻底改变了人类对世界的理解方式。数学在这一时期的变革性进展，成为了现代数学发展的根基，也为科学技术的进一步进步提供了强有力的工具。

1.4 现代数学时期

从 19 世纪中叶起，数学进入了一个高度抽象化和系统化的阶段，被称为现代数学时期。这个时期的数学阶段不仅延续了之前的分析学发展，还引入了全新的几何和代数理论。代数、几何和分析学等传统学科在此期间

发生了质的飞跃，数学的研究对象和方法也逐渐向高度抽象化发展，推动了数学成为一门更加系统和广泛应用的科学。

现代数学的一个显著特征是对数学基础的重新审视与抽象概念的扩展。罗巴切夫斯基和黎曼的非欧几何，颠覆了传统欧几里得平面几何观，提出了球面和鞍面等不同几何结构，揭示了更为广泛的空间和结构关系。并为爱因斯坦的广义相对论提供了数学基础。拓扑学作为新的分支，也在 19 世纪逐渐兴起，打破了传统几何的局限，成为数学研究连续性、边界与形态的重要工具。

同时，现代数学的发展离不开对无穷概念和数学基础的深入研究。康托尔的集合论，为处理无穷大的数学研究提供了严格的工具，将无穷大和无穷小的概念精确化，成为现代数学和数理逻辑的基础理论之一。集合论的发展不仅使数学在抽象层面上得以统一，还激发了对数学自身基础的研究。集合论和数理逻辑的兴起为数学理论提供了全新的理论框架，希尔伯特、哥德尔等数学家在此领域的工作，使得数学的公理化体系进一步得到发展与完善。

20 世纪，统计学、拓扑学、泛函分析等新分支陆续创立，使数学更多元化、更富实用性。数学在众多领域的应用范围得到了前所未有的扩展，数学在物理学、工程学、经济学以及其他自然科学和社会科学等各个学科中的作用变得愈加重要。

现代数学时期的另一个重要推动力是计算机的发明和信息技术的迅猛发展。20 世纪中期，图灵、冯·诺依曼等科学家为计算机科学奠定了理论基础，计算理论逐渐成为数学的重要分支。计算机的强大计算能力使得复杂的数学问题得以快速求解，同时也极大地推动了数理逻辑和算法理论的发展，数学的潜能和边界更进一步发掘。

随着数学的抽象化与理论化趋势日益加深，数学在深入自然科学领域的同时，还广泛渗透到信息科学、工程学、经济学、社会科学等多个领域，推动了现代社会各个层面的进步。现代数学逐渐成为理解自然世界、构建理论模型和推动技术创新的核心力量。

总之，现代数学时期是数学高度抽象化、系统化的阶段。数学基础理论

的深入研究与应用范围的广泛扩展，使得数学不仅在理论层面得到了重大发展，也成为了推动科学和技术进步的关键推动力。通过集合论、非欧几何、拓扑学和计算理论的引入与发展，数学在 20 世纪的进步为现代社会的各个领域带来了不可忽视的影响。

1.5 小结

纵观以上四个时期，数学的发展脉络清晰呈现。数学从最初解决日常问题的工具，逐步演化为一门以逻辑推理和抽象思维为核心的科学。数学史既是一部理论创新史，也是一部与社会发展和科学进步紧密相连的演进史。

从萌芽阶段的经验性计算到古希腊数学家奠定的逻辑推理基础，再到近代变量数学的飞跃和现代数学的高度抽象化，数学经历了从实用工具到抽象学科的跨越。随着社会与科学的持续发展，数学也成为了理解世界、解决问题和推动技术进步的核心力量。

1.6 数学史上的三次数学危机

数学发展的历程中，曾三次面临深刻的理论挑战，这些危机不仅推动了数学的变革，也影响了其作为一门科学的根本性质。这三次数学危机分别发生在古希腊时期、17 世纪微积分的创立期以及 19 世纪末的集合论时代。每一次危机都促使数学家重新审视数学理论的基本概念，构建更加严密的数学体系，从而推动了数学从工具性学科向更高抽象层次的科学发展。

1.6.1 第一次危机：无理数的发现与算术信仰的破灭

第一次数学危机发生在古希腊，起因是**无理数**的发现。古希腊的毕达哥拉斯学派主张“万物皆数”，但这里的“数”是指整数或整数之比，即有理数。他们认为世界的规律可以通过数与比例来完美解释，这一思想赋予

了数学一种神秘的普适性。

危机的产生

然而，毕达哥拉斯学派在研究边长为 1 的等腰直角三角形时却遇到了矛盾。根据毕达哥拉斯定理（即勾股定理），斜边长度的平方为 $2 (= 1^2 + 1^2)$ ，但可以证明斜边长度无法用任何两个整数的比值来表示，这意味着它不属于有理数。这一发现彻底动摇了毕达哥拉斯学派对于有理数是万物根源的信念，引发了数学史上的第一次重大危机。

无理数的存在打破了古希腊数学家对数字和比例的简化认识，表明数的体系并不完备，迫使数学家们不得不重新审视数的定义。

危机的解决

1. 转向几何方法 为了应对无理数问题，古希腊数学家选择更多依赖**几何方法**而非算术来处理无理数的概念。欧几里得在其著作《几何原本》(Elements*) 中，系统化了几何学，通过线段、面积等几何量来间接表示无理数，成功绕过了当时无法表达无理数的难题。

几何化的处理方式成为希腊数学家解决无理数问题提供了一个有效的工具，维持了数学的逻辑一致性。几何学在这一危机后成为古希腊数学的主导分支。

2. 比与比例的概念 欧几里得在几何学中进一步发展了**比（比例）理论**，通过探讨不同长度线段之间的比例关系，间接处理无理数表达问题。在《几何原本》第十卷中，他讨论了不成比例的线段（即不能用有理数表示其比例的线段），这实际上就是无理数的一种几何表述。一个著名的例子是黄金分割比例。这种方法让数学家能够处理无理数带来的计算问题，并保持几何学的逻辑一致性。

3. 无理数的接受与扩展 虽然古希腊数学家未能明确提出“无理数”这一术语，但他们的几何手段为后来接受与正式提出无理数提供了基础。到 17 世纪，随着代数学的迅速发展，数学家们开始正视并重新定义数的概念。

无理数逐渐从几何比率演变为代数中的一类新的数字体系，并在数学的各个分支中逐渐占据了重要地位。

4. **实数体系的建立** 19 世纪，数学家通过构建更加严谨的实数理论彻底解决了无理数的表示问题。魏尔斯特拉斯等人通过极限和连续性的概念，为实数定义奠定了基础，构建了完整的实数体系，统一了有理数和无理数的表示方式。至此，无理数得到了明确的数学定义，彻底解决了自古希腊时期以来的无理数危机。

危机的意义

无理数危机的解决是数学史上的一大转折点，经过了数代数学家的努力。虽然无理数的发现带来了危机，但最终促使了数学向更高的层次发展。几何学的抽象化、代数学的进步以及实数体系的确立，标志着数学摆脱了毕达哥拉斯学派的局限，迈入了新的发展阶段。这场危机不仅将数的概念从有理数扩展到无理数，还为后来的数学分析和数论奠定了坚实的基础。

1.6.2 第二次数学危机：微积分基础的争议与解析

第二次数学危机出现在 17 世纪，伴随着**微积分**的诞生。微积分由牛顿和莱布尼茨独立提出，是解决变化率和曲线面积等问题的强大工具。

危机的产生

虽然在解决实际问题上取得了巨大的成功，但微积分的早期发展在理论基础存在许多模糊之处，尤其是关于**无穷小量** (infinitesimals) 的使用，引发了深刻的数学危机。微积分的核心思想之一是使用无穷小量来定义变化率和累积变化。比如，导数被定义为“函数的瞬时变化率”，而积分则表示曲线下面积的无限累加。然而，当时的数学家并没有严格定义什么是无穷小量，它既不能被归为零，也不是某个确定的数，以致于在某些推导过程中无穷小量一会等于 0，一会又不等于 0。这种模糊性使得微积分缺乏严密的逻辑基础，许多数学家无法接受微积分作为严格数学工具的合理性。贝

克莱等学者猛烈批评了微积分理论，指出其在逻辑上存在的缺陷，“微积分似乎依赖于‘幽灵般的消失量’”。

危机的解决

解决这一危机的关键在于**极限** (limit) 概念的引入。17 世纪末至 18 世纪初，数学家们逐渐认识到，无穷小量可以通过极限概念加以精确描述。极限理论通过定义函数在某一点附近的行为，能够描述无穷小量趋于零的过程，避免对模糊无穷小量概念的依赖。

19 世纪，柯西和魏尔斯特拉斯等数学家通过引入**极限理论**，对极限、连续性、导数和积分的定义进行了重新审视，对微积分进行了严密的逻辑重构。

柯西首次明确使用极限概念来定义导数和积分，奠定了现代分析学的基础。而魏尔斯特拉斯则通过对极限的精确定义，彻底摆脱了无穷小量的概念，构建了严谨的微积分体系。极限概念取代了无穷小量，导数被定义为函数在某一点的瞬时变化率，积分则作为求和的极限。这一重新定义消除了无穷小量的模糊性，将微积分从模糊的直觉推导转变为明确的、严格的数学定义，确保了微积分中的推导和计算具有严格的逻辑基础。通过这种方式，微积分危机得到了全面解决，数学家们能够自信地使用微积分来解决变化率和复杂的动态问题。

随着分析学的成熟，数学推导的严谨性成为了核心标准。柯西和魏尔斯特拉斯等人的工作推动了数学分析的形式化，所有推导必须建立在清晰定义和严密逻辑的基础上。这种对严谨性的要求确保了未来数学发展的稳定性和一致性，使得数学成为了一门具有深厚逻辑基础的学科。

危机的意义

第二次数学危机的解决，标志着数学从经验性工具走向了更加严谨的理论体系。通过引入极限概念和分析学的系统化构建，数学家们不仅解决了微积分中的基础问题，还推动了现代数学分析的诞生。这一危机的解决

具有深远的意义，不仅使微积分成为物理学、天文学、工程学等领域的基础工具，还推动了整个数学的发展。微积分危机的解决使得数学家们对数、函数和极限有了更深刻的理解，并奠定了未来分析学和数理逻辑的基石。

1.6.3 第三次危机：集合论与无穷的悖论

第三次数学危机发生在 19 世纪末至 20 世纪初，伴随着**集合论**的诞生和发展。**康托尔**在 19 世纪提出了集合论，首次系统地研究了无穷集合的性质，并对无穷数进行了分类和操作。他证明了无穷集合不仅存在，而且可以通过不同的方式进行数学上的操作。然而，随着无穷概念的深入研究，数学家们开始意识到在无穷集合中存在的悖论，这些悖论挑战了数学的逻辑一致性。

最著名的悖论是**罗素悖论**。它揭示了集合论中定义集合的一些方式会导致自相矛盾。例如，考虑“所有不包含自身的集合的集合”这一定义，这样的集合如果包含自身就违反了定义，但如果不包含自身，它又应该包含自己。这种自相矛盾的问题对整个数学的基础提出了挑战，暴露了当时的数学体系存在严重的不完整性。

面对这些悖论，数学家们开始寻求解决方案。**希尔伯特**发起了一个庞大的计划，试图通过公理化数学来消除这些不一致性。**哥德尔的不完备性定理**最终表明，任何公理化体系内部都无法完全解决这些问题，数学总是存在某些无法在体系内部证明或证伪的命题。这一危机迫使数学家们重新思考数学的逻辑结构，并促成了数理逻辑、集合论以及形式化数学的深入发展。

1.6.4 第三次数学危机及其解决：集合论与逻辑基础的动摇

第三次数学危机发生在 19 世纪末至 20 世纪初，源自**集合论**的提出及其暴露出的逻辑悖论问题。康托尔所创立的集合论在数学上提供了一种全新的方法来处理无穷大和无穷小的问题，并在一定程度上统一了数学的基础。然而，随着对集合论的深入研究，数学家们发现其中隐藏着自相矛盾的

悖论，最著名的便是**罗素悖论** (Russell' s Paradox)。这一发现暴露了当时集合论的基础漏洞，动摇了整个数学体系的逻辑一致性，标志着数学史上的第三次重大危机。

危机的产生

康托尔在 19 世纪末提出了**集合论**，对数学领域产生了深远的影响。这一理论通过对无穷大的精确描述，为数学提供了处理无限集的新工具。此外，引入集合的概念，康托尔重新定义了数的构成方式。然而，随着集合论的推广，数学家们逐渐发现了一些无法避免的矛盾，特别是**自指悖论**，其中最具代表性的就是罗素悖论。

罗素悖论考虑这样一个集合：**所有不包含自身的集合的集合**，问这个集合是否包含自身？**如果该集合包含自身，就违反了自身的定义；如果不包含自身，又与定义矛盾。**

为了形象地说明**罗素悖论**，我们可以借用著名的**理发师悖论**。“理发师悖论”是罗素悖论的通俗表达版本，帮助我们更直观地理解其逻辑上的自相矛盾。

理发师悖论：

在一个小镇上，有一位理发师，他发布了这样一个规定：**他只为那些不自己剃须的人剃须**。也就是说，理发师为所有不自己剃须的居民剃须，而所有自己剃须的居民则不由理发师剃须。于是问题来了——**谁给理发师剃须？**

这个问题引发了两种情况：1. 如果理发师不自己剃须，那么根据规则，他应该由自己来剃须，因为他不属于那些自己剃须的人。2. 但是，如果理发师给自己剃须，他属于那些自己剃须的人，就不属于理发师的服务对象，理发师就不应该给自己剃须。

于是，无论理发师是否自己剃须，都会违反规则。这就是理发师悖论，它揭示了在规定中存在的自相矛盾。这个悖论的本质在于自指——理发师同时属于要剃须和不剃须的两种情况，从而导致了逻辑上的矛盾。

罗素悖论：罗素悖论与理发师悖论类似，它讨论的是**集合**的自包含问

题。它考虑这样的集合：**所有不包含自身的集合的集合**，问这个集合是否包含自身。

- 如果这个集合包含自身，那么它就不属于那些不包含自身的集合，因此不能包含自身。
- 如果这个集合不包含自身，那么根据定义，它必须包含自身，因为它属于那些不包含自身的集合。

因此，这种情况下也产生了自相矛盾，就像理发师悖论一样，这也是一种**自指性悖论**，在逻辑上无法自洽。

罗素悖论暴露出在集合论的基本定义中存在自相矛盾的逻辑缺陷，打破了数学家对集合论及其逻辑基础的信心。

这一悖论引发了数学家对数学基础的全面反思，特别是对数学逻辑和集合论的可靠性的质疑。如果作为集合论无法避免悖论，数学的逻辑基础和所有建立在这些逻辑基础上的数学理论也将面临同样的不确定性。

危机的解决

为了解决这一危机，数学家们开始重新审视数学的逻辑基础，试图通过更加严密的逻辑系统来修补集合论的悖论，并确保数学体系的完整性和一致性。解决这一危机的主要路径有以下几方面：

1. 形式系统的引入

解决罗素悖论的关键之一在于对数学进行形式化处理。以希尔伯特为代表的数学家提出了**形式系统**的思想，即通过定义一组公理和推理规则，将所有数学命题都归结为形式符号的推理。在这种系统中，所有推理必须严格按照形式化规则进行，以确保逻辑的自洽性。希尔伯特的形式系统被认为是解决罗素悖论的一种手段，因为通过形式化处理可以避免自指性和逻辑上的悖论。

希尔伯特的“公理化计划”试图通过一组完备的公理和逻辑规则构建数学的基础确保数学推理的一致性和完备性，并证明数学体系的无矛

盾性。然而，这一计划在哥德尔的不完备性定理面前遭遇了挑战，但它奠定了数学逻辑的基础，为后来的形式逻辑系统和数学结构提供了工具。

2. 类型论的提出

为了解决集合论中的悖论，罗素本人提出了**类型论** (Theory of Types)，该理论通过对集合进行分层，将集合划分为不同的类型，禁止集合包含自身或同类类型的集合，从而避免自指性带来的矛盾。这种层次化的集合结构避免了自指的产生，有效消除了罗素悖论带来的自相矛盾。但类型论也受到一些批评，特别是由于它的操作复杂性以及对数学理论应用的限制。然而，类型论在逻辑学和计算机科学中的应用仍然具有重要意义，尤其在编程语言理论中得到了广泛应用。

3. 公理化集合论

集合论的进一步发展得益于**策梅洛-弗兰克尔公理系统** (Zermelo-Fraenkel set theory, ZF)。这一系统通过一套精心设计的公理，对集合的构成和操作进行了规范化处理，避免了自指和无限回归等问题，消除了罗素悖论的根源。策梅洛首先提出了以选择公理为基础的集合论公理系统，后来弗兰克尔对其进行了扩展，形成了 ZF 体系。ZF 公理化系统通过严格的公理定义，为集合论提供了一个无悖论的逻辑基础，确保了数学推理的可靠性。

ZF 集合论不仅为集合论奠定了坚实的基础，还成为了现代数学中集合论的标准体系。通过公理化的方式，数学家能够在逻辑上避免悖论，同时也确保了数学体系的逻辑一致性和严格性。**举个例子**

4. 哥德尔不完备性定理

尽管公理化的集合论解决了逻辑悖论问题，但库尔特·哥德尔 (Kurt Gödel) 的**不完备性定理** (Gödel's Incompleteness Theorem) 揭示了一个新的局限性：在任何足够复杂的公理系统中，都存在一些命题，既

无法在系统内部证明其真伪，也无法推翻。这一结果否定了希尔伯特的完备性计划，证明了即便数学可以通过形式系统避免自相矛盾，也无法保证其逻辑的完备性。数学在本质上是无法完备的。

尽管如此，哥德尔不完备性定理并未动摇数学的基础，反而让数学家更加意识到逻辑系统的局限性。数学家因此更加重视逻辑学的精密性，推动了数理逻辑和元数学的进一步发展。

危机的意义

第三次数学危机通过公理化、形式系统、类型论和逻辑分析的多重努力得到了有效解决。这一危机不仅推动了数学基础理论的深入研究，也促使数学家对逻辑一致性和严密性的要求更为严格。通过策梅洛-弗兰克尔公理化体系，数学家为现代集合论提供了无悖论的基础。尽管哥德尔的不完备性定理提出了数学体系不完备的本质限制，指出数学系统永远不可能完美无缺，但它同时也为数学逻辑的发展提供了新的方向。

这一危机的解决，使得数学从逻辑上更加稳固，并为后续的数学研究奠定了更高标准的严谨性。数学基础的重建不仅加强了数学逻辑的力量，还推动了现代数学向更高层次的抽象发展，为数理逻辑、模型论和计算理论等新兴学科的诞生铺平了道路。

这些三次数学危机深刻影响了数学的演进，促使数学家们不断重新审视基本概念，并推动了数学向更高的抽象层次发展。每一次危机的解决不仅重塑了数学的结构，还推动了新领域的诞生，使数学始终在挑战中突破，走向新的高度。

1.7 小结

纵观历史，数学的应用几乎渗透到了每一个领域中。人类历史上的每一个重大事件的背后都有数学的身影：

- 达芬奇的绘画（15-16 世纪）

- 哥白尼的日心说（16 世纪）
- 牛顿的万有引力定律（17 世纪）
- 马尔萨斯的人口论（18 世纪）
- 巴赫的 12 平均律（18 世纪）
- 孟德尔的遗传学（19 世纪）
- 晶体结构的确定（19 世纪）
- 人人平等（所有的直角都相等）、三权分立的政治结构（19 世纪）
- 无线电波的发现（19 世纪）
- 巴贝奇的“机械”计算机（19 世纪）
- 达尔文的进化论（19 世纪）
- 爱因斯坦的相对论（20 世纪初）
- DNA 双螺旋疑结的打开（20 世纪）
- 冯·诺依曼的二进制编码和现代计算机（20 世纪）
- 图灵机（20 世纪）
-

1.8 简明数学史

课本中字斟句酌的叙述，未能表现出创造过程中的斗争、挫折，以及在建立一个可观的结构之前，数学家所经历的艰苦漫长的道路。学生一旦认识到这一点，他将不仅获得真知灼见，还将获得顽强地追究他所攻问题的勇气，并且不会因为自己的工作并非完美无缺而感到颓丧，实在说，叙述数学家如何跌跤，如何在迷雾中摸索前进，并且如何零零碎碎地得到他们的成果，应使搞研究工作的任一新手鼓起勇气。

克莱因，《古今数学思想》序言

数学的发展历程如同一条不断延展的长河，从最初的数字发明，到公元前 5 世纪的希腊数学奠基，再到随后的数千年中，数学逐渐演变为一门多维度、多分支的科学。通过计算与推理的结合，数学不仅成为解决现实问题的工具，也升华为探索抽象概念与逻辑关系的强大思维体系。

数学的发展史可以大致划分为四个不同的时期：数学萌芽时期、初等数学时期、近代数学时期和现代数学时期。需要说明的是，精确地划分这些阶段是不可能的，因为每个时期的特征都是在前一时期的基础上逐渐形成的。然而，这些阶段反映了数学在每个历史阶段中的不同侧重与进步，揭示了数学从最早的经验积累到复杂的理论构建，乃至今天在科技与智能领域的广泛应用的深刻演化。每个时期都在数学发展中扮演了不可或缺的角色。

让我们依次回顾这些数学发展的重要阶段，探索其背后的历史背景与核心成就。

1.8.1 数学萌芽时期

数学的萌芽时期从远古时代延续至公元前 5 世纪，是人类最早利用数学工具应对日常生活需求的阶段。

这一阶段的数学起源于最基本的数数活动。通过手指计数、刻痕和结绳等原始计数手段，人类逐渐形成了自然数的概念。自然数的确立是数学

发展的第一步，也是人类对数量的最早认识。从简单的数数开始，逐渐发展出加减乘除等基本运算，为解决日常生活中的问题提供了有效的工具。

古埃及人发展了一些基础的几何公式，在建造金字塔时已经能够运用高度和角度的几何关系；美索不达米亚的会计师不仅掌握了加法和乘法，还能够解简单的二次方程，用于管理粮食和资源。古代美索不达米亚和埃及的泥板和石刻记录了这些早期的数学活动，展现了数学与生活实践的紧密联系。

巴比伦人对天体运动的观察和历法推算也推动了数学的发展。为了精确预测日食、月相以及制定历法，巴比伦的天文学家需要处理大量的时间和角度计算。这些天文观测不仅促进了数学在测量和计算方面的进步，也推动了几何和代数的进一步发展。

这一时期并没有明确的个人数学家记载，更多的是群体性活动。古埃及的建筑师和美索不达米亚的会计师是这一阶段数学发展的重要推动者。埃及人在几何测量中的应用和美索不达米亚人对天文学和代数的研究，构成了数学早期发展的代表性成就。

这一阶段的数学活动是解决问题的经验性工具，尚未形成系统的理论。但它为后续的数学体系发展奠定了数与形的概念基础。

1.8.2 初等数学时期

公元前 5 世纪开始，数学进入了初等数学时期。这个时期的数学探索更加系统和深入，尤其是在欧几里得几何和代数方程的研究中，数与形的关系得到了更加严谨的探讨，算术、几何、代数和三角等数学分支逐渐成形。

毕达哥拉斯：数与宇宙的关系

数学的哲学化起点源自古希腊的毕达哥拉斯学派。毕达哥拉斯 (Pythagoras) 及其追随者提出了“万物皆数”的思想，认为宇宙的本质可以通过数来理解。这一理念激励了希腊数学家们将数学视作解读自然现象的工具。

毕达哥拉斯定理（即勾股定理）是这一学派最著名的成就之一，标志着数学开始从经验性计算向理性推理的迈进，开启了数与形结合几何学研究。

欧几里得：公理化体系的奠基人

如果说毕达哥拉斯奠定了数学的哲学基础，那么欧几里得（Euclid）则为数学建立了逻辑结构。他的《几何原本》（《Elements》）是古代数学史上最具影响力的著作之一，也是现代数学公理化体系的奠基之作。

欧几里得通过公理和定理的形式，系统地将几何学结构化，强调了证明的重要性。欧几里得展示了如何从少数的基础假设（公理）出发，通过严密的逻辑推导，推导出一系列复杂的几何命题。这种公理化方法对后世的数学家产生了深远影响，甚至成为了现代数学研究的重要框架。欧几里得的几何不仅仅是关于形状和空间的学问，更标志着数学作为一种基于推理的演绎学科的正式诞生。

阿基米德：数学与物理的桥梁

阿基米德（Archimedes）是古希腊另一位杰出的数学家，他不仅在数学领域取得了重大的突破，还在物理学、机械学等领域做出了重要贡献。阿基米德将几何与物理现象紧密结合，开创了利用数学模型解决物理问题的先例。

他在几何领域的突破，如圆周率的近似计算、浮力定律及流体静力学基本定理的证明，展示了数学在物理学应用中的强大力量。阿基米德的工作不仅扩展了数学的应用范围，还展现了数学在解释自然现象中的力量。

亚里士多德：逻辑与推理

亚里士多德（Aristotle）是古希腊著名的哲学家。亚里士多德认为，数学不应只停留在经验性的层面，而应该通过演绎推理去发现隐藏在事物背后的逻辑关系。他提出的三段论和归纳法，帮助数学家们更好地理解 and 构

建逻辑推理过程。这种逻辑推理体系推动了古希腊数学的进一步发展，数学家们开始通过推理和证明而非直观的经验得出结论。

算术与几何这两大分支的创立，标志着数学开始作为一门理论化学科的诞生，逻辑推理和证明逐渐成为数学的核心方法。与此同时，代数学在这一时期取得了重要进展，自然数、有理数和无理数的运算逐渐成为代数的核心主题。除此之外，这一阶段的代数学还开始引入虚数，推动了数的概念向更广的领域扩展。

古希腊数学的遗产

通过抽象思维和逻辑推理，建立了数学作为一种独立学科的基础。古希腊数学家们的贡献不仅仅是发现了一些几何定理和代数法则，更重要的是他们发展了数学思维的方式——通过演绎、证明、公理化等方法，将数学从经验性工具转变为一种严谨的科学。这一传统不仅奠定了现代数学的基础，还推动了之后数千年数学和科学的进步。

中世纪的阿拉伯数学家翻译了希腊经典，并引入了印度的十进制数和“零”的概念。阿尔·花刺子密 (al-Khwarizmi) 等数学家对代数学的发展做出了巨大贡献，他的著作奠定了代数理论奠定了坚实的基础。

中国的《九章算术》和印度的基础代数成就，也为初等数学的发展增添了重要内容。中国古代数学强调实用性，广泛应用于农业、建筑和税务管理；而印度数学则对数论和代数的早期发展做出了杰出贡献。这些不同文化的数学成果，最终共同塑造了初等数学的广阔基础。

这一时期涵盖了公元前 5 世纪到 17 世纪前的数学发展。数学不再仅限于解决实际问题，而是向抽象领域迈进。古希腊数学通过几何学和数论的研究，构建了数学推理和证明的数学体系。这一阶段的数学成就不仅构成了今天中学数学的主要内容，还对现代数学的基本理论结构产生了深远的影响。

1.8.3 近代数学时期

从 17 世纪开始，随着资本主义的崛起和工业革命的推动，数学进入了一个全新的阶段——变量数学时期。这一时期的数学从研究静态图形和数量问题逐步转向关注变化与运动问题，变量和函数的引入是更好描述运动和变化的关键。

牛顿和莱布尼茨分别独立发明了微积分，标志着数学史上一个重要的转折点。微积分提供了一套精确描述连续变化与瞬时变化的数学工具，成为解决诸如速度、加速度、曲线下面积等问题的强大工具。牛顿通过微积分为物理学中的万有引力定律奠定了理论基础，而莱布尼茨则将微积分符号化并推广到欧洲，极大地推动了数学的发展。微积分不仅让数学得以分析瞬时变化，还为后续的数学分析开创了新的方向。

解析几何的诞生是这一时期的另一个重大突破。笛卡尔通过引入坐标系，将几何与代数结合起来，使得复杂的几何图形、物理的运动及其空间关系可以通过代数方程来精确描述。借助于笛卡尔坐标系，数学家们能够用代数表达曲线、直线的关系，从而简化了几何中的很多问题。解析几何不仅为物理学中的动力学提供了有力工具，还为现代数学的发展铺平了道路。

近代数学时期的另一个重要分支是概率论。概率论起初由费马和帕斯卡为了研究赌博中的随机事件而诞生，但很快超越了这一领域，成为研究不确定性和随机现象的重要工具。费马还对数论做出了重要贡献，提出了许多关于素数与数之间关系的问题，激发了后世数学家对数论的广泛研究。欧拉、拉格朗日等人进一步推动了数论的发展，探讨了代数结构和数论的基本问题。

与此同时，分析学作为微积分的延续，成为这一时期的核心数学分支。通过函数和极限概念的引入，数学家们能够处理无穷小量和变化中的量，开创了分析学的时代。数学分析不仅成为这一时期的核心理论，不仅解决了古希腊时期悬而未决的几何问题，还广泛渗透进了物理学、天文学和工程学，极大地推动了科学的进步。

从 17 世纪开始，数学逐步系统化，并成为理解自然世界的核心工具。

科学革命带动了数学的飞速发展，数学不仅在传统的代数和几何领域取得了突破，还在物理学、天文学、工程学等领域中发挥了重要作用。变量数学的引入让人们能够更好地理解宇宙中的变化与运动，推动了自然科学的进步。

总的来说，近代数学时期不仅为数学的进一步抽象化奠定了基础，还通过微积分、解析几何和概率论的兴起，彻底改变了人类对世界的理解方式。数学在这一时期的变革性进展，成为了现代数学发展的根基，也为科学技术的进一步进步提供了强有力的工具。

1.8.4 现代数学时期

从 19 世纪中叶起，数学进入了一个高度抽象化和系统化的阶段，被称为现代数学时期。这个时期的数学阶段不仅延续了之前的分析学发展，还引入了全新的几何和代数理论。代数、几何和分析学等传统学科在此期间发生了质的飞跃，数学的研究对象和方法也逐渐向高度抽象化发展，推动了数学成为一门更加系统和广泛应用的科学。

现代数学的一个显著特征是对数学基础的重新审视与抽象概念的扩展。罗巴切夫斯基和黎曼的非欧几何，颠覆了传统欧几里得平面几何观，提出了球面和鞍面等不同几何结构，揭示了更为广泛的空间和结构关系。并为爱因斯坦的广义相对论提供了数学基础。拓扑学作为新的分支，也在 19 世纪逐渐兴起，打破了传统几何的局限，成为数学研究连续性、边界与形态的重要工具。

同时，现代数学的发展离不开对无穷概念和数学基础的深入研究。康托尔的集合论，为处理无穷大的数学研究提供了严格的工具，将无穷大和无穷小的概念精确化，成为现代数学和数理逻辑的基础理论之一。集合论的发展不仅使数学在抽象层面上得以统一，还激发了对数学自身基础的研究。集合论和数理逻辑的兴起为数学理论提供了全新的理论框架，希尔伯特、哥德尔等数学家在此领域的工作，使得数学的公理化体系进一步得到发展与完善。

20 世纪，统计学、拓扑学、泛函分析等新分支陆续创立，使数学更多元化、更富实用性。数学在众多领域的应用范围得到了前所未有的扩展，数学在物理学、工程学、经济学以及其他自然科学和社会科学等各个学科中的作用变得愈加重要。

现代数学时期的另一个重要推动力是计算机的发明和信息技术的迅猛发展。20 世纪中期，图灵、冯·诺依曼等科学家为计算机科学奠定了理论基础，计算理论逐渐成为数学的重要分支。计算机的强大计算能力使得复杂的数学问题得以快速求解，同时也极大地推动了数理逻辑和算法理论的发展，数学的潜能和边界更进一步发掘。

随着数学的抽象化与理论化趋势日益加深，数学在深入自然科学领域的同时，还广泛渗透到信息科学、工程学、经济学、社会科学等多个领域，推动了现代社会各个层面的进步。现代数学逐渐成为理解自然世界、构建理论模型和推动技术创新的核心力量。

总之，现代数学时期是数学高度抽象化、系统化的阶段。数学基础理论的深入研究与应用范围的广泛扩展，使得数学不仅在理论层面得到了重大发展，也成为了推动科学和技术进步的关键推动力。通过集合论、非欧几何、拓扑学和计算理论的引入与发展，数学在 20 世纪的进步为现代社会的各个领域带来了不可忽视的影响。

1.9 小结

纵观以上四个时期，数学的发展脉络清晰呈现。数学从最初解决日常问题的工具，逐步演化为一门以逻辑推理和抽象思维为核心的科学。数学史既是一部理论创新史，也是一部与社会发展和科学进步紧密相连的演进史。

从萌芽阶段的经验性计算到古希腊数学家奠定的逻辑推理基础，再到近代变量数学的飞跃和现代数学的高度抽象化，数学经历了从实用工具到抽象学科的跨越。随着社会与科学的持续发展，数学也成为了理解世界、解决问题和推动技术进步的核心力量。

Chapter 2

人工智能的三种思维：从理论到应用的跨越

发展数学理论是一回事，实现它又是另一回事。

——约翰·冯·诺伊曼

来自应用，回归应用：从数学思维到算法思维到工程思维

数学思维：

-理想情形 -存在性 -可构造性

算法思维

-算法复杂度 -算法优化 -稳定性

工程思维

-允许误差 -大规模问题 -鲁棒性 -经济效应

举一些数值算法稳定性的反例

例：近似计算 $S_n = \int_0^1 \frac{x^n}{x+5} dx$ ，其中 $n = 1, 2, \dots, 8$ 解： $S_n + 5S_{n-1} = \int_0^1 \frac{x^n + 5x^{n-1}}{x+5} dx = \int_0^1 x^{n-1} dx = 1/n$ 无论何种学问，构建理论是一回事，将其付诸实现则是另一回事。AI 的研究同样如此。

AI 研究的复杂性不仅源于理论的深度，还在于将其应用于现实世界的挑战。解决一个 AI 问题往往要求从**数学思维**、**算法思维**和**工程思维**三个方

面进行多角度思考。数学、算法和工程三种思维方式既互相联系，又各有侧重，从不同层面定义了 AI 的研究框架：数学思维为理论提供框架，算法思维将其具体化为可计算的实现方案，工程思维则确保方案在现实中的可行性和应用价值。数学、算法和工程三种思维共同构成了全面理解和解决 AI 问题的整体方法论。

本章将深入探讨这些思维方式，理解它们如何在不同层面上塑造现代智能系统的实现路径。

2.1 数学思维：定义和可能性的框架

数学思维是 AI 研究的起点，为定义、分析和解决智能与学习的基本问题提供了框架。通过数学思维，研究者得以抽象出智能和学习的核心科学问题，构建符合逻辑且可行的智能模型，并进一步探索其解的存在性和特性。对于 AI 而言，这不仅意味着找到一组解，更是考量这些解在理想条件下的**存在性**、**唯一性**和**构造性**，确保从逻辑上能够定义和证明智能的实现可能性。

主要体现在以下几个方面：

1. **理想情形**：数学思维的“理想情形”，是指研究者通常在简化、理想化的环境中建立模型，以便能够从纯粹数学的角度分析智能系统的潜在行为和特性。例如，
 - **线性模型的假设**：在早期的机器学习和回归分析中，常假设数据间关系是线性的，这使得问题的分析和求解可以通过线性代数完成，虽然实际中数据往往具有非线性特性。
 - **凸优化假设**：在神经网络训练中，我们假设损失函数为凸函数来分析算法收敛性和解的稳定性，因为凸函数可以保证找到优化问题存在全局最优解。然而实际中的损失函数往往是非凸的，导致全局最优解难以找到，但凸优化理论仍为非凸优化的启发式方法提供了基础。

- **无噪声数据假设：**在信号处理或统计学习中，我们通常假设数据没有噪声，即数据完全准确无误。这个理想情形让我们可以专注于分析算法的基本特性和效果。尽管现实数据几乎总是带有噪声，这一假设帮助我们更清楚地理解算法在“最优条件”下的性能。
- **完全信息假设：**在强化学习中，通常假设智能体可以完全观察到状态的所有信息（完全信息），这被称为马尔可夫决策过程 (MDP)。这一理想假设使得我们能够推导出解决 MDP 的核心算法，如 Q-learning 和动态规划，从而允许智能体基于当前状态做出最优决策。尽管在实际应用中，智能体常只能观测到部分信息，信息往往是不完全的。因此需要用部分可观测马尔可夫决策过程 (POMDP) 来建模。
- **均匀分布假设：**在随机算法或统计推断中，均匀分布是理想化的假设之一。例如在蒙特卡洛模拟中，假设数据或样本来自均匀分布以简化概率计算。均匀分布假设常常使得复杂问题更易于处理，尽管在现实中，数据的分布通常不均匀，这一理想情形仍为其他分布下的理论分析提供了起点。

这些理想情形帮助研究者在数学框架下构建简化模型，使得智能系统的行为可以被有效分析。这些理想化的假设虽然不完全适用于现实中的复杂性，但为现实条件下的实际研究提供了启发。

2. **存在性问题：**在数学中，解的存在性是算法设计的前提，它告诉我们所研究的问题是否具备可解性。存在性解答了“问题是否有解”的疑问，是算法设计的理论依据。例如：
 - **支持向量机研究中的最优超平面：**在分类问题中，支持向量机通过优化理论证明最优超平面的存在性，确保能够找到一个分隔两类数据的最佳边界。
 - **多目标优化问题的帕累托前沿：**在多目标优化中，通过证明帕累托

托前沿的存在性，确定可以找到在各目标之间无明显优劣关系的解集。这种存在性证明在多目标场景下尤为关键。

- **神经网络中的逼近定理：**神经网络的万能逼近定理表明，只要层数和神经元数量足够多，前馈神经网络就能够逼近任意连续函数。这一存在性定理确保了神经网络在理论上具备学习复杂映射关系的能力，为构建强大的模型提供了可能性。

3. **可构造性：**数学思维不仅关注解的存在，还注重解的具体实现可能性，即可构造性。这确保所设计的算法在理论上可行，且实际可实现。例如：

- **梯度下降法：**在最优化问题中，存在最优解并不足够，还需有具体方法找到该解。梯度下降法是一种有效的数值方法，通过逐步调整参数接近最优解。可构造性使梯度下降能够成为实际优化问题的核心算法。
- **数独问题的解构造：**存在性证明表明数独问题有解，但要找到这个解则需要特定的构造方法。回溯算法是一种常见的求解数独问题的方法，保证了解的具体实现可行性。
- **矩阵分解的可实现性：**在主成分分析（PCA）中，矩阵的特征值和特征向量的存在性说明解是存在的，但通过特征分解构造出主成分的实际计算方法则体现了解的可构造性。这让 PCA 能够在实际中应用于数据降维。

可构造性这一思想是从数学思维向算法思维的自然过渡，使得理论上的解在现实中成为可计算、可操作的实际方法。

数学思维注重理论上的严谨性与可证明性。这确保 AI 能够在抽象层面上构建逻辑严密且可行的智能模型，并在理想条件下分析智能系统的行为，使得后续的计算实现与工程应用成为可能。

2.2 算法思维：从理论到可计算的路径

数学思维可以帮助我们抽象问题的本质特征，并提供理论基础，为智能系统的研究提供理论框架。而算法思维则是将这些理论转化为可计算、可执行的步骤与逻辑流程的关键。在 AI 研究中，算法思维至关重要，它将抽象的数学模型转化为可以实际执行的计算过程，并优化这些过程，使得它们不仅可行而且高效。

算法思维是数学理论向现实转化的关键步骤，它不仅关注算法的准确性，还要考虑其效率、稳定性和资源利用，使得算法可以在有限计算资源下实际执行。

算法思维主要体现在算法复杂度、优化和稳定性三个方面。

2.2.1 算法复杂度

复杂度分析是算法设计中的核心问题，尤其是在大数据和实时计算需求下。AI 模型往往面临大量计算，算法复杂度直接影响算法在处理大规模数据时的可行性和效率。

算法复杂度通常以**时间复杂度**和**空间复杂度**来衡量。时间复杂度描述了算法在数据规模变化时所需的运行时间，而空间复杂度则描述了算法在执行过程中所需的存储空间。

- 1. 时间复杂度：**时间复杂度反映了算法执行过程中，随着输入数据规模增长所需的运行时间。例如，在图像识别任务中，卷积神经网络 (CNN) 逐层提取图像特征，处理的复杂度随着网络层数和输入图片的分辨率增长而增加。通常情况下，时间复杂度衡量使用 O 记号表示：如 $O(n)$ 、 $O(n^2)$ 等， $O(n)$ 代表算法的执行时间与输入数据量成正比，而 $O(n^2)$ 代表执行时间随输入量的平方增长。在实际应用中，优化时间复杂度是确保 AI 模型可以在合理时间内完成任务的前提，这在需要实时反应的系统中尤为重要。

- **图像处理任务中的时间复杂度：**在图像分类和物体识别任务中，模型需要处理数百万像素，提取特征用于分类任务。卷积神经网络（CNN）通过引入局部感受野和共享权重的机制，大大降低了计算复杂度，使得大规模数据集上的高效图像识别成为可能。CNN 的优化不仅使得算法适用于海量图片处理，也为自动驾驶中的实时物体识别提供了技术基础。

随着数据量和图像分辨率的提升，CNN 的卷积层和池化层操作将耗费大量计算时间。如果模型的时间复杂度过高，将难以满足实时处理的需求，尤其是在自动驾驶等需要实时反馈的应用场景中。自动驾驶中的物体识别算法必须在极短时间内完成复杂场景的分析，确保车辆能够快速决策。通过降低模型的时间复杂度或采用轻量化网络结构（如 MobileNet），可以提升处理速度，保障应用在实时系统中的响应速度。

- **推荐系统中的时间复杂度：**推荐系统在处理用户和商品数据的海量组合时，常面临计算复杂度的挑战。例如，协同过滤算法在传统情况下计算复杂度较高，需要遍历大量数据。随着数据量增大，计算的时间复杂度可能达到 $O(n^2)$ 或更高，使得推荐系统的实时计算难以实现。为此，一些优化方法，如矩阵分解和基于图的推荐算法，在复杂度控制上做出了优化，使得算法可以在大型电商平台和社交媒体中提供实时推荐。
- **大规模搜索算法：**搜索问题是经典的 AI 任务，比如导航系统的路径规划。传统的广度优先搜索（BFS）和深度优先搜索（DFS）在复杂度上表现不佳。A* 算法通过结合启发式搜索，在计算复杂度上得到了显著提升，确保算法能够在较短时间内完成最优路径的搜索。A* 算法应用于无人驾驶和地图导航中，使其能够快速找到从当前位置到目标的最优路径。

2. **空间复杂度：**空间复杂度描述了算法在运行中需要占用的内存资源，特别是在大规模数据处理时，空间复杂度的优化至关重要。在 AI 任

务中，许多算法需要在处理时临时存储中间数据和模型参数，如果空间复杂度过高，将会占用大量存储资源，导致效率低下甚至无法执行。

- **深度学习中的空间复杂度：**在深度神经网络中，每一层都需要存储大量权重和中间结果（如激活值）。随着模型的层数和参数数量增加，空间复杂度也会急剧上升，通常呈 $O(n^2)$ 或更高的增长趋势。例如，在自然语言处理任务中，BERT 等预训练模型含有数十亿个参数，其空间复杂度极高，要求高配置的硬件资源支持。为了降低空间复杂度，研究者提出了模型剪枝、量化和蒸馏等方法，通过压缩模型参数来降低内存需求，使得这些模型可以在移动设备和嵌入式系统上有效运行。
- **动态编程中的空间复杂度优化：**动态编程在许多 AI 算法中被广泛应用，比如在处理最短路径或最优策略的问题时。传统动态编程的空间复杂度往往较高，因为它存储了大量中间结果。为了解决这一问题，优化动态编程算法往往使用滚动数组等技巧，动态更新和覆盖原有存储，减少所需内存，达到空间复杂度的优化。例如，在自然语言处理中，使用滚动数组结构可以显著降低序列处理任务的空间需求，使模型更高效。

算法复杂度在 AI 算法设计中扮演着重要角色。通过分析和优化时间复杂度和空间复杂度，算法思维能够保障 AI 模型在大规模数据处理中的可行性和高效性。在图像识别、推荐系统、深度学习模型和动态编程等应用中，复杂度分析为算法的性能优化提供了有力的指导，使得 AI 能够在更大规模和更复杂的环境中得到广泛应用。

2.2.2 算法优化

优化是 AI 算法设计的核心，特别是在机器学习和深度学习中。优化算法不仅提升了效率，还使得 AI 模型在不同任务中的表现更加优良。算法优

化直接关系到模型的精度和速度，通过减少算法运行时间或提升算法性能，确保模型更加高效、准确。

在 AI 领域，优化问题无处不在。

- **深度神经网络训练：**反向传播（Backpropagation）算法是深度学习模型训练的基础，需要对神经网络中的每一个参数进行优化。传统的随机梯度下降（SGD）会更新数百万个参数以最小化损失函数，但收敛速度较慢。Adam 优化器、RMSprop 等改进算法通过自适应调整学习率，显著提升了收敛效率并降低了陷入局部最优解的风险。优化算法不仅减少了训练时间，还提高了模型的泛化能力，使得深度学习可以在诸如语言翻译、图像分类等任务中取得更高的准确率。
- **强化学习中的策略优化：**在强化学习中，优化算法同样起着关键作用。比如 Q-learning 是一种经典的算法，用于离散环境中的策略优化。然而在连续和高维环境中，这种方法不适用，研究者采用了深度强化学习（如 DQN 和 PPO），通过神经网络来逼近 Q 值，使得强化学习可以在复杂的任务中表现出色。策略优化提升了 AI 系统在动态环境中的适应性，被广泛用于游戏 AI、机器人控制等领域。
- **机器学习中的模型压缩：**在移动设备和嵌入式系统中，为了在有限的硬件资源下实现 AI 应用，研究者开发了模型压缩技术，如剪枝（Pruning）和量化（Quantization）。这些方法通过减小模型规模或精度，显著减少了计算资源的需求。优化算法在资源有限的环境下保证了模型的性能，使得图像处理、语音识别等任务可以高效运行在移动设备上。
- **强机器学习中的模型压缩：**在移动设备和嵌入式系统中，为了在有限的硬件资源下实现 AI 应用，研究者开发了模型压缩技术，如剪枝（Pruning）和量化（Quantization）。这些方法通过减小模型规模或精度，显著减少了计算资源的需求。优化算法在资源有限的环境下保证了模型的性能，使得图像处理、语音识别等任务可以高效运行在移动

端设备上。

2.2.3 算法稳定性

AI 算法的稳定性决定了 AI 模型在不确定环境下的可靠性和鲁棒性。稳定性分析关注算法在不同输入或噪声干扰下保持输出一致性的能力。AI 应用常在真实世界数据中遇到噪声和变化，因此稳定性在 AI 算法中的作用至关重要。

- **金融预测中的噪声处理：**在金融预测模型中，数据中常常充满噪声，市场波动的微小变化会对模型产生巨大影响。稳定性在此类模型中尤为重要，因为市场数据的噪声可能导致预测不准确。研究者们采用正则化技术（如 L2 正则化）来增加模型的鲁棒性，从而减少对噪声的敏感性，以提升金融预测的稳定性。
- **图像识别的抗扰性：**图像识别模型需要对噪声和输入扰动具备一定的抗扰性。例如，在自动驾驶应用中，摄像头捕获的图像可能受到光照、天气等因素的影响。通过使用数据增强技术，如随机旋转、剪切和颜色抖动，可以在训练时加入不同的场景变化，使模型在不同环境下表现稳定。抗扰性提升了算法的鲁棒性，保证了图像识别在多变环境下的性能。
- **自然语言处理中的错词纠正：**在自然语言处理（NLP）应用中，输入的文本数据可能存在拼写错误、口语化表述等问题。若模型的稳定性不佳，则可能因轻微的输入错误而产生误判。通过数据增强或错词处理技术，模型可以识别不同拼写变体并正常输出，提升模型在不完美数据上的表现。这种稳定性确保了语音助手和智能客服系统的回答更符合用户需求。

通过算法思维，AI 研究不仅将理论转化为可计算的流程，还推动了算法的创新与优化。算法思维为 AI 模型的实现提供了系统化路径，奠定了模型在现实环境中的计算基础。

通过控制算法复杂度、运用优化技术以及设计稳定性保障，算法思维为 AI 模型在多样化应用中的高效执行提供了坚实基础。从图像识别、推荐系统到金融预测和自动驾驶，算法思维驱动了 AI 从理论到实践的系统转化，确保了模型的高效性和可靠性，为其在实际场景中的应用奠定了可靠保障。

2.3 工程思维：从可计算到可用的实际落地

工程思维是 AI 从理论和算法走向现实应用的关键一步，是 AI 算法应用到实际中的最终环节。数学和算法的严谨性使 AI 模型具备了逻辑上的可行性和计算上的可操作性，而工程思维则进一步推动了 AI 的实际应用，使之能够在多变的环境中高效、可靠地运行，并满足实际应用中的多种约束。

工程思维的核心在于将可计算的算法转化为可用的产品和服务，确保 AI 系统不仅具备计算能力，还在真实场景中展现出足够的适应性和鲁棒性。工程思维面向大规模可用的解决方案，所以它关注如何在复杂的现实环境中有效落地算法，确保模型在真实场景中不仅能运行，而且高效、可靠，并满足实际应用中的各种约束。

AI 系统在面对真实世界时，不仅要完成预设任务，还要应对复杂多变的环境。工程思维因此强调对实际应用需求的适应，包括适度误差、大规模计算、鲁棒性、可扩展性、成本效益等方面，使得 AI 系统在应对现实复杂性时具有稳定性、扩展性和经济性。这一思维推动将理论模型和技术转化为可以普遍应用的大规模解决方案，真正满足不同领域的实际需求。

- **误差容忍与容错性：**

在实际应用中，完全精确的计算通常既不必要也不经济，因此允许一定范围的误差成为工程优化的必然。在面对真实世界的的数据时，精确解往往不如近似解更具实际价值。适当的误差容忍不仅降低了成本，还使得系统更加高效。为了提高速度和处理复杂问题的灵活性，工程思维鼓励在确保总体决策质量的前提下接受一定误差，这种做法使 AI 系统在处理非结构化数据时更加实用。

例如，在**图像识别**任务中，模型可能因为噪声或光线的变化而产生轻微偏差，只要这种误差不影响整体决策，就可以在工程应用中接受。这种误差容忍的思想是图像识别模型能够更快速地处理图像，实现实时响应。

在**自动驾驶**中，虽然系统要求高精度的物体识别，但在特定场景中允许适度误差，以提高系统的响应速度，使车辆能够迅速应对环境变化，从而兼顾精度和实时性。

在**推荐系统**中，算法并不需要找到完美的推荐，只要提供与用户兴趣足够相关的内容即可。因此，推荐算法在计算上允许一定误差，以确保系统能在用户实时使用中快速响应，提供流畅的体验。

同样地，语音识别系统在噪声、口音等因素影响下，难以保证绝对准确。语音识别通常接受小误差，使得语音识别在不牺牲用户体验的情况下维持高效的响应速度，避免因追求精度而导致反应速度过慢。举例：微信的语音识别

这种允许适度误差的工程思维在 AI 系统的设计中至关重要，它在确保足够精度的同时，使系统具备了适应性与高效性，在精度与实时性之间找到最佳平衡。

- **大规模问题的高效处理**：现实应用的规模往往远超实验室环境，在现实场景中，AI 系统常常面临大规模数据的处理需求。为了实现大规模应用中的高效响应，工程思维通过分布式计算和数据并行处理技术，将算法复杂度优化和资源合理调度结合在一起，使得系统能够在短时间内完成数据分析和结果返回，实现了大规模数据处理的高效性。

例如，

在**搜索引擎**中，算法需快速处理数十亿条网页数据，以秒级响应用户搜索请求。为了实现这一点，工程思维通过分布式计算、并行处理等技术，使算法能够在极短时间内完成大规模数据分析。

在**推荐系统**中，处理数百万用户和上亿个商品的海量数据是系统的常

态。推荐系统需要在最短时间内生成个性化推荐结果，这不仅依赖于优化算法的设计，还需要使用分布式计算技术来支持大规模并行处理，将复杂任务拆解成小块，以应对海量数据处理。这不仅提升了系统的实时响应能力，还使得模型能够适应用户需求的动态变化。

在**图像分类**和**自然语言处理**任务中，处理大型图像数据集（如 ImageNet）或长文本数据也面临相似的需求，单一计算节点的资源通常不足以应对这些任务。因此工程上通常采用分布式训练，将模型任务分配到多节点、多服务器环境下并行处理，以大幅提升系统的整体计算能力和响应效率。这种方法为图像处理、文本处理等大规模应用提供了计算基础，使得系统能够高效应对海量数据。

- **鲁棒性设计**：现实的 AI 应用面对的是动态、不可控的环境。工程思维要求 AI 系统具有鲁棒性，即在面对数据波动、异常输入、设备差异、环境干扰及复杂环境时，仍然能够保持稳定和可靠。鲁棒性是工程设计中的一个关键因素。

以**自动驾驶系统**为例。自动驾驶系统必须在各种天气、复杂路况和突发交通状况中保持稳定运行，这对鲁棒性提出了极高要求。自动驾驶系统集成多传感器（如摄像头、激光雷达、雷达）以提供冗余信息，即便某一传感器受干扰，其他传感器也能保障系统运行。此外，通过大量极端场景的仿真训练和场景测试，系统获得应对突发状况的能力，使其在毫秒级时间内完成环境识别、路径规划和避障决策。这种鲁棒性设计确保了自动驾驶在复杂环境中的安全性和可靠性。

在**医疗 AI** 应用中，系统需要在面对患者数据的多样性和变化时保持高精度。不同医院的设备和数据采集方式各异，导致患者数据可能受到噪声或设备偏差的影响。为确保 AI 模型在多样化输入下的稳定性和准确性，工程思维通过鲁棒性测试和参数调整，使系统能够应对现实中的数据波动和异常情况。例如，通过鲁棒性设计，AI 模型能够针对噪声和设备差异进行优化，即便在不同医院或检测设备的条件下，依然能够提供高效、精确的结果，从而保障医疗 AI 系统在动态、复

杂的现实环境中的可靠表现。

自动驾驶系统是另一个典型案例。自动驾驶需要应对复杂的路况和多变的环境因素，包括雨天、夜晚以及突如其来的障碍物等。这就要求系统在极端条件下依然能够迅速做出可靠的决策。通过工程思维中的鲁棒性设计，系统在不同环境下均能稳定运行，从而保障了自动驾驶的安全性和可靠性。

在**金融预测系统**中，市场数据波动剧烈，且受多种因素的影响。为了避免因市场剧烈波动导致的系统失效或错误决策，AI 模型必须具备足够的鲁棒性。工程思维在这里通过确保系统在市场波动中仍能保持一致性表现，从而使 AI 模型在极端经济条件下也能做出稳健的预测，提升了系统的可靠性和实用性。

综上，通过对鲁棒性的重视和设计，工程思维确保了 AI 系统在复杂且不确定的环境中依然保持高效和稳定的表现，使得 AI 在实际应用中更加可靠和可用，能够在不同环境下正常运行，应对各种现实干扰。

- **经济效益与资源效率：**

工程思维不仅关注 AI 系统的性能，还重视资源利用率和成本效益，以确保系统在真实应用中既高效又经济。

例如，在**边缘设备**上的 AI 应用（如智能家居设备）对计算和存储资源极其有限，需要设计简化版的模型，确保高效运行的同时控制成本。此外，通过低精度计算或量化方法，工程思维可以在性能和资源消耗之间取得平衡。

例如，在**边缘设备**上（如智能家居或便携式健康监测设备）运行的 AI 应用，计算和存储资源非常有限。工程思维在此强调模型的轻量化，通过**低精度计算、模型量化和剪枝**等优化技术，降低功耗和存储需求，使得 AI 应用在受限资源条件下也能高效运行，从而实现规模化应用的经济可行性。

在**医疗 AI** 领域，成本效益同样至关重要。过高的系统成本会限制技

术的普及，而过低的资源配置则可能影响性能，因此工程思维要求在性能和经济性之间找到合理平衡，使系统既具备商业价值，又具备可持续性。这种成本与资源的平衡，使得 AI 技术在多样化应用场景中得以普及，满足了不同行业对可靠性和经济性的需求。

工程思维让 AI 技术从实验室中走向真实场景，为其提供了落地所需的弹性和适应力，使得 AI 系统在多变的现实环境中稳定、可靠地运行，从而解决多样化的实际问题。

通过允许适度误差、处理大规模数据、提升系统鲁棒性以及优化经济效应，AI 系统实现了从可计算到可用的过渡，从理论模型转化为具有实用价值的技术系统，推动了 AI 技术在社会中的广泛应用。从自动驾驶、智慧医疗到工业自动化，工程思维赋予 AI 系统面对现实挑战的应变能力，确保其在各类场景中高效运作，让 AI 技术真正服务于社会需求，成为各行业不可或缺的技术支撑。

2.4 两个从数学思维到工程思维的例子

在本节中，我们将介绍推荐系统和数字图像处理，以此说明数学思维、算法思维和工程思维如何在 AI 系统设计和实现中层层递进、互相支撑。

2.4.1 数字图像处理：从理论到实际应用的三重思维

SVD 分解.....

以数字图像处理为例，我们可以从数学思维、算法思维和工程思维三个方面来探讨其在 AI 系统中的实现过程。

假设应用场景是一个**自动驾驶系统中的实时图像分类任务**，要求系统能识别交通信号、行人、车辆等关键元素。

2.4.2 数学思维：图像处理的理论基础

在数字图像处理任务中，数学思维定义了图像数据的处理方式以及背后的理论框架。数学思维关注图像的特性和转化，将复杂的视觉任务抽象为特征提取和分类问题。

图像表示与矩阵运算

图像在数学上被表示为矩阵，每个像素点对应一个矩阵元素。数学思维通过线性代数和矩阵变换帮助我们定义图像的基础处理方式。例如，通过卷积运算提取图像的边缘、角点和纹理特征，这些特征对于图像分类至关重要。

卷积操作的存在性与稳定性

卷积神经网络（CNN）使用了大量的卷积运算以提取图像特征。数学思维帮助我们证明卷积核在一定条件下能够提取稳定、有效的特征。例如，边缘检测的卷积核在任意位置都可以应用于图像，并且能够稳健地捕捉到物体边缘，这使得卷积在图像特征提取中的应用成为可能。

概率建模与分类

在图像分类任务中，我们通常使用概率建模来判断图像所属的类别。数学思维通过概率论确保分类器的准确性和一致性。例如，使用最大似然估计（MLE）来判断像素特征与目标类别的相关性，为图像分类奠定了理论基础。

2.4.3 算法思维：从理论模型到具体算法

在算法思维层面，我们将数学模型转化为具体的图像处理算法，以确保其在复杂的数据中具有可计算性、效率和鲁棒性。

时间复杂度

图像处理任务通常需要在短时间内完成大量计算，时间复杂度成为关键问题。例如，CNN 中的卷积操作通过共享权重来降低计算复杂度，使得算法能够在合理时间内处理大量图像数据。这一优化使得 CNN 在自动驾驶中的实时图像处理成为可能。

算法优化

为了处理大量图像数据并确保分类的准确性，算法思维引入了优化技术。比如，在训练 CNN 模型时，采用随机梯度下降（SGD）等优化算法不断调整参数，使模型的特征提取能力不断提高，从而达到更好的分类效果。这种优化不仅提高了分类的精度，还提升了模型的计算效率。

算法稳定性

图像处理系统在遇到不同光照、天气等条件变化时仍需保持稳定性能。算法思维通过数据增强和正则化技术，提高系统在不同场景下的稳定性。比如在自动驾驶中，对图像进行不同角度、亮度的调整，使模型更具有鲁棒性，避免因光照变化而影响识别效果。

2.4.4 工程思维：图像处理的实际落地

工程思维关注如何将图像处理算法部署在自动驾驶系统中，使得模型在真实环境中高效、可靠地工作。

允许误差

在自动驾驶中，图像识别算法需要高精度，但并不需要绝对的像素级精确度。工程思维允许对图像处理任务设定一定的误差范围，以提升系统响应速度。比如，在车辆检测中，模型只需定位到车辆的大致位置，无需完

全精确到每个边缘点。这种误差容忍确保了图像处理算法的实时性，提升了系统的整体性能。

大规模计算

自动驾驶系统通常会接收和处理多个摄像头的的数据，这对系统的计算能力提出了挑战。工程思维通过分布式计算和边缘计算等技术，确保系统能够实时处理海量图像数据。例如，通过将计算任务分配到不同的边缘节点，可以快速处理多个摄像头的图像，从而实现实时监控和决策。

鲁棒性

自动驾驶面临多变的环境，比如雨天、雾天、夜间等不同光照和天气条件。工程思维在图像处理系统的设计中加入了鲁棒性考虑，确保系统在多样化条件下依然可靠。通过预训练不同环境下的图像数据，模型在遇到特殊情况时能够适应并作出正确的响应，避免误识别或漏识别情况的发生。

经济效应

在自动驾驶的硬件中运行图像处理算法需要考虑成本。工程思维通过模型压缩、量化等方法，将算法转化为轻量化的模型，确保其在有限的硬件资源上也能高效运行。例如，在车载设备中，轻量化的模型降低了存储和能耗需求，为规模化生产提供了经济性支持。

2.4.5 总结

在数字图像处理任务中，**数学思维**为图像处理定义了理论框架，从矩阵表示到概率建模，为图像分类和特征提取提供了基础；**算法思维**则进一步将这些理论转化为可行的计算步骤和优化策略，提高了系统的可计算性和执行效率；**工程思维**确保图像处理算法能够应对复杂的现实场景，确保在成本受限、环境多变的情况下依然具备稳定性和经济性。

2.4.6 数学思维：推荐系统的理论建模

推荐系统的核心任务是为用户找到他们可能喜欢的内容（例如商品、电影、音乐等），这是一个典型的预测问题。数学思维帮助我们在抽象层面上定义这个问题，通过对用户行为的建模找到推荐算法的理论基础。常见的数学方法包括矩阵分解和向量空间模型：

矩阵分解

通过构建用户与项目的评分矩阵，推荐问题可以被表示为矩阵分解问题。数学思维定义了这一评分矩阵的特性和结构，并通过奇异值分解 (SVD) 等技术探索其潜在特征。**存在性**问题在此处确保了该矩阵可以被有效分解，以提取出每个用户和物品的潜在特征向量。

相似性度量

推荐系统依赖于用户和项目之间的相似性来生成推荐。例如，余弦相似性、皮尔逊相关系数等方法用于衡量不同用户或物品的相似性。数学思维在此为定义相似性度量提供了理论依据，确保系统在计算相似度时具备合理性。

概率模型

例如在基于概率图模型的推荐系统中，我们可以使用贝叶斯模型，预测用户对未接触项目的评分概率。这种模型确保系统具备合理的推荐结果的概率解释。

2.4.7 算法思维：理论到实现的路径

在算法思维的层面上，我们将推荐系统的数学模型转化为实际可行的算法，并对算法复杂度、优化和稳定性进行考量。

算法复杂度

推荐系统需要处理大量用户和项目的数据，计算复杂度成为一个关键问题。矩阵分解的直接计算复杂度很高，算法思维通过优化，如使用**随机梯度下降**和**分布式计算**，来减少复杂度。这些优化确保了算法在大规模数据处理时仍能在合理时间内完成任务。

优化问题

矩阵分解问题需要优化用户和项目的特征向量，使得系统能够拟合已有的评分数据。常见的优化算法包括**随机梯度下降**和 Adam 优化器等，这些方法可以在迭代中不断调整参数，以获得更好的推荐精度。

算法的稳定性

推荐系统的算法需要在用户评分数据存在一定噪声的情况下依然有效。算法思维通过**正则化**来提升系统在不同数据分布下的稳定性，避免推荐结果过度依赖特定用户的偏好数据。

2.4.8 工程思维：推荐系统的实际部署

在工程思维的层面，我们需要考虑如何将理论和算法转化为能在大规模生产环境中稳定、可靠运行的系统。

允许误差

在推荐系统中，我们通常不需要找到用户的“完美”推荐，而是提供大致符合用户兴趣的推荐内容。例如，推荐系统可以允许一定的计算误差以提升处理速度，使得系统能够满足实时响应的需求。

大规模数据处理

推荐系统需要处理成千上万的用户和上亿个项目。为此，工程思维通过分布式系统（如 Hadoop、Spark）和云计算技术支持大规模数据的实时处理。模型可以在多个节点上并行运行，大大提升系统处理数据的速度。

鲁棒性

推荐系统需要在不同用户行为（如异常评分、短期偏好变化）或数据源变化（如新商品、新用户）下保持稳定的推荐效果。工程思维通过设计数据预处理和动态更新机制，确保系统在面对这些变化时依然具有稳定的性能。

经济效应

推荐系统的存储和计算资源消耗通常很大。在工程思维的优化下，系统可以采用模型压缩、权重量化等技术，在确保准确率的同时减少资源消耗。通过云服务进行按需分配的计算资源，也降低了运行成本，确保系统在大规模商业应用中具有经济可行性。

2.4.9 综合说明

在推荐系统的开发中，**数学思维**定义了推荐任务的核心问题和方法，构建了系统的理论基础。接下来，**算法思维**将这些数学模型转化为实际可计算的步骤，使得系统不仅能给出准确的推荐结果，还能高效、稳定地执行。最后，**工程思维**关注将这一算法落地应用，使得推荐系统能够在真实场景中处理海量数据，满足用户的实时需求，并在资源有限的环境下实现经济性。

2.5 小结：三种思维的交融与驱动

从数学思维、算法思维再到工程思维，AI 的发展从理论走向了实践，每一步都在推动人工智能的进步。**数学思维**赋予了 AI 坚实的理论基础，为探索智能的可能性提供了方向；**算法思维**则将数学转化为具体计算方法，使得智能从可定义走向可实现；**工程思维**则是实现 AI 的最终一步，通过考虑环境适应性、成本和规模等因素，推动了 AI 的落地应用。三种思维的交互塑造了 AI 的现代图景，让我们在创新的路上不断前行。这三种思维的融合不仅是技术路径的演进，更体现了 AI 发展中的哲学思辨与应用智慧，成为推动 AI 走向未来的重要动力。

从理论的存在性到计算过程的优化，再到应用的落地，这些思维贯穿了 AI 技术的整个发展脉络。

Chapter 3

机器学习：学习如何学习？

机器学习是对能通过经验自动改进的计算机算法的研究。

—Mitchell [1997]

人工智能从诞生至今，经历了一次又一次的繁荣与低谷，其发展历程大体上可以分为“推理期”，“知识期”和“学习期” [?, ?]。

你可能已经接触过编程，甚至开发过一些程序。同时，你或许也读过关于深度学习或者机器学习的铺天盖地的报道，尽管这些技术常常被赋予了更广义的名字“人工智能”。实际上，或者说幸运的是，大部分程序并不需要深度学习或者广义的人工智能技术。例如，为微波炉设计一个用户界面时，我们只需简单设置几个按钮，并编写规则来精确描述微波炉在各种情况下的表现。再比如，设计一个电子邮件客户端，虽然复杂一些，但仍可以通过逻辑来实现：创建输入框接收收件人、主题和正文，监听用户输入，并在“发送”按钮被点击时检查邮箱格式和主题内容，再通过协议发送邮件。

这些例子表明，很多常见程序的实现并不依赖真实世界的的数据，也不需要从数据中提取特征。只要有足够的常识和编程技巧，我们就可以通过逻辑和规则完成这些任务。

事实上，符号主义 AI 是 AI 发展的第一阶段。在人工智能半个多世纪的发展历程中，符号主义 AI 曾主导数十年。通过人工设定规则和逻辑推

理，符号主义 AI 为解决复杂问题提供了切实可行的框架，推动了专家系统和符号推理模型在多个领域取得成果。符号主义 AI 的典型方法，如博弈树和专家系统中的推理，擅长解决规则明确的问题。

然而，随着应用需求的拓展，符号主义的局限性逐渐显现：人工规则难以精确描述复杂的现实场景，知识工程的构建过程费时费力且难以扩展，特别是在面对海量、非结构化数据时，手工设定规则既低效，又难以有效应对。这种局限性催生了对新的自动化学习方式的需求。

3.1 机器学习成为必然选择

[?]

我们很容易就能找到一些即使是世界顶尖的程序员也无法仅凭编程技巧解决的问题。这些问题的共同特点在于它们“只可意会而难以言传”：对于人类而言，这些任务似乎轻而易举，但要解释我们是如何做到的却并不简单——很难明确地描述出其中的规则和细节。这些特性使得依靠人工设计程序来解决此类问题变得困难重重。

假设我们希望开发一个程序来识别图 3.1 中有没有猫。这个问题对于我们来说非常简单，正常视力的人都能一眼分辨。然而，如果要基于规则和编程来实现这一判定，任务复杂得难以想象，甚至曾让顶尖的计算机科学家和程序员感到棘手。

在符号主义 AI 的框架下，我们需要手动定义规则来描述“猫”的特征，比如毛发分布、耳朵形状、眼睛大小、尾巴形状等。实际上，要判断图像中是否有猫，必须结合成千上万像素的特征，如边缘、质地、形状，甚至是眼睛和鼻子的具体细节。但这种方法对复杂图像来说几乎不可行。以一张 512×512 像素的黑白图像为例。每个像素取值在 0 到 255 之间，那么所有可能的像素组合多达 $256^{512 \times 512} = 256^{262144}$ 种。这样的天文数字，即便在当今的计算能力下也难以实现。更复杂的是，不同图像中的猫在姿态、颜色、角度、光线和背景等方面可能千差万别。因此，为猫的所有可能形态设计一套完备的规则几乎不可能。



图 3.1: 识别 “猫”



图 3.2: 手写数字识别 (图片来源 [Le-Cun et al., 1998]))

我们再来看另一个例子——手写体数字识别。手写数字识别 [?, ?] 是一个经典的机器学习任务，对人来说很简单，但对计算机而言却十分困难。不同人书写的数字风格和特征各异。比如，数字“5”的形状在不同书写习惯下变化多端，笔画粗细、弯曲程度和角度均不相同。要编写一套基于规则的算法来识别数字“5”，几乎无法穷尽所有可能的变化。类似地，其他手写数字的多样性和变形空间，使得基于人工规则来识别这些数字成为一项无法完成的任务。

在现实生活中，很多问题如人脸识别、物体识别、语音识别等，都和猫的识别、手写体数字识别一样，属于“只可意会不可言传”的温特，难以通过穷尽特征规则来精确完成，即使结合一些启发式规则，其过程也极其复杂。因此，基于符号规则的方法并不适合解决这些“意会难传”的任务。因此，AI 需要一种能够自动提取规律的学习方式。

3.1.1 机器学习：从数据中学习规律

一种解决以上问题的思路是逆向思考：与其设计繁琐的规则去定义“猫”的特征，不如从最终的需求入手，尝试“用数据编程”。通过将大量样本数据“喂给”模型，让模型自动提取出共性和模式，从而实现自动化学习。

以“猫的识别”为例，我们可以收集大量已知包含猫和不包含猫的图像，模型通过这些样本的训练后，能够找到模式并生成一个函数，用于判断图像中是否包含猫。这个函数的形式可以因问题的不同而变化：它可能是简单的二次函数，也可能是复杂的神经网络模型，而其具体参数则通过数据自动确定。类似的过程也适用于手写体数字识别等任务。为了让计算机识别手写数字，我们可以准备大量带标注的手写体数字图像作为训练数据，通过学习算法，模型会生成一套识别规则，用于识别新的手写体数字。

这一基于数据自动优化函数参数的过程，正是机器学习的本质：让计算机从数据中学习规律。

3.2 机器学习是什么？

机器学习 (Machine Learning, ML)，顾名思义，机器具备有学习的能力。更具体地，机器学习是指让计算机从数据中进行自动学习，得到某种知识或规律，然后利用学习到的规律 (模型) 对未知或无法观测的数据进行预测。机器具备学习能力之后，可以做很多事。比如下棋、图像识别、语音识别等等。

机器学习和普通程序的一个本质区别是需要样本数据，是一种数据驱动的方法。这种“用数据编程”的方法论构成了当今机器学习和深度学习的核心思想。

事实上，这种方式与人类的学习过程十分相似：教小孩认识物品和数字时，我们也是通过展示大量实例帮助他们从中总结规律。同样，计算机通过“看”大量样本，从中学习特征，再利用这些特征识别新的样本。

面对规则难以解决的任务，机器学习成为了一个自然的选择。这种自下而上通过数据驱动自动学习和优化参数的方法，使得模型能够适应更为复杂的环境和动态任务。

无论是猫和手写数字的识别，还是更为复杂的语言和视觉生成任务，机器学习都展现了符号主义 AI 无法比拟的灵活性。随着数据量和计算能力的提升，机器学习逐渐取代了早期的规则定义方法，广泛应用于模式识别、预测等领域，已成为人工智能发展的重要基石。伴随着方法论的突破以及计算资源和数据量的提升，机器学习在 1980 年代之后逐渐取代符号主义，成为 AI 的主流。机器学习不仅拓展了 AI 的应用范围，还为现代 AI 在图像识别、自然语言处理等领域的应用奠定了坚实基础。

3.3 机器学习：寻找一个函数

机器学习的过程实际上是“寻找一个函数”，即学习一个映射 $f: X \rightarrow Y$ ，以描述输入 X 与输出 Y 之间的关系，如图 3.3 所示。

机器学习的核心在于构造映射，这一原则贯穿了不同的应用场景：

无论是传统的 AI 应用（如机器翻译、图像识别），还是如今大热的生成式模型（如“文生文”、“图生文”、或“语音生文本”等），其核心都是在构建一个函数，将不同类型的输入映射为对应的输出。例如，

- **图像分类：**模型通过学习图像的像素特征，找到一个函数，将其映射到相应的分类标签，最终输出准确的结果。
- **机器翻译模型：**将一句话映射到另一种语言下的等义句
- **语音识别：**输入是声音信号，输出是对应的文字内容。语音识别的函数需要将连续的语音信号转化为离散的文本信息，这一映射极为复杂，人类难以直接手工定义。
- **图像识别：**输入是一张图片，输出是这张图片中的内容（如分类标签或对象名称）。这一函数需要捕捉像素间的复杂关系来识别图像中的模式。
- **围棋对弈：**以 AlphaGo 为例，这里的函数输入是棋盘上黑白子的位置分布，输出是机器下一步的最佳落子位置。这个函数需要从海量的棋谱中学习策略，评估每种可能的走法。
- **文本生成文本：**如大语言模型（LLM），通过训练大量文本数据，实现从语言到语言的映射，如回答问题、生成摘要等。
- **图像生成文本：**在图像描述任务中，模型通过对图像的分析将图像转化为文本描述，实现“图像到语言”的映射。这个映射函数训练的核心是让模型能够从图像中提取特征，将图像的关键信息通过自然语言表达出来。
- **文本生成图像：**文本生成图像（如 DALL-E）将描述性文本转化为图像，是一个“文字到图像”的映射过程，这种映射往往需要处理大量语言和视觉信息的复杂关联。

- **语音生成语音**：语音识别和合成是通过分析音频特征生成文字或合成语音，实质是语音到语音的映射函数。
- **大模型**：即使是复杂的生成式大模型，如 ChatGPT 或 DALL-E，依然是在文本和图像之间构建映射关系：从用户输入的文本生成合适的回答或图像，这些映射关系都来源于对数据关联的学习。

这些映射任务依赖于深度学习中的神经网络，通过多层神经网络捕捉数据之间的深层模式，处理复杂的输入与输出关系。

因此，所有这些任务背后的共性是，它们都需要一个极为复杂且难以手工定义的函数来描述输入与输出的关系。最终的任务都是在“寻找一个函数”——即在已知的输入与期望的输出之间找到最合适的映射关系。

机器学习通过大量标注好的输入和对应的输出（样本）的训练，自动构建这个映射函数，以最小化预测结果与真实标签之间的误差为目标，不断迭代优化模型参数，从而将输入转化为期望的输出。最终，模型不仅在训练数据上表现良好，还能在新样本上有较强的泛化能力，从而实现准确的预测或分类。

- 语音识别 $f(\text{语音}) = \text{"你好"}$
- 图像识别 $f(\text{9}) = \text{"9"}$
- 围棋 $f(\text{落子位置}) = \text{"6-5"}$ (落子位置)
- 机器翻译 $f(\text{"你好!"}) = \text{"Hello!"}$
- ChatGPT: $f(\text{"请给我写一篇演讲稿..."}) = \text{"尊敬的各位来宾, ..."}^1$
- Midjourney 们: $f(\text{"三月, 樱花季, 大学校园, 插画风格"}) = \text{樱花校园插画}$
-

(a) 机器学习 ~ 寻找一个函数



(b) 主流的 LLM 应用

图 3.3: 机器学习 $\approx$ 寻找一个函数

¹事实上，从更广义的角度看，不仅机器学习，符号主义 AI 乃至整个数学科学研究都是在寻找某种映射或函数。无论是符号主义 AI 中的逻辑推理，还是数学运算的算法设计，




图 3.4: 机器学习-构造一个函数

3.3.1 数据驱动的函数优化

事实上，从更广义的角度看，不仅机器学习，符号主义 AI 乃至整个数学研究都是在寻找某种映射或函数，将输入转化为理想的输出结果。例如，用于诊断血液感染的医疗专家系统 MYCIN，即是通过一系列推理规则将患者症状映射到可能的疾病诊断和治疗方案。

然而，与符号主义 AI 不同的是，机器学习并不依赖人工定义的规则，而是通过数据驱动的方式自动寻找映射函数。通常，机器学习算法首先选择一个合适的模型结构（例如线性回归、决策树、神经网络等）来表达输入 X 和输出 Y 之间的关系，通过大量标注样本数据的训练不断优化模型参数，

本质上都是在构建映射，将输入转化为理想的输出结果。

在符号主义 AI 中，人工构建的规则或知识库即为映射的载体。例如，通过逻辑规则构建推理引擎，输入一些前提条件后，系统可以推导出结论；这种推理过程就是一种映射，将输入事实映射到可能的结论。

数学中的很多经典算法同样是映射的体现。例如，辗转相除法是一种将两个整数映射到它们最大公因子的函数，归结起来是一系列除法操作的映射过程。类似地，求解一元二次方程、最小公倍数等，都可以被看作是将特定输入映射到对应结果的算法。

这种“寻找映射”的思想不仅贯穿于 AI 和数学，更广泛地延伸到科学的其他领域。从本质上说，科学研究的很多过程也在尝试通过公式、定理、模型等将实验条件与结果进行关联，使得我们能够从已知条件出发预测或解释未知现象。这也正是科学和技术的核心追求：构建从数据、规律到结果的高效映射，将复杂的现实问题简化为可以求解的模型。

使得输出尽可能接近目标。

在机器学习中，“寻找函数”并非直接写出公式，而是让机器通过优化算法自行找到尽可能最佳的近似映射。无论是线性回归、支持向量机、神经网络还是深度学习模型，核心都是利用大量数据训练出一组参数，使得模型在新样本上也能表现良好。

3.3.2 挑战：找到一个精准的函数

“寻找一个函数”听起来很直观，但在复杂应用中，找到这一映射并不容易。现实世界的输入 X 和输出 Y 往往包含大量的噪声和多样性，使得找到普适的映射函数异常困难。例如，图像生成文本的模型不仅要识别出图像中的物体，还需捕捉上下文关系。类似地，在文本生成图像的任务中，则要从语言描述中理解意图并生成符合要求的图像。即便是同样的输入文本，也可能对应到多种不同的视觉表现形式。这些任务要求模型具备高度的抽象和泛化能力，能够在不完美的数据中找到模式，确保它对新数据同样适用。这些任务

这种“映射的难题”也带来了多样化的模型结构和优化算法，不同的模型结构被引入以解决特定问题。比如卷积神经网络（CNN）在图像处理中的应用、递归神经网络（RNN）和自注意力机制（Transformer）在序列数据中的应用等。这些模型的共同目标是优化映射函数，使模型更好地理解输入与输出的关系。

3.3.3 机器学习的未来：构建更灵活的映射函数

未来，随着计算能力的提升和模型设计的改进，机器学习将支持更复杂的多模态映射，推动 AI 系统在文本、图像、语音等多种数据形式间灵活转换。无论是自动驾驶、智能医疗，还是多模态智能系统，核心任务始终是构建更高效、精确的映射函数。

随着机器学习和深度学习的发展，“寻找一个函数”这一任务上正不断迈向新的高度。从单一的输入输出模式到复杂的多模态映射，未来的 AI 系

统或将实现文本、图像与语音之间的无缝转换，从而构建出真正多功能的智能系统。

3.4 机器学习三要素：模型、学习准则、优化

机器学习的核心任务是从数据中寻找一个映射函数，将输入转化为期望的输出。为了实现这一目标，需要围绕**模型**、**学习准则**和**优化**这三个关键要素展开工作。这三者共同构成了机器学习算法的理论基础和实践框架。

3.4.1 模型：映射关系的表示

在机器学习中，**模型**用于表示输入与输出关系的数学结构，它定义了映射 $f: X \rightarrow Y$ 的具体形式。

为了定义映射 $f: X \rightarrow Y$ ，一个机器学习任务要先需要确定其输入空间 X 和输出空间 Y ，不同机器学习任务的主要区别在于输出空间不同。在分类、回归、生成等不同任务中，模型的类型和结构也有所差异。在两类分类问题中 $Y = +1, -1$ ，在 K 类分类问题中 $Y = 1, 2, \dots, K$ ；在回归问题中 $Y = \mathbb{R}$ ；而在图像生成文本（如图像描述）任务中，输入空间为图像特征，通常表示为高维张量 $X = \mathbb{R}^{H \times W \times C}$ ，其中， H 是图像的高度， W 是宽度， C 是通道数（通常为 3，表示 RGB 通道），而输出空间为描述图像的自然语言文本序列 $\{y_1, y_2, \dots, y_m\}$ ， $y_j \in \mathcal{V}$ 。

常见的模型可以分为线性模型和非线性模型两种。线性模型的形式如下：

$$f(\mathbf{x}; \theta) = \mathbf{w}^T \mathbf{x} + b,$$

其中， $\mathbf{x}$ ，参数 θ 包含了权重向量 $\mathbf{w}$ 和偏置 b 。

广义的非线性模型可以写为多个非线性基函数 $\phi(\mathbf{x})$ 的线性组合

$$f(\mathbf{x}; \theta) = \mathbf{w}^T (\mathbf{x}) + b, \quad (3.1)$$

其中 $\phi(\mathbf{x}) = [\phi_1(\mathbf{x}), \phi_2(\mathbf{x}), \dots, \phi_K(\mathbf{x})]^T$ 为 K 个非线性基函数组成的向量，参数 θ 包含了权重向量 $\mathbf{w}$ 和偏置 b 。

对于复杂非线性关系的任务，通常采用**神经网络或深度学习模型**：

$$\phi_k(x) = h(\mathbf{w}_k^T \phi'(\mathbf{x}) + b_k), \forall 1 \leq k \leq K, \quad (3.2)$$

其中 $h(\cdot)$ 为非线性函数， $\phi'(\mathbf{x})$ 为另一组基函数， $\mathbf{w}_k$ 和 b_k 为可学习的参数，则 $f(\mathbf{x}; \theta)$ 就等价于神经网络模型。

模型可以看作是映射函数 f 的候选集合，例如 $f(\mathbf{x}; \theta)$ 表示带有参数 θ 的模型。在训练过程中，模型的目标是通过优化参数 θ 来学习数据中的规律。

3.4.2 学习准则：衡量映射的好坏

损失函数

0-1 损失函数

平方损失函数

交叉熵损失函数

Hinge 损失函数

3.4.3 风险最小化准则

期望风险

经验风险

过拟合。

总之，机器学习中的学习准则并不仅仅是拟合训练集上的数据，同时也要使得泛化错误最低。给定一个训练集，机器学习的目标是从假设空间中找到一个泛化错误较低的“理想”模型，以便更好地对未知的样本进行预测，特别是不在训练集中出现的样本。因此，机器学习可以看作是一个从有限、高维、有噪声的数据上得到更一般性规律的泛化问题。和过拟合相反的一个概念是欠拟合 (underfitting)，即模型不能很好地拟合训练数据，

在训练集的错误率比较高。欠拟合一般是由于模型能力不足造成的。图 2.3 给出了欠拟合和过拟合的示例。




图 3.5: 欠拟合和过拟合

结构风险

学习准则，也称为**目标函数**或**损失函数**，是用于衡量模型映射质量的指标。它反映了当前模型的输出与期望输出之间的差距。

不同机器学习任务所用的学习准则不同。比如，回归任务通常使用均方误差（MSE）来衡量预测值与真实值之间的差距：

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

分类任务通常使用交叉熵损失衡量预测分布与真实分布之间的差异：

$$\text{CrossEntropy} = -\frac{1}{n} \sum_{i=1}^n \sum_{c=1}^C y_{i,c} \log \hat{y}_{i,c}$$

而生成任务则常用对抗损失（GAN）或重构误差（如自编码器）来评估模型性能。

学习准则的定义直接影响模型优化的目标，也决定了模型是否能够有效捕捉数据中的规律。

3.4.4 优化：找到最优参数

参数与超参数：在机器学习中，优化又可以分为参数优化和超参数优化。模型 $f(\mathbf{x}; \theta)$ 中的 θ 称为模型的参数，可以通过优化算法进行学习。除了可学习的参数 θ 之外，还有一类参数是用来定义模型结构或优化策略的，这类参数叫做超参数 (hyper-parameter)。

常见的超参数包括：聚类算法中的类别个数、梯度下降法的步长、正则项的系数、神经网络的层数、支持向量机中的核函数等。超参数的选取一般都是组合优化问题，很难通过优化算法来自动学习。因此，超参数优化是机器学习的一个经验性很强的技术，通常是按照人的经验设定，或者通过搜索的方法对一组超参数组合进行不断试错调整。

优化是指通过调整模型参数 θ ，使学习准则（损失函数）达到最小值的过程。优化算法负责寻找模型的最佳参数，使其能够在输入与输出之间建立最佳的映射关系。

常见的优化方法包括：

梯度下降 (Gradient Descent)

为了充分利用凸优化中一些高效、成熟的优化方法，比如共轭梯度、拟牛顿法等，很多机器学习方法都倾向于选择合适的模型和损失函数以构造一个凸函数作为优化目标。但也有很多模型（比如神经网络）的优化目标是非凸的，只能退而求其次找到局部最优解。

在机器学习中，最简单、常用的优化算法就是梯度下降法，即通过迭代的方法来计算训练集 D 上风险函数的最小值。通过计算损失函数相对于参数的梯度，逐步更新参数以减少误差。

$$\theta_{t+1} = \theta_t - \eta \cdot \nabla_{\theta} L = \theta_t - \eta \cdot \frac{\partial \mathcal{R}_D(\theta)}{\partial \theta} \quad (3.3)$$

其中 θ_t 是第 t 次迭代时的参数值， η 是学习率 (learning rate)，决定参数更新的步长。

随机梯度下降 (SGD)

在每次迭代中只使用一个或部分样本计算梯度，适用于大规模数据集。

在公式 (3.3) 的梯度下降法中，目标函数是整个训练集上风险函数，这种方式称为批量梯度下降法 (Batch Gradient Descent, BGD)。批量梯度下降法在每次迭代时需要计算每个样本上损失函数的梯度并求和。当训练集中的样本数量 N 很大时，空间复杂度比较高，每次迭代的计算开销也很大。在机器学习中，我们假设每个样本都是独立同分布的从真实数据分布中随机抽取出来的，真正的优化目标是期望风险最小。批量梯度下降相当于是从真实数据分布中采集 N 个样本，并由它们计算出来的经验风险的梯度来近似期望风险的梯度。为了减少每次迭代的计算复杂度，我们也可以在每次迭代时只采集一个样本，计算这个样本损失函数的梯度并更新参数，即随机梯度下降法 (Stochastic Gradient Descent, SGD)。当经过足够次数的迭代时，随机梯度下降也可以收敛到局部最优解 [Nemirovski et al., 2009]。

提前停止

高级优化算法

如 Adam、RMSProp 等，通过自适应调整学习率以加速收敛。

优化过程的目标是使模型在训练数据上表现良好，同时具备在新数据上的泛化能力。这要求优化算法在训练中平衡收敛速度和泛化能力。

3.4.5 三要素的协同作用

模型提供了问题的解决空间，是映射关系的表达。**学习准则**定义了优化目标，用于衡量模型的表现。**优化方法**是通向目标的手段，帮助模型在候选空间中找到最优解。

不同机器学习算法的区别在于模型、学习准则 (损失函数) 和优化算法的差异。相同的模型也可以有不同的学习算法。比如线性分类模型有感知器、logistic 回归和支持向量机，它们之间的差异在于使用了不同的学习准

则和优化算法。

三要素的协同作用贯穿于机器学习的整个过程，推动着从理论到实践的每一步。不同的模型结构、学习准则和优化策略的组合，构成了机器学习的多样性和灵活性，也为解决各种实际问题提供了广泛的可能性。

3.4.6 监督学习、无监督学习和强化学习

机器学习的任务可以根据训练样本提供的信息和反馈方式的不同，划分为三种主要的学习范式：**监督学习**、**无监督学习**和**强化学习**。这三种方式的核心区别在于输入数据是否标注、模型训练过程中是否提供明确的目标信号以及反馈机制的设计。

3.4.7 监督学习：通过标注数据进行映射学习

监督学习需要提供大量标注好的训练样本。每个样本由输入 (X) 和期望输出 (Y) 组成，模型通过学习从输入到输出的映射函数 $f: X \rightarrow Y$ ，以最小化预测输出和真实标签之间的误差。

- **数据需求**：- **输入**：标注好的样本对 (X, Y) ，如图像与其对应的分类标签、句子与其翻译结果。- **反馈**：明确的错误信号（如预测值和真实值的差距）。

- **特点**：- 数据标注成本高，尤其在图像分类、语音识别等需要人工标注的任务中。- 适合有明确目标的任务，例如分类、回归和生成任务。

- **典型应用**：- 图像分类 (ImageNet)、语音识别 (Speech-to-Text)、机器翻译 (Google Translate)。

根据标签类型的不同：分类与回归

在监督学习中，根据标签 y 的类型不同，可以进一步分为 ** 分类 (Classification) ** 和 ** 回归 (Regression) ** 两种任务。这两类任务的主要区别在于输出的目标变量是离散值还是连续值。

—

****1. 分类 (Classification) **** - **** 定义 ****: 当标签 y 是离散的类别时, 任务被称为分类问题。模型需要根据输入 X 对样本进行分类, 输出类别标签。- **** 特点 ****: - 标签取值离散且有限 (如 0/1、类别 A/B/C 等)。- 训练目标通常是最大化样本分配到正确类别的概率。- **** 典型应用 ****: - **** 手写数字识别 ****: 输入是手写数字的图像, 输出是数字标签 (如 0-9)。- **** 垃圾邮件检测 ****: 输入是邮件文本内容, 输出是类别标签 (垃圾邮件或非垃圾邮件)。- **** 图像分类 ****: 输入是一张图片, 输出是图像所属的类别标签 (如猫/狗)。- **** 常用算法 ****: - 逻辑回归、支持向量机 (SVM)、决策树、随机森林、神经网络等。

****2. 回归 (Regression) **** - **** 定义 ****: 当标签 y 是连续值时, 任务被称为回归问题。模型需要根据输入 X 预测一个连续值。- **** 特点 ****: - 标签取值是实数或连续整数 (如温度、房价)。- 训练目标通常是最小化预测值与真实值之间的误差。- **** 典型应用 ****: - **** 房价预测 ****: 输入是房屋的特征 (如面积、房间数、位置), 输出是房价的具体数值。- **** 工资预测 ****: 输入是员工的相关特征 (如年龄、教育背景、工作年限), 输出是对应的工资。- **** 股票价格预测 ****: 输入是历史股价和其他影响因素, 输出是未来的股价。- **** 常用算法 ****: - 线性回归、岭回归、LASSO 回归、决策树回归、神经网络等。

**** 对比分类与回归 ****

** 类别 **	** 标签类型 **	** 任务目标 **	** 典型任务 **	** 常用指标 **
** 分类 **	离散值	输出样本所属类别	手写数字识别、垃圾邮件检测	准确率、F1 分数
** 回归 **	连续值	预测目标值的具体数值	房价预测、工资预测	均方误差、绝对误差

分类和回归是监督学习中的两大核心任务, 分别对应离散和连续标签的预测需求。根据问题的特点选择合适的任务类型, 可以更高效地构建模

型并解决实际问题。

3.4.8 无监督学习：通过未标注数据发现模式

无监督学习的训练数据仅包含输入 X ，没有对应的标签 Y 。目标是通过分析输入数据的结构，发现潜在模式或分布规律。

- **数据需求**：- **输入**：未标注的样本集合 X 。- **反馈**：无明确目标，仅基于数据内部关系（如相似性、分布密度）生成学习信号。

- **特点**：- 无需标注数据，成本低，更适合处理海量数据。- 常用于探索数据结构、降维、聚类或生成任务。

- **典型应用**：- 聚类分析（如市场细分）、降维（PCA、t-SNE）、生成模型（GAN、VAE）。

3.4.9 强化学习：通过与环境互动学习策略

强化学习不同于监督和无监督学习，其目标是通过试探和互动，从环境中获得反馈信号来学习最优决策策略。模型需要在状态空间 S 和动作空间 A 中寻找最优的策略 $\pi(a|s)$ ，以最大化累积奖励 R 。

- **数据需求**：- **输入**：环境状态 S 和当前动作 A 。- **反馈**：延迟的奖励信号 R （如分数、收益）。

- **特点**：- 无需预定义输入输出对，学习目标通过环境反馈动态生成。- 常用于动态和决策问题，如游戏、控制系统。

- **典型应用**：- 游戏对弈（AlphaGo）、自动驾驶、机器人控制。

结合场景的选择

如果任务可以明确量化输入输出关系且有足够标注数据，监督学习是首选。在缺乏标注但数据量庞大的场景，无监督学习有助于发现数据的潜在结构。对于需要实时互动和优化的任务（如游戏、控制系统），强化学习是最优选择。

监督学习、无监督学习和强化学习共同构成了机器学习的三大核心范式，各自对应不同的应用场景与需求，推动了人工智能在多领域的蓬勃发展

学习范式	监督学习	无监督学习	
训练样本	标注好的 (X, Y) 数据	无标注的 X 数据	智能体和环境
优化目标	$y = f(\mathbf{x})$ 或 $p(y \mathbf{x})$	$p(\mathbf{x})$ 或带隐变量 $\mathbf{z}$ 的 $p(\mathbf{x} \mathbf{z})$	奖励/惩罚
学习准则	期望风险最小化、最大似然估计	最大似然估计、最小重构错误	策略
反馈方式	明确的目标值	隐含的模式或结构	
适用场景	分类、回归、生成任务	数据聚类、降维、分布估计	涉

表 3.1: 监督学习、无监督学习、强化学习对比

展。

监督学习的人工标注成本确实很高，尤其是在需要大量高质量标注数据的复杂任务中，这一问题尤为显著。

Hinton 从生物学角度的解释非常有趣且具有启发性：

神经元突触的数量：人类大脑中约有 10^{14} 个神经元突触，这意味着需要调整的连接或权重数量极为庞大。生命的时间限制：生命长度大约为 10^9 秒，这意味着如果每个突触的调整都依赖外界的监督信号（如人工标注），时间远远不够。核心观点：Hinton 的观点表明：

生物大脑不能依赖完全监督的方式来学习所有需要的知识，因为监督信号既稀缺又成本高昂。人类更多地依靠无监督学习和自监督学习来利用环境中丰富的未标注数据，提取信息并构建内在模型。例如，观察世界、模仿行为、通过互动学习规律。机器学习中的启示：监督学习的局限性：

人工标注不仅昂贵，而且难以覆盖多样化的现实场景。某些任务（如语言模型、大规模图像生成）所需的标注数据量极其庞大，难以完全依赖人工标注。发展方向：

无监督学习：利用未标注数据，挖掘数据中的潜在模式和结构。自监督学习：通过设计任务（如预测未见部分、填补缺失内容等），在无标注数据上生成训练信号。例如，BERT 使用了“掩盖词预测”任务，DALL-E 利用“图像-文本匹配”任务。半监督学习：结合少量标注数据和大量未标注数据，降低标注成本。

总结：Hinton 的观点提醒我们，在生物与人工智能中，完全依赖监督信号的学习方式不仅不现实，也效率低下。未来的研究应更多关注如何高效地利用无标注数据，让模型像人类一样从环境中主动学习，进一步提升学习效率和适应能力。

3.4.10 深度学习，真的行

通俗来说，机器学习是一门讨论各式各样的适用于不同问题的函数形式，以及如何使用数据来有效地获取函数参数具体值的学科。深度学习是指机器学习中的一类函数，它们的形式通常为多层神经网络。近年来，仰仗着大数据集和强大的硬件，深度学习已逐渐成为处理图像、文本语料和声音信号等复杂高维度数据的主要方法。

我们现在正处于一个程序设计得到深度学习的帮助越来越多的时代。这可以说是计算机科学历史上的一个分水岭。举个例子，深度学习已经在你的手机里：拼写校正、语音识别、认出社交媒体照片里的好友们等。得益于优秀的算法、快速而廉价的算力、前所未有的大量数据以及强大的软件工具，如今大多数软件工程师都有能力建立复杂的模型来解决十年前连最优秀的科学家都觉得棘手的问题。

3.5 .1. 起源

虽然深度学习似乎是最近几年刚兴起的名词，但它所基于的神经网络模型和用数据编程的核心思想已经被研究了数百年。自古以来，人类就一直渴望能从数据中分析出预知未来的窍门。实际上，数据分析正是大部分自然科学的本质，我们希望从日常的观测中提取规则，并找寻不确定性。

早在 17 世纪，[雅各比·伯努利 (1655–1705)] 提出了描述只有两种结果的随机过程（如抛掷一枚硬币）的伯努利分布。大约一个世纪之后，[卡尔·弗里德里希·高斯 (1777–1855)] 发明了今日仍广泛用在从保险计算到医学诊断等领域的最小二乘法。概率论、统计学和模式识别等工具帮助自

然科学的实验学家们从数据回归到自然定律，从而发现了如欧姆定律（描述电阻两端电压和流经电阻电流关系的定律）这类可以用线性模型完美表达的一系列自然法则。

即使是在中世纪，数学家也热衷于利用统计学来做出估计。例如，在[雅各比·科贝尔（1460–1533）]的几何书中记载了使用 16 名男子的平均脚长来估计男子的平均脚长。

现代统计学在 20 世纪的真正起飞要归功于数据的收集和发布。统计学巨匠之一[罗纳德·费雪（1890–1962）]对统计学理论和统计学在基因学中的应用功不可没。他发明的许多算法和公式，例如线性判别分析和费雪信息，仍经常被使用。即使是他在 1936 年发布的 Iris 数据集，仍然偶尔被用于演示机器学习算法。

[克劳德·香农（1916–2001）]的信息论以及[阿兰·图灵（1912–1954）]的计算理论也对机器学习有深远影响。图灵在他著名的论文[《计算机器与智能》]中提出了“机器可以思考吗？”这样一个问题[1]。在他描述的“图灵测试”中，如果一个人在使用文本交互时不能区分他的对话对象到底是人类还是机器的话，那么即可认为这台机器是有智能的。时至今日，智能机器的发展可谓日新月异。

另一个对深度学习有重大影响的领域是神经科学与心理学。既然人类显然能够展现出智能，那么对于解释并逆向工程人类智能机理的探究也在情理之中。最早的算法之一是由[唐纳德·赫布（1904–1985）]正式提出的。在他开创性的著作[《行为的组织》]中，他提出神经是通过正向强化来学习的，即赫布理论[2]。赫布理论是感知机学习算法的原型，并成为支撑今日深度学习的随机梯度下降算法的基石：强化合意的行为、惩罚不合意的行为，最终获得优良的神经网络参数。

来源于生物学的灵感是神经网络名字的由来。这类研究者可以追溯到一个多世纪前的[亚历山大·贝恩（1818–1903）]和[查尔斯·斯科特·谢灵顿（1857–1952）]。研究者们尝试组建模仿神经元互动的计算电路。随着时间发展，神经网络的生物学解释被稀释，但仍保留了这个名字。时至今日，绝大多数神经网络都包含以下的核心原则。

-交替使用线性处理单元与非线性处理单元，它们经常被称为“层”。-使用链式法则（即反向传播）来更新网络的参数。

在最初的快速发展之后，自约 1995 年起至 2005 年，大部分机器学习研究者的视线从神经网络上移开了。这是由于多种原因。首先，训练神经网络需要极强的计算力。尽管 20 世纪末内存已经足够，计算力却不够充足。其次，当时使用的数据集也相对小得多。费雪在 1936 年发布的 Iris 数据集仅有 150 个样本，并被广泛用于测试算法的性能。具有 6 万个样本的 MNIST 数据集在当时已经被认为是非常庞大了，尽管它如今已被认为是典型的简单数据集。由于数据和计算力的稀缺，从经验上来说，如核方法、决策树和概率图模型等统计工具更优。它们不像神经网络一样需要长时间的训练，并且在强大的理论保证下提供可以预测的结果。

3.6 1.2. 发展

互联网的崛起、价廉物美的传感器和低价的存储器令我们越来越容易获取大量数据。加之便宜的计算力，尤其是原本为电脑游戏设计的 GPU 的出现，上文描述的情况改变了许多。一瞬间，原本被认为不可能的算法和模型变得触手可及。这样的发展趋势从如下表格中可见一斑。

年代	数据样本个数	内存	每秒浮点计算数	— : — : ———— ——— : — : —————
1970	102102 (Iris)	1KB	100K (Intel8080)	
1980	103103 (波士顿房价)	100KB	1M (Intel80186)	
1990	104104 (手写字符识别)	10MB	10M (Intel80486)	
2000	107107 (网页)	100MB	1G (IntelCore)	
2010	10101010 (广告)	1GB	1T (NVIDIAC2050)	
2020	10121012 (社交网络)	100GB	1P (NVIDIADGX-2)	

很显然，存储容量没能跟上数据量增长的步伐。与此同时，计算力的增长又盖过了数据量的增长。这样的趋势使得统计模型可以在优化参数上投入更多的计算力，但同时需要提高存储的利用效率，例如使用非线性处理单元。这也相应导致了机器学习和统计学的最优选择从广义线性模型及核方法变化为深度多层神经网络。这样的变化正是诸如多层感知机、卷积神

神经网络、长短期记忆循环神经网络和 Q 学习等深度学习的支柱模型在过去 10 年从坐了数十年的冷板凳上站起来被“重新发现”的原因。

近年来在统计模型、应用和算法上的进展常被拿来与寒武纪大爆发（历史上物种数量大爆发的一个时期）做比较。但这些进展不仅仅是因为可用资源变多了而让我们得以用新瓶装旧酒。下面的列表仅仅涵盖了近十年来深度学习长足发展的部分原因。

-优秀的容量控制方法，如丢弃法，使大型网络的训练不再受制于过拟合（大型神经网络学会记忆大部分训练数据的行为）[3]。这是靠在整个网络中注入噪声而达到的，如训练时随机将权重替换为随机的数字[4]。-注意力机制解决了另一个困扰统计学超过一个世纪的问题：如何在不增加参数的情况下扩展一个系统的记忆容量和复杂度。注意力机制使用了一个可学习的指针结构来构建出一个精妙的解决方法[5]。也就是说，与其在像机器翻译这样的任务中记忆整个句子，不如记忆指向翻译的中间状态的指针。由于生成译文前不需要再存储整句原文的信息，这样的结构使准确翻译长句变得可能。-记忆网络[6]和神经编码器—解释器[7]这样的多阶设计使得针对推理过程的迭代建模方法变得可能。这些模型允许重复修改深度网络的内部状态，这样就能模拟出推理链条上的各个步骤，就好像处理器在计算过程中修改内存一样。-另一个重大发展是生成对抗网络的发明[8]。传统上，用在概率分布估计和生成模型上的统计方法更多地关注于找寻正确的概率分布，以及正确的采样算法。生成对抗网络的关键创新在于将采样部分替换成了任意的含有可微分参数的算法。这些参数将被训练到使辨别器不能再分辨真实的和生成的样本。生成对抗网络可使用任意算法来生成输出的这一特性为许多技巧打开了新的大门。例如生成奔跑的斑马[9]和生成名流的照片[10]都是生成对抗网络发展的见证。-许多情况下单块 GPU 已经不能满足在大型数据集上进行训练的需要。过去 10 年内我们构建分布式并行训练算法的能力已经有了极大的提升。设计可扩展算法的最大瓶颈在于深度学习优化算法的核心：随机梯度下降需要相对更小的批量。与此同时，更小的批量也会降低 GPU 的效率。如果使用 1,024 块 GPU，每块 GPU 的批量大小为 32 个样本，那么单步训练的批量大小将是 32,000 个以上。近

年来李沐 [11]、YangYou 等人 [12] 以及 XianyanJia 等人 [13] 的工作将批量大小增至多达 64,000 个样例,并把在 ImageNet 数据集上训练 ResNet-50 模型的时间降到了 7 分钟。与之相比,最初的训练时间需要以天来计算。-并行计算的能力也为至少在可以采用模拟情况下的强化学习的发展贡献了力量。并行计算帮助计算机在围棋、雅达利游戏、星际争霸和物理模拟上达到了超过人类的水准。-深度学习框架也在传播深度学习思想的过程中扮演了重要角色。[Caffe](<https://github.com/BVLC/caffe>)、[Torch](<https://github.com/torch>) 和 [Theano](<https://github.com/Theano/Theano>) 这样的第一代框架使建模变得更简单。许多开创性的论文都用到了这些框架。如今它们已经被 [TensorFlow](<https://github.com/tensorflow/tensorflow>) (经常是以高层 API[Keras](<https://github.com/keras-team/keras>) 的形式被使用)、[CNTK](<https://github.com/Microsoft/CNTK>)、[Caffe2](<https://github.com/caffe2/caffe2>) 和 [ApacheMXNet](<https://github.com/apache/incubator-mxnet>) 所取代。第三代,即命令式深度学习框架,是由用类似 NumPy 的语法来定义模型的 [Chainer](<https://github.com/chainer/chainer>) 所开创的。这样的思想后来被 [PyTorch](<https://github.com/pytorch/pytorch>) 和 MXNet 的 [GluonAPI](<https://github.com/apache/incubator-mxnet>) 采用,后者也正是本书用来教学深度学习的工具。

系统研究者负责构建更好的工具,统计学家建立更好的模型。这样的分工使工作大大简化。举例来说,在 2014 年时,训练一个逻辑回归模型曾是卡内基梅隆大学布置给机器学习方向的新入学博士生的作业问题。时至今日,这个问题只需要少于 10 行的代码便可以完成,普通的程序员都可以做到。

2.3 深度学习基础——三种模型

2.3.1 起源

随着第一台电子计算机的问世,人工智能技术的发展拉开序幕。人工智能研究者基于对“智能”的不同理解,逐渐形成了符号主义、联结主义以及行为主义三大流派 [17]。其中,人工神经网络 [18] 是连接主义的代表模型,它通过模拟生物神经网络及其机制,形成了由大量神经元通过互相连

接作用形成的网络系统。从上世纪 40 年代的 M-P 神经元和 Hebb 学习准则，到 50 年代的感知器模型，再到 60 年代的自组织映射网络，许多神经计算模型都发展成信号处理、机器视觉、自然语言处理等领域的经典方法 [19]。然而，由于当时该方法的不完备性，对深层神经网络的研究曾一度消弭 [21][22]。2006 年，Hinton 指出具有隐藏层的网络具有优异的特征学习能力，提出了一种面向复杂通用学习任务的深层神经网络。自此，崭新的神经网络研究时代开启，深度学习的概念开始被提出。

2.3.2 单层感知器模型

自从 Cajal 开创了神经元学说以来，许多神经元传递信号的方式在被逐渐发现。下图为一个简化的神经元模型：

图 2.3.1 简化的神经元模型

神经元在无信号输入时保持抑制状态。而当树突和胞体接受的兴奋电位总和超过某个阈值时，它会进入兴奋状态，并经由轴突发出脉冲，刺激其他神经元。而神经元的 M-P 模型 [6] 正是经由这个原理而提出，如下图所示：

图 2.3.2 M-P 模型

图中的 $x_1, x_2, \dots, x_n$ 表示其他相连的神经元传递的输入信号， w_{ij} 代表每个输入信号的权值， f 称为激励函数， y_j 表示当前神经元的输出，那么可以得到表达式：其中 b_j 代表使该神经元激活所需要的阈值。这种通过逻辑角度来描述神经元的方法，为神经网络的理论研究开辟了道路。

2.3.3 多层感知器模型

单层感知机虽然在某些问题上有效，但是并不能解决诸如线性不可分问题等多种问题 [23]。因此，多层感知机的概念产生：它的结构由输入层、隐藏层及输出层构成。下图是一个多层感知器的结构图：

图 2.3.3 多层感知机结构图

注意到，这里每两层之间的任意神经元都与另一层的所有神经元相连接。与单层感知器模型相同，每个输入信号都有一个对应的连接权值，而每一个神经元的输入为前一层所有神经元的输出的加权和。假设 x_m^l 代表着第 l 层第 m 个神经元的输入值， y_m^l 和 b_m^l 分别为该神经元的输出值和偏置

值, $w_{im}^{(l-1)}$ 代表该神经元与第 $i-1$ 层第 i 个神经元的连接权值, 那么有:

$$y_m^l = f(x_m^l)$$

虽然多层感知器模型解决了单层感知器的缺陷, 但是却带来了新的问题, 如下图所示, 如果需要处理一个 $1000*1000$ 像素的 3 通道 RGB 图片, 即使在隐藏层只设置了 1000 个结点, 那么待处理的参数也是多达 $1e9$ 的量级。这仅仅只是一层, 如果需要得到拟合度高的网络, 那么待处理的节点个数将是一个天文数字。同时, 这么多参数也可能会带来过拟合的问题。因此, 亟需一个新的模型来克服这一缺陷。

2.3.4 卷积神经网络模型

2.3.4.1 感受野

1962 年, 科学家发现在视觉皮层中存在一系列构造复杂的细胞, 它们只能识别到视觉输入空间的局部区域, 因此被称为“感受野” [25]。下图为一个感受野模式图:

图 2.3.4 感受野模式图图中最上方的小圆圈就代表着众多感受野, 光感受器将得到的信息整合并传递到神经元中, 最后再经过进一步处理传到大脑。在识别图片时, 这些细胞首先捕捉图片的边缘和轮廓, 然后将其整合成一些完整的校组件, 最后再将这些小部分最终整合成待识别的对象。下图为人脸识别上的一个例子:

图 2.3.5 感受野

2.3.4.2 边缘提取 [26]

上文在提及感受野时, 描述了这些细胞会首先捕捉图片的边缘。那么基于这种边缘提取的思想, 也同样被运用到了神经网络中。以提取水平和垂直的信息为例, 如下图所示:

图 2.3.6 边缘提取

由于图像可以用多个矩阵来表示, 因此期望能用一种矩阵运算实现上图的提取效果, 这便引入了“卷积”这一概念。首先, 卷积操作定义为对图像矩阵和滤波矩阵做多次内积, 如下图所示:

图 2.3.7 卷积图 2.3.8 滤波矩阵

内积指的是两矩阵对应元素相乘, 并将其求和放在结果矩阵的相应位

置上。在提取运算过程中，图中的卷积核（即 filter）从左到右，从上到下移动过整个图像矩阵，每移动一步分别计算原图中被卷积核覆盖的部分与卷积核的内积。右图中的这个 6×6 的图像矩阵有一个明显的垂直边缘，那么经过与图中所示的卷积核作卷积运算，在最终结果 4×4 的矩阵中，确实提取到了这个垂直边缘，读者可自行模拟这个运算过程。

2.3.4.3 卷积层 [26]

以上介绍了感受野和边缘检测的概念，通过运用这些思想，卷积神经网络（Conventional Neural Network, CNN）就模仿了大脑识别图像的这一过程。

首先，卷积神经网络的第一层被称为卷积层，与上述介绍的操作相对应。它的目的是为了提取输入的不同特征，前文中提到的垂直边缘只是众多需要被提取的特征之一。当然，正如大脑中视觉细胞的提取结构，某些卷积层只提取一些诸如边缘和线条等较低级的特征，更高层的网络能从低级特征中进一步提取更复杂的特征。在如此多层的提取中，提取到的特征矩阵会越来越小，这会带来边缘信息丢失等问题，举例来说：

图 2.3.9 边缘信息丢失

如图为一个 5×5 的单通道图片，通常使用一个 3×3 大小的卷积核运算得到一个 3×3 大小的运算结果。如果重复这样的操作多次，那么图像的大小最后可能变成了 1×1 ，而 1×1 的图像毫无特征可言，这并不是我们期望得到的结果。于是接下来引入了零填充的概念：零填充操作非常简单，在每次卷积结束后，在图像最外层加上若干层 0 值。注意到，由于 0 在内积运算中对结果不会造成影响，因此不会对图片增加额外的干扰信息。零填充操作如下图所示：

图 2.3.10 零填充除此以外，卷积层中还有步长、多卷积核以及参数计算公式等内容，虽然其概念和计算并不复杂，但都过于细节，不在此作详细阐述。

2.3.4.4 池化层

其次，经过卷积层提取后的特征图数量可能仍然很大，此时需要下采样，即池化操作。目的有二，其一如上文所述是为了减少特征图数，其二还可以提高特征图的鲁棒性，防止过拟合。通常在卷积层后增加一个池化层，

一般通过取区域最值、平均值的方法进行采样。最常见的池化层是规模为 2×2 ，步幅为 2，对输入的每个深度切片进行下采样。每个操作对四个数进行，下图所示为一个最大值池化：

图 2.3.11 池化

值得注意的是，池化操作不需要进行学习，也不像卷积需要通过梯度下降进行更新。

2.3.4.5 全连接层

卷积层 + 池化层可以统一看成 CNN 的特征提取层，那么在提取完以后，最终将学习到的特征应用于模型需要的任务。这一层的操作主要有两步：第一步将所有的特征图进行扁平化（变为 $1 \times N$ 的向量），第二步再接一个或多个全连接层，进行模型的学习。下图中的 Fully connection 部分即为全连接层：

图 2.3.12 全连接层

2.3.4.6 CNN 小结

下图为卷积神经网络训练的基本结构。与传统机器学习方法相比，CNN 的权值共享思想使得网络中需要训练的参数变少，降低复杂度的同时，减少了过拟合，更易于训练。到此，对神经网络基础的介绍结束，下一节将结合图像处理中的一个具体方向——目标检测，进一步介绍神经网络在图像处理方向上的发展史。

图 2.3.13 卷积神经网络训练的基本结构

上图为卷积神经网络训练的基本结构。与传统机器学习方法相比，CNN 的权值共享思想使得网络中需要训练的参数变少，降低复杂度的同时，减少了过拟合，更易于训练。到此，对神经网络基础的介绍结束，下一节将结合图像处理中的一个具体方向——目标检测，进一步介绍神经网络在图像处理方向上的发展史。

2.3.2 深度学习图像处理的发展——以目标检测为例 [26][27][28][29]

2.4.1 起源

ImageNet Large Scale Visual Recognition Challenge (ILSVRC) 是 2010 年到 2017 年间举办的机器视觉领域最受追捧且最具权威的学术竞赛之一。

在图像分类这个竞赛分支中，2010 年与 2011 年的获胜团队使用了传统的图像分类算法，最低取得了 28.2 % 的错误率。而 2012 年的获胜团队首次将深度学习用于大规模图像分类，使得其错误率比亚军低了 10 %。从这一年开始，深度学习方法在图像领域开始被广泛采用，新的模型的涌现不断降低错误率，而大规模数据集的出现更使其得到了充分的训练。接下来本文会从目标检测方面更详细的介绍其发展。

2.4.2 R-CNN

物体检测相比于图像分类要来的更加复杂，因为我们需要对一张图像中可能含有的多个不同种类的物体进行定位和识别。2012 年深度学习所取得的成功也同样影响到了物体检测的领域，Girshick 等开始目标检测中运用卷积神经网络，提出了 R-CNN 模型。在介绍 R-CNN 之前，我们先简单介绍一下目标检测的滑动窗口方法。它的核心思想就是从左到右，从上到下地滑动窗口，利用分类识别目标。如下图所示：

图 2.4.1 滑动窗口

但是这样的思想存在一个问题：如左图所示，识别人的窗口需要一个竖长方形窗口。但是如果把这个窗口平移到右边，试图用它来识别车辆，但是由于车辆的宽度大于长度，能符合这个窗口的概率不大。同样，如果用右图中识别车辆的横长方形识别人，也同样不成功。因此需要提前设计好多个可能会用到的窗口大小，每种窗口都滑动提取数张图片。提取成功后，将其输入 CNN 分类器中完成后续操作。可以发现，这是一种暴力式的操作，不仅会消耗大量的计算力量，由于人为设定的窗口大小大概率不准，因此其识别率也不高。这种思想的意义在于提供了一种解决目标检测问题的思路。

R-CNN 模型框架如下图所示，它与上述方法不同，不使用暴力方法，而是用候选区域方法，改变了目标检测的模型思路。R-CNN 模型在当时以优异的性能令世人瞩目。后续的 SPPNet、Fast R-CNN、Faster R-CNN 都是在此基础上加以改进的。

图 2.4.2 R-CNN 示意图

具体来说，第一步是生成候选框。这里用到了一种叫做选择性搜索

(Selective Search) 的方法。首先将每个像素作为单独的一组，然后计算每一组的纹理，将两个最接近的组结合起来，重复这样的操作直到所有区域不能再结合为止。下图展示了如何使区域增长：

图 2.4.3 选择搜索算法

这一步中，我们在一张图片上提取了大约 2000 个候选区域。需要注意的是这些候选区域的大小不固定，而 CNN 需要固定大小的输入，所以需要再对候选区域做一些尺寸上的修改。在处理完毕后，第二步 CNN 将在这些候选区域的基础上，提取出更高级、更抽象的特征，作为下一步分类器的输入，提取的这些特征通常会储存在磁盘中。

图 2.4.4 特征提取步骤

第三步，R-CNN 使用支持向量机 (SVM) 进行二分类，这是整个流程中最重要的一部分。假如共需检测 n 个类别，那么需要 n 个不同类别的 SVM 分类器，并且每个分类器会对所有 2000 个候选区域的特征向量进行打分，判断其是否为当前这个 SVM 需要判断的物体类别。具体来说：

图 2.4.5 SVM 分类

如图所示，如果需要识别的类别为猫与狗，那么首先对这 2000 个候选区域是否为猫进行打分。注意到这里的分数只能为是或否，这就是所谓二分类器的意义。同理，狗类别的 SVM 对每张图片是否为狗进行打分。经过所有 SVM 判断结束后，我们可以大体了解这些候选区域中哪些是无关背景，哪些是需要的目标，以及其具体类别。

第四步，我们发现第一步中得出的建议框有重叠的情况，因此需要利用上一步的打分结果剔除重复的建议框。这其中又引出了一种新方法：非极大值抑制 (NMS)。其首要目的就是一个物体只保留一个最优的框，去除那些冗余的候选框。首先，它根据上一步中的打分结果进行概率筛选，将 2000 个区域筛选至一个很小的数值。而这些剩下的框几乎都包含了一部分的图像内容，用上述方法得到的打分结果类似，难以再次筛选。因此下一步需要分别计算每一个候选框与实际目标区域的交并比 (IOU)，即两图像边框交集的面积与两图像边框并集的面积之比，以及各候选框两两之间的交并比。以下图为例：

图 2.4.6 非极大值抑制

我们发现经过概率筛选后还剩下五个候选框，其中 A、C 框对应黑车，B、D、E 对应白车。那么接下来就要从这两组中分别保留一个与对应车辆重合度最大的候选框。图中已经标识了它们各自相对于车辆的 IoU，那么对于黑车而言，最高的是 A 框。再对 A 框与 C 框计算 IoU，如果其 $\text{IoU} > 0.5$ ，那么意味着两者重合率较高，可以删除掉其中与目标物体重合率不高的，也就是 C。对 B、D、E 而言这个步骤同理，最终只保留了 B。最终在这五个候选框中检测出了 A 与 B 这两个目标。当然，在这个过程后依然还会有位置不准确的情况出现，因此需要用回归训练的方式修正这些候选区域。由于涉及到较多回归知识，在此不再过多赘述。通过以上四个步骤，R-CNN 最终输出了图片中需要被检测的目标位置。

图 2.4.7 VOC2010 数据集运行结果这种方法在 RASCAL VOC 2010 数据集中取得了出色的效果，mAP（对所有目标类别检测的效果取平均值）达到了 53.7 %。但是它仍存在一些尚未解决的问题：首先，由于在提取特征阶段，依然采用传统的选择搜索方法，导致候选区域的数量过多。而对于每个特征，所有的这些候选区域都将被输入到 CNN 中提取一次，不仅占用了大量磁盘空间，还非常耗时。在上述数据集中，检测一张图像的平均时间高达 47s。其次，图像在统一尺寸的过程中易失真，导致不期望看到的几何形变。如下图所示，对这些问题的思考最终导致了 SPP-Net 的产生。

图 2.4.8 SPP-Net 引入 2.4.3 SPP-Net[32]

为了解决上述 R-CNN 的部分缺陷，He 等在 2014 年提出了 SPP-Net，主要创新点在于将一个空间金字塔池化层（spatial pyramid pooling, SPP）添加在卷积层和全连接层之间，从而能适应任何尺寸的图像输入。同时，它还对特征提取步骤进行了修改，使得不需要每个候选区域都经过 CNN，只需要将整张图片输入，使运行速度得到了极大的提高，该层结构如下图所示：

图 2.3.9 SPP-Net

上一行的流程为标准 R-CNN 的流程，而下一行为将其改进后的 SPP-Net 流程。可以发现 R-CNN 先对图像进行选择与变换，再加入卷积层进行

提取特征，而 SPP-Net 则直接将整张图片加入卷积层中，得到全图的特征图。随后，通过映射的方式将选择性搜索在原图中的位置对应到特征图中的相应位置。而这些映射过来的特征向量，经过空间金字塔池化层 (spatial pyramid pooling, SPP)，输出固定大小的特征向量，后续部分与 R-CNN 相同。那么下面将介绍每一步的细节。对于映射操作，我们已经通过 CNN 提取到了整张图片的特征图，并通过选择性搜索算法得到了原图的候选框，接下来需要建立起两张图中对于同一物体的坐标对应关系。如下图所示：

图 2.4.10 映射

这种映射已有明确的数学公式描述，在此不做深入探讨。

下一步，由于在上一步中映射到的特征图大小不一，但是对于一个固定的 CNN，全连接层的输入是一个提前设定好的固定的数值，那么我们需要将特征图转换成固定大小特征向量。而这正是 SPP 的核心作用。假设需要被处理的某个候选区域的特征图的大小为 $12 \times 10 \times 256$ ，那么如下图所示，SPP 会通过池化的方式，把每一个候选区域都变成 1×1 、 2×2 和 4×4 的三张子图，连接到一起变为 $(16+4+1) \times 256 = 5376$ 的大小，并将其交给下一步处理。可以发现，对每一个候选区域的特征图都可以转换为这种形式，这样就实现了大小的统一。

图 2.4.11 空间金字塔池化层 SPP-Net 通过上述方式降低了卷积运算的数据量，减少了运算时间。然而，SPP-Net 算法依然使用了 R-CNN 的框架，由于 SVM 的存在，特征需要存入磁盘，空间占用较大。

2.3.2.4 Fast R-CNN[33] 经由 R-CNN 和 SPP-Net 的经验，在 2015 年，R-CNN 的提出者之一 Girshick 又再次提出了 Fast R-CNN 模型。他发现，上述的两种方法都需要多次训练模型，如训练卷积神经网络和训练 SVM。因此，他提出的 RoI pooling 整合了整个模型，将 CNN、RoI pooling、分类器甚至前文中省略的回归模块一起训练。下面给出了 Fast R-CNN 的整体流程图：

图 2.4.12 Fast R-CNN 首先，Fast R-CNN 的前几个操作与 SPP-Net 相同。它首先将整个图片输入到一个基础卷积网络中，得到整张图的特征图，然后再将原图中选择性搜索算法的得到的候选框映射到特征图中。接下来，

类似于 SPP-Net 中的 SPP 层，Fast R-CNN 给出了一个 RoI pooling 层。可以发现它其实是一个简化版本的 SPP 层。如下图所示：

图 2.4.13 ROI pooling 层在 SPP 层中，我们的得到了大小为 1×1 、 2×2 和 4×4 的三张子图，但是在 RoI pooling 层中我们仅仅通过池化的方式得到了一张 4×4 的子图。虽然前者相对而言较准确一些，但是后者的速度快很多。此外，Faster R-CNN 的整个框架都直接用一个神经网络相连，这是因为 R-CNN 中 CNN 的训练与 SVM 的训练互相独立，两者的参数都无法互相影响，将 SVM 分类通过其他方法代替以后，使得所有过程都在整体的框架中进行，前后部分互相进行反馈与调整。并且，由于不再存在两个的独立的过程，中间也无需再用硬盘空间暂时保存信息，一切都在内存中存储，解决了磁盘占用大的问题。在上述反馈过程中，需要进行损失的计算，这一部分同样涉及到了复杂的数学公式，同样不再赘述。在同样的 RASCAL VOC 2007 数据集，Fast R-CNN 的 mAP 达到了 68.4%。但是，无论是 R-CNN，SPP-Net 还是 Fast R-CNN，其都是建立在传统的选择搜索的基础上，而这成为了上述方法的瓶颈。

2.3.2.5 Faster R-CNN[34] 为了彻底解决这个短板，同年，Ren 等针对选择性搜索算法提取特征较慢的问题，提出了 Faster R-CNN。在该论文中，区域建议网络（RPN）的概念首次被提出，它被设计用来替代传统的选择性搜索算法。简单来说，Faster R-CNN 中也加入了一个提取边缘的神经网络，即寻找候选框的工作也交给神经网络了，如下图所示：

图 2.4.14 R-CNN 算法进化那么需要关注的重点就在于其代替选择性搜索方法的区域建议网络，其主要作用也是为了得出比较准确的候选区域。它的思路是用 $n \times n$ （默认 3×3 ）大小的窗口去扫描特征图，并且在每个被扫描的位置中都考虑 9 种可能的参考窗口（anchors），如下图所示：

图 2.4.15 区域建议网络注意到，上述的 9 种参考网络非常考究。它使用了 128、256、512 三种尺度的窗口大小，对于每种尺度分别又有 1: 1、1: 2、2: 1 三种长宽比，共计 $3 \times 3 = 9$ 种参考窗口。如下图所示：

图 2.4.16 参考窗口形状与大小在得到上述候选区域后，我们将它进行分类判别为前景或背景，并用回归方法修正位置，再加入 RoI 层中，后续

的流程与 Fast R-CNN 类似。这种方法提出 RPN 网络取代了传统的选择搜索算法。自此，目标检测的四个步骤，即寻找候选区域、提取特征、目标分类、调整位置被统一到了一个深度神经网络框架中。

图 2.4.17 Faster R-CNN 结构 2.3.2.6 FPN[35] 然而，卷积神经网络在提取特征时，高层特征容易保留语义信息，低层特征容易保留位置信息。具体到目标检测领域，高层特征虽然能保留语义信息，但是由于此时特征图的尺寸较小，含有的位置信息并不多，不利于物体检测；低层网络虽然包含比较多的位置信息，但是图像的语义信息并不多，不利于图像的分类，这个问题在小尺寸物体检测上更为显著，这也就是为什么物体检测算法普遍对小物体检测效果不好的最重要原因之一。基于这种问题，研究者们想到可以使用合并后的高层和低层特征来同时满足分类和检测的需求。传统的金字塔模型通过直接输入多尺度图像的方式构建多尺度的特征，如下图 2.4.18 所示，但是这样的计算成本太高。而 R-CNN、Fast R-CNN 和 Faster R-CNN 选择了只对卷积最顶层，即语义最丰富的一层进行特征提取，如下图 2.4.19 所示，但是如上文所言，这样对于目标的检测能力太差。其他方法如利用卷积网络的层次结构，在提取特征的过程中通过网络的不同层得到了多尺度的特征图。该方法虽然能提高精度，且基本上没有增加耗时，但是依然没有使用更加低层的特征图，对小物体的检测能力较弱。

图 2.4.18 单层特征图 2.4.19 多层特征于是，综合以上几点考虑，Lin 等提出了特征金字塔网络（FPN）方法。如下图 2.4.20 所示，FPN 不仅使用了层次较深的特征图，并且浅层的特征图也被应用到 FPN 中。并通过自底向上，自顶向下以及横向连接将这些特征图高效的整合起来，在提升精度的同时并没有大幅增加检测时间。上述三个具体操作在此不作深入讨论，实验证明，该特征金字塔结构的特征提取效果优于单尺度的特征提取效果。

图 2.4.20 FPN 模型到此，对双阶段目标检测算法的总结告一段落，列出下表再次将其进行对比：表 2.4.1 二阶段目标检测算法性能对比算法数据集 mAP(%) R-CNN PASCAL VOC 2007 58.5 SPP-Net PASCAL VOC 2007 59.2 Fast R-CNN PASCAL VOC 2007 68.0 Faster R-CNN PASCAL VOC 2007 78.0 FPN MS-COCO 34.4

表 2.4.2 二阶段目标检测算法综合对比算法创新点优势缺陷 R-CNN 将 CNN 应用于目标检测，利用选择分类算法和支持向量机开创深度学习在目标检测领域的先河耗时、占用空间大、易失真 SPP-Net 引入空间金字塔池化层，修改特征提取方式解决失真问题，加快运行效率占用空间依然很大 Fast R-CNN 引入 softmax 替代支持向量机，引入奇异值分解减少了储存空间的占用整体耗时受到选择搜索算法的限制 Faster R-CNN 引入区域建议网络，设计了多参考窗口机制实现端到端的目标检测模型，降低用时对小目标检测能力较差 FPN 引入多层特征与特征融合大幅度提高对小目标的检测能力

2.4.7 单阶段算法与两阶段算法 [36] 上文中出现了两阶段这个字眼，两阶段指的是实现检测的方式主要有两个过程：第一步，提取候选区域；第二步，再对区域进行 CNN 分类识别。因此，它又被称为基于候选区域的检测。而单阶段目标检测算法没有候选区域提取阶段，它采用一个网络一步到位，训练过程也相对简单，可以在一个阶段直接确定目标类别并得到位置检测框。其代表算法有 YOLO 系列与 SSD 系列。由于篇幅问题与作者水平限制，本文中对单阶段目标检测算法不再作深入讨论。2.4.8 总结

图 2.4.21 目标检测路线图上图给出了目标检测近 20 年来的里程碑算法，目标检测技术从传统的选择搜索算法到如今的深度学习算法，在提升精度的同时减少了对耗时和空间的需求。过去的几年中，不断有成熟的目标检测算法应用在工业界落地，不仅便利了人们的生活，也给学术界提供了丰富的灵感来源。下一小节，我们将实现一个简单的人脸识别技术用以演示。

2.4.9 深度学习图像处理举例我们在 github 上下载了几个已经训练好的模型，并以人脸检测为例：

“11.png”和“12.png”使用如下的 Python 代码实现：检测的结果为：

3.7 1.3. 成功案例

长期以来机器学习总能完成其他方法难以完成的目标。例如，自 20 世纪 90 年代起，邮件的分拣就开始使用光学字符识别。实际上这正是知名的 MNIST 和 USPS 手写数字数据集的来源。机器学习也是电子支付系统的支柱，可以用于读取银行支票、进行授信评分以及防止金融欺诈。机器学习算法在网络上被用来提供搜索结果、个性化推荐和网页排序。虽然长期处于公众视野之外，但是机器学习已经渗透到了我们工作和生活的方方面面。直到近年来，在此前认为无法被解决的问题以及直接关系到消费者的问题上取得突破性进展后，机器学习才逐渐变成公众的焦点。这些进展基本归功于深度学习。

-苹果公司的 Siri、亚马逊的 Alexa 和谷歌助手一类的智能助手能以可观的准确率回答口头提出的问题，甚至包括从简单的开关灯具（对残疾群体帮助很大）到提供语音对话帮助。智能助手的出现或许可以作为人工智能开始影响我们生活的标志。-智能助手的关键是需要能够精确识别语音，而这类系统在某些应用上的精确度已经渐渐增长到可以与人类比肩 [14]。-物体识别也经历了漫长的发展过程。在 2010 年从图像中识别出物体的类别仍是一个相当有挑战性的任务。当年日本电气、伊利诺伊大学香槟分校和罗格斯大学团队在 ImageNet 基准测试上取得了 28-博弈曾被认为是人类智能最后的堡垒。自使用时间差分强化学习玩双陆棋的 TD-Gammon 开始，算法和算力的发展催生了一系列在博弈上使用的新算法。与双陆棋不同，国际象棋有更复杂的状态空间和更多的可选动作。“深蓝”用大量的并行、专用硬件和博弈树的高效搜索打败了加里·卡斯帕罗夫 [17]。围棋因其庞大的状态空间被认为是更难的游戏，AlphaGo 在 2016 年用结合深度学习与蒙特卡罗树采样的方法达到了人类水准 [18]。对德州扑克游戏而言，除了巨大的状态空间之外，更大的挑战是博弈的信息并不完全可见，例如看不到对手的牌。而“冷扑大师”用高效的策略体系超越了人类玩家的表现 [19]。以上的例子都体现出了先进的算法是人工智能在博弈上的表现提升的重要原因。-机器学习进步的另一个标志是自动驾驶汽车的

发展。尽管距离完全的自动驾驶还有很长的路要走，但诸如 [Tesla](<http://www.tesla.com/>)、[NVIDIA](<http://www.nvidia.com/>)、[MobilEye](<http://www.mobileye.com/>) 和 [Waymo](<http://www.waymo.com/>) 这样的公司发布的具有部分自动驾驶功能的产品展示出了这个领域巨大的进步。完全自动驾驶的难点在于它需要将感知、思考和规则整合在同一个系统中。目前，深度学习主要被应用在计算机视觉的部分，剩余的部分还是需要工程师们的大量调试。

以上列出的仅仅是近年来深度学习所取得的成果的冰山一角。机器人学、物流管理、计算生物学、粒子物理学和天文学近年来的发展也有一部分要归功于深度学习。可以看到，深度学习已经逐渐演变成一个工程师和科学家皆可使用的普适工具。

3.8 1.4. 特点

在描述深度学习的特点之前，我们先回顾并概括一下机器学习和深度学习的关系。机器学习研究如何使计算机系统利用经验改善性能。它是人工智能领域的分支，也是实现人工智能的一种手段。在机器学习的众多研究方向中，表征学习关注如何自动找出表示数据的合适方式，以便更好地将输入变换为正确的输出，而本书要重点探讨的深度学习是具有多级表示的表征学习方法。在每一级（从原始数据开始），深度学习通过简单的函数将该级的表示变换为更高级的表示。因此，深度学习模型也可以看作是由许多简单函数复合而成的函数。当这些复合的函数足够多时，深度学习模型就可以表达非常复杂的变换。

深度学习可以逐级表示越来越抽象的概念或模式。以图像为例，它的输入是一堆原始像素值。深度学习模型中，图像可以逐级表示为特定位置和角度的边缘、由边缘组合得出的花纹、由多种花纹进一步汇合得到的特定部位的模式等。最终，模型能够较容易根据更高级的表示完成给定的任务，如识别图像中的物体。值得一提的是，作为表征学习的一种，深度学习将自动找出每一级表示数据的合适方式。

因此，深度学习的一个外在特点是端到端的训练。也就是说，并不是将单独调试的部分拼凑起来组成一个系统，而是将整个系统组建好之后一起训练。比如说，计算机视觉科学家之前曾一度将特征抽取与机器学习模型的构建分开处理，像是 Canny 边缘探测 [20] 和 SIFT 特征提取 [21] 曾占据统治性地位达 10 年以上，但这也正是人类能找到的最好方法了。当深度学习进入这个领域后，这些特征提取方法就被性能更强的自动优化的逐级过滤器替代了。

相似地，在自然语言处理领域，词袋模型多年来都被认为是不二之选 [22]。词袋模型是将一个句子映射到一个词频向量的模型，但这样的做法完全忽视了单词的排列顺序或者句中的标点符号。不幸的是，我们也没有能力来手工抽取更好的特征。但是自动化的算法反而可以从所有可能的特征中搜寻最好的那个，这也带来了极大的进步。例如，语义相关的词嵌入能够在向量空间中完成如下推理：“柏林-德国 + 中国 = 北京”。可以看出，这些都是端到端训练整个系统带来的效果。

除端到端的训练以外，我们也正在经历从含参数统计模型转向完全无参数的模型。当数据非常稀缺时，我们需要通过简化对现实的假设来得到实用的模型。当数据充足时，我们就可以用能更好地拟合现实的无参数模型来替代这些含参数模型。这也使我们可以得到更精确的模型，尽管需要牺牲一些可解释性。

相对其它经典的机器学习方法而言，深度学习的不同在于：对非最优解的包容、对非凸非线性优化的使用，以及勇于尝试没有被证明过的方法。这种在处理统计问题上的新经验主义吸引了大量人才的涌入，使得大量实际问题有了更好的解决方案。尽管大部分情况下需要为深度学习修改甚至重新发明已经存在数十年的工具，但是这绝对是一件非常有意义并令人兴奋的事。

最后，深度学习社区长期以来以在学术界和企业之间分享工具而自豪，并开源了许多优秀的软件库、统计模型和预训练网络。正是本着开放开源的精神，本书的内容和基于它的教学视频可以自由下载和随意分享。我们致力于为所有人降低学习深度学习的门槛，并希望大家从中获益。

3.9 1.5. 小结

-机器学习研究如何使计算机系统利用经验改善性能。它是人工智能领域的分支，也是实现人工智能的一种手段。-作为机器学习的一类，表征学习关注如何自动找出表示数据的合适方式。-深度学习是具有多级表示的表征学习方法。它可以逐级表示越来越抽象的概念或模式。-深度学习所基于的神经网络模型和用数据编程的核心思想实际上已经被研究了数百年。-深度学习已经逐渐演变成一个工程师和科学家皆可使用的普适工具。

3.10 1.6. 练习

-你现在正在编写的代码有没有可以被“学习”的部分，也就是说，是否有可以被机器学习改进的部分？-你在生活中有没有这样的场景：虽有许多展示如何解决问题的样例，但缺少自动解决问题的算法？它们也许是深度学习的最好猎物。-如果把人工智能的发展看作是第一次工业革命，那么深度学习和数据的关系是否像是蒸汽机与煤炭的关系呢？为什么？-端到端的训练方法还可以用在哪里？物理学，工程学还是经济学？-为什么应该让深度网络模仿人脑结构？为什么不该让深度网络模仿人脑结构？

2016 年 3 月 10 日，AlphaGo 登上了各大头条。谷歌研发的人工智能出乎大众意料，打败了围棋界公认的最优秀棋手之一李世石。围棋与国际象棋一样，也是一种两人游戏。然而一直以来，围棋之于国际象棋，就像国际象棋之于井字棋。围棋更复杂，组合更多，也更难以预计。最优秀的围棋棋手有时候甚至会依靠某种直觉，但他们也无法解释这些直觉的来源——有些人甚至断言，这是一种超越机器能力的人类智能。长期以来，最优秀的算法也只能勉强追上中等水平的围棋棋手。

但在数年之间，某种机器学习的模型接连取得了不同凡响的成绩。物体识别、人脸识别、光学字符识别、自然语言处理、自动化翻译以及推荐系统从前都是机器无法解决的问题，但突然之间，它们全部都被深度学习解决了。硅谷的所有投资者挂在嘴边的就只剩下这几个词语，所有网络巨

头都开始吹嘘自己现在能够提供些什么新服务。深度学习那引发轰动的成功与经典软件工程的众多方法形成了鲜明的对比。人们习惯先构筑一个理论，用来保证某项技术能正确运作；然后，人们就会沮丧地发现技术超出了理论。这就引发了下面这个永恒的问题：理论和实践之间的差距从何而来？有一句俏皮话是这样说的：“理论上它们是一样的，但是在实践中嘛……”但深度学习的情况似乎与此正好相反。似乎没有任何理论能够预言我们手头上的这项技术会取得成功。理论研究者被打打了个措手不及。深度学习的性能简直好得离谱，但似乎没有人知道为什么。深度学习在实践中效果很好，但它在理论上是否可行？这次，实干家对这个问题感兴趣，是因为他们也感觉到，深度学习在理论理解上取得的任何进步，都有可能显著地甚至戏剧性地推动人工智能的发展。

特征学习在深度学习大获成功之前，专业的数据科学家必须干预机器学习的算法，为的是对原始数据进行“清理”，预先简化数据的分析。深度学习研究的主要动机之一就是希望将数据预处理自动化，绕过对数据科学家技能的需求。这种做法让深度学习成为一把瑞士军刀，能够适应各种媒介，无论是图像、音频、视频、文字还是其他实时传感器的探测结果。

人工神经网络的灵感其实来自我们的大脑皮层。这是因为神经科学发现，我们的大脑会通过逐步抽象的方式来分析眼睛所看到的事物。眼睛中的传感器又被称为视锥细胞和视杆细胞，它们会探测那些令其进入激发状态的光线，得到光线的亮度和颜色。计算机科学家会说，这相当于图像中每一个像素的亮度和颜色。我们赋予深度神经网络的可观测变量的，正是这种原始数据。然后，负责计算的第二层神经元一般会衡量相邻像素之间的相关度。人类的第二层神经元都会连接着眼睛的几个视锥细胞和视杆细胞。

人工智能的前沿就是所谓的卷积神经网络 (convolutionneuralnetwork, 简称 CNN，因为它们与数学中的卷积运算有关)。这些网络的灵感就是来自视皮层的大体结构。图像分析的性能似乎依靠的正是这种抽象层次的堆积，而只有深度足够大的网络才能做到这一点。

单词的向量表示人们在自然语言处理的经验中也发现了类似的现象。自然语言处理的难点之一就是含有大量的自然语言词汇。与其让单一的神

神经元专门负责每一个词语的理解，不如通过每个词语与其他词语之间的关系来理解它们。奇怪的是，用数学的语言来说，要做到这一点，我们可以将词语组成的空间嵌入高维线性空间中，这个维度一般来说在 50 和 100 之间。用不那么晦涩的语言来说，每一个词语都会对应着多个神经元的某个激活组合。2013 年，一个由托马斯·米科洛夫领导的谷歌研究团队成功让神经网络学会了之前说的这种英语单词的神经元表达，这是一项引人注目的成就。他们将这种表达称为 word2vec。这种表达能以前述的方式将所有英语单词转换为高维空间中的向量。人们借此对所有单词组成的集合在表示方式上进行精简与结构化，因为从信息的角度来看，单词的向量表示更紧凑，仅需更少的比特数就能描述。但好处不止于此！单词的向量表示还能解释单词之间的众多联系。的确，米科洛夫研究团队的重大发现之一，就是单词之间的向量加法符合我们的直觉。比如，他们发现如果进行皇帝-男人 + 女人的向量运算的话，得到的结果大概就是皇后这个词语的向量表达 [2]！更令人着迷的是，我们在 GAN 中也能观察到这种现象。收集一些戴太阳镜的人的图像和没戴太阳镜的人的图像，你可以利用 GAN 计算出戴太阳镜的人对应的向量平均值以及没戴太阳镜的人对应的向量平均值。然后将这两个向量相减，得到的差就是某个向量，从直觉上来说，它对应着“戴太阳镜”。现在考虑一张没戴太阳镜的人的图像，计算它的向量表示，然后加上“戴太阳镜”的向量表示，就得到了一个新向量。现在利用 GAN 生成这个向量的对应图像。令人惊叹的是，得到的图像就是原来的图像中的人戴上了眼镜 [3]！真是难以置信！神经网络对不同抽象概念的向量求和结果的诠释竟然如此契合大脑对这些概念的直觉组合。

据此，能够阅读实体书的神经网络应该是一个深度神经网络，其中前几层是卷积神经网络，能够识别图像中的字符。然后，在负责视觉的这几层神经元之下，我们会发现一层能将字符合并为词语的神经元，以及另一层将词语转化为向量的神经元，就像 word2vec 所做的那样。最后，还有几层神经元负责解释那些表示词语的向量，将它们与其他概念联系起来。这些概念可以来自对图像或者其他信号的额外分析。因此，高效的深度神经网络在看到猫的照片或者读到“猫”这个词语的时候，应该能够激活同一组神

经元。为此，对原始数据的预处理似乎至关重要。一般来讲，对于原始数据的概括来说，无论是为了压缩体量宏大的原始数据，让计算能够在合理的时间内完成，还是为了揭示原始数据中相关性的切实解释，网络深度似乎都必不可少。

指数式的表达能力 ※ 2016 年 6 月 16 日，美国斯坦福大学、美国康奈尔大学以及谷歌大脑 (GoogleBrain) 的合作研究人员在 arXiv 上传了两篇非同凡响的论文。我被它们对抽象方法所获成功的别样解释深深迷住了。在本书中，我只能描述其中于我而言最有吸引力的那一篇。这篇论文题为《深度神经网络中经由暂态混沌出现的指数性表达能力》(“Exponential Expressivity in Deep Neural Networks through Transient Chaos”)。它结合了大量复杂、高深却鲜有联系的数学概念，比如混沌理论、平均场论和几何曲率。我们慢慢解释。这篇论文一开头就认为，神经网络不过是一个复杂的数学函数。这个函数以一组测量数据作为输入，然后将其转化为深度概念的组合。测量数据的集合在数学上组成了一个所谓的向量，我们可以将它看成极高维度的空间中的一个点。而深度概念的组合也是如此，它本身就是极高维度的空间中的一个点。这样的话，神经网络就可以被看成从第一个空间到第二个空间的几何变换。这篇论文提出的问题如下：“典型”的神经网络是如何将空间变形的？一个“随机选取”的神经网络平均而言是不是会将这些点到处移动？还是说，它会在变换中保留曲线的某些几何特性？这篇论文的回答引人深思：几何结构的复杂度会随着神经网络深度的增加呈指数增长。更准确地说，论文研究了几何图形的全局曲率³。从直觉上来说，圆就是弯曲程度最小的闭合图形，因为它的弯曲是为了回到自己的出发点。此外，无论圆的大小如何，它的全局曲率总是等于 $\tau \sim 6.28$ 。反之，一条在空间中的所有维度上都反复摆动的精细曲线会拥有非常大的全局曲率。(MW：傅里叶变换和曲率的关系：全局曲率越大，所需要的傅里叶级数越多，图形越复杂)³ 全局曲率就是曲线方向上单位向量导数的范数的积分。这篇论文证明了，对于足够“激动”的随机神经网络，几何图形的曲率会随着网络宽度的增长而呈多项式函数上升，并随着深度的增长呈指数上升。换句话说，比起宽度，网络的深度能让神经网络以更快的速度使对应的几何变换变得更复杂。所以，这说明深度是识别与分析分形结构的

关键，分形结构代表的就是那些并不总是光滑且正则的行为。然而，在我们周围的这个世界之中，分形结构似乎无处不在 [4]，无论是在生物学、宇宙学还是金融之中！同样，即使这种说法看似抽象甚至荒谬，但在所有图像组成的浩瀚集合之中，所有包含猫的图像组成的集合很可能同样有着分形结构。因此，网络的深度可能就是识别图像中有没有猫的关键，对于众多更复杂的任务来说也是如此。

3.11 1. 引言

自古以来，人类对于自身大脑的探索从未停止。大脑，这个复杂而精密的器官，不仅赋予了我们思考、感知和学习的能力，更让我们在漫长的进化过程中脱颖而出，成为地球上最智慧的生物。然而，尽管科学家们已经取得了许多关于大脑结构和功能的重大发现，但大脑的工作机制仍然充满了未知和神秘。

在大脑的探索之旅中，一个尤为引人注目的领域是神经网络。神经网络，特别是人脑中的神经网络，是一个由数以亿计的神经元通过突触相互连接而成的庞大网络。这些神经元和突触不仅负责传递和处理信息，还通过复杂的交互作用，实现了我们的各种感知、思考和行为。

受到人脑神经网络的启发，科学家们开始尝试构建人工神经网络(Artificial Neural Networks, ANNs)，以模拟大脑的信息处理过程。

人工神经网络 4 大理论支柱为“阈值逻辑”、“Hebb 学习率”、“梯度下降”、“反向传播”，前 2 个理论解决了单个神经元层面的建模问题，后 2 个理论则解决了多层神经网络训练问题。

2006 年 Hinton 首次实现了 5 层神经网络的训练，之后行业迎来爆发式发展，不断验证了该技术。

深度学习具备坚实的数学理论基础支撑。人脑绝大多数活动本质上都是广义计算问题，因此人脑其实是一个复杂的函数，深度学习就是去找到这个函数，万能近似定理则从数学上证明了一定条件下深度神经网络模型能够模拟任意的函数。用于深度学习的算力以 6 年 30 万倍的速度增加，算

力是核心瓶颈也是未来提升的关键。从进化角度看，人的智能是一个随着神经元数量提升，从量变到质变的过程，这个量变过程对应人工智能中模型所用算力的提升过程。目前能够实现的 AI 模型中不论从神经元个数还是连接数量看，与真实人类还有较大的差距，未来随着现有芯片技术的不断推进，和突破冯诺依曼架构的类脑芯片等新技术的发展，算力的持续突破将会不断释放人工智能技术的潜力。

面对大数据的人类大脑

这些算法似乎都离日常生活非常遥远。你可能会说你能够一一记住自己接收的所有数据，但这就错得离谱了。

人们可能从未察觉，每时每刻充斥我们大脑皮层的数据量大得可怕，有如 CERN 需要处理的数据量。我们的视觉、听觉、嗅觉、触觉、温度感觉，以及其他数不清的感觉，每秒都会向我们传输大约十亿字节 (1GB) 的数据 [4]。如果我们把数十年间收集到的数据累计起来的话，我们会发现感官接收到的数据总量需要用百亿亿字节 (EB) 作为计量单位！这可以说是大得可怕。

与现代信息技术面对的情况类似，我们的大脑也无法储存自身接收到的所有数据。它也不想这样做，因为其中绝大部分数据没有意义，它不得不忘记绝大部分数据。

在视觉数据的处理中，这种状况尤其突出。据神经科学家马库斯·赖希勒所言 [5]，我们的视皮层拥有惊人的能力，可以将十亿字节的视觉数据转换为几千字节的有用数据，这种处理在每一秒都在进行，而且只需要消耗极少的能量 [footnote 视觉]。[footnote 视觉]: 赖希勒估计，我们的视网膜每秒会收集到大约 10^{10} 比特的数据，但到达初级视皮层的第四层的数据只有大约 10^4 比特。

在更普遍的意义上，大脑会优先保留数据的“大体概念”，而不是具体细节。一般来说，我敢打赌你不能背出这本书前 15 章中的任意一句话。但在我的期望中，你应该记住了这些章节讨论的是贝叶斯公式、它的逻辑基础、它在归纳推理问题上的应用、它的历史、所罗门诺夫妖及其在博弈论中的应用，甚至还有它与演化理论之间的联系。即使你可能没有记住读到的

任何一个句子，但我仍然希望你记住了读到的文字中各种基础概念的抽象表达。

对于接收到的信息只保留压缩过后的表示，这种能力并非弱点，而正是大脑的强大之处。我们一般都能够回忆起那些重要的事物，而且完全忘却那些对我们来说无足轻重的东西。

用贝叶斯帮助记忆我们之前看到，人类大脑令人叹服的地方之一，就是它将极大量原始数据压缩为寥寥几个想法的能力。受此启发，人工智能研究者发明了自编码器这一架构。自编码器的任务，就是对大量信息进行精简，这些信息可以是高分辨率的图像或者整部电影，等等，最终只留下内容的精髓。换句话说，这些神经网络尝试做到的，正是我们在语文课上被要求做的一种练习：撰写摘要。为了测试摘要的质量，人们也要求自编码器对自己生成的摘要进行解压缩，设想与这一摘要相关的高分辨率图像或其他原始数据是什么样子的。要做到这一点，关键之一就是利用贝叶斯方法。对数据重组，其实就是确定什么数据会得出眼前这个摘要。这正是贝叶斯公式的典型应用！我们需要确定这个摘要的可能原因，因此

<!--[截屏 2024-09-0418.50.53](/Users/Min369/Downloads/同步空间/Obsidian/书/截屏 2024-09-0418.50.53.png) -->

另外，我们在下一章也会看到人工智能研究者如何利用这一公式，引入不常见的摘要，向机器赋予了创造性。

短期记忆与长期记忆

金特和朱莉娅·肖研究的是长期记忆。其中，信息被储存在大脑皮层这一神经网络的拓扑结构之中。问题在于访问这些数据可能很困难，需要测试信号在网络中传播的各种可能方式。回忆一首有名的歌曲的歌词一般来说就是这样的情况。在刚开始回忆时，我们通常想起几个词之后就想不起来了，就好像大脑中电信号的流动停滞了，或者流向了错误的方向一样。然而在重复这种流动之后，我们最终仍能找到正确的道路，回忆起整首歌的歌词。

人们在大型数据库中搜寻信息的时候也会碰到同样的问题。给谷歌和其他公司带来巨大财富的事物之一，就是为了加速信息搜索而整合互联网

数据的方法。但这并不只是信息整合的问题，人们也经常要在储存容量和存储速度之间对储存信息的媒介进行取舍。

递归神经网络

无论如何，人工神经网络的研究选择了第三条道路：神经信号的环路传播。包含这种环路的神经网络架构又叫递归神经网络。在处理当前数据时，这种网络能够利用前一时刻的部分信息。对于处理本质上有时序特性的数据，比如书中的文本或者讲话中的声音，递归神经网络已经成为最尖端的技术。

递归神经网络用到的技巧也包含在一类更广泛的拥有内部状态的算法之中。值得一提的是，这一类算法包括之前谈到的卡尔曼滤波器和隐马尔可夫模型。内部状态的任务就是以精练的方式提取出前一时刻的信息，用以更好地理解前一个被分析的数据。然而另一个问题就是，与数据读取相比，内部状态会以什么样的速度变化。我有幸在自己学习数学和指导学生学习的过程中都观察到了一点东西。第一次读一份文献时（比如说你正在看的这本书），最好不要停留在细节上，以免偏离阅读的主线。因为如果读得太慢，换种说法，就是对于短期记忆这一内部状态修改得太多的话，会使思绪偏离文献想让我们思考的东西。因此，有时候先迅速浏览一遍，再多花点时间细细阅读，最后再速读一遍，这样可能效果更好。每一次阅读都会带来新的东西，因为每一次阅读都联系着短期记忆这一内部状态的不同变化动态。到这里为止，我们讨论的还是对数据的线性阅读，但我们阅读或者聆听的方式并非完全线性的。的确，当某个句子非常晦涩的时候，我们一般会重读几次，然后才继续线性阅读。同样，有时候如果别人一句话还没说完，我们就无法理解。在梵语、印地语和日语中，动词位于句末，所以这种情况尤其显著。同样道理，在数学论文中，计算过程之后通常会有对计算的解释。还有些笑话、广告和电影，正是结尾决定了它们的意义。

为了同时利用过去和未来的数据理解现在，人们提出了另一种神经网络架构，那就是所谓的双向递归神经网络。为了将未来纳入其中，这些网络必须延长得出回应的时间。我们可以打赌，人类大脑中也有类似的结构。这也能解释我们在经过一段延迟之后才理解笑话的能力，甚至有时候这种

延迟本身就引人发笑。

最后，人工智能领域的一项最新进展就是引入了迫使遗忘的神经元件。那就是所谓的 LSTM 架构，意思是“长短期记忆”(long-short-term memory)。除了递归神经网络中常见的那些神经元环路之外，LSTM 还拥有另一个额外的环路，它激活的时候会强制让所有神经元环路中的信号消失。这也许就解释了为什么我们在讨论中被打断之后，有时候很难回想起之前讨论的话题。

目前，在处理本质上有时序特性的数据方面，比如语音识别、自然语言分析，等等，LSTM 及其变体似乎就是最尖端的人工智能方法。但我承认自己不理解它为何如此成功，我也承认自己没有足够的专业水平来预测这些领域未来的前沿进展。

3.12 2. 背景

3.12.1 第一阶段

1943 年，美国神经生理学家沃伦·麦卡洛克和数学家沃尔特·皮茨对生物神经元进行建模，首次提出了一种形式神经元模型。这个神经元模型通过电阻等元件构建的物理网络得以实现，被称为 M-P 模型。1958 年，罗森布拉特又提出来了感知器，这意味着经过训练后，计算机能够确定神经元的连接权重。就这样，神经网络的研究迎来了第一次高潮。然而在 1969 年，明斯基等人指出感知器无法解决线性不可分问题，使得神经网络网络的研究陷入了第一次低谷。

3.12.2 第二阶段

1986 年，Rumelhart(鲁梅尔哈特)等人提出了误差反向传播算法通过设置多层感知器，解决了线性不可分问题。从反向传播算法的发表开始，神经网络迎来第二次高潮。1989 年，Yann Lecun 等研究人员实现了一个 7 层的卷积神经网络 LeNet-5，识别手写数字的精度达到了 98

3.12.3 3. 第三阶段

2006 年, Hinton(辛顿) 等人利用限制玻尔兹曼机对神经网络的连续层进行建模, 使用逐层预训练的方法抽取模型数据中的高维特征, 后来又提出了深度信念网络。这一技巧随后被众多学者推广到了许多不同的神经网络架构上, 大大地提高了模型在测试集上的泛化效果。同时, 随着硬件计算能力和算法的提升, 网络隐层可以不断增加, 于是以 Hinton 为代表的研究人员重新将人工神经网络定义为深度学习。人工神经网络定义为深度学习, 并进行推广。自 2011 年起, 神经网络就在语音识别和图像识别基准测试中获得了压倒性优势, 由此迎来了它的第三次高潮。

3.12.4 3. 结构

![R-C](file:///Users/Min369/Library/Group

三个层次: 输入层、隐藏层和输出层

输入层是神经网络的基层, 它负责接收外界的输入数据。这些数据可以是图像、声音、文本等各种形式, 经过预处理后转换成神经网络能够接受的形式。隐藏层是神经网络的核心部分, 它由多个神经元组成, 负责处理输入数据并传递到下一层。隐藏层的设计和数量需要根据具体的任务来确定, 它们的作用是对输入数据进行分类或预测。输出层是神经网络的最高层, 它负责将隐藏层处理后的结果转换成实际输出

圆形节点与人工神经元:

在人工神经网络中, 每个圆形节点代表一个人工神经元。这些神经元通过特定的连接方式相互交互, 模拟生物神经网络的工作原理。

连接与信号传递:

箭头表示从一个神经元的输出到另一个神经元的输入的连接。通过这些连接, 信号可以在网络中传递, 从一个人工神经元传递到另一个。

权重与激活函数:

每个节点都代表一种特定的输出函数, 称为激活函数。每两个节点间的连接都有一个与之相关的权重值, 表示前一个神经元对后一个神经元的

影响程度。

网络输出：

网络的输出会根据网络的连接方式、权重值以及激励函数的不同而变化。通过调整这些参数，人工神经网络能够学习和适应不同的输入模式，产生预期的输出结果。

3.12.5 4. 如何训练

4.1 简介

反向传播算法(Backpropagation)是目前用来训练人工神经网络(ArtificialNeuralNetwork ANN)的最常用且最有效的算法。其主要思想是：

(1) 将训练集数据输入到 ANN 的输入层，经过隐藏层，最后达到输出层并输出结果，这是 ANN 的前向传播过程；

(2) 由于 ANN 的输出结果与实际结果有误差，则计算估计值与实际值之间的误差，并将该误差从输出层向隐藏层反向传播，直至传播到输入层；

(3) 在反向传播的过程中，根据误差调整各种参数的值；不断迭代上述过程，直至收敛。

4.2 数学推导

1. 变量定义

先定义一些变量：

2. 代价函数

代价函数被用来计算 ANN 输出值与实际值之间的误差。常用的代价函数是二次代价函数 (Quadraticcostfunction)：

其中， x 表示输入的样本， y 表示实际的分类，

3. 公式及其推导

本节将介绍反向传播算法用到的 4 个公式，并进行推导。如果不想了解公式推导过程，请直接看第 4 节的算法步骤。

公式 1 (计算最后一层神经网络产生的错误)：

其中，

首先看上面证明的第一行，我们知道损失函数的形式，输出层的每一个输出都能够看作是损失函数的一个变量。

要是不理解的话，假设我们这里的损失函数为之前提到过的二次函数在神经网络里面可以写为上面的形式，因为一个网络的输出就是最后一层的输出。这下能不能够明显的理解上面的那句话了呢？

那么证明第一行就是通过链式法则得到的。

然后只有和是有依赖关系的，其他的没有依赖关系的求导为 0 不见了，因此，只剩下第二行。第二行出来了，又因为，那么后面的也就都容易推出来了。

公式 2（由后往前，计算每一层神经网络产生的错误）：

推导过程：

通过这个公式，只要我知道 $l+1$ 层的误差，那么我就能够知道 l 层的误差，由此，我就能够倒退直到第 1 层的误差。这个式子就体现了误差的反向传播的特点。然后公式 1 和公式 2 结合起来，我们就能够求出神经网络中任何一层，任何一个神经元上面的误差。

公式 3（计算权重的梯度）：

推导过程：

这个公式告诉我们，某个神经元上面误差对于偏置的偏导要等于在这个神经元上面的误差。而我们之前已经说过了，我们要求梯度的话就需要求出这些偏导，现在通过误差间接得到了偏导。很巧妙。

公式 4（计算偏置的梯度）：

推导过程：

4. 反向传播算法伪代码

输入训练集

对于训练集中的每个样本 x ，设置输入层（Inputlayer）对应的激活值：

前向传播：

计算输出层产生的错误：

反向传播错误：

使用梯度下降（gradientdescent），训练参数：

4.3 激活函数

激活函数(ActivationFunction),就是在[人工神经网络](<https://baike.baidu.com/item/人工神经网络/382460>)的神经元上运行的[函数](<https://baike.baidu.com/item/函数/301912>),负责将神经元的输入映射到输出端,旨在帮助网络学习数据中的复杂模式。

常见类型: ReLU、Sigmoid、Tanh

Sigmoid 激活函数的数学表达式为:

导数表达式为:

函数图像如下:

tanh 激活函数的数学表达式为:

函数图像如下:

实际上, Tanh 函数是 sigmoid 的变形:

与 sigmoid 不同的是, tanh 是“零为中心”的。因此在实际应用中, tanh 会比 sigmoid 更好一些。但是在饱和神经元的情况下, tanh 还是没有解决梯度消失问题。

什么情况下适合使用 Tanh?

tanh 的输出间隔为 1, 并且整个函数以 0 为中心, 比 sigmoid 函数更好;

在 tanh 图中, 负输入将被强映射为负, 而零输入被映射为接近零。

Tanh 有哪些缺点?

仍然存在梯度饱和的问题

依然进行的是指数运算

ReLU 激活函数的数学表达式为:

函数图像如下:

什么情况下适合使用 ReLU?

ReLU 解决了梯度消失的问题, 当输入值为正时, 神经元不会饱和

由于 ReLU 线性、非饱和的性质, 在 SGD 中能够快速收敛

计算复杂度低, 不需要进行指数运算

ReLU 有哪些缺点?

与 Sigmoid 一样，其输出不是以 0 为中心的

DeadReLU 问题。当输入为负时，梯度为 0。这个神经元及之后的神经元梯度永远为 0，不再对任何数据有所响应，导致相应参数永远不会被更新

训练神经网络的时候，一旦学习率没有设置好，第一次更新权重的时候，输入是负值，那么这个含有 ReLU 的神经节点就会死亡，再也不会被激活。所以，要设置一个合适的较小的学习率，来降低这种情况的发生

4.1 人工神经网络在各个领域中的应用

3.12.6 人工神经网络在信息领域中的应用

在处理许多问题中，信息来源既不完整，又包含假象，决策规则有时相互矛盾，有时无章可循，这给传统的信息处理方式带来了很大的困难，而神经网络却能很好的处理这些问题，并给出合理的识别与判断。

1. 信息处理

现代信息处理要解决的问题是很复杂的，人工神经网络具有模仿或代替与人的思维有关的功能，可以实现自动诊断、问题求解，解决传统方法所不能或难以解决的问题。人工神经网络系统具有很高的容错性、鲁棒性及自组织性，即使连接线遭到很高程度的破坏，它仍能处在优化工作状态，这点在军事系统电子设备中得到广泛的应用。现有的智能信息系统有智能仪器、自动跟踪监测仪器系统、自动控制制导系统、自动故障诊断和报警系统等。

2. 模式识别

模式识别是对表征事物或现象的各种形式的信息进行处理和分析，来对事物或现象进行描述、辨认、分类和解释的过程。该技术以贝叶斯概率论和申农的信息论为理论基础，对信息的处理过程更接近人类大脑的逻辑思维过程。现在有两种基本的模式识别方法，即统计模式识别方法和结构模式识别方法。人工神经网络是模式识别中的常用方法，近年来发展起来的人工神经网络模式的识别方法逐渐取代传统的模式识别方法。经过多年的研究和发展，模式识别已成为当前比较先进的技术，被广泛应用到文字识

别、语音识别、指纹识别、遥感图像识别、人脸识别、手写体字符的识别、工业故障检测、精确制导等方面。

3.12.7 人工神经网络在医学中的应用

由于人体和疾病的复杂性、不可预测性，在生物信号与信息的表现形式上、变化规律（自身变化与医学干预后变化）上，对其进行检测与信号表达，获取的数据及信息的分析、决策等诸多方面都存在非常复杂的非线性联系，适合人工神经网络的应用。目前的研究几乎涉及从基础医学到临床医学的各个方面，主要应用在生物信号的检测与自动分析，医学专家系统等。

1. 医学专家系统

传统的专家系统，是把专家的经验 and 知识以规则的形式存储在计算机中，建立知识库，用逻辑推理的方式进行医疗诊断。但是在实际应用中，随着数据库规模的增大，将导致知识“爆炸”，在知识获取途径中也存在“瓶颈”问题，致使工作效率很低。以非线性并行处理为基础的神经网络为专家系统的研究指明了新的发展方向，解决了专家系统的以上问题，并提高了知识的推理、自组织、自学习能力，从而神经网络在医学专家系统中得到广泛的应用和发展。在麻醉与危重医学等相关领域的研究中，涉及到多生理变量的分析与预测，在临床数据中存在着一些尚未发现或无确切证据的关系与现象，信号的处理，干扰信号的自动区分检测，各种临床状况的预测等，都可以应用到人工神经网络技术。

3.12.8 人工神经网络在交通领域的应用

近年来人们对神经网络在交通运输系统中的应用开始了深入的研究。交通运输问题是高度非线性的，可获得的数据通常是大量的、复杂的，用神经网络处理相关问题有它巨大的优越性。应用范围涉及到汽车驾驶员行为的模拟、参数估计、路面维护、车辆检测与分类、交通模式分析、货物运营管理、等领域并已经取得了很好的效果。

4.2 人工神经网络应用和卷积对比

随着科技的快速发展，深度学习已经成为了人工智能领域的重要分支。在深度学习中，卷积神经网络（CNN）和人工神经网络（ANN）是两种最为常见的网络类型。它们在结构和应用上存在一些显著的区别。本节将对分析 CNN 和 ANN 的区别，并通过实例阐述两者的应用。

CNN 和 ANN 的区别主要体现在两个方面：结构和应用。首先，从结构上看，CNN 侧重于处理图像数据，它的卷积层和池化层能够有效降低参数的数量，提高网络的性能；而 ANN 则没有这种结构上的限制，可以自由地设计神经网络结构来解决不同的问题。其次，从应用上看，CNN 在处理图像任务时表现出色，如图像分类、目标检测等；而 ANN 则更加通用，可以应用于各种类型的数据和任务。在应用案例方面，CNN 和 ANN 各有优势。例如，在 [图像识别](<https://cloud.baidu.com/product/imagerecognition>) 任务中，CNN 可以通过学习自动提取图像的特征，从而实现高效的图像分类。相比之下，ANN 需要手动设计特征，因此在这方面的表现可能不如 CNN。然而，在某些复杂的任务中，如 [自然语言处理](<https://cloud.baidu.com/product/wenxinworkshop>) (NLP)，ANN 则可能更有优势。ANN 可以通过构建深层神经网络，学习和理解语言的复杂模式和结构，从而实现高效的文本分类和语言翻译等任务。

猫是什么？2012 年，谷歌因一条奇怪而又令人不安的公告登上了各大新闻头条。据这些头条所说，谷歌的人工智能发现了“猫”这个概念 [9]！很多人可能觉得这是个平平无奇的新闻，但对我来说，这是机器学习的一个里程碑式的惊人突破，可能比 AlphaGo 在四年之后大败李世石给人留下的印象更深刻、更出人意料。要理解这一点，首先要说明谷歌的人工智能是一个人工神经网络，带有一些接收器，让它可以“看见”数字化图像。谷歌给这个人工神经网络展示了 1000 万幅图像，其中不包含上下文。然后，谷歌将这个人工神经网络放进某种相当于核磁共振成像的处理系统中，用以测量它暴露在其他图像中的时候神经元的实时激活状态。谷歌意识到其中某些神经元大体上当且仅当向其展示的图像包含一只猫时才会激活！真正给人留下深刻印象的是，这并不是谷歌在设计这个人工智能的时候设定的目标。这个人工智能的目标是以最合理有效的方式分析、处理并解释图像中

的内容。人工智能必须为它看到的那些图像建立一个模型。为此，它必须做的事情之一就是解释图像中某些像素颜色之间反复出现的相关性。比如说，当图像中的某些像素构成了眼睛的形状，那么在它的左边或者右边不远处通常会有一份与这些像素相似的复制品。一只眼睛的图像通常伴随着另一只眼睛的图像。怎么解释眼睛很少单独出现这一点呢？最惊人的其实是，这个问题的解释似乎大体符合我们之中大多数人会给出的答案：因为照片拍到的动物通常有两只眼睛。人、狗和猫（几乎）都拥有两只眼睛这个事实对我们来说似乎如此微不足道，人们几乎不会对它花上任何时间进行思考。我们是如此习惯于日常生活中的事物，以至于我们甚至不再寻求解释——但这其实是个迷人的生物学问题，需要对视差的数学理解！但对我来说更迷人的，我们竟然可以（大体上）对于什么是人、什么是猫、什么又是狗达成共识。我们甚至没有意识到这些概念既抽象又模糊！猫是什么？怎么定义猫这个概念？更重要的是，猫存在吗？要理解“猫”这个概念的奇怪之处，我们可以先强调这个定义有多么模糊。人们一般认为猫就是两只猫交配后产生的东西，换句话说，猫的双亲都是猫。到这里为止还没有什么惊人的东西，甚至这可能还是非常显然的东西。但其中大有深意。比如说现在有一只猫，它的双亲都是猫，它的双亲的双亲也是猫，它的双亲的双亲的双亲也是猫，以此类推。但是这种对时间的回溯并没有尽头！根据这种推理，我们必须回溯生命演化树，到达猫还没有出现的年代！的确，如果我们回溯到几亿年甚至几十亿年前，我们会到达一个没有哺乳动物、脊椎动物，甚至连真核生物都不存在的时代！猫的双亲都是猫，或者说猫就是两只猫交配后产生的东西，这些说法在逻辑上就有矛盾 [10]。我预计到有些读者会提出用 DNA 的概念来定义猫这个概念。然而这会导致几个问题。首先，我们还没有对猫的所有基因组进行测序，而我们可能永远无法对所有猫的基因组进行测序，因为未来的猫现在还没有出生！所以怎么定义一组与猫对应的 DNA 代码并不是一个显然的问题。其次，即使我们成功做到了这一点，还要对动物进行基因组测序才能断定它是不是猫，这个解决方案在现实中完全不可行。再次，人们也许会严肃地考虑，包含猫的全套 DNA 的一个单独的猫细胞，比如猫毛中的细胞，它算不算一只猫？最后也是最重要的一点

就是，DNA 这个概念在大约半个世纪之前完全不存在。往好了说，这意味着薛定谔、达尔文和亚里士多德在谈论猫的时候其实不知道自己在说什么。我们必须理解这个显而易见的事实：“猫”这个词并没有一个令人满意的严谨的定义。如果我问你猫是什么，你无法给出一个普遍适用、毫无争议的定义。而这不是什么惊人的事情，毕竟你不是通过这种方式学到怎么认知并使用“猫”这个概念的！如果你大概知道猫是什么，那是因为你已经看过上千张甚至上百万张猫的图像，你也听说过猫，也读过有关猫的材料。你通过观察大量数据学到了猫是什么。但你从来没有看见过关于“猫是什么”的形式定义！实际上，在人类历史中，没有人知道怎么给出“猫是什么”的形式定义。还有更神奇的。必定存在第一个想到“猫”这个概念的人。因为这个人第一个想到这个概念的，不会有人教他这一点，所以这个人就自己发明了“猫”这个概念。为什么？他又是怎么做到的？人类引入的新概念从何而来？这种能力是人类智慧特有的吗？我觉得谷歌人工智能的发现非常震撼人心，因为它给出了这些问题的答案。不，这并非人类智慧特有的能力，因为谷歌的神经网络同样做到了这一点。而它做到这一点是因为它希望分析、综合并解释数字化图像中不同像素颜色之间的相关性，它希望得到一个模型来描述自己看到的東西，而它找到的模型自然导致了“猫”这个概念的诞生！

正确问题的近似解答的价值远远大于错误问题的精确解答的价值。——约翰·图基 (1915—2000) 真理 (.....) 实在过于复杂，除了近似以外都不可行。——约翰·冯·诺伊曼 (1903—1957)

无穷计算在数学里遍地都是。这些计算中最著名的可能是周角率 (它与历史上“喧宾夺主”的圆周率 [2] 的关系是)。在 14 世纪，伟大的印度智者摩陀婆就发现了一个惊人的等式的交错和的 8 倍！；也就是说，周角率不过就是奇数倒数我们可能会认为这种无穷计算毫无用处。但事实上，无穷计算在应用数学的简单模型中无处不在，流体力学方程 (导数和积分都是无穷步的计算结果) 就是一个例子。这是因为，即使无穷计算只代表了一种不可计算的理想情况，但它一般能指出进行近似计算的巧妙方法。比如摩陀婆的等式就能用于计算的近似值，也就是说，它可以用于计算半径已知的圆的

周长。工程师在实践中使用的正是这类近似方法。如果你在常用的计算器或者谷歌上查询的值，它们很有可能会撒一点小谎，只给你提供小数点后十几位数字的近似值。这个问题并非只在上发生。你的计算器对于那些二进制表示并非有限的数都处理得非常糟糕 [3]，这样的数包括无理常数，例如和，还有某些有理数，比如 $1/3$ 和 0.2 。此外，因为计算器只能处理近似值，所以它可能会得出一些违反常理的结果，比如说，或者在比大得多的时候会得到，即使本身大于 0。数学家经常会认为，在计算机上进行的计算只不过是数学理论的近似。所罗门诺夫妖的立场却完全相反。对于所罗门诺夫妖来说，实数之类的对象只不过是一些让我们可以构建算法并对其更好地进行思考的模型。特别是对于尝试追随所罗门诺夫妖步伐的计算机科学家来说，他们用于尝试衡量置信度的模型并不是由实数作为参数组成的模型，而是那些储存在计算机文件中的模型，其中用到的只是数学模型中实数的截断。正因如此，与数学的理想状态相反，人工神经网络的大小可以用字节来计数 4。

渐近展开如果说对这样的数值进行高精度计算毕竟获益有限，那么对物理学、生物学或者数学中出现的曲线、函数和行为进行近似就会产生大量的应用。通过素数定理对素数计数函数进行近似就是这样的情况。更一般的框架中存在这样一项工具，它对于任意模型都可以计算出比模型本身简单得多的近似版本。这项工具就是渐近展开。一般来说，渐近展开可以让我们用一条直线来逼近圆上的一小段圆弧，或者用平面来逼近（相当圆润的）地球的一小块表面。用代数术语来说，这相当于用形如的仿射方程来逼近所谓的非线性方程。对于那些变化足够小的现象来说，这种近似完全是可以接受的。这就解释了为什么我们要在学校里花上这么长的时间来研究这些简单的方程，以及为什么这些方程在科学中无处不在 5。

对物理学家来说不可或缺的渐近展开，最精彩的例子可能就是爱因斯坦的广义相对论方程。它的渐近展开可以导出牛顿力学！换个说法，就是牛顿的力学定律，特别是关于万有引力的定律，只不过是爱因斯坦方程的近似，在有限的场景里完全适用。这种有限的场景就是所谓的“弱引力”情况 6。[4] 6 更准确地说，这应该是时空曲率极小的情况。

实用主义的限制然而在现实中，计算能力是有限的。我们之前也看到了，在地球上执行超过 10^{90} 个计算步骤是种不切实际的愿望。这就大大降低了我们用贝叶斯公式进行计算的能力。

作为比较，人类大脑包含大约 10^{15} 突触，这意味着对大脑的完整描述至少需要比特的信息。研究所有包含这么多字符的理论，至少需要 $2^{10^{15}}$ 次计算！因此，即使能用到古戈尔个宇宙，对这些理论应用贝叶斯公式也完全是一种幻想。

图灵的机器学习 1950 年，艾伦·图灵将这个关于算法不可避免的复杂度的论证过程漂亮地转移到了人工智能问题上。在一篇发表在期刊《心灵：心理学与哲学季度评论》(Mind, a Quarterly Review of Psychology and Philosophy) 上，题为《计算机制与智能》(“Computing Machinery and Intelligence”) 的论文中，图灵首先提出了一个与算法执行所需时间没什么关系的问题：“机器能思考吗？”图灵尝试回答的就是这个问题。然而“思考”这个词的模糊性让他尝试将问题精确化。与其考虑这个问题，图灵提出了另一个问题，就是机器是否能像人那样行动。

更准确地说，图灵提出了以下的测试：要求一位人类 A 与另外两个实体 X 和 Y 进行书面通信，而这两个实体 X 和 Y 分别是人类和一台机器。如果人类 A 无法分辨 X 和 Y 之中哪一个实体是人类的话，那么机器就通过了测试。换句话说，如果机器知道怎么模仿人类，而任何人类都无法分辨出这台机器不是人类的话，那么机器就成功通过了测试。这就是图灵所谓的“模仿游戏”，我们今天将它称为图灵测试 [5]。

在论文的第 3 节到第 5 节中，图灵重提了他 1936 年的工作，严格定义了机器到底是什么——这个概念推动了计算机的发明，接着就是数字时代的到来！然后在论文的第 6 节中，图灵否定了尝试证明机器不可能思考的 9 个经典论证。但更重要的是，在论文的第 7 节，图灵预料到了其测试中的难点及解决方法。即使仍然不能说计算机当时已经存在，但图灵不仅已经预料到了它们会在未来出现，而且还预料到了它们以后的性能将足以在模仿游戏中取胜：“(工程上的进步) 似乎不可能不足够 (使其通过测试)。”对于图灵来说，“这个问题主要是编程问题”。特别是，图灵以惊人的远见推测

出，能成功通过图灵测试的程序代码至少需要大概 10^9 个字符来描述。也就是说，用我们在第 7 章引入的术语来说，图灵自己猜测，图灵测试的所罗门诺夫复杂度应该以十亿字节来计量。为了得到这个估计值，图灵依靠的是他所知的唯一一台能通过图灵测试的机器。对，我说的就是人类大脑！毕竟还有什么能比人类更善于模仿人类呢？对图灵来说值得庆幸的是，当时的神经科学已经给出了人类大脑复杂度的估计值，提出人类的神经元之间大约有 10^{11} 到 10^{15} 个突触——现代的估计值处于 10^{14} 和 5×10^{14} 之间。图灵提出，只有一小部分突触对于通过图灵测试来说是必不可少的，这就是需要 10^{15} 个字符这个数字的来历。

同样出于他无比的智慧，图灵注意到人类大脑能够通过图灵测试。于是他猜测，通过模仿人类大脑成功完成图灵测试，我们能更好地构建能够通过测试的机器。然而图灵也注意到，儿童教育同样是大脑最终发育过程中的重要一环。“儿童的大脑可能类似于我们在文具店买到的笔记本，”图灵这样写道，“没什么机关，但有许多张白纸⁸。”图灵从而提出，为了帮助机器填满它自己的白纸，可以让它从数据中学习。学习机器的概念，也就是能够学习的机器，就此诞生。

因此，学习机器这个想法能够让机器自己写出包含数十亿字符的程序——必要时可以写得更长。用更贴近算法的语言来说，这相当于肯定了机器学习最终可以让我们研究并探索那些描述长度超过十亿比特的算法。而更关键的是，引导这种探索的并非程序员的指尖，而是原始数据，就像儿童接收到的那样。需要特别指出，图灵的这段论证反驳了众多知识分子的想法，其中还包含一些专家，他们经常这样说：“机器学习效果不错——但数学家不知道为什么。”这是 2015 年《连线》(Wired) 杂志上一篇文章的标题。然而早在 1950 年，艾伦·图灵就预言了机器学习未来会取得成功，甚至明确指出它会在 20 世纪末出现！更厉害的是，关于机器学习会在众多任务中超越人类编写的程序这一情况，图灵已经强调了它的确切原因：只有机器学习才能探索那些长度超过十亿字节的算法空间 [6]。同样，某些专家经常指责那些庞大的神经网络无法被明确解释。然而，巨大而高效的神经网络无法用寥寥几个字符描述出来，至少无法以准确的方式描述出来，这并

不令人意外。这是因为，如果神经网络能被简单描述的话，这个不太长的描述就会是简短的一种算法，它能够生成另一个算法（神经网络），并借此解决图灵测试之类的问题。这样的话，这个简短的算法就能解决图灵测试。然而，我们刚才推测，这项测试无法被简短的算法解决。

现在剩下的就是明确指出用什么方法来探索长度巨大的算法组成的空间。然而艾伦·图灵并没有指出要做到这一点可以使用的方法，他只是断言学习能力将会是关键。在 21 世纪初，人们提出了大量的方法。我们之前已经谈到过其中几种。不分先后的话，我们可以举出线性回归、逻辑斯谛回归、决策树、决策森林、支持向量机、神经网络、贝叶斯网络，还有马尔可夫随机场。我们会在本章和后面几章中再详细讨论最后这三个机器学习算法。

实用贝叶斯主义为了解决像图灵测试那样拥有巨大的所罗门诺夫复杂度的问题，实用贝叶斯主义者只能放弃贝叶斯公式。他更应该利用那些所需时间没有超出现实可能性的方法。由此我们需要调整“有用”这个概念。对于纯粹贝叶斯主义者来说，置信度高的理论就是有用的；但对于实用贝叶斯主义者来说，置信度很高，但所需计算时间超出常理的理论实际上并没有用。因此，实用贝叶斯主义者将注意力转向了所需计算时间较短的理论之中更可信的那一部分。

这就让我们能够解释素数定理给出的近似以及牛顿运动定律在实用中的置信度了。对于纯粹贝叶斯主义者来说，这两种描述都没有任何用处，因为两者分别被素数的精确计算以及爱因斯坦的广义相对论超越。然而实用贝叶斯主义者则乐于拥抱这些近似方法，因为它们对计算的需求明显小得多。计算的近似值需要的时间是 $\log$ ，而牛顿理论中的向量和微分计算与爱因斯坦理论中的张量计算相比远远更快。只要在我们身处的场景中，这两种近似精确到足以被接受（分别是值很大的情况和弱引力的情况），那么对于实用贝叶斯主义者来说，这两种近似就比精确的版本更有用！这种与计算时间有关的“有用”概念同样可以作为对神经网络惊人的成功的首要解释。这是因为，神经网络，或者至少是所谓的前馈神经网络，与那些更精细的算法相反，需要的计算时间不长，而且必定有所限制（图 14.1）。实际

上，如果我们考虑前馈神经网络的一个足够广泛的定义，那么这些网络组成的集合恰好就是快速并行算法的集合。因此，在前馈神经网络上进行机器学习，其实就相当于利用快速算法尽可能好地对数据进行解释（如果可能的话，也要利用合适的贝叶斯先验置信度）。所以，这就是迈向实用贝叶斯主义的第一步。

图 14.1 神经网络就是神经元之间一系列通信以及神经元本身进行的基本计算的总和。如果这种通信是无环的，我们就说这是个前馈神经网络，从直觉上来说，也就是通信只会朝一个方向进行，从来不会形成一个闭环

思

人工智能 (Artificial Intelligence, AI) 始于一个简单的想法。计算机被发明之后，人们很快认识到它的能力远不限于数值计算，可以通过对信息和指令编程完成很多以往只有人脑才能完成的任务。

强调像人一样强调合理性思考

像人一样地思考

合理地思考

行动像人一样地行动合理地行动

|| 强调像人一样 | 强调合理性 | |:—: |:—: |:—: | | 思考 | 像人一样地思考 | 合理地思考 | | 行动 | 像人一样地思考 | 合理地行动 |

3.12.9 人工智能：广跨各学科，综合文理工

人工智能：对人的意识、思维过程进行模拟的一门学科。

3.12.10 发展历程：AI 的三次热潮和相应的研究学科突破

人工智能发展如同过山车，忽上忽下，从创立以来不断分化

AI 数理基础切换：从基于逻辑的表达与推理到基于统计的学习与计算

3.12.11 三次热潮的总结

第一阶段 (前 30 年): 以数理逻辑的表达与推理为主。杰出代表, 如 John McCarthy、Marvin Minsky、Herbert Simon: 懂很多认知科学的东西, 有很强的全局观念, 拿过图灵奖和很多大奖。但工具基本都是基于数理逻辑和推理。逻辑的东西发展得干净、漂亮。但符号的知识表达不落地;

第二阶段 (近 30 年): 以概率统计的建模、学习和计算为主。视觉、自然语言、认知、机器学习、机器人五大领域在 1990 年中期都找到了概率统计这个新“机制”: 统计建模、机器学习、随机算法……

人工智能的主要学派 | 符号主义学派 Symbolicism | 联结主义学派 Connectionism | 行为主义学派 Actionism | |—:|—:|—:| | 起源于 2300 年前的逻辑主义、心理学派和计算机学派 | 起源于上世纪 40 年代仿生学派或生理学派 | 起源于上世纪 40 年代, 进化主义、控制论 || 认知即计算: 用符号、规则和逻辑来表征指示和进行逻辑推理 | 认知即网络: 用概率矩阵和加权神经元进行模式识别、分类 | 认知即行动: 基于“感知-行动”生成变化, 为特定目标获取其中最优化解 || 基本算法: 规则和决策树 | 基本算法: 深度学习神经网络 | 基本算法: 遗传算法、蚁群算法、强化学习 |

三大学派的方法论

| 符号主义学派 Symbolicism | 联结主义学派 Connectionism | 行为主义学派 Actionism | |—:|—:|—:| | 知识自上而下地设计 | 知识自下而上地涌现 | 知识自下而上地涌现 || 经由专家自上而下基于逻辑设计、推理来实现 | 通过模拟大脑的结构 (神经网络) 来实现知识 | 从简单生物体与环境互动的模式中寻找知识

参考文献

3.13 线性神经网络

在介绍深度神经网络之前, 我们需要了解神经网络训练的基础知识。本章我们将介绍神经网络的整个训练过程, 包括: 定义简单的神经网络架构、

数据处理、指定损失函数和如何训练模型。为了更容易学习，我们将从经典算法——线性神经网络开始，介绍神经网络的基础知识。经典统计学习技术中的线性回归和 softmax 回归可以视为线性神经网络，这些知识将为本书其他部分中更复杂的技术奠定基础。

-3.1. 线性回归

文生文、文生图、文生视频

