

时间:

1956以前 数学理论、工程技术的准备

1956-1974 逻辑表达 - 启发式搜索

1974-1980 低谷

1980-1987 专家系统, 神经网络的诞生

1987-2012 低谷 (二值图问题) · 分化: 视觉、语言、认知、学习, 和机器人

2012 DL, 生成式AI, 大模型之始

第一阶段 1990之前 逻辑、表达与推理

第二阶段 1990之后 (近20年) 概率: 模型与计算

逻辑/数学主义

符号主义 认知即计算 (符号、规则、逻辑推理、推理引擎)

统计建模 本学习 随机算法

符号/生理主义

联结主义 认知即网络 (根据连接和加和神经元进行模式识别与学习)

↑
概率统计为本制

现代主义/控制论

行为主义 认知即控制 (基于感知-行动的生成变化为特定目标采取最优解)

知识自上而下, 知识自下而上

设计: ①: 专家系统/推理设计/推理引擎; ②: 模拟和两两信息/系统知识; ③: 从简单生物体与环境互动模式中寻找知识

动机

数学思维 理想情形, 存在性, 可构造

理论

算法思维 算法复杂度, 算法优化, 健壮性

方法

工程思维 允许误差, 大规模问题, 鲁棒性

应用

1978年

希尔伯特纲领: (12分) 公理化统一整个数学

完备性: 一切数学命题都可通过公理集有穷步推定真伪
相容性: 不能从公理系统导出矛盾
可判定性 (第1问题) 任一给定的命题
设计一个过程/方法, 通过有穷次计算, 判定该命题是否可解
存在一个算法判定是否一个语句能够被证明

↑
逻辑与公理化
加信息

↑
构造
数学内部
确定性的希望

$\zeta(n, n, 1)$

哥德尔第一定理 任何包含自然数和相容形式系统F中, 存在不可判定命题S, 即S在F中既不能被证明, 也不能被证伪

哥德尔第二定理 任何包含自然数和相容形式系统F中, 相容性/不矛盾性不能在F中被证明

重新评估数学哲学

不完备性/逻辑与逻辑自洽不可兼得; 不完备 → 更深层理论中 完备
证明: 欧氏几何 → 非欧几何, 欧氏几何 → 相对论, 量子力学

(哲学上):
不完备性/不确定性 → 人类知识的局限
→ 真理是不可诉感觉

Church定理

否定希尔伯特判定问题

"入" 悖论

$$\sum_{i=1}^n a_i x_i = c$$

$a_i, b_i, c \in \mathbb{Z}$

判定丢番图方程的可解性：给定一个方程，判定是否存在整数解，即任意一个未知数的丢番图方程。

希尔伯特第十问题：

方程，设计一个过程，判定方程是否有解，判定方程是否有解是不可解的。


"停机问题"：

任意一个程序是否在有限时间内结束运行

图灵机定理

图灵机判定问题不可判定 (由阿兰图灵证明)

严格证明明确程序
为量子计算机奠定基础
证明计算存在界限



现代科学在哲学三大成果

哥德尔不完备性定理、塔斯基的形式语言的真理理论、图灵机判定问题

S 停止时 S 不终止
S 不终止时 S 停止

现代计算机反映计算的哪些过程

抽象：问题形式化 → 可计算问题

理论：寻找求解可计算问题的方法、(算法)

设计：模型的具体实现

算法定义：一组明确，可以执行步骤的有序操作，且在有限的时间终止，并产生结果

特性：有效性、确定性、可终止性

评价：时、空复杂度

P、NP

是/否为确定性形式问题

自动机理论、分布式算法、并行算法

自动机理论：由程序按操作顺序执行

分布式算法：任务 → 小任务 → 分配到各台设备上工作

时间：多条线路同时工作
空间：多个处理器并发计算

冯诺依曼体系结构：

第一台通用可编程计算机

ENIAC (电子开关、电路编程、卡片读取穿孔) → 查尔斯·巴贝奇

第一台由现代意义的通用计算机

EDVAC (电子数据访问计算机) → 冯·诺依曼

近代数学：

微分方程、微分几何、复变函数、代数几何


现代数学：

代数几何、代数几何、代数几何、代数几何

第三次数学危机

罗素悖论

① 集合论 → 公理集合论 → 公理集合论
② 数理逻辑 (集合论 → 公理集合论 → 公理集合论)
③ 哥德尔不完备性定理
④ 计算复杂性理论



Turing: Colossus
Enigma
密码机

FSM
有限状态机

计算原子弹的能量

非线性数学

近代数学、分析

代数几何、分析

欧氏几何、非欧几何

非欧几何、非欧几何

非欧几何、非欧几何

可计算理论: 有效, 确定, 可终止
(接近于算法理论)

图灵关于硬件和数学模型的观点 图灵认为难在硬件而非数学模型

控制论 (1948 维纳《控制论》(Cybernetics) —— 研究动物和机器中控制和通讯的科学
 特性: “人与机器都是通过反馈来实现某种目标”

1950 维纳《人有人的用处：控制论与社会》

Wiener 行为主义智能
智能的表述 与环境的交互

```

graph TD
    A[智能的设计] --> B[智能的测试]
    B --> C[调整框架]
    C --> B
    B --> D[尝试测试]
    D --> B
  
```

自动机器与人进行对比,两者均由感知装置,信息传递装置,行动装置构成独立系统

① 神经网络: 应用: 神经网络; 反向传播算法

② 强化学习: 根据行为回报 改变迭代

更少的人类智能参与

自主寻找反复迭代多次成型 图像分割, 手写识别
(只可管分, 不可管信) 还未搞懂 自主识别

人工规则与专家系统面临困难

需要各领域的专家知识，过程复杂
→ 可扩展性 通用性差

- 统计学习
 - 贝叶斯学习

- 监督
- 非监督
- 半监督
- 强化

Diagram illustrating a function f mapping inputs to outputs:

Inputs (multiple lines) are processed by the function f to produce a single output.

Labels:

- Input: 输入 (Input)
- Process: 规则 (Rule)
- Output: 输出 (Output)

$(\theta_{\text{old}}) \quad x \longrightarrow f(x, \theta^*)$

(输出) $\max$ 极大 · 似然 · 估计

$$\text{Cost}(h_\theta(x), y) = -y \log(h_\theta(x)) - (1-y) \log(1-h_\theta(x))$$

0-1 $L(y, f(x)) = \begin{cases} 1 & y = f(x) \\ 0 & y \neq f(x) \end{cases}$

绝对 $L(y, f(x)) = |y - f(x)|$

平方 $L(y, f(x)) = (y - f(x))^2$

对数: $L(y, P(y|x)) = -\ln P(y|x)$
 $L(y, f(x)) = \begin{cases} -\ln f(x) & y=1 \\ \ln(1-f(x)) & y \neq 1 \end{cases}$
 (Logistic 回归)




损失 $L(y, f(x)) = e^{-y \cdot f(x)}$

期望风险 $R(f) = E_{(x,y) \sim p(x,y)}$ 好某个 $L(y, f(x))$

经验风险 $R_D^{emp}(\theta) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))$ 退化 $\rightarrow$ 我们假设分布均匀 E 就是均值

结构风险 $R(\theta) + \lambda \|\theta\|^2 \rightarrow$ 正则化项

凸优化基本定理



过拟合：
- 参数过多
- 数据分布不均……

对已知数据拟合效果好
对未知数据预测能力很差

回归和分类的区别

与 y_i 连续值，实数值

线性最小二乘法的解定理（正规矩阵法）

α^* 是 $X\alpha = b$ 的最小二乘解 $\iff \alpha^*$ 为 $X^T X \alpha = X^T b$ 的解

多元线性回归

正规矩阵法： $\alpha = (X^T X)^{-1} X^T y$

$\hat{y} = w^T x + b = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$

$L(y, f(x)) = \frac{1}{N} \sum_{i=1}^N (y_i - f(x_i))^2$

梯度下降法（三种）

$\frac{\partial L}{\partial w_j} = 2 \sum_{i=1}^N (y_i^{(w)} - f^{(w)}(x_i)) (-x_{ij}) = 0$

$\frac{\partial L}{\partial b} = 2 \sum_{i=1}^N (y_i^{(w)} - f^{(w)}(x_i)) = 0$

$\begin{cases} w_j := w_j - \alpha \cdot \frac{\partial L(y, f(x))}{\partial w_j} \\ b := b - \alpha \cdot \frac{\partial L(y, f(x))}{\partial b} \end{cases}$ 迭代移动方向

$\begin{cases} w_j := w_j - \alpha \cdot \frac{1}{N} \sum_{i=1}^N \frac{\partial L(y, f(x))}{\partial w_j} \\ b := b - \alpha \cdot \frac{1}{N} \sum_{i=1}^N \frac{\partial L(y, f(x))}{\partial b} \end{cases}$

批量 $\rightarrow$ 慢

随机 $\rightarrow$ 快


小批量 $\rightarrow$ 适中

All $\rightarrow$ mini-batch

$N \rightarrow m$

学习率过小和过大的情况、超参数


模型外部加约束，无法从数据得到



初值 迭代 问题

归一化 max-min法

$$x' = \frac{x - \min}{\max - \min}$$



处理过拟合的方法

- ① 增加数据
- ② 引入正则化

- L1
- L2
- 岭
- Lasso
- ...

分类
判别式模型

$f(x) = y$ 线性回归, SVM, MP, MLP, ...

生成式模型

$P(Y|x)$ Sigmoid 回归 CRF (条件随机场)
 $P(x, y) \sim P(x, y)$
 $P(Y|x) = \frac{P(x, y)}{P(x)}$




判别式方法

$$y / P(Y|x) = f(x)$$

生成式方法

隐变量
收敛快



$$p(Y|x) = \frac{P(x, y)}{P(x)}$$


逻辑斯提回归

还原概率分布

$$\sigma = \frac{1}{1 + e^{-w^T x + b}}$$

$$\phi(x) = \frac{1}{1 + e^{-x}}$$

$$\phi(x) = \phi(x) \cdot (1 - \phi(x))$$



优: 权重、梯度、概率值→排序、决策
易理解、训练

劣: S型
两端变化小, 中间变化大, 敏感元不充分

Sigmoid: $L(y, f(x)) = \frac{1}{2} \cdot \frac{1}{N} \sum_{i=1}^N L(y^{(i)}, f^{(i)}(x))$? $\times$ ① 不好求 ② 非凸, 无最优解

设 $h_\theta(x) = P(y=1 | \theta, x)$, $1 - h_\theta(x) = P(y=0 | \theta, x)$

$$L(\theta) = P(Y|X, \theta) = \prod_{j=1}^N P(y^{(j)} | x^{(j)}, \theta) = \prod_{j=1}^N (h_\theta(x^{(j)}))^{y^{(j)}} (1 - h_\theta(x^{(j)}))^{1-y^{(j)}}$$

极大似然估计

$$L(y, h_\theta(x)) = \ln L(\theta) = - \sum_{i=1}^N (y^{(i)} \ln h_\theta(x^{(i)}) + (1-y^{(i)}) \ln (1 - h_\theta(x^{(i)})))$$


对数似然

$$\frac{\partial L}{\partial w_i} = \sum_{j=1}^N (y^{(j)} - h_\theta(x^{(j)})) x_i^{(j)}$$

$y=1$ $y=0$

K-邻近算法 (KNN) 算距离——找邻居——做分类 $\times$

计算训练样本与所有训练样本的距离, 以最近邻者为分类标签



对噪声过于敏感, 样本不纯时影响明显

$k \rightarrow$ 奇数, 防平票, 不小不大. 以 k 个最近邻者为决策变量

改进: 利用权重. 近邻权重小, 远邻则大. 大小 $\rightarrow$ 易受噪声影响, 太大 $\rightarrow$ 其他类的点可能太多. k 值一般用交叉验证确定.

将距离远近也考虑在内 (避免数量误判)


$$k \leq \sqrt{N} \text{ (经验值)}$$

缺点 ① 存储全部训练样本 ② 计算目标样本与所有训练样本的距离: 改进——

1. 对样本进行组织整理, 分群分层. 将计算压缩至靠近小范围邻域内. 避免盲目计算距离.
2. 在原有样本挑选对分类计算有效的样本. 使样本总数合理减少.


支持向量机 (SVM) 寻找线性可分情形下最优分类面

决策面, 支持向量, 决策边界



对偶问题

$\rightarrow$ 矩阵求



$$y = \begin{cases} 1, & w^T x + b \geq 0 \\ -1, & w^T x + b < 0 \end{cases}$$

最小化问题 $m = \frac{1}{\|w\|}$ $m \uparrow$ 越好 $\leftrightarrow \min \|w\|$




线性不可分, 高维映射

软间隔, 硬间隔

允许间隔内有点 (噪声)

核函数 (特性+4种常见的)



$$K: X \times X \rightarrow R$$

避免把数据映射到高维

线性核: $K(x, x') = x^T x'$ 内积

多项式核: $K(x, x') = (x^T x' + c)^d$ 通过 d 控制复杂度

高斯径向基核 (RBF): $K(x, x') = \exp(-\frac{\|x - x'\|^2}{2\sigma^2})$ 无限维映射, 0 控制平滑

Sigmoid 核 $K(x, x') = \tanh(k x^T x' + c)$

类似神经网络

核函数 ① 对称性 $K(x, y) = K(y, x)$, $x, y \in \mathcal{X}$
 $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ ② 半正定性 (Mercer 条件): $\forall$ 有限样本 $x_1, \dots, x_n$, 对应 Gram 矩阵 $(K(x_i, x_j))_{n \times n}$ 为半正阵 (所有特征值非负)
 $K(x, y)$ 的含义: $\exists \phi: \mathcal{X} \rightarrow \mathcal{H}$, s.t. $K(x, y) = \langle \phi(x), \phi(y) \rangle$, $\langle \cdot, \cdot \rangle$ 表示内积. 意义: 无需显式构造高维空间 ③ 隐式映射
 描述 x, y 在高维空间的相似性 就可以定义它们的核

万能核函数定理 如高维 (如核) 理论难以逼近任何复杂决策边界, 只要核函数选择得当, 数据足够

SVM 可拟在任何二分类分布 (理论上)

实际上 $\begin{cases} \text{采用有万能逼近能力的核函数} \\ \text{精确调整核参数与正则化系数} \\ \text{特征向量 } X \text{ 不应对应不同权重} \end{cases}$


松弛变量: 引入松弛变量, 找到容忍部分分类的解 取规范间隔

SVM 局限: ① 超大规模数据集: $O(n^2 \sim n^3)$ 复杂度 ② 需要核序元运算, 只能产生 Y/N 2 种答案
 ③ 与分类: 额外处理 ④ 存在大量噪声与冗余, 决策边界扭曲, 泛化性能差
 ⑤ 类别不平衡: 对少数样本识别难度较大 ⑥ 非线性可分, 但核函数选择不当

与神经网络的比较

同: 万能逼近器

异: $\begin{cases} \text{实验方式} \begin{cases} \text{SVM: 核技巧隐式映射到高维空间} \\ \text{NN: 多层非线性变换显式建模} \end{cases} \\ \text{理论信息} \begin{cases} \text{SVM: 全局最优解 (唯一)} \\ \text{NN: 局部最优解 (不唯一)} \end{cases} \\ \text{应用范围} \begin{cases} \text{SVM: 小数据集} \\ \text{NN: 大数据集, 可扩展性} \end{cases} \end{cases}$



没有人工标注或分布下降

非监督学习: 没有标注的数据中, 学习数据统计规律与内在结构

聚类 $X = (x_{ki})_{m \times n}$ 样本集合 $\begin{matrix} a & b & c & d & e & f & g & \dots \\ \begin{matrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{matrix} & \begin{matrix} x_5 \\ x_6 \\ x_7 \\ x_8 \end{matrix} & \dots & \end{matrix}$ 纵向数据

闵可夫斯基距离 $\{x_1, x_2, \dots, x_n\}$ x_i 表示 m 维向量, x_{ij} 表示第 j 维向量的第 i 个特征

相关系数

$|r| \rightarrow 1$ 相似

$r_{ij} \rightarrow 0$ 不相似

$$d_{ij} = \left(\sum_{k=1}^m |x_{ik} - x_{jk}|^p \right)^{\frac{1}{p}}$$

$p=1$, 曼哈顿距离
 $p=2$, 欧氏距离
 $p=\infty$, 切比雪夫距离

$$r_{ij} = \frac{\sum_{k=1}^m (x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j)}{\sqrt{\sum_{k=1}^m (x_{ik} - \bar{x}_i)^2} \sqrt{\sum_{k=1}^m (x_{jk} - \bar{x}_j)^2}}$$


$$\bar{x}_i = \frac{1}{m} \sum_{k=1}^m x_{ik}$$

相似样本 在空间中距离更近

① "相似"度量

余弦相似性, 相似度

$$c_{ij} = \frac{\sum_{k=1}^m x_{ik} x_{jk}}{\sqrt{\sum_{k=1}^m x_{ik}^2} \sqrt{\sum_{k=1}^m x_{jk}^2}}$$



簇: 样本子集: def: $H_G(G \subseteq X)$ 给定一个 $T \geq 0, \forall x_i, x_j \in G (d_{ij} \leq T)$. 则 G 为一个簇


$\bar{x}_G = \frac{1}{n_G} \sum_{i=1}^{n_G} x_i$

D_G (直径) $= \max_{x_i, x_j \in G} d_{ij}$; 簇间距

层次聚类

簇之间存在层次

- $D_{PS} = \min \{d_{ij} \mid x_i \in G_P, x_j \in G_Q\}$ 最短
 - $D_{PS} = \max \{d_{ij} \mid x_i \in G_P, x_j \in G_Q\}$ 最长
 - $D_{PL} = d_{\bar{x}_P, \bar{x}_Q}$ 中心
 - $D_{PL} = \frac{1}{n_P n_Q} \sum_{x_i \in G_P} \sum_{x_j \in G_Q} d_{ij}$ 平均
- 各种直径 $\rightarrow$ 簇间距离度量



聚合聚类 (自下而上)

- ① 每个样本分为一个簇
- ② 合并相邻簇
- ③ 重复至条件结束

分裂聚类 (自上而下)

- ① 开始为一个簇
- ② 将已有类中相距最远样本分为两个簇
- ③ 重复至条件结束

K-means 聚类

n 个样本 $\rightarrow k$ 个簇, s.t. 每个样本到簇中点距离最小

$X = \{x_1, \dots, x_n\}$, 在维度 m .

partition $\rightarrow G_1, G_2, \dots, G_k, G_i \cap G_j = \emptyset, \bigcup_{i=1}^k G_i = X, C$ 表示对 X 的划分为 $\{G_i \mid G_i \cap G_j = \emptyset, \bigcup_{i=1}^k G_i = X\}$

① 选择 k 个簇的中心, 将样本指派到 k 个簇

② 更新每个簇的中心 $\bar{x}_{G_i}$


③ 直至收敛

$X_0 = (x_{g_0}, x_{g_2}, \dots, x_{g_k})$ 初始簇中心
 可以从层次聚类, 得到 k 个点, 用这 k 点做 k -means

降维

样本距离 $O(f(n)) \rightarrow O(f(\frac{n(n-1)}{2})) = O(f(n^2))$ 维度灾难

在高维空间的数据稀疏, 距离计算困难 称为维度灾难 对策: 降维.



① 线性变换: d 维空间样本 $X = \{x_1, x_2, \dots, x_n\}$

d' 维样本 $Z = W^T X$

变换 W : d' 个 d 维基向量

$W = (d_1, d_2, \dots, d_{d'})$

$X \xrightarrow{W^T} Z$

$\{x_1, \dots, x_n\} \rightarrow \{z_1, \dots, z_n\}$

$x_i \rightarrow z_i$. z_i 是 x_i 在基向量 $\{d_1, \dots, d_{d'}\}$ 中的坐标

$V_{ij}: d_i, d_j$ 正交 $\rightarrow W$ 为正交变换, 新空间中属性为原空间中属性的线性组合

$$\min f = \sum_{i=1}^k \sum_{j=1}^{n_i} d_{x_j^{(i)}, \bar{x}_{G_i}}$$

$x_j^{(i)}$ 表示 i 个簇中的第 j 个样本

$d = \|x_j^{(i)} - \bar{x}_{G_i}\|$

$x_i \rightarrow z_i$
 $z_i = W^T x_i$
 $= (d_1^T x_i, d_2^T x_i, \dots, d_{d'}^T x_i)$
 $[d, x_i] [d, x_j] [d, x_i]$
 $= (z_{i1}, z_{i2}, \dots, z_{id'})$
 在矩阵中坐标

线性降维

主层次分析 (PCA)



起平面 $\left\{ \begin{array}{l} \text{最近重线性: 样本离起平面足够近} \\ \text{最大均匀性: 样本点在起平面散影可以分开} \end{array} \right.$

协方差阵

$$\boxed{x x^T} w = \lambda w$$


→ 特征值分解: $\lambda_1 \geq \lambda_2$

$$x_i \longrightarrow W^T x_i \quad \text{L 误差最大}$$

④ 论理理

Laplacian SVM

.....




PCA 的推导

$$= (w_1, w_2, \dots, w_d)$$


di: 超考 eg KNN
Kmeans
来求定

强化学习


计算机程序与环境的交互,同时呈现出输入目标,从环境状态到行为映射的学习
↓
导航 以使系统行为从环境中获得累积奖励最大化和最强学习方法




在线学习方法



1. 初始化训练集,而通过与环境地交互与反馈




2. 没有关于动作标记, 而在女性一段时间内, 利用身体语言推断自慰动作的项






“11222”

· 验证



感知 选择 有一个
环境 动作 最终目标





模型评价

Accuracy = $\frac{T}{T+F}$
准确率

> 分类混淆矩阵:


	T	F
P	TP	FP
N	TN	FN

正例: 最关心, 有少数
其余: 负例

预测疾病

患者 正 P
健康 负 N

True
False



precision = $\frac{TP}{TP+FP}$
精确率

预测为正例的数据中, 预测正确

eg 股票, 预测股票已买入, 要看这支股票赚1亏多少

recall = $\frac{TP}{TP+FN}$
召回率

真实为正例的数据中, 预测正确

eg 疾病, 真病人查错情况应尽量小
1-召回率

兼顾: F1 测度:

$$\frac{1}{F1} = \frac{1}{2} \left(\frac{1}{precision} + \frac{1}{recall} \right)$$

调和平均

两者都高才高, 其一做就很低

兼顾